

08 DE MAYO DEL 2026

REFLEXIÓN ÉTICA DEL PROYECTO.

INTEGRANTES:

BRYAN ISMAEL ALVARADO QUIMIZ

DIEGO ANDRÉ ARÁMBULO VÍTORES

Reflexión Ética del Proyecto

Agente de Inteligencia Artificial Conversacional para Sistemas de Gestión Documental

Este documento consolida la reflexión ética del proyecto de tesis sobre el agente de inteligencia artificial conversacional integrado en una plataforma de gestión documental empresarial. La estructura integra tres componentes complementarios: el caso de estudio sobre identificación de riesgos éticos asociados al uso de inteligencia artificial en sistemas de gestión documental, el workshop de análisis de stakeholders y sus valores, y el workshop de impacto social y responsabilidad. Cada componente se desarrolla aplicando marcos éticos reconocidos en la literatura especializada y se contrasta con los hallazgos empíricos obtenidos durante la fase experimental, particularmente las métricas de desempeño del modelo NLU disponibles en el repositorio del proyecto.

Caso de Estudio: Identificación de Riesgos Éticos

Contexto del Caso

El proyecto incorpora un agente conversacional sobre la plataforma de gestión documental que opera en una organización. El agente recibe consultas por voz o texto, identifica la intención del usuario mediante un clasificador zero-shot basado en XLM-RoBERTa y ejecuta acciones operativas como listar expedientes, descargar documentos o navegar entre módulos del sistema. Esta funcionalidad procesa información altamente sensible: datos de clientes, contenido contractual, expedientes y correspondencia profesional protegida por deberes de confidencialidad documental. El análisis de los riesgos éticos parte de los resultados empíricos disponibles en el repositorio, que evidencian limitaciones técnicas con implicaciones éticas concretas: un Accuracy global del 53.8 % sobre las pruebas evaluadas y un Recall del 15.8 % en la clase de navegación, lo que indica que el sistema interpreta erróneamente la mayoría de las consultas de orientación como solicitudes operativas.

Identificación de Riesgos Éticos

La caracterización de los riesgos éticos del proyecto se construye sobre los principios fundamentales de la ética aplicada a la inteligencia artificial sintetizados por Jobin et al. (2019): justicia, transparencia, beneficencia, no maleficencia, autonomía, privacidad y responsabilidad. Cada uno de estos principios genera categorías específicas de riesgo cuando se contrasta con la operación real del sistema en el dominio legal. La Tabla 1 consolida los riesgos identificados, su naturaleza, evidencia empírica disponible y nivel de severidad estimado.

Tabla 1*Riesgos éticos identificados en el proyecto*

Riesgo	Categoría	Manifestación en el proyecto	Evidencia empírica	Severidad
Sesgo de dominio	Justicia / Equidad	El modelo NLU presenta sesgo sistemático hacia la clase Descarga, derivando consultas de navegación hacia operaciones de descarga.	Recall N = 0.158 sobre 19 casos	Alta
Opacidad algorítmica	Transparencia	El usuario recibe una respuesta sin información sobre la confianza del modelo ni sobre el razonamiento que llevó a la acción ejecutada.	Confianza media 0.762 no expuesta al usuario	Media
Acción no consentida	Autonomía	El sistema ejecuta acciones sobre los documentos sin que el usuario confirme la interpretación de su consulta.	Tasa de errores del 46.2 % sobre 65 evaluaciones	Alta
Filtración de datos cliente	Privacidad	Los audios procesados por Google Cloud Speech-to-Text salen del entorno on-premise hacia infraestructura externa.	Componente cloud activo en pipeline ASR	Crítica
Trazabilidad insuficiente	Responsabilidad	Las decisiones del agente se ejecutan sin un registro completo que permita reconstruir el razonamiento ante una auditoría.	No documentada en el pipeline actual	Media
Discriminación lingüística	No discriminación	El modelo presenta degradación ante variantes dialectales del español ecuatoriano y modismos coloquiales.	Caída de Accuracy ante peticiones informales	Media
Daño profesional al cliente	No maleficencia	Una respuesta incorrecta del agente puede inducir al usuario profesional a tomar decisiones sobre información sesgada o errónea.	Riesgo derivado del Accuracy 0.538	Crítica
Dependencia tecnológica	Autonomía profesional	El uso prolongado del agente puede reducir la práctica profesional de búsqueda y razonamiento del usuario profesional.	No medida en la fase actual	Baja

Nota. Elaboración propia. Las severidades se asignan en escala de tres niveles según la combinación de probabilidad de ocurrencia y magnitud del impacto sobre el usuario o el cliente de la organización usuaria.

Análisis de Impacto en Grupos de Usuarios

El impacto del agente conversacional no se distribuye de manera uniforme entre los usuarios del sistema. Mehrabi et al. (2021) advierten que la evaluación ética de los sistemas de inteligencia artificial debe diferenciar entre usuarios directos, indirectos y grupos vulnerables, dado que las consecuencias de los errores del modelo difieren sustancialmente según la posición que cada grupo ocupa en la cadena de uso. La Tabla 2 desagrega los grupos de usuarios identificados en el proyecto y caracteriza el impacto diferencial sobre cada uno.

Tabla 2

Impacto diferencial por grupo de usuarios

Grupo de usuarios	Tipo	Impacto principal	Manifestación específica	Vulnerabilidad
Usuarios profesionales senior	Directo	Reducción de tiempo en búsquedas documentales rutinarias dentro de la plataforma de gestión documental.	Beneficio operativo; juicio profesional preservado.	Baja
Usuarios profesionales junior	Directo	Riesgo de sobre-reliancia en respuestas del agente sin verificación crítica.	Pueden tomar respuestas erróneas como válidas por menor experiencia profesional.	Media
Asistentes administrativos	Directo	Aceleración de tareas operativas en la plataforma de gestión documental; potencial sustitución parcial de funciones rutinarias.	Beneficio en eficiencia; riesgo laboral indirecto.	Media
Personal operativo	Directo	Cambio en flujos de trabajo; necesidad de capacitación específica.	Adopción heterogénea según familiaridad con tecnología.	Media
Clientes de la organización	Indirecto	Sus datos son gestionados por usuarios autorizados de la organización contratante, la cual ha suscrito un contrato de servicio con el proveedor. Cada usuario acepta el acuerdo de manejo y uso de datos al ingresar a la plataforma, conforme a la LOPDP.	El consentimiento está cubierto en dos niveles : el contrato comercial firmado por la organización y el acuerdo de uso aceptado por cada usuario al ingresar.	Media
Clientes en situación vulnerable	Indirecto	Personas o entidades cuyos datos son procesados por la plataforma de gestión documental sin que tengan capacidad de revisión.	Una respuesta errónea puede afectar decisiones organizacionales críticas. El sistema dispone de canales de atención donde el agente puede escalar el caso a un técnico para solventarlo; sin embargo, el tiempo de resolución representa un riesgo operativo cuando la información involucrada es sensible o urgente.	Crítica
Terceros relacionados con la organización	Indirecto	Pueden verse afectados si información imprecisa influye en decisiones organizacionales que les conciernen.	Asimetría informativa derivada del uso del agente entre organizaciones que sí lo emplean y las que no.	Media
Hablantes con variantes dialectales	Excluido	El reconocimiento de habla y la clasificación NLU se degradan ante modismos regionales.	Acceso desigual a la funcionalidad del agente.	Alta

Nota. Elaboración propia. La columna Vulnerabilidad refleja la combinación entre el grado de exposición al sistema y la capacidad del grupo para detectar y corregir los errores del agente.

Grupos en Situación de Vulnerabilidad

La identificación de grupos vulnerables exige especial atención en el análisis ético del proyecto. Tres grupos concentran el mayor riesgo de impacto adverso: los clientes en situación de vulnerabilidad, asilo o derechos humanos donde un error documental puede comprometer libertades fundamentales, los hablantes con variantes dialectales del español ecuatoriano cuya interacción con el agente se degrada por sesgo lingüístico, y los usuarios profesionales junior cuya formación profesional puede verse afectada por la sobre-reliancia en un sistema con Accuracy del 53.8 %. Bender et al. (2021) advierten que la opacidad de los modelos de lenguaje genera asimetrías particularmente lesivas en estos grupos, dado que carecen de los recursos cognitivos o profesionales para detectar los errores del sistema.

Análisis de Impacto Diferencial

El impacto diferencial mide cómo un mismo sistema produce efectos desiguales sobre distintos grupos sociales. Barocas y Selbst (2016) describen el fenómeno como impacto dispar, situación en la que un sistema aparentemente neutral genera desventajas sistemáticas sobre grupos específicos. En el agente conversacional del proyecto, el impacto diferencial se manifiesta en tres dimensiones medibles que la Tabla 3 sintetiza.

Tabla 3
Dimensiones del impacto diferencial del sistema

Dimensión	Descripción del efecto desigual	Grupo más afectado	Mitigación propuesta
Lingüística	Degradación del reconocimiento ante modismos regionales del español guayaquileño.	Hablantes de variantes dialectales	Fine-tuning con LoRA sobre corpus enriquecido con dialectos locales.
Profesional	Diferencias en la capacidad de detectar errores del agente según experiencia.	Usuarios profesionales junior y asistentes	Capacitación obligatoria con casos prácticos de errores documentados.
Tecnológica	Diferencias en la facilidad de adopción según familiaridad con interfaces conversacionales.	Personal operativo de mayor edad	Diseño con doble interfaz: voz y texto, con tutoriales accesibles.
Procesal	Errores del agente afectan más a clientes con menor capacidad de revisión documental.	Clientes en situación vulnerable	Validación humana obligatoria sobre acciones críticas; trazabilidad completa.

Nota. Elaboración propia. Las mitigaciones propuestas constituyen requisitos funcionales para una segunda iteración del sistema y no se encuentran implementadas en la entrega actual.

Argumentación con Marcos Éticos y Normativos

La argumentación ética del proyecto se construye sobre cinco frameworks complementarios que abordan dimensiones distintas del problema. Su aplicación cruzada al caso permite identificar riesgos que un único framework, por su orientación específica, podría pasar por alto. La Tabla 4 sistematiza la aplicación de cada framework al proyecto del agente conversacional.

Tabla 4
Aplicación de frameworks éticos al proyecto

Framework	Pregunta guía aplicada	Hallazgo en el proyecto	Marco normativo
Ética por principios	¿Qué principio sería más grave violar en el proyecto?	Justicia y transparencia. El sesgo Recall N = 0.158 viola la equidad en la atención de consultas.	Jobin et al. (2019); Floridi y Cowls (2019)
Enfoque basado en riesgos	¿Qué podría salir mal aunque el proyecto funcione técnicamente?	Acciones documentales irreversibles ejecutadas sobre interpretación incorrecta de la consulta.	AI Act de la Unión Europea (2024)
Responsabilidad / Rendición de cuentas	¿Quién asume la responsabilidad si el agente causa un daño?	La cadena involucra al organización usuaria, la empresa proveedora del software como propietario de la plataforma de gestión documental y el proveedor cloud.	Normativa sectorial aplicable a cada cliente
Derechos humanos y privacidad	¿Qué derecho podría ser afectado por el proyecto?	Privacidad de los clientes; deberes de confidencialidad documental; protección de datos personales.	LOPD del Ecuador (2021); Constitución, Art. 66
Ética por diseño	¿En qué etapa se materializan los riesgos éticos?	Etapas de inferencia en producción; sin auditoría continua se vuelven irreversibles.	Cavoukian (2011); ISO/IEC 42001 (2023)

Nota. Elaboración propia. La aplicación cruzada de los cinco frameworks permite identificar riesgos que cada enfoque por separado podría omitir, particularmente la dimensión de daño irreversible asociada a las acciones automatizadas sobre el repositorio documental.

Marco Normativo Aplicable al Proyecto

El proyecto se desarrolla en Ecuador y se alinea con tres cuerpos normativos vigentes. La Ley Orgánica de Protección de Datos Personales del año 2021 establece obligaciones sobre el tratamiento de datos personales, exige el consentimiento informado del titular y restringe la transferencia transfronteriza de información sensible. La normativa sectorial aplicable a cada organización cliente del software condiciona el tratamiento de sus documentos según el sector regulado al que pertenezca, dado que la plataforma opera bajo un modelo multi-empresa que atiende organizaciones de diferentes industrias. La Constitución de la República, en su artículo 66, garantiza el derecho a la protección de datos de carácter personal y la no discriminación. Adicionalmente, aunque no es vinculante en Ecuador, el AI Act de la Unión Europea aprobado en 2024 sirve como marco de referencia para la clasificación de sistemas de inteligencia artificial según su nivel de riesgo, ubicando aquellos aplicados a la gestión de información sensible en categoría de riesgo significativo.

Workshop: Análisis de Stakeholders y sus Valores

Mapeo Exhaustivo de Stakeholders

El mapeo de stakeholders del proyecto distingue cuatro categorías según su nivel de visibilidad y la naturaleza de su relación con el sistema. Freeman (2010) define el mapeo de actores como un ejercicio que debe trascender los grupos directamente beneficiados para incluir a quienes resultan afectados sin haber participado en la decisión de implementación. La Tabla 5 consolida el mapeo aplicado al proyecto, incorporando explícitamente los stakeholders invisibles que con frecuencia se omiten en análisis convencionales.

Tabla 5

Mapeo de stakeholders del proyecto

Stakeholder	Tipo	Valor principal	Explicación contextualizada
Usuarios profesionales de la organización	Directo / Visible	Autonomía	Usuarios principales del agente; deben mantener juicio profesional sobre las respuestas para no comprometer su independencia técnica.
Asistentes administrativos	Directo / Visible	Confiabilidad	Realizan consultas operativas frecuentes sobre el repositorio; necesitan respuestas consistentes y predecibles.
Personal operativo	Directo / Visible	Confianza	Adopta el agente para tareas documentales; requiere capacitación adecuada y acompañamiento durante la transición.
Equipo TI del estudio	Directo / Visible	Responsabilidad profesional	Custodia el sistema y la integración del agente; responde por la disponibilidad y seguridad operativa.
Autores del proyecto	Directo / Visible	Representabilidad	Diseñan e implementan el agente; responden por la calidad metodológica y técnica de la solución.
Clientes de la organización	Indirecto / Forzado	Confianza	Sus documentos se procesan mediante el agente; no interactúan directamente pero asumen los riesgos de privacidad.
Terceros relacionados con la organización	Indirecto / Forzado	Confianza	Pueden verse afectados por decisiones organizacionales construidas con apoyo del agente, sin saberlo.
Proveedor cloud (Google)	Indirecto / Forzado	Seguridad	Procesa los audios del módulo ASR; su política de retención y uso de datos condiciona la privacidad del sistema.
Comunidad Hugging Face	Indirecto / Forzado	Representabilidad	Aporta los modelos preentrenados open source que sustentan el módulo NLU del agente.
Autoridad de protección de datos (Ecuador)	Regulador	Seguridad	Vigila el cumplimiento de la LOPDP; tiene capacidad sancionatoria sobre el estudio.
Tribunal académico	Regulador	Responsabilidad profesional	Evalúa el rigor académico y ético del proyecto; condiciona la aprobación de la tesis.
Comunidad de organizaciones que utilizan plataformas de gestión documental	Sociedad / Indirecto	Confianza	Beneficiaria sectorial del avance tecnológico; afectada por errores que pueden generar percepciones negativas sobre la inteligencia artificial aplicada.

Hablantes con variantes dialectales	Afectado invisible	Equidad	Grupo no contemplado explícitamente; sufre degradación del servicio sin canal formal de queja.
Personas con discapacidad auditiva	Afectado invisible	Equidad	No pueden usar la modalidad de voz; el sistema debe garantizar igualdad funcional vía texto.

Nota. Elaboración propia. La columna Tipo distingue entre stakeholders directos (interactúan con el sistema), indirectos (afectados sin interacción), reguladores (vigilan el cumplimiento) y afectados invisibles (impactados sin representación formal en el proyecto).

Análisis de Valores e Intereses entre Stakeholders

Los valores éticos asociados a cada stakeholder no operan en aislamiento sino en tensión permanente entre sí. Mitchell et al. (1997) sostienen que la priorización de stakeholders debe considerar tres atributos simultáneos: poder, legitimidad y urgencia, dado que ningún sistema puede satisfacer todas las expectativas de todos los actores. La Tabla 6 identifica las tensiones más relevantes detectadas entre los actores del proyecto y propone una aproximación de resolución.

Tabla 6

Tensiones de valores entre stakeholders del proyecto

Tensión identificada	Stakeholders en conflicto	Aproximación de resolución	Prioridad
Eficiencia operativa vs. autonomía profesional	Organización usuaria ↔ Usuarios profesionales senior	Definir umbrales de confianza por debajo de los cuales el agente solicita confirmación humana.	Alta
Disponibilidad del servicio vs. soberanía de datos	Equipo TI ↔ Clientes de la organización	Mantener componentes sensibles on-premise; cifrar audios en tránsito hacia Google Cloud.	Crítica
Innovación tecnológica vs. cumplimiento normativo	Autores del proyecto ↔ Autoridad de datos	Documentar el cumplimiento de la LOPDP; designar delegado de protección de datos.	Crítica
Adopción rápida vs. equidad lingüística	Organización usuaria ↔ Hablantes con variantes dialectales	Fine-tuning con corpus dialectal; mantener canal alternativo por texto.	Alta
Reducción de costos vs. transparencia	Dirección de la empresa proveedora del software ↔ Usuarios del agente	Exponer la confianza del modelo en cada respuesta; permitir auditoría por usuario.	Media
Velocidad de despliegue vs. validación humana	Equipo técnico ↔ Tutora académica	Establecer puntos de control con validación humana sobre acciones críticas.	Alta

Nota. Elaboración propia. La columna Prioridad refleja la severidad combinada de la tensión sobre los principios éticos del proyecto y la urgencia de su resolución dentro del horizonte de implementación.

Priorización de Actores Clave

La priorización aplica el modelo de Mitchell et al. (1997) que combina poder, legitimidad y urgencia para clasificar a los stakeholders en categorías operativas. Los actores que concentran los tres atributos denominados definitivos exigen atención permanente y recursos asignados en el proyecto. Los actores con dos atributos requieren atención sostenida, y los que poseen uno demandan monitoreo periódico. La Tabla 7 aplica esta clasificación al mapeo del proyecto.

Tabla 7
Priorización de stakeholders según poder, legitimidad y urgencia

Stakeholder	Poder	Legitimidad	Urgencia	Categoría	Atención requerida
Usuarios profesionales de la organización	Alto	Alta	Alta	Definitivo	Permanente
Clientes de la organización	Bajo	Alta	Alta	Dependiente	Defensa proactiva
Equipo TI del estudio	Alto	Alta	Media	Dominante	Sostenida
Autoridad de protección de datos	Alto	Alta	Baja	Dominante	Cumplimiento estricto
Hablantes con variantes dialectales	Bajo	Alta	Media	Dependiente	Inclusión activa
Proveedor cloud	Alto	Media	Baja	Latente	Monitoreo
Tribunal académico	Alto	Alta	Alta	Definitivo	Permanente

Nota. Elaboración propia, basada en el modelo de saliencia de stakeholders propuesto por Mitchell et al. (1997). Categoría Definitiva: poder + legitimidad + urgencia. Dominante: poder + legitimidad. Dependiente: legitimidad + urgencia. Latente: poder predominante.

Workshop: Impacto Social y Responsabilidad

Frameworks Éticos Aplicados al Proyecto

La evaluación del impacto social del proyecto se construye sobre cinco frameworks complementarios que abordan dimensiones distintas del análisis ético. Cada framework plantea una pregunta guía cuya aplicación al agente conversacional permite identificar una clase específica de riesgos y beneficios. Floridi y Cowls (2019) sostienen que la aplicación combinada de varios frameworks reduce los puntos ciegos analíticos que cada enfoque, individualmente, presenta por su orientación particular.

Tabla 8

Frameworks éticos aplicados al agente conversacional

Framework	Idea central aplicada	Análisis del proyecto	Riesgos detectados
Ética por principios	Justicia, transparencia, beneficencia y autonomía aplicadas a la operación del agente.	El principio más comprometido es la justicia, dado el sesgo Recall N = 0.158 que afecta de manera desigual a los usuarios según el tipo de consulta. La transparencia se ve afectada por la ausencia de exposición de la confianza del modelo al usuario final.	Sesgo, daño a grupos vulnerables, decisiones no transparentes.
Enfoque basado en riesgos	Identificación de riesgos técnicos, éticos y sociales aunque el sistema funcione correctamente.	El sistema puede ejecutar acciones documentales irreversibles sobre interpretaciones erróneas. Su uso en escenarios de derechos humanos podría amplificar errores con consecuencias graves para clientes vulnerables.	Uso indebido, impactos no intencionales, escalada del daño.
Responsabilidad y rendición de cuentas	Identificación clara de quién diseña, implementa y responde por el comportamiento del sistema.	La cadena de responsabilidad involucra tres niveles: los autores del agente responden por la calidad del modelo; el equipo TI del estudio por la integración; el organización usuaria por el uso profesional ante el cliente.	Atribución difusa de responsabilidad ante incidentes.
Derechos humanos y privacidad	Protección de la confidencialidad y los derechos fundamentales del titular de los datos.	La transferencia de audios al servicio cloud de Google Cloud Speech-to-Text introduce un riesgo a la confidencialidad sometida a deberes de confidencialidad documental. La LOPDP del Ecuador exige consentimiento informado del titular.	Uso indebido de datos, vigilancia, exclusión.
Ética por diseño	Evaluación continua y mejora iterativa desde la fase de diseño hasta la operación productiva.	El proyecto adopta evaluación sobre métricas reales (Accuracy, Recall, F1) y un pipeline reproducible. Sin embargo, no se ha establecido un mecanismo de monitoreo continuo en producción que detecte degradaciones del modelo.	Correcciones tardías, daños irreversibles.

Nota. Elaboración propia. La aplicación combinada de los cinco frameworks evidencia que ningún enfoque individual cubre todos los riesgos éticos del proyecto. La integración cruzada permite construir una respuesta más completa.

Balance entre Impactos Positivos y Negativos

La evaluación del impacto social del proyecto exige un balance honesto entre los beneficios derivados de la automatización documental y los riesgos asociados al funcionamiento imperfecto del agente. Floridi (2023) advierte que la sola identificación de beneficios sin contraposición a los costos sociales constituye una práctica de rendición de cuentas insuficiente, y propone que toda evaluación ética incorpore una matriz comparativa que permita visualizar las dos dimensiones simultáneamente. La Tabla 9 sintetiza este balance aplicado al proyecto.

Tabla 9*Balance de impactos sociales del proyecto*

Impactos positivos	Impactos negativos
Reducción del tiempo dedicado a búsquedas documentales rutinarias por parte del personal de la organización usuaria.	Errores documentales generados por el modelo NLU con Accuracy 0.538 que pueden inducir decisiones profesionales sobre información sesgada.
Mejora del acceso a la información para personal junior y administrativo, reduciendo barreras de búsqueda manual.	Riesgo de sobre-reliancia profesional que erosiona la capacidad de búsqueda y razonamiento del usuario profesional en formación.
Estandarización de los flujos de consulta documental que reduce variaciones de criterio entre operadores.	Sesgo lingüístico que excluye a hablantes con variantes dialectales o discapacidad auditiva del beneficio del sistema.
Trazabilidad parcial de las consultas operativas que permite construir indicadores de productividad.	Pérdida de control sobre los datos del cliente al transferir audios a infraestructura cloud externa.
Disminución del costo operativo recurrente al apoyarse en herramientas open source y capa gratuita inicial.	Asimetría informativa entre las organizaciones usuarias del agente y las que aún no lo utilizan en la plataforma de gestión documental.
Ampliación de la oferta tecnológica disponible para el sector empresarial ecuatoriano que utiliza plataformas de gestión documental de tamaño mediano.	Posibilidad de uso indebido si las acciones del agente no quedan registradas con suficiente trazabilidad para auditoría.

Nota. Elaboración propia. La distribución equilibrada entre impactos positivos y negativos refleja un sistema en estado actual con beneficios reales pero limitaciones técnicas que exigen intervención antes del despliegue masivo.

Implicaciones a Corto y Largo Plazo

El análisis temporal del impacto distingue entre las consecuencias inmediatas observables durante los primeros meses de operación y los efectos estructurales que se acumulan en el mediano y largo plazo. Bender et al. (2021) sostienen que muchos de los riesgos éticos más graves de los modelos de lenguaje no se manifiestan en evaluaciones de corto plazo sino en patrones de uso prolongado que erosionan capacidades cognitivas o reproducen sesgos a escala. La Tabla 10 desagrega las implicaciones del proyecto según su horizonte temporal.

Tabla 10*Implicaciones del proyecto a corto y largo plazo*

Horizonte	Implicaciones positivas	Implicaciones negativas
Corto plazo (0–6 meses)	Reducción del tiempo en búsquedas; aceleración de tareas operativas; capacitación del personal en herramientas de inteligencia artificial.	Errores frecuentes ante consultas mal interpretadas; resistencia al cambio en personal con menor familiaridad tecnológica.
Mediano plazo (6–18 meses)	Estandarización de flujos documentales; consolidación de la solución en la cultura organizacional.	Posible degradación del modelo si no se realiza monitoreo continuo; exposición acumulada de datos cliente al servicio cloud.
Largo plazo (más de 18 meses)	Generación de valor competitivo para el estudio; aporte sectorial al ecosistema legal ecuatoriano; capitalización de aprendizajes.	Erosión potencial de la práctica profesional crítica de los usuarios profesionales junior; riesgo regulatorio si la LOPDP endurece las exigencias.

Nota. Elaboración propia. El análisis a largo plazo incorpora factores estructurales como cambios regulatorios y evolución de la práctica profesional, dimensiones que un análisis puramente técnico tiende a omitir.

Declaración de Responsabilidad Ética

Impacto del Sistema en la Sociedad y su Criticidad

El agente conversacional para gestión documental ejerce un impacto social que excede el ámbito interno de la organización usuaria. Su despliegue afecta directamente la calidad del servicio profesional ofrecido a los clientes, la protección de información sensible sometida al deberes de confidencialidad documental, y las condiciones laborales del personal cuyas tareas se transforman por la automatización. La criticidad del sistema se ubica en nivel alto según la clasificación que el AI Act de la Unión Europea aplica a los sistemas de inteligencia artificial usados en servicios de gestión de información sensible: aunque no realiza acciones jurídicas vinculantes, su salida influye sobre decisiones humanas que sí lo son. Esta criticidad obliga a la organización usuaria, a los autores del proyecto y a quienes operen el sistema en producción, a asumir compromisos formales que vayan más allá de la declaración de buenas intenciones.

La responsabilidad ética se distribuye entre tres niveles claramente identificables. Los autores del proyecto responden por la calidad metodológica del modelo, la documentación de sus limitaciones y la transparencia sobre las métricas obtenidas; estos compromisos se materializan en el repositorio público del proyecto. El equipo de tecnología de la organización usuaria responde por la integración segura del agente, el cumplimiento de la LOPDP y el monitoreo continuo del sistema en producción. La organización usuaria, en su condición de prestador del servicio profesional, responde ante el cliente por las consecuencias del uso del agente en el manejo de su caso, condición que no se transfiere al sistema técnico, aunque la decisión haya sido apoyada por él.

Compromisos Concretos, Medibles y Operativos

La declaración de responsabilidad ética se traduce en compromisos cuyo cumplimiento debe poder revisarse de manera periódica. La Tabla 11 detalla los compromisos asumidos por el proyecto, su naturaleza, indicador de seguimiento y plazo de cumplimiento.

Tabla 11

Compromisos éticos del proyecto

Compromiso	Operacionalización	Indicador de seguimiento	Plazo
Transparencia de la confianza del modelo	Exponer al usuario la confianza del clasificador en cada respuesta del agente.	Porcentaje de respuestas con confianza visible al usuario; meta del 100 %.	Sprint posterior al despliegue inicial.
Validación humana en acciones críticas	Solicitar confirmación explícita antes de ejecutar acciones irreversibles como descargas o eliminaciones.	Tasa de acciones críticas con confirmación humana; meta del 100 %.	Despliegue inicial.
Trazabilidad de decisiones	Registrar consulta, intención detectada, confianza, acción ejecutada y respuesta del usuario.	Cobertura de log; meta del 100 %.	Despliegue inicial.
Cumplimiento de la LOPDP	Designar delegado de protección de datos; documentar el flujo de datos y el consentimiento informado.	Auditoría LOPDP aprobada; meta del 100 % de hallazgos cerrados.	Antes del despliegue productivo.
Inclusión lingüística	Mantener la modalidad de texto plenamente funcional como alternativa accesible al canal de voz.	Paridad funcional voz-texto; meta del 100 %.	Despliegue inicial.
Documentación pública del modelo	Publicar tarjeta del modelo con métricas, limitaciones, sesgos identificados y contextos de uso recomendados.	Tarjeta del modelo publicada y actualizada anualmente.	Sprint 5 del proyecto.
Capacitación obligatoria	Formar a los usuarios del agente sobre sus limitaciones y la necesidad de revisión profesional crítica.	Cobertura de capacitación; meta del 100 % del personal usuario.	Antes del uso productivo.
Canal de reporte de errores	Establecer mecanismo accesible para que cualquier usuario reporte respuestas erróneas del agente.	Tiempo de respuesta a reporte; meta menor o igual a 48 horas.	Despliegue inicial.

Nota. Elaboración propia. Cada compromiso se redacta como obligación operacionalizable, con un indicador medible y un plazo definido. El cumplimiento se documentará en informes trimestrales presentados a la dirección de la empresa proveedora del software de gestión documental y a la dirección académica.

Síntesis de la Reflexión Ética

La reflexión ética del proyecto identifica ocho riesgos principales asociados al funcionamiento del agente conversacional, distribuidos entre cuatro categorías: justicia y equidad, transparencia, autonomía y privacidad. La aplicación cruzada de cinco frameworks éticos sobre el caso permite construir un análisis robusto que contempla tanto los principios fundamentales como las consecuencias prácticas del despliegue. El mapeo de stakeholders incorpora actores tradicionales y afectados invisibles que con frecuencia se omiten en análisis convencionales, particularmente los hablantes con variantes dialectales y las personas con discapacidad auditiva.

El balance entre impactos positivos y negativos evidencia que el proyecto genera valor social genuino en términos de eficiencia operativa y democratización tecnológica para el sector empresarial ecuatoriano que utiliza plataformas de gestión documental de tamaño mediano. Sin embargo, las limitaciones técnicas identificadas en la fase experimental, particularmente el Accuracy del 53.8 % y el Recall del 15.8 % en la clase de navegación, exigen intervención antes del despliegue productivo. Los nueve compromisos formalizados en la Tabla 11 traducen esta reflexión en obligaciones operacionalizables con indicadores medibles y plazos definidos, lo que permite que la responsabilidad ética del proyecto trascienda la declaración de buenas intenciones y se inscriba como práctica continua de mejora.

Referencias

- Barocas, S., & Selbst, A. D. (2016). Big data's disparate impact. *California Law Review*, 104(3), 671-732. <https://doi.org/10.15779/Z38BG31>
- Bender, E. M., Gebru, T., McMillan-Major, A., & Shmitchell, S. (2021). On the dangers of stochastic parrots: Can language models be too big? *Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency*, 610-623. <https://doi.org/10.1145/3442188.3445922>
- Cavoukian, A. (2011). *Privacy by design: The 7 foundational principles*. Information and Privacy Commissioner of Ontario.
- Floridi, L. (2023). *The ethics of artificial intelligence: Principles, challenges, and opportunities*. Oxford University Press.
- Floridi, L., & Cowls, J. (2019). A unified framework of five principles for AI in society. *Harvard Data Science Review*, 1(1). <https://doi.org/10.1162/99608f92.8cd550d1>
- Freeman, R. E. (2010). *Strategic management: A stakeholder approach*. Cambridge University Press.
- Jobin, A., Ienca, M., & Vayena, E. (2019). The global landscape of AI ethics guidelines. *Nature Machine Intelligence*, 1(9), 389-399. <https://doi.org/10.1038/s42256-019-0088-2>
- Mehrabi, N., Morstatter, F., Saxena, N., Lerman, K., & Galstyan, A. (2021). A survey on bias and fairness in machine learning. *ACM Computing Surveys*, 54(6), 1-35. <https://doi.org/10.1145/3457607>
- Mitchell, R. K., Agle, B. R., & Wood, D. J. (1997). Toward a theory of stakeholder identification and salience: Defining the principle of who and what really counts. *Academy of Management Review*, 22(4), 853-886. <https://doi.org/10.5465/amr.1997.9711022105>
- Parlamento Europeo. (2024). Reglamento (UE) 2024/1689 del Parlamento Europeo y del Consejo, por el que se establecen normas armonizadas en materia de inteligencia artificial (Reglamento de Inteligencia Artificial). *Diario Oficial de la Unión Europea*.
- Registro Oficial del Ecuador. (2021). *Ley Orgánica de Protección de Datos Personales*. Registro Oficial Suplemento 459. Asamblea Nacional del Ecuador.