



Maestría en Inteligencia Artificial
Proyecto Integrador Caso de Negocio



Título de la propuesta o iniciativa: Agente de Inteligencia Artificial para asistencia y guía usando lenguaje natural en una plataforma de gestión documental.

Bryan, ALVARADO QUIMIZ^a y Diego ARÁMBULO VÍTORES^b bajo la dirección de Alexandra Arciniegas^c

a Analista QA grupo Calderon. E-mail bryan.alvarado@uees.edu.ec

b Ingeniero en Sistemas Computacionales. E-mail diego.arambulo@uees.edu.ec

c Magister en Auditoria de tecnologías de la Información - Universidad Espíritu Santo, Ecuador.
E-mail aarciniegas@uees.edu.ec

SÍNTESIS:

El 70% de las empresas en Latinoamérica utilizan software de gestión documental (Mobile Time, 2026). Sin embargo, estos sistemas presentan interfaces complejas que dificultan la búsqueda y navegación eficiente de documentos, generando cuellos de botella cuando múltiples usuarios realizan solicitudes simultáneas. Se propone un agente conversacional con pipeline ASR + NLU + RAG integrado en la plataforma de gestión documental existente, que permite realizar consultas en lenguaje natural por voz o texto, eliminando la curva de aprendizaje de la interfaz gráfica.

OBJETIVO RELEVANTE DEL PROYECTO:	Desarrollar e integrar un agente conversacional de inteligencia artificial en una plataforma de gestión documental empresarial que permita a los usuarios realizar búsquedas, descargas y navegación mediante comandos en lenguaje natural por voz o texto, reduciendo la dependencia de interfaces gráficas tradicionales y mejorando la eficiencia operativa del sistema existente.
MODELO Y TÉCNICAS ELEGIDAS:	Pipeline ASR + NLU + RAG: Google Cloud Speech-to-Text (reconocimiento de voz); XLM-RoBERTa ANLI zero-shot (clasificación de intenciones); Babelscape WikiNEuRal (extracción de entidades); spaCy es_core_news_lg (procesamiento lingüístico); FAISS + Qwen 2.5-1.5B (recuperación aumentada por generación). Backend: Python + FastAPI. Despliegue: Docker.
PALABRAS CLAVE	Agente conversacional, gestión documental, reconocimiento automático del habla, comprensión del lenguaje natural, generación aumentada por recuperación.



**UNIVERSIDAD DE ESPECIALIDADES ESPÍRITU SANTO
FACULTAD DE POSTGRADO**

MAESTRÍA EN INTELIGENCIA ARTIFICIAL

TEMA:

**AGENTE DE INTELIGENCIA ARTIFICIAL PARA ASISTENCIA Y GUÍA
USANDO LENGUAJE NATURAL EN UNA PLATAFORMA DE GESTIÓN
DOCUMENTAL.**

**TRABAJO DE TITULACIÓN PREVIO A LA OBTENCIÓN DEL TÍTULO DE
MAGÍSTER EN INTELIGENCIA ARTIFICIAL**

AUTORES:

**DIEGO ANDRÉ ARÁMBULO VÍTORES
BRYAN ISMAEL ALVARADO QUIMIZ**

TUTOR:

MG. ALEXANDRA J. ARCINIEGAS C.

SAMBORONDÓN ECUADOR

MAYO 2026

DEDICATORIA

A mi persona por creer en sí misma y no decaer durante el proceso, a mi mamá y familiares que siempre nos están dando su apoyo incondicional. A los docentes de la Maestría en Inteligencia Artificial de la UEES, por el conocimiento que dio fundamento a este trabajo.

Bryan Ismael Alvarado Quimiz

Dedicado a las 2 mujeres más importantes de mi vida, mi esposa y mi madre, que son mis más grandes apoyos y nunca dejaron de creer en mí y en mis capacidades de lograr grandes cosas.

Diego André Arámbulo Vítóres

AGRADECIMIENTO

Expresamos nuestro más sincero agradecimiento a la Mgs. Alexandra J. Arciniegas Calderón, directora de esta tesis, por su acompañamiento metodológico, rigor académico y la generosa orientación brindada durante el desarrollo de cada fase del proyecto.

Agradecemos a la Universidad de Especialidades Espíritu Santo (UEES) y a la Facultad de Postgrado por proveer el entorno académico e intelectual que permitió desarrollar una investigación de este alcance.

Extendemos nuestro reconocimiento a los profesionales que aportaron retroalimentación técnica, así como a los compañeros de cohorte cuyas discusiones enriquecieron el enfoque metodológico de este trabajo.

Diego André Arámbulo Vítores

Diego André Arámbulo Vítores

RESUMEN

Las plataformas empresariales de manejo documental enfrentan fricción operativa cuando los usuarios deben localizar archivos mediante interfaces tradicionales. El proyecto propone construir un asistente conversacional modular que opere sobre voz y texto en español ecuatoriano, partiendo de la hipótesis de que una arquitectura open-source desplegada localmente alcanza precisión comparable a soluciones comerciales sin comprometer la soberanía de datos. Se integraron cinco componentes en un pipeline modular: reconocimiento del habla con Google Cloud Speech-to-Text, procesamiento lingüístico con spaCy es_core_news_lg, clasificación zero-shot mediante XLM-RoBERTa ANLI, reconocimiento de entidades con WikiNEuRal, recuperación aumentada con FAISS y MiniLM, y generación contextualizada con Qwen 2.5-1.5B-Instruct. La evaluación se condujo sobre un corpus balanceado de 81 registros y 21 audios sintéticos bajo cinco escenarios adversos. El módulo NLU alcanzó 95.24 % de accuracy en condiciones limpias y 90.48 % bajo ruido sintético; el módulo ASR registró WER inferior al 5 %; la métrica de fidelidad contextual del RAG alcanzó 0.83. La arquitectura propuesta valida la viabilidad técnica del enfoque modular open-source para entornos regulados que requieren control soberano sobre la información sensible.

Palabras clave: asistente conversacional, recuperación aumentada por generación, clasificación zero-shot, soberanía de datos, NLU.

ABSTRACT

Enterprise document management platforms face operational friction when users must locate files through traditional interfaces. This project proposes the construction of a modular conversational assistant operating over voice and text in Ecuadorian Spanish, departing from the hypothesis that an open-source architecture deployed locally achieves accuracy comparable to commercial solutions without compromising data sovereignty. Five components were integrated into a modular pipeline: speech recognition with Google Cloud Speech-to-Text, linguistic processing with spaCy es_core_news_lg, zero-shot classification through XLM-RoBERTa ANLI, entity recognition with WikiNEuRal, augmented retrieval with FAISS and MiniLM, and contextualized generation with Qwen 2.5-1.5B-Instruct. The evaluation was conducted on a balanced corpus of 81 records and 21 synthetic audio samples under five adverse scenarios. The NLU module reached 95.24 % accuracy in clean conditions and 90.48 % under synthetic noise; the ASR module recorded a WER below 5 %; the RAG contextual faithfulness metric reached 0.83. The proposed architecture validates the technical viability of the modular open-source approach for regulated environments that require sovereign control over sensitive information.

Keywords: conversational assistant, retrieval-augmented generation, zero-shot classification, data sovereignty, NLU.

ÍNDICE GENERAL

DEDICATORIA	2
AGRADECIMIENTO.....	3
RESUMEN.....	4
ABSTRACT.....	5
ÍNDICE GENERAL.....	6
ÍNDICE FIGURAS	12
ÍNDICE TABLA	14
1 CAPÍTULO I: INTRODUCCIÓN.....	18
1.1 CONTEXTO DEL PROYECTO	19
1.2 JUSTIFICACIÓN.....	19
2 CAPITULO II: FORMULACIÓN DEL PROBLEMA Y PROPUESTA DE SOLUCIÓN	21
2.1 EVALUACIÓN DE PROBLEMAS ENFOQUE SMART.....	21
2.1.1 Creación de Matriz SMART de Proyecto Titulación	21
2.1.2 Sustentación y justificación de puntajes asignados	22
2.2 DEFINICIÓN DEL PROBLEMA.....	23
2.2.1 Pitch del Problema	23
2.3 PROPUESTA DE SOLUCIÓN	24
2.3.1 Pitch Solución Propuesta.....	24
2.4 ALCANCE DEL SISTEMA	25
3 CAPITULO III: ESTADO DEL ARTE	26
3.1 REVISIÓN DE LITERATURA Y SOLUCIONES EXISTENTES	26
3.1.1 Agente de Inteligencia Artificial Conversacional para Sistemas de Gestión Documental... 26	
3.1.2 Estrategia de Búsqueda Bibliográfica	26
3.1.3 Ecuaciones de Búsqueda y Palabras Clave	27
3.1.4 Criterios de Inclusión y Exclusión	28

3.2 MAPA DEL ESTADO DEL ARTE.....	31
3.2.1 Estructura del Mapa.....	31
3.2.2 Análisis de Coincidencias Entre Investigaciones.....	33
3.2.3 Tendencias Tecnológicas Identificadas.....	35
3.2.4 Diagrama Conceptual del Estado del Arte.....	37
3.2.5 Soluciones Existentes en el Mercado	37
3.2.6 Brechas Identificadas en el Estado del Arte	40
3.2.7 Mapa Conceptual del Estado del Arte.....	43
4 CAPITULO IV: PLAN DE TRABAJO Y RECURSOS	45
4.1 METODOLOGÍA DE DESARROLLO ÁGIL.....	45
4.1.1 Marco Metodológico.....	45
4.2 CRONOGRAMA.....	46
4.2.1 Plan de Sprints	46
4.2.2 Diagrama de Gantt.....	47
4.3 PLAN DE RECURSOS.....	47
4.3.1 Recursos Humanos	49
4.3.2 Recursos Tecnológicos.....	50
4.3.3 Recursos de Datos.....	53
4.3.4 Integración con el Sistema Existente	54
4.4 DEFINICIÓN DE HITOS Y ENTREGABLES	56
4.4.1 Indicadores de Cumplimiento.....	58
5 CAPITULO V: ANÁLISIS Y PREPARACIÓN DE DATOS	60
5.1 ANÁLISIS EXPLORATORIO DE DATOS EDA.....	60
5.1.1 Descripción del dataset.....	60
5.1.2 HALLAZGOS PRINCIPALES	85
5.2 PREPARACIÓN DE DATOS.....	89

5.2.1 Pipeline de limpieza.....	95
5.3 INGENIERÍA DE CARACTERÍSTICAS.....	99
5.4 BALANCEO Y AUMENTO DE DATOS.....	101
5.4.1 Estrategias de balanceamiento.....	101
5.4.2 Técnicas de data augmentation.....	103
5.5 PIPELINE DE PROCESAMIENTO.....	105
5.5.1 Hallazgos del pipeline de procesamiento.....	107
6. MODELADO Y ANÁLISIS COMPARATIVO	112
6.1 MÓDULO 1: RECONOCIMIENTO AUTOMÁTICO DEL HABLA (ASR).....	112
6.1.1 Criterios de comparación.....	112
6.1.2 Modelos evaluados.....	113
6.1.3 Matriz comparativa y selección justificada.....	117
6.2 MÓDULO 2: COMPRENSIÓN DEL LENGUAJE NATURAL (NLU/PLN).....	126
6.2.1 Criterios de comparación.....	126
7. EVALUACIÓN DEL MODELO.....	136
8. EVALUACIÓN Y OPTIMIZACIÓN	191
8.1 WORKSHOP DE ESTRÉS DEL SISTEMA.....	191
8.2 SIMULACIÓN DE DATOS RUIDOSOS E INCOMPLETOS.....	191
1. 8.3 MÓDULO 1.- ASR (AUDIOS).....	192
2. 8.4 MÓDULO 2.- PLN / NLU (INTENCIONES).....	192
3. 8.5 MÓDULO 3.- RAG (BASE DE CONOCIMIENTO).....	192
8.6 MODELADO FORMAL DEL RUIDO Y CUANTIFICACIÓN DE NIVELES.....	192
8.7 EVALUACIÓN BAJO CAMBIOS EN LA DISTRIBUCIÓN DE DATOS (DATA DRIFT).....	206
8.8 TIPOLOGÍA DEL DRIFT Y DISEÑO EXPERIMENTAL.....	206
8.9 IMPLICACIONES PARA EL DESPLIEGUE EN PRODUCCIÓN.....	208
8.10 CONCLUSIONES DE RESULTADOS OBTENIDOS.....	212

8.11 INTERPRETACIÓN CUANTITATIVA DEL EFECTO ACUMULATIVO.....	214
8.12 CURVAS DE DEGRADACIÓN POR MÓDULO.....	214
8.13 SÍNTESIS DE HALLAZGOS CUANTITATIVOS.....	215
8.2 AJUSTE DE HIPERPARÁMETROS.....	215
8.15 DEFINICIÓN DEL CASO DE ESTUDIO.....	216
8.16 PROBLEMA.....	216
8.17 PROPUESTA DE MODELO.....	217
8.18 HIPERPARÁMETROS RELEVANTES.....	223
8.19 DISEÑO Y EJECUCIÓN DE EXPERIMENTOS.....	226
8.20 ESPACIO DE BÚSQUEDA EXPERIMENTAL.....	227
8.21 PROTOCOLO DE REPRODUCIBILIDAD EXPERIMENTAL.....	230
8.22 OBSERVACIÓN DE RESULTADOS OBTENIDOS.....	233
8.23 INSIGHTS DETECTADOS.....	234
8.24 RANKING DE IMPORTANCIA DE HIPERPARÁMETROS.....	240
8.25 VALIDEZ ESTADÍSTICA DE LAS CONCLUSIONES.....	246
8.26 INTERPRETACIÓN Y TOMA DE DECISIONES.....	247
8.27 REDUCCIÓN DEL ESPACIO DE BÚSQUEDA.....	248
4. 8.28 MULTI_LABEL = TRUE: GENERA CONFLICTO Y BAJA EL RENDIMIENTO.....	248
8.29 RECOMENDACIONES DE TUNING Y ADICIONALES.....	249
8.30 REPRODUCIBILIDAD DEL PIPELINE EXPERIMENTAL.....	250
8.31 ARTEFACTOS PÚBLICOS DEL EXPERIMENTO.....	250
8.32 PROCEDIMIENTO DE REPLICACIÓN.....	252
8.33 LIMITACIONES RECONOCIDAS.....	252
9. IMPLEMENTACIÓN Y DEMO.....	253
9.1 DESCRIPCIÓN DE LA ARQUITECTURA DEL SISTEMA.....	253
9.2 FLUJO DEL MODELO EN PRODUCCIÓN.....	254

9.3 DESCRIPCIÓN DEL DEMO INTERACTIVO	255
10. ANÁLISIS ÉTICO DEL PROYECTO.....	256
11. ANÁLISIS DE CASOS DE ÉXITO Y FRACASO	277
11.1 METODOLOGÍA DE ANÁLISIS.....	277
11.2 CONTEXTUALIZACIÓN DE LOS CASOS SELECCIONADOS.....	278
11.3 CASO DE ÉXITO: KLARNA AI ASSISTANT.....	280
11.3.1 Descripción general.....	280
11.3.2 Factores determinantes del éxito	281
11.3.3 Evolución posterior y aprendizajes	281
11.4 CASO DE FRACASO: AIR CANADA CHATBOT	282
11.4.1 Descripción general.....	282
11.4.2 Decisión judicial y argumentos del tribunal.....	282
11.4.3 Factores determinantes del fracaso.....	284
11.4.4 Repercusión mediática y jurídica.....	284
11.5 COMPARACIÓN SINTÉTICA ENTRE LOS DOS CASOS	285
11.6 BUENAS PRÁCTICAS EXTRAÍDAS	289
11.7 CONCLUSIONES DEL ANÁLISIS COMPARATIVO.....	290
12. LIMITACIONES Y TRABAJOS FUTUROS.....	291
12.1 LIMITACIONES TÉCNICAS	291
12.2 LIMITACIONES DE DATOS.....	292
12.3 RIESGOS NO CUBIERTOS	293
12.4 LÍNEAS FUTURAS DE INVESTIGACIÓN	293
13. CONCLUSIONES	295
13.1 VALOR DEL PROYECTO.....	295
13.2 APOORTE ACADÉMICO Y PRÁCTICO.....	295
14. REFERENCIAS BIBLIOGRÁFICAS.....	296

15. ANEXOS	297
15.1 ANEXO A: EVIDENCIAS DEL DEMO INTERACTIVO.....	297
15.2 ANEXO B: CATÁLOGO DE PROMPTS DE PRUEBA.....	302

ÍNDICE FIGURAS

Figura 1 Visión general del tema seleccionado junto a sus métricas.....	22
Figura 2 Matriz SMART basada en puntuaciones.....	22
Figura 3 Mapa conceptual del estado del arte - Agente de Inteligencia Artificial	
Conversacional para Sistema de Gestión Documental	44
Figura 4 Distribución temporal de los sprints del proyecto.....	47
Figura 5 Muestra del dataset.....	61
Figura 6 Catálogos del dataset	62
Figura 7 Distribución de clases.....	64
Figura 8 Estadísticas descriptivas de frases	69
Figura 9 Distribución de longitud de frases.....	70
Figura 10 Identificación de outliers en longitud de frases.....	71
Figura 11 Distribución con sesgo	73
Figura 12 Longitud promedio por intención	75
Figura 13 Estado del dato por intención	76
Figura 14 Distribución por tipo de petición del usuario	78
Figura 15 Impactos del preprocesamiento	79
Figura 16 Nubes de palabras de los manuales de usuario.....	81
Figura 17 Nubes de palabras de los manuales técnico.....	82
Figura 18 Diagrama de Similitud léxica entre frases de intención LD (listar documento)	
.....	83
Figura 19 Optimización de Tamaño de Manuales	98

Figura 20	Confianza de Texto vs Confianza de Interacción.....	101
Figura 21	Balance de intenciones de datos	102
Figura 22	Distribución de Longitud de Texto	104

ÍNDICE TABLA

Tabla 1	Ecuaciones de búsqueda aplicadas en la revisión bibliográfica.....	27
Tabla 2	Criterios de inclusión y exclusión aplicados a la búsqueda bibliográfica	28
Tabla 3	Flujo de selección bibliográfica - Protocolo PRISMA	29
Tabla 4	Corpus final de 20 artículos seleccionados para el estado del arte.	30
Tabla 5	Mapa del estado del arte por enfoque metodológico	32
Tabla 6	Principales coincidencias temáticas en el corpus de 20 artículos	34
Tabla 7	Relaciones entre los enfoques metodológicos del estado del arte	37
Tabla 8	Comparativa analítica de soluciones existentes en gestión documental conversacional.....	39
Tabla 9	Brechas identificadas, evidencia bibliográfica y aporte del proyecto.....	43
Tabla 10	Cronograma detallado por sprint del proyecto de tesis.....	46
Tabla 11	Recursos del proyecto	49
Tabla 12	Equipo humano del proyecto y distribución de responsabilidades	50
Tabla 13	Recursos tecnológicos del proyecto sin costos asociados.....	51
Tabla 14	Recursos de datos del proyecto.....	53
Tabla 15	Delimitación entre componentes existentes y aportes del proyecto	55
Tabla 16	Hitos, entregables y criterios de aceptación del proyecto	56
Tabla 17	Indicadores de cumplimiento al 30 de abril de 2026	59
Tabla 18	Esquema formal del dataset - Módulo NLU	61
Tabla 19	Auditoría de calidad del dataset - Resultados verificados	65

Tabla 20	Dimensión evaluada.....	65
Tabla 21	Estadísticas descriptivas de longitud de frases por clase de intención	70
Tabla 22	Correlaciones entre variables del corpus NLU	76
Tabla 23	Distribución de frecuencias - Variables categóricas.....	78
Tabla 24	Resumen de hallazgos del Análisis Exploratorio de Datos	94
Tabla 25	Características construidas en la etapa de Feature Engineering - Datos del corpus 81	100
Tabla 26	Pipeline automatizado de preparación de datos - Etapas, artefactos y salidas verificables.....	106
Tabla 27	Criterios formalizados de evaluación para modelos ASR	112
Tabla 28	Métricas de desempeño comparativo — Modelos ASR evaluados.....	113
Tabla 29	Matriz multicriterio ponderada — Selección de modelo ASR	117
Tabla 30	Criterios formalizados de evaluación — Modelos NLU de clasificación Zero-Shot	126
Tabla 31	Métricas de desempeño — Modelos de clasificación Zero-Shot de intenciones	127
Tabla 32	Análisis empírico de generalización del modelo NLU — Datos del repositorio	189
Tabla 33	Matriz formal de cuantificación del ruido aplicado al pipeline	193
Tabla 34	Impacto cuantitativo del ruido sobre las métricas del pipeline.....	194
Tabla 35	Tipología y diseño experimental del Data Drift evaluado	206
Tabla 36	Impacto cuantitativo del drift sobre las métricas del pipeline	207

Tabla 37	Estrategias de mitigación del drift por tipo y fase del ciclo de vida	208
Tabla 38	Métricas de latencia y throughput por módulo del pipeline	210
Tabla 39	Hallazgos críticos en pruebas de estrés operativo.....	210
Tabla 40	Métricas avanzadas de evaluación del módulo RAG	212
Tabla 41	Curvas de degradación cuantitativa por módulo del pipeline.....	214
Tabla 42	Protocolo de reproducibilidad experimental aplicado	230
Tabla 43	Distribución estratificada del corpus por clase de intención	231
Tabla 44	Ranking de importancia mediante fANOVA con intervalos de confianza	241
Tabla 45	Validación estadística de las decisiones de configuración	246
Tabla 46	Artefactos públicos para reproducir el experimento	251
Tabla 47	Componentes tecnológicos de la arquitectura del sistema.....	253
Tabla 48	Flujo de procesamiento del agente conversacional en producción.....	254
Tabla 49	Resultados de validación funcional del demo.....	255
Tabla 50	Riesgos éticos identificados en el proyecto	257
Tabla 51	Impacto diferencial por grupo de usuarios.....	259
Tabla 52	Dimensiones del impacto diferencial del sistema.....	261
Tabla 53	Aplicación de frameworks éticos al proyecto.....	262
Tabla 54	Mapeo de stakeholders del proyecto.....	264
Tabla 55	Tensiones de valores entre stakeholders del proyecto	266
Tabla 56	Priorización de stakeholders según poder, legitimidad y urgencia.....	268
Tabla 57	Frameworks éticos aplicados al agente conversacional.....	269
Tabla 58	Balance de impactos sociales del proyecto	271

Tabla 59	Implicaciones del proyecto a corto y largo plazo	272
Tabla 60	Compromisos éticos del proyecto	274
Tabla 61	Dimensiones del análisis comparativo aplicadas a cada caso de estudio	277
Tabla 62	Contextualización comparativa de los casos: industria, objetivo e impacto..	278
Tabla 63	Métricas operativas de Klarna AI Assistant en el primer mes de operación .	280
Tabla 64	Argumentos del Tribunal en la decisión Moffatt v. Air Canada (2024 BCCRT 149)	282
Tabla 65	Análisis comparativo entre Klarna AI Assistant y Air Canada Chatbot.....	285
Tabla 66	Análisis causal por factores estructurales en los dos casos analizados.....	287
Tabla 67	Manifestación de errores comunes en los casos analizados.....	288
Tabla 68	Buenas prácticas extraídas del análisis comparativo	289
Tabla 69	Limitaciones técnicas identificadas en el sistema.....	291
Tabla 70	Limitaciones de datos identificadas	292
Tabla 71	Riesgos no cubiertos por el alcance de la investigación	293
Tabla 72	Líneas futuras de investigación priorizadas	293

1 Capítulo I: Introducción

La digitalización de los procesos documentales en las organizaciones ha generado un incremento sostenido en el volumen de información gestionada mediante plataformas especializadas. A medida que estas plataformas incorporan mayores capacidades de almacenamiento e indexación, los usuarios enfrentan una curva de aprendizaje creciente para localizar, descargar y navegar entre documentos de manera eficiente. Esta brecha entre la capacidad del sistema y la facilidad de uso constituye el problema central que motiva el desarrollo del agente conversacional propuesto en este proyecto.

Los avances recientes en modelos de lenguaje de gran escala y en arquitecturas de recuperación aumentada por generación han abierto una oportunidad concreta para reducir esta brecha mediante la incorporación de interfaces conversacionales en lenguaje natural. Mobile Time (2026) señala que el 70% de las empresas en Latinoamérica utilizan software de gestión documental, lo que representa un universo significativo de potenciales beneficiarios directos de esta solución. Un agente conversacional integrado en la plataforma permite que el usuario realice consultas, descargue archivos o navegue entre módulos mediante comandos de voz o texto, sin necesidad de conocer la estructura interna del sistema.

El proyecto se desarrolla sobre una plataforma de gestión documental existente y en producción, adoptando un enfoque de incorporación de nueva funcionalidad sin modificar los componentes base del sistema. La arquitectura integra tres módulos secuenciales: reconocimiento automático del habla para la conversión de voz a texto, comprensión del lenguaje natural para la identificación de intenciones y extracción de entidades, y recuperación aumentada por generación para la consulta contextualizada sobre la documentación técnica y de usuario. El

proyecto se ejecuta en cinco sprints entre el 22 de marzo y el 15 de mayo de 2026, siguiendo la metodología ágil Scrum.

1.1 Contexto del proyecto

Las plataformas de gestión documental empresarial constituyen sistemas críticos para la operación organizacional moderna, almacenando y gestionando volúmenes crecientes de información sensible relacionada con contratos, expedientes, certificados y comunicaciones internas. Sin embargo, la usabilidad de estas plataformas presenta desafíos persistentes: la localización de documentos específicos, la navegación entre módulos y la descarga de archivos asociados a entidades específicas requieren del usuario un conocimiento detallado de la estructura del sistema y la aplicación de filtros complejos sobre interfaces tradicionales. Esta fricción operativa genera una pérdida de productividad medible y limita la adopción del sistema por parte de usuarios no especializados.

El desarrollo reciente de modelos de lenguaje de gran escala (LLM) y arquitecturas de procesamiento de lenguaje natural permite la construcción de agentes conversacionales que median la interacción entre el usuario y el sistema mediante lenguaje natural. Conforme al reporte Mobile Time (2026), el 73% de los usuarios empresariales prefieren interfaces conversacionales sobre interfaces tradicionales para tareas rutinarias de consulta documental, lo que justifica la implementación de un agente especializado para este dominio.

1.2 Justificación

El proyecto se justifica desde tres perspectivas. Primera, desde la perspectiva tecnológica, integra cinco componentes de inteligencia artificial especializados (reconocimiento de voz, procesamiento lingüístico, comprensión semántica, recuperación documental y generación de

respuestas) en un pipeline modular operativo en producción. Segunda, desde la perspectiva empresarial, aborda una necesidad identificada en una plataforma de gestión documental real con base de usuarios establecida, lo que permite validar la solución sobre escenarios de uso auténticos. Tercera, desde la perspectiva académica, documenta el proceso completo desde el análisis de datos hasta la evaluación ética y de robustez del sistema, generando un caso de estudio replicable para investigaciones futuras.

El presente informe se organiza en quince secciones que documentan sistemáticamente el desarrollo del proyecto. La sección dos formula el problema y propone la solución. La sección tres presenta el estado del arte y las soluciones existentes. La sección cuatro describe el plan de trabajo y los recursos utilizados. Las secciones cinco a ocho cubren el análisis de datos, el modelado, la evaluación y la optimización. La sección nueve presenta la implementación y el demo interactivo en producción. La sección diez aborda el análisis ético. La sección once analiza casos comparables de éxito y fracaso. Las secciones doce y trece presentan las limitaciones identificadas y las conclusiones. Las secciones catorce y quince contienen las referencias bibliográficas y los anexos del proyecto.

2 Capitulo II: Formulación del Problema y Propuesta de Solución

2.1 Evaluación de Problemas Enfoque SMART

2.1.1 Creación de Matriz SMART de Proyecto Titulación

Optimización de la experiencia de usuario en la plataforma de Gestión Documental mediante la implementación de un agente conversacional basado en inteligencia artificial.

Actualmente, la plataforma de gestión documental presenta una arquitectura de información compleja que dificulta la navegabilidad y el descubrimiento de servicios para el usuario final. Esta fragmentación de módulos genera una curva de aprendizaje elevada y una fricción constante en la experiencia de usuario U/X, expuesto en un incremento de los tiempos de resolución de tareas y en la saturación de los canales de soporte técnico humano por consultas de baja complejidad. Al carecer de un sistema de asistencia contextual e inmediata, la plataforma no logra resolver de manera autónoma las dudas recurrentes, lo que deriva en una disminución de los índices de satisfacción del usuario y en una reducción operativa que eleva los costos de mantenimiento.

Figura 1
Visión general del tema seleccionado junto a sus métricas

3. Agente IA para SISAD Asistente conversacional web		Prioridad media
S	Específico	Asistente conversacional para consultas y guía dentro del sistema
M	Medible	Precisión de respuestas, satisfacción del usuario
A	Alcanzable	Alta — tecnología madura y disponible
R	Relevante	Media-Alta — optimización institucional
T	Temporal	3 – 6 meses

Figura 2
Matriz SMART basada en puntuaciones

Matriz SMART — Evaluación de proyectos							
Puntaje por dimensión (escala 1–5)							
Proyecto	S	M	A	R	T	Sumatoria	Promedio
— escala 1–5 —	Específico	Medible	Alcanzable	Relevante	Temporal	/25	/5.0
1. Intérprete voz/texto → señas PLN + avatar	4	4	3	5	3	19	3.8
2. Visión artificial → audio/Braille Detección de entorno	4	4	3	5	3	19	3.8
3. Agente IA para SISAD Asistente web conversacional	5	5	5	4	5	24	4.8
5 — muy alto 4 — alto 3 — medio							

2.1.2 Sustentación y justificación de puntajes asignados

Agente de IA para la plataforma de gestión documental

- S = 5.- Temática muy clara, es de dominio específico cerrada al la plataforma de gestión documental.

- M=5.- Fácil de medir, tanto por métricas cuantitativas y cualitativas como: precisión, satisfacción y tiempos de respuestas.
- A=5.- Viabilidad total con las herramientas actuales disponibles como LLM y apis.
- R=4.- La relevancia es algo baja debido a que no tiene mayor impacto en las índoles sociales. El proyecto permitirá la automatización de hasta el 60% de las consultas recurrentes que actualmente soporta el personal humano.
- T=5.- Factible dentro del tiempo que dure el curso de titulación.

Criterios de evaluación para la propuesta

Para realizar la correcta evaluación de la propuesta, debemos utilizar indicadores cuantitativos y cualitativos, debido a que se perciben datos estadísticos de tiempo y satisfacción del cliente, cada indicador podría englobarse en alguna de los 2 grandes grupos que son:

Indicadores cualitativos

- Medición de satisfacción del cliente
- Grado de adopción dentro de los usuarios
- Análisis de sentimiento en foros (opcional)

Indicar cuantitativos

- Recisión de respuestas
- WER - Word Error Rate para los prompts ingresados
- Latencia de respuesta del agente
- Porcentaje de mejora en la velocidad de respuesta ofertado al cliente

2.2 Definición del Problema

2.2.1 Pitch del Problema

Estimados compañeros reciban un cordial saludo, somos Diego Arambulo y Bryan Alvarado, y nuestro proyecto integrador nace de una pregunta que cualquier empresa con sistema de gestión documental debería hacerse. ¿Cuánto tiempo pierde un operario buscando un documento antes de poder atender a un cliente?

Según Mobile Time (2026), el 70% de las empresas en Latinoamérica utilizan software de gestión documental. Una penetración que convierte esta herramienta en un estándar del sector. Sin embargo, ese crecimiento trae consigo un problema que pocas organizaciones han resuelto, la congestión operativa en la búsqueda y recuperación de documentos.

Cuando múltiples usuarios realizan solicitudes simultáneas sobre archivos, anexos o información específica, los sistemas tradicionales generan cuellos de botella que ralentizan la atención, sobrecargan al equipo de soporte y degradan la experiencia del usuario. El impacto no es solo operativo, cada solicitud no atendida a tiempo representa una pérdida económica real, deterioro de la imagen del producto y, en el mediano plazo, adelanto de su obsolescencia frente a soluciones más ágiles de la competencia.

2.3 Propuesta de solución

2.3.1 Pitch Solución Propuesta

Ante esta problemática, se propone el desarrollo de un **agente conversacional inteligente** integrado a sistemas de gestión documental existentes, capaz de procesar solicitudes expresadas en lenguaje natural y ejecutar dos funciones críticas, guiar al usuario dentro del sistema hacia opciones de cierta profundidad y complejidad, y recuperar documentación específica asociada a un usuario o temática determinada, sin intervención humana del equipo de soporte.

La propuesta se sustenta en una arquitectura de tres módulos interconectados: reconocimiento automático del habla (ASR), comprensión del lenguaje natural (NLU) e integración con una base de conocimiento mediante estrategias RAG, lo que permite una interacción fluida, precisa y adaptada al perfil del usuario administrativo.

El valor diferencial de la solución reside en la **interoperabilidad en lenguaje natural**, eliminando la curva de aprendizaje técnico para perfiles no especializados y convirtiendo la búsqueda documental en una conversación. La propuesta está orientada a pequeñas y medianas empresas con sistemas de gestión documental propios que busquen incorporar inteligencia artificial como ventaja competitiva, en un momento en que los modelos de lenguaje de gran escala han alcanzado niveles de madurez que hacen viable su implementación en entornos productivos reales.

2.4 Alcance del sistema

El alcance del agente conversacional se acota a tres categorías de intención del usuario: Navegación (N), referida a consultas informacionales sobre el funcionamiento de la plataforma; Descarga de Documentos (DD), referida a solicitudes de obtención de archivos específicos identificados por entidades como cédulas, nombres o fechas; y Listar Documentos (LD), referida a solicitudes de listado de documentos que cumplen criterios definidos. Las consultas fuera de estas tres categorías activan el mecanismo de fallback controlado.

3 Capítulo III: Estado del Arte

3.1 Revisión de literatura y soluciones existentes

3.1.1 Agente de Inteligencia Artificial Conversacional para Sistemas de Gestión Documental

Este documento expone los recursos del proyecto y el estado del arte que sustenta la propuesta del proyecto. La estructura del trabajo se organiza en cuatro componentes: el mapa del estado del arte con análisis de tendencias, soluciones existentes y brechas identificadas, el cronograma metodológico ágil, el plan integral de recursos y la definición de hitos y entregables. La revisión bibliográfica privilegia fuentes primarias publicadas entre los años 2020 y 2025, con énfasis en investigaciones de alto impacto académico que documentan avances en reconocimiento automático del habla, comprensión del lenguaje natural y generación aumentada por recuperación, las tres dimensiones técnicas que estructuran la arquitectura propuesta.

3.1.2 Estrategia de Búsqueda Bibliográfica

Marco Conceptual de la Búsqueda. La estrategia de búsqueda se diseñó conforme a los lineamientos de la metodología PRISMA adaptada a revisiones de tipo narrativo-analítico, dado que el alcance del trabajo no exige un protocolo sistemático completo, pero sí demanda trazabilidad en la selección de fuentes. Page et al. (2021) describen que la transparencia en la documentación de la estrategia de búsqueda constituye una práctica recomendada en cualquier revisión académica, independientemente de su naturaleza sistemática o narrativa, porque permite reproducir el proceso de identificación de literatura y verificar la cobertura temática lograda.

Bases de Datos Consultadas. La búsqueda se ejecutó sobre cinco repositorios académicos reconocidos por su rigor en el dominio de la inteligencia artificial y el procesamiento del lenguaje natural. Las bases consultadas fueron Scopus, IEEE Xplore, ACM Digital Library, ACL Anthology y arXiv. La inclusión de arXiv responde a la velocidad de publicación característica del campo, donde los avances metodológicos relevantes circulan inicialmente como preprints antes de su aparición en actas de congresos arbitrados. Como complemento, se utilizó Google Académico para la consulta de citaciones y revisión de trabajos derivados.

3.1.3 Ecuaciones de Búsqueda y Palabras Clave

Tabla 1

Ecuaciones de búsqueda aplicadas en la revisión bibliográfica

Eje temático	Ecuación de búsqueda	Scopus	IEEE	ACM	ACL	arXiv	Total	Selec.
1. Reconocimiento automático del habla	("automatic speech recognition" OR "ASR") AND ("transformer" OR "self-supervised") AND ("multilingual" OR "Spanish") NOT ("medical")	68	82	35	19	10	214	3
2. Clasificación de intenciones NLU	("intent classification" OR "natural language understanding") AND ("zero-shot" OR "transfer learning") AND ("XLM" OR "multilingual")	54	38	42	38	14	186	5
3. Generación aumentada por recuperación	("retrieval-augmented generation" OR "RAG") AND ("document" OR "enterprise") AND ("evaluation" OR "benchmark")	78	52	55	45	68	298	6
4. Sesgo y equidad en modelos de lenguaje	("bias" OR "fairness") AND ("language model" OR "NLP") AND ("evaluation" OR "metric")	125	87	118	52	30	412	3
5. Metodología ágil en proyectos de IA	("agile" OR "scrum") AND ("research project" OR "machine learning") AND ("management" OR "framework")	52	38	25	0	12	127	3
TOTALES	5 ecuaciones aplicadas sobre 5 repositorios académicos	377	297	275	154	134	1.237	20

Nota. Elaboración propia. Las ecuaciones se aplicaron sobre los campos de título, resumen y palabras clave de los repositorios consultados, de los años 2020-2025.

3.1.4 Criterios de Inclusión y Exclusión

La aplicación de criterios explícitos de inclusión y exclusión permitió reducir el universo inicial de 1.237 documentos a una selección final de 20 referencias relevantes para los ejes temáticos del proyecto. La Tabla 2 detalla los criterios aplicados, distinguiendo aquellos orientados a garantizar la pertinencia temática de los que aseguran la calidad metodológica de las fuentes seleccionadas.

Tabla 2

Criterios de inclusión y exclusión aplicados a la búsqueda bibliográfica

Tipo	Criterios de inclusión	Criterios de exclusión
Temporales	Publicaciones entre los años 2020 y 2025, salvo trabajos seminales con vigencia metodológica.	Documentos anteriores al año 2018, salvo referentes históricos o metodológicos consolidados.
Tipo de fuente	Artículos arbitrados, actas de congresos indexados y libros académicos editados.	Notas de prensa, blogs comerciales y materiales sin proceso de revisión por pares.
Idioma	Publicaciones en inglés y español; preferencia por trabajos con experimentación en español.	Trabajos en idiomas distintos sin traducción al inglés o al español verificable.
Pertinencia temática	Trabajos centrados en agentes conversacionales, ASR, NLU, RAG o gestión documental.	Investigaciones aplicadas a dominios sin transferencia conceptual al proyecto.
Calidad	Fuentes con DOI verificable, indexación reconocida o citas documentadas.	Documentos sin metadatos básicos, sin DOI o con conflictos de autoría no resueltos.

Nota. Elaboración propia. Los criterios se aplicaron de manera secuencial: primero los temporales y de tipo de fuente, posteriormente los de pertinencia temática y, en última instancia, los de calidad documental.

Conforme a los lineamientos de Page et al. (2021), el proceso de selección bibliográfica se documentó mediante el esquema PRISMA, que distingue cuatro etapas secuenciales: identificación de registros, detección de duplicados, filtrar por título y resumen, y evaluación del texto completo. La Tabla 3 sintetiza el flujo cuantificado de registros en cada etapa.

Tabla 3*Flujo de selección bibliográfica - Protocolo PRISMA*

Etap	Descripción	Registros	Acción aplicada
E1	Identificación: búsqueda en 5 repositorios con 5 ecuaciones	1.237	Aplicación de ecuaciones en Scopus, IEEE, ACM, ACL y arXiv
E2	Eliminación de duplicados entre bases de datos	992	Descartar 245 registros duplicados entre repositorios
E3	Filtrado por título y resumen (criterios temporales, tipo de fuente, idioma)	120	Descartar 872 registros por irrelevancia temática o criterios de exclusión
E4	Evaluación de texto completo (pertinencia, calidad, DOI)	35	Descartar 85 registros por baja pertinencia al proyecto
E5	Selección final: artículos incluidos en la revisión	28	Lectura completa; alineación con los ejes temáticos del proyecto
E6	Corpus final tras depuración de fuentes secundarias y reportes de industria	20	Excluir 8 fuentes de menor rigor académico o relevancia directa

Nota. Elaboración propia, conforme a los lineamientos del protocolo PRISMA (Page et al., 2021). En la etapa E2 se identificaron duplicados cruzando los identificadores DOI y los títulos normalizados entre las cinco bases de datos.

Tras la aplicación del protocolo de selección, el corpus bibliográfico del estado del arte queda conformado por 20 artículos de investigación seleccionados por su pertinencia directa con los componentes del pipeline ASR + NLU + RAG, su rigor metodológico y la disponibilidad de identificador DOI que garantiza la trazabilidad de la fuente. La Tabla 4 presenta el corpus definitivo con la información bibliográfica esencial.

Tabla 4

Corpus final de 20 artículos seleccionados para el estado del arte.

#	Título	Apellidos del autor	Año	DOI / Fuente
1	<i>Wav2Vec 2.0: A framework for self-supervised learning of speech representations</i>	Baevski et al.	2020	https://doi.org/10.48550/arXiv.2006.11477
2	<i>On the dangers of stochastic parrots: Can language models be too big?</i>	Bender et al.	2021	https://doi.org/10.1145/3442188.3445922
3	<i>Benchmarking large language models in retrieval-augmented generation</i>	Chen et al.	2024	https://doi.org/10.1609/aaai.v38i16.29728
4	<i>Unsupervised cross-lingual representation learning at scale</i>	Conneau et al.	2020	https://doi.org/10.18653/v1/2020.acl-main.747
5	<i>QLoRA: Efficient finetuning of quantized LLMs</i>	Dettmers et al.	2023	https://doi.org/10.48550/arXiv.2305.14314
6	<i>Retrieval-augmented generation for large language models: A survey</i>	Gao et al.	2024	https://doi.org/10.48550/arXiv.2312.10997
7	<i>LoRA: Low-rank adaptation of large language models</i>	Hu et al.	2022	https://doi.org/10.48550/arXiv.2106.09685
8	<i>ChatGPT for good? On opportunities and challenges of large language models for education</i>	Kasneci et al.	2023	https://doi.org/10.1016/j.lindif.2023.102274
9	<i>Retrieval-augmented generation for knowledge-intensive NLP tasks</i>	Lewis et al.	2020	https://doi.org/10.48550/arXiv.2005.11401
10	<i>Few-shot learning with multilingual generative language models</i>	Lin et al.	2022	https://doi.org/10.18653/v1/2022.emnlp-main.616
11	<i>Few-shot parameter-efficient fine-tuning is better and cheaper than in-context learning</i>	Liu et al.	2023	https://doi.org/10.48550/arXiv.2205.05638
12	<i>A survey on bias and fairness in machine learning</i>	Mehrabi et al.	2021	https://doi.org/10.1145/3457607
13	<i>The PRISMA 2020 statement: An updated guideline for reporting systematic reviews</i>	Page et al.	2021	https://doi.org/10.1136/bmj.n71

14	<i>Robust speech recognition via large-scale weak supervision</i>	Radford et al.	2023	https://proceedings.mlr.press/v202/radford23a.html
15	<i>Reproducible and replicable machine learning pipelines</i>	Schelter et al.	2022	https://doi.org/10.1145/3501816
16	<i>The Scrum Guide: The definitive guide to Scrum</i>	Schwaber & Sutherland	2020	https://scrumguides.org
17	<i>Literature review as a research methodology: An overview and guidelines</i>	Snyder	2019	https://doi.org/10.1016/j.jbusres.2019.07.039
18	<i>WikiNEuRal: Combined neural and knowledge-based silver data creation for multilingual NER</i>	Tedeschi et al.	2021	https://aclanthology.org/2021.findings-emnlp.215
19	<i>EDA: Easy data augmentation techniques for boosting performance on text classification tasks</i>	Wei & Zou	2019	https://doi.org/10.18653/v1/D19-1670
20	<i>A survey of large language models</i>	Zhao et al.	2023	https://doi.org/10.48550/arXiv.2303.18223

Nota. Elaboración propia. Los 20 artículos seleccionados cubren los cinco ejes temáticos de la búsqueda. Las entradas sin DOI corresponden a actas de conferencias de alto impacto (NeurIPS, ICML) cuya identificación se realiza mediante el URL oficial del congreso. El corpus excluye reportes de industria, libros de texto y artículos cuyo aporte quedó cubierto por referencias más recientes o directamente relacionadas con los componentes del pipeline del proyecto.

3.2 Mapa del Estado del Arte

3.2.1 Estructura del Mapa

El mapa del estado del arte se estructura en cuatro dimensiones analíticas que permiten visualizar las relaciones entre las investigaciones revisadas: enfoques metodológicos predominantes, variables de evaluación utilizadas, tendencias temporales y vacíos metodológicos identificados. Esta organización responde al principio descrito por Snyder (2019), quien sostiene que un mapa del estado del arte debe trascender la enumeración descriptiva de fuentes y construir una representación analítica que evidencie cómo cada trabajo se vincula con los demás dentro del campo de estudio.

Tabla 5

Mapa del estado del arte por enfoque metodológico

Enfoque	Trabajos representativos	Variables evaluadas	Periodo	Tendencia
Transformers ASR	Radford et al. (2023); Baevski et al. (2020); Chen et al. (2024)	Word Error Rate, latencia, robustez ante ruido	2020-2024	↑ Creciente
NLU multilingüe	Conneau et al. (2020); Liu et al. (2023); Lin et al. (2022)	Accuracy, F1-Score, transferencia entre lenguas	2020-2024	↑ Creciente
RAG empresarial	Lewis et al. (2020); Gao et al. (2024); Chen et al. (2024)	Faithfulness, exactitud factual, calidad de la respuesta	2020-2025	↑ Acelerada
Fine-tuning eficiente	Hu et al. (2022); Dettmers et al. (2023); Liu et al. (2023)	Costo computacional, calidad post-ajuste, tiempo de entrenamiento	2022-2025	↑ Acelerada
Reconocimiento NER	Tedeschi et al. (2021); Conneau et al. (2020); Wei & Zou (2019)	Precision, Recall, F1 por tipo de entidad	2020-2024	→ Estable
Sesgo y equidad	Mehrabi et al. (2021); Zhao et al. (2023); Bender et al. (2021)	GAP, paridad demográfica, equidad de oportunidad	2020-2024	↑ Creciente
Aplicaciones empresariales	Castellanos et al. (2022); Kasneci et al. (2023); Zhao et al. (2023)	Tasa de adopción, ROI, satisfacción del usuario	2022-2025	↑ Acelerada

Nota. Elaboración propia. La tendencia se determinó conforme al volumen de publicaciones por año y al impacto promedio medido en citas. Las flechas representan: ↑ creciente, → estable, ↓ decreciente.

3.2.2 Análisis de Coincidencias Entre Investigaciones

El análisis cruzado del corpus de 20 artículos seleccionados permite identificar convergencias temáticas y metodológicas que validan la pertinencia de la arquitectura propuesta para el proyecto. La convergencia más significativa se registra en torno a los modelos transformer multilingües: doce de los veinte artículos referencian o aplican variantes de la familia XLM-R o RoBERTa como componente central de sus sistemas de comprensión del lenguaje natural, lo que consolida la elección de XLM-RoBERTa ANLI como clasificador de intenciones del módulo NLU. Conneau et al. (2020), Lin et al. (2022) y Liu et al. (2023) coinciden en documentar que el preentrenamiento masivo sobre corpus multilingüe reduce significativamente la necesidad de datos etiquetados en el idioma objetivo, argumento directamente aplicable al contexto de bajo recurso del proyecto.

Una segunda convergencia relevante agrupa los artículos sobre generación aumentada por recuperación: Lewis et al. (2020), Gao et al. (2024) y Chen et al. (2024) coinciden en documentar que el esquema RAG mitiga de forma consistente el problema de las alucinaciones en sistemas generativos al anclar las respuestas en documentos recuperados, ventaja especialmente crítica en contextos empresariales donde la trazabilidad de la información es un requisito operativo. Los tres artículos reportan mejoras en métricas de exactitud factual superiores al 15 % frente a sistemas netamente generativos, lo que fundamenta la decisión de incluir el módulo RAG sobre los manuales del sistema existente.

En el eje de reconocimiento de habla, Baevski et al. (2020) y Radford et al. (2023) coinciden en que las arquitecturas basadas en aprendizaje autosupervisado sobre corpus masivos superan consistentemente a los modelos híbridos HMM-DNN en métricas de Word Error Rate,

particularmente ante variación dialectal y ruido ambiental, condiciones presentes en el entorno operativo del sistema. Esta coincidencia refuerza la decisión de priorizar Google Cloud Speech-to-Text, que opera bajo el mismo paradigma, frente a alternativas locales de menor escala. Finalmente, Mehrabi et al. (2021) y Bender et al. (2021) concuerdan en documentar que el sesgo de dominio es el riesgo más frecuente en sistemas NLP desplegados fuera del dominio de preentrenamiento, hallazgo que se materializa empíricamente en los resultados del proyecto con un Recall de 15.8 % sobre la clase de navegación. La Tabla 6 sintetiza las principales coincidencias detectadas entre los artículos del corpus.

Tabla 6

Principales coincidencias temáticas en el corpus de 20 artículos

Eje temático	Artículos coincidentes	Hallazgo convergente
Transformers multilingües	Conneau et al. (2020); Lin et al. (2022); Liu et al. (2023); Hu et al. (2022); Dettmers et al. (2023)	El preentrenamiento masivo multilingüe permite operar en idiomas de bajo recurso. El fine-tuning eficiente (LoRA, QLoRA) reduce el costo de adaptación al dominio.
Generación RAG vs. generativa pura	Lewis et al. (2020); Gao et al. (2024); Chen et al. (2024)	El esquema RAG reduce alucinaciones en más del 15 % frente a sistemas puramente generativos, con mejoras en trazabilidad y exactitud factual.
Reconocimiento de habla con autosupervisión	Baevski et al. (2020); Radford et al. (2023)	Los modelos de gran escala con aprendizaje autosupervisado superan a los híbridos HMM-DNN en WER, especialmente ante variación dialectal y ruido.
Sesgo de dominio en NLP	Mehrabi et al. (2021); Bender et al. (2021); Zhao et al. (2023)	El sesgo residual hacia el dominio de preentrenamiento es el riesgo más frecuente. Se agrava cuando el sistema opera fuera del dominio original.
Reconocimiento de entidades (NER)	Tedeschi et al. (2021); Conneau et al. (2020)	Los modelos NER multilingües entrenados sobre corpus de Wikipedia presentan alta transferibilidad hacia dominios especializados sin ajuste adicional.
Reproducibilidad de pipelines IA	Chelton et al. (2022); Page et al. (2021)	La documentación explícita de las etapas del pipeline y los criterios de selección de datos es condición necesaria para la validez experimental.

Data augmentation en bajo recurso	Wei & Zou (2019); Baevski et al. (2020)	Las técnicas de augmentación textual permiten compensar la escasez de datos etiquetados en dominios especializados con varianza controlada.
--	---	---

Nota. Elaboración propia. La coincidencia se define como la presencia del mismo hallazgo metodológico o técnico en dos o más artículos del corpus, con independencia del dominio de aplicación. El análisis cruzado se realizó sobre los resúmenes, conclusiones y secciones de limitaciones de cada artículo.

3.2.3 Tendencias Tecnológicas Identificadas

El campo de los agentes conversacionales basados en inteligencia artificial atraviesa una fase de transformación acelerada marcada por la convergencia de tres líneas de investigación que configuran el estado del arte contemporáneo. La primera corresponde al reconocimiento automático del habla mediante arquitecturas transformer entrenadas con supervisión débil sobre corpus masivos multilingües. Radford et al. (2023) describen el cambio paradigmático que abandona los modelos ocultos de Markov en favor de transformers de secuencia a secuencia capaces de generalizar entre idiomas tipológicamente próximos al español. Esta transición metodológica se acompaña de mejoras sustanciales en la robustez ante ruido ambiental y variantes dialectales, factores críticos en escenarios productivos.

La segunda línea corresponde a los modelos de comprensión del lenguaje natural con capacidades zero-shot multilingüe. Conneau et al. (2020) establecen el referente metodológico al demostrar que el preentrenamiento masivo sobre corpus de cientos de idiomas permite a un mismo modelo desempeñarse en lenguas con escasa representación durante el entrenamiento. Liu et al. (2023) extienden esta línea al demostrar que el fine-tuning eficiente en pocas muestras supera al aprendizaje en contexto para tareas de clasificación, mientras que Lin et al. (2022) profundizan en las capacidades de transferencia entre tareas de inferencia textual y clasificación de intenciones. La concurrencia de estos trabajos consolida una tendencia que reduce

drásticamente el costo de despliegue de sistemas conversacionales en idiomas distintos del inglés.

La tercera línea se concentra en la generación aumentada por recuperación, esquema descrito por Lewis et al. (2020) como una arquitectura híbrida que combina la capacidad generativa de los modelos de lenguaje con la precisión factual de los sistemas de recuperación. Gao et al. (2024) presentan una revisión sistemática del campo en la que documentan más de doscientos trabajos publicados en los últimos tres años, evidencia empírica del crecimiento acelerado del enfoque. Chen et al. (2024) aportan estudios comparativos sobre la efectividad del RAG en escenarios empresariales, donde la trazabilidad de las respuestas constituye un requerimiento operativo esencial.

Adicionalmente al núcleo conceptual descrito, dos tendencias secundarias merecen atención analítica. Por un lado, las técnicas de fine-tuning eficiente lideradas por LoRA, propuesta inicialmente por Hu et al. (2022) y posteriormente refinada por Dettmers et al. (2023) mediante la integración con cuantización a cuatro bits. También, el creciente interés académico por la evaluación de sesgo en modelos multilingües, dimensión documentada por Mehrabi et al. (2021) y Zhao et al. (2023), cuyos hallazgos influyen directamente sobre los protocolos de evaluación adoptados en el proyecto.

3.2.4 Diagrama Conceptual del Estado del Arte

Tabla 7

Relaciones entre los enfoques metodológicos del estado del arte

	Entrada	Procesamiento	Recuperación	Salida
Capa técnica	ASR (Google Cloud STT)	NLU (XLM-RoBERTa, spaCy)	NER (WikiNEuRal)	RAG (Lewis et al.)
Métricas	WER Latencia	Accuracy F1-Score	Precision Recall	Faithfulness Exactitud
Referente clave	Google (2024)	Conneau et al. (2020)	Tedeschi et al. (2021)	Gao et al. (2024)
Madurez	Producción	Producción	Producción	Crecimiento

Nota. Elaboración propia. El diagrama representa las cuatro capas del pipeline conversacional propuesto, sus métricas de evaluación, los referentes bibliográficos clave y el nivel de madurez tecnológica de cada componente conforme al modelo TRL.

3.2.5 Soluciones Existentes en el Mercado

El ecosistema actual de agentes conversacionales aplicados a la gestión documental se encuentra segmentado en tres categorías diferenciadas según su grado de adaptabilidad, arquitectura técnica y modelo de costos. La primera categoría agrupa las soluciones SaaS generalistas dominadas por proveedores tecnológicos globales que ofrecen plataformas de procesamiento documental con asistencia conversacional integrada. La segunda categoría comprende los sistemas verticales especializados en sectores específicos como el legal, el financiero o el de salud. La tercera abarca las soluciones de código abierto que permiten construir agentes personalizados sobre modelos preentrenados.

En el ámbito SaaS generalista, Microsoft SharePoint Premium incorpora capacidades de búsqueda inteligente y resumen automático mediante Copilot, mientras que Google Document AI ofrece extracción estructurada de datos a partir de documentos no estructurados. Kasneci et al. (2023) analizan el impacto de estas plataformas en entornos académicos y empresariales,

destacando que su robustez técnica y soporte multilingüe coexisten con limitaciones críticas en personalización profunda y dependencia de transferencia de datos a infraestructura externa, dimensión problemática en sectores con requerimientos estrictos de soberanía de la información.

Las soluciones verticales presentan mayor especialización funcional, pero suelen estar restringidas a casos de uso específicos. Plataformas como Kira Systems en el sector legal o ABBYY FlexiCapture en procesos administrativos ofrecen extracción avanzada de información sobre tipos predefinidos de documentos. Castellanos et al. (2022) documentan que la rigidez funcional de estas plataformas y sus elevados costos de licenciamiento las hacen inaccesibles para las pequeñas y medianas empresas, precisamente el segmento empresarial más numeroso en países como Ecuador, lo que profundiza la brecha de transformación digital entre grandes corporaciones y organizaciones de menor escala.

El segmento de código abierto ha experimentado un crecimiento significativo con la liberación de modelos como XLM-RoBERTa, Whisper, Llama y Mistral, junto con frameworks como Haystack y LangChain que orquestan los componentes de un pipeline conversacional. Zhao et al. (2023) documentan que esta vía ofrece la mayor flexibilidad de personalización y soberanía de datos, aunque demanda capacidades técnicas avanzadas en el equipo de implementación. La selección entre las tres categorías depende del balance entre tres variables: presupuesto disponible, requerimientos de soberanía de datos y necesidad de personalización al dominio.

Tabla 8

Comparativa analítica de soluciones existentes en gestión documental conversacional

Categoría	Solución representativa	Principal	Costo	Limitación crítica
SaaS generalista	Microsoft SharePoint	Robustez técnica y soporte	Alto	Datos transferidos fuera del cliente
	Copilot	multilingüe consolidado		
SaaS generalista	Google Document AI	Extracción estructurada con OCR avanzado	Alto	Personalización limitada al dominio
Vertical legal	Kira Systems	Extracción especializada de cláusulas contractuales	Muy alto	Catálogo cerrado de tipos documentales
Vertical financiero	ABBYY FlexiCapture	Procesamiento de formularios estructurados	Alto	Inflexibilidad ante variaciones del documento
Open source	Haystack + Whisper +	Personalización total y	Bajo	Demanda capacidad técnica avanzada
	XLM-RoBERTa	soberanía de datos		
Open source	LangChain + Llama	Orquestación flexible de cadenas RAG	Bajo	Curva de aprendizaje pronunciada

Nota. Elaboración propia. La clasificación de costo refleja licenciamiento e infraestructura típica para una mediana empresa: bajo (menor a USD 1.000 mensuales), alto (USD 1.000 a USD 10.000) y muy alto (mayor a USD 10.000), pero estos valores están sujetos a cambios dependiendo la demanda que tengan en solicitudes. El proyecto de tesis se ubica en la categoría de código abierto y se usa Google Speech-to-Text versión de pruebas para esta fase.

3.2.6 Brechas Identificadas en el Estado del Arte

Análisis Crítico de Vacíos Metodológicos. El análisis comparativo del estado del arte permite identificar cuatro brechas principales que el proyecto de tesis aborda de forma directa. El reconocimiento de estas brechas no se limita a la enumeración de carencias, sino que constituye el fundamento argumentativo de la pertinencia investigativa del trabajo. Cada brecha identificada se documenta en su naturaleza técnica, lingüística, económica o metodológica, en sus manifestaciones concretas en la literatura revisada y en el aporte específico que el proyecto realiza para su mitigación.

Brecha lingüística. La primera brecha corresponde a la limitada disponibilidad de soluciones conversacionales adaptadas al español ecuatoriano y a las variantes dialectales latinoamericanas. La mayoría de los sistemas comerciales y los modelos preentrenados se construyen sobre corpus dominados por el inglés y el español peninsular, lo que genera degradación de rendimiento ante modismos regionales como los presentes en Guayaquil. Castellanos et al. (2022) documentan que esta brecha lingüística constituye un obstáculo crítico para la adopción de agentes conversacionales en el ecosistema empresarial latinoamericano. Lin et al. (2022) refuerzan esta observación al evidenciar que las variantes con menor representación en el preentrenamiento sufren caídas de hasta veinte puntos porcentuales en métricas de comprensión cuando se comparan con la variante peninsular.

Brecha de soberanía de datos. La segunda brecha tiene relación con la soberanía de los datos. Las soluciones SaaS dominantes transfieren los documentos del cliente a servidores externos, esquema incompatible con sectores regulados salud, banca, sector público en los que la legislación local impide la salida de información del territorio nacional. En Ecuador, la Ley Orgánica de Protección de Datos Personales (Asamblea Nacional del Ecuador, 2021) establece en su artículo 55 restricciones explícitas sobre la transferencia internacional de datos personales, condicionándola a que el país receptor garantice un nivel de protección equivalente al establecido en la ley ecuatoriana; este requisito hace que el uso de plataformas SaaS con procesamiento en servidores extranjeros sea jurídicamente problemático para organizaciones que gestionan información personal de ciudadanos ecuatorianos. Schelter et al. (2022) refuerzan esta perspectiva desde el ángulo técnico al documentar que la disponibilidad de pipelines totalmente locales y reproducibles constituye un requerimiento creciente en entornos empresariales con restricciones de soberanía, requerimiento todavía insuficientemente cubierto por la oferta del mercado.

Brecha de accesibilidad económica. La tercera brecha se refiere a la accesibilidad económica de las soluciones existentes. Las plataformas verticales especializadas presentan barreras de entrada que las hacen inalcanzables para las pequeñas y medianas empresas, precisamente el segmento empresarial más numeroso en países como Ecuador. Mobile Time (2024) reporta que el setenta por ciento de las pymes latinoamericanas enfrenta limitaciones presupuestarias que les impiden acceder a soluciones SaaS de gestión documental con asistencia conversacional. Esta brecha de asequibilidad limita la transformación digital de la mayoría de las organizaciones del país y profundiza la desigualdad tecnológica entre grandes corporaciones y pequeñas empresas.

Brecha de sesgo de dominio. La cuarta brecha, de naturaleza técnica, corresponde al sesgo de dominio que presentan los modelos zero-shot multilingües al ser desplegados en contextos especializados. Los resultados empíricos del proyecto evidencian que el modelo XLM-RoBERTa preentrenado sobre los corpus XNLI y ANLI alcanza una precisión global de 0.538 sobre el corpus del sistema de gestión documental, con un recall particularmente bajo en la clase de navegación equivalente a 0.158. Liu et al. (2023) caracterizan este patrón como sesgo residual al dominio de preentrenamiento y proponen estrategias de fine-tuning eficiente como solución; sin embargo, la incorporación sistemática de estas técnicas a sistemas conversacionales empresariales sigue siendo materia de investigación activa. Bender et al. (2021) advierten que el despliegue de modelos preentrenados sin caracterización previa del comportamiento en el dominio objetivo puede conducir a degradaciones operativas significativas en sistemas productivos.

Tabla 9*Brechas identificadas, evidencia bibliográfica y aporte del proyecto*

Brecha	Evidencia en literatura	Aporte del proyecto	Documentado en
Lingüística	Castellanos et al. (2022);	Corpus sintético construido con modismos del español ecuatoriano y léxico documental.	Dataset de 81 registros del repositorio.
	Lin et al. (2022)		
Soberanía de datos	Asamblea Nacional del Ecuador (2021); Schelter et al. (2022)	Arquitectura híbrida con Google Cloud Speech-to-Text como módulo activo y Vosk evaluado como alternativa offline propuesta para fase posterior.	Documento de Análisis de Algoritmos.
Accesibilidad económica	Mobile Time (2024)	Pipeline construido sobre componentes open source con costo operativo escalable.	Plan de Recursos del proyecto.
Sesgo de dominio	Liu et al. (2023); Bender et al. (2021)	Diagnóstico cuantitativo del sesgo y propuesta de fine-tuning con LoRA.	modeloXdataset_result.json del repositorio.


Nota. Elaboración propia. Cada brecha identificada se vincula con un aporte concreto del proyecto y un artefacto disponible en el repositorio público de la investigación.

3.2.7 Mapa Conceptual del Estado del Arte

El mapa conceptual sintetiza las relaciones entre los ejes de búsqueda del estado del arte, los artículos seleccionados por eje y los hallazgos técnicos que fundamentan directamente las decisiones de diseño del proyecto. La estructura sigue la lógica del pipeline propuesto: desde la capa de entrada por voz (módulo ASR) hasta la respuesta generada mediante recuperación documental (módulo RAG), pasando por la comprensión de intenciones (módulo NLU).

Figura 3

Mapa conceptual del estado del arte - Agente de Inteligencia Artificial Conversacional para Sistema de Gestión Documental



Nota. Elaboración propia con herramientas de IA. El mapa sintetiza los cinco ejes temáticos del estado del arte, los hallazgos convergentes y las decisiones de diseño del proyecto. La base inferior muestra el flujo PRISMA de selección bibliográfica.

4 Capítulo IV: Plan de Trabajo y Recursos

4.1 Metodología de desarrollo ágil

El desarrollo del proyecto adoptó la metodología ágil Scrum con sprints de dos semanas, formando un total de cinco sprints entre el 22 de marzo y el 15 de mayo de 2026. Cada sprint culmina con un entregable formal validado por la directora de tesis. La selección de Scrum responde a tres criterios: la naturaleza iterativa del desarrollo de sistemas de inteligencia artificial, la necesidad de validar cada componente del pipeline de forma incremental y la posibilidad de incorporar retroalimentación de las revisiones académicas en cada iteración.

4.1.1 Marco Metodológico

La planificación del proyecto se estructura siguiendo el marco de trabajo Scrum adaptado a proyectos de investigación aplicada en inteligencia artificial. Schwaber y Sutherland (2020) definen Scrum como un marco ligero que ayuda a las personas, equipos y organizaciones a generar valor mediante soluciones adaptativas para problemas complejos, principio especialmente pertinente en proyectos de IA donde la incertidumbre técnica obliga a ciclos cortos de experimentación y validación. Highsmith (2002), obra seminal que estableció los fundamentos conceptuales del desarrollo ágil de software y cuya vigencia metodológica ha sido reafirmada por revisiones posteriores del campo (Schwaber & Sutherland, 2020), refuerza esta orientación al destacar que las metodologías ágiles permiten descomponer entregables complejos en incrementos progresivos, reduciendo el riesgo de desviación entre el resultado final y los requerimientos iniciales.

El cronograma se organiza en cinco sprints distribuidos a lo largo de ocho semanas comprendidas entre el 22 de marzo y el 15 de mayo de 2026. Cada sprint produce un incremento

funcional que culmina con uno o varios entregables académicos formales, alineados con los hitos definidos por la maestría. La planificación contempla revisiones semanales con la dirección de tesis y entrega quincenal de productos al campus virtual según las fechas establecidas por la coordinación académica.

4.2 Cronograma

El cronograma del proyecto se estructura en cinco sprints con objetivos específicos. La Tabla 10 presenta el cronograma detallado.

4.2.1 Plan de Sprints

Tabla 10

Cronograma detallado por sprint del proyecto de tesis

#	Periodo	Sprint / Fase	Objetivos	Entregable presentado
1	22 marzo – 4 abril	Definición y EDA	Identificación del problema, metodología SMART, análisis exploratorio del corpus y selección de algoritmos.	Foro Académico (22/3), Workshop SMART (27/3), Análisis de Algoritmos (4/4) y EDA (4/4).
2	5 – 17 abril	Preparación y Evaluación	Limpieza, normalización, balanceo y data augmentation; pipeline de preprocesamiento; evaluación inicial del modelo.	Preparación y Procesamiento de Datos (12/4) y Evaluación Modelo IA (17/4).
3	18 – 24 abril	Optimización y Estrés	Optimización del modelo, pruebas de estrés sobre los módulos del pipeline, simulación de escenarios críticos.	Presentación: Evaluación y optimización (24/4) y Workshop: Simulación de escenarios críticos (24/4).
4	25 abril – 8 mayo	Recursos, Estado del Arte y Ética	Consolidación del estado del arte, plan de recursos, hitos del proyecto y reflexión ética sobre la solución propuesta.	Recursos y Estado del Arte (8/5) y Reflexión Ética del Proyecto (8/5).

			Consolidación del documento final,	Presentación final del proyecto
5	9 – 15 mayo	Cierre y Demo	desarrollo de la demo interactiva y caso de estudio comparativo.	(15/5), Demo interactivo (15/5) y Caso de estudio (15/5).

Nota. Elaboración propia. Fechas conforme al cronograma oficial publicado por la coordinación de la maestría. Cada sprint culmina con una reunión de revisión y retrospectiva, conforme a las prácticas de Scrum descritas por Schwaber y Sutherland (2020).

4.2.2 Diagrama de Gantt

Figura 4

Distribución temporal de los sprints del proyecto

Sprint	Sem 1 22-28 mar	Sem 2 29 mar-4 abr	Sem 3 5-11 abr	Sem 4 12-17 abr	Sem 5 18-24 abr	Sem 6 25 abr-1 may	Sem 7 2-8 may	Sem 8 9-15 may
1. Definición y EDA								
2. Preparación y Evaluación								
3. Optimización y Estrés								
4. Recursos y Ética								
5. Cierre y Demo								

Nota. Elaboración propia. Las celdas marcadas indican actividad principal del sprint en la semana correspondiente. El proyecto se ejecuta entre el 22 de marzo y el 15 de mayo de 2026, totalizando ocho semanas de trabajo.

4.3 Plan de recursos

La premisa en la utilización de herramientas open source y servicios con capa gratuita durante la fase de construcción del agente, lo que se logra mediante el uso de entornos colaborativos como Google Colab para el desarrollo experimental, modelos open source disponibles en plataformas como Hugging Face para los componentes de inteligencia artificial y la capa gratuita de Google Cloud Speech-to-Text para el reconocimiento de habla. Es importante

señalar que el servicio de Google Cloud Speech-to-Text tiene un costo asociado al consumo cuando supera la cuota gratuita de pruebas; los valores actualizados pueden consultarse en la documentación oficial del proveedor en cloud.google.com/speech-to-text/pricing. En caso de que la organización destinataria no asuma el costo del servicio, la funcionalidad de reconocimiento de voz puede desactivarse y el agente continúa operando en modalidad de texto. Esta orientación permite mantener la fase de investigación libre de inversión adicional para la empresa, dejando el dimensionamiento productivo como una decisión posterior a la validación funcional del agente.

El entorno empresarial al que va dirigida la solución corresponde a una firma de servicios profesionales del sector legal con una plantilla de entre 50 y 250 colaboradores, en la que se gestionan diariamente expedientes, contratos y documentos. La modalidad de integración prevista es híbrida, dado que la empresa cuenta con infraestructura on-premise consolidada para la custodia documental y, simultáneamente, utiliza servicios cloud para capacidades específicas como respaldos cifrados y comunicación con clientes externos. El agente conversacional se integrará en este esquema mediante un módulo desplegable sobre la infraestructura existente, sin requerir migración de la plataforma documental actual.

Los recursos del proyecto se organizan en cuatro categorías: recursos humanos, recursos computacionales, recursos de datos y recursos de software. La Tabla 18 sintetiza los recursos utilizados.

Tabla 11

Recursos del proyecto

Categoría	Recurso	Rol o función en el proyecto
Humano	Investigador 1 (QA)	Análisis y validación de calidad del modelo. Pruebas de estrés.
Humano	Investigador 2	Desarrollo del backend. Implementación del pipeline. Despliegue.
Humano	Directora de tesis	Validación académica de cada sprint. Asesoría metodológica.
Computacional	Google Colab Pro	Entrenamiento y evaluación de modelos en GPU.
Computacional	Servidor cloud con dominio	Despliegue del demo en producción con SSL y Docker.
Datos	Corpus de transcripciones	81 registros balanceados. 21 audios de prueba.
Datos	Documentación del sistema	Manuales de usuario y técnico para indexación RAG.
Software	Python 3.10 + FastAPI	Framework principal del backend.
Software	Docker	Contenedorización del servicio para despliegue.
Software	GitHub	Control de versiones del código fuente.

Nota. Elaboración propia. Repositorio: github.com/diegoarambulo/GRUPO_1.

4.3.1 Recursos Humanos

El equipo del proyecto se compone de los autores de la tesis, quienes asumen los roles técnicos de implementación, junto con la directora académica que aporta supervisión metodológica. El alcance del trabajo se enmarca en el contexto de la maestría, por lo que no contempla la incorporación de personal adicional remunerado. La asignación de

responsabilidades se realizó conforme al perfil técnico de cada autor y a la distribución equitativa de la carga de trabajo a lo largo de los seis sprints.

Tabla 12

Equipo humano del proyecto y distribución de responsabilidades

Rol	Integrante	Responsabilidad principal	Dedicación	Sprints asignados
Investigador principal	Investigador 1	Diseño del pipeline, implementación de los módulos ASR y RAG, integración del backend del agente.	20 h semanales	1, 2, 4, 5, 6
Investigador asociado	Investigador 2	Construcción del corpus NLU, evaluación experimental, análisis de sesgo y métricas del modelo.	20 h semanales	1, 3, 5, 6
Tutora académica	Directora de tesis (directora)	Revisión metodológica, validación de hipótesis y supervisión del avance académico.	2 h semanales	1 a 6

Nota. Elaboración propia. La carga de trabajo se distribuye conforme al perfil técnico de cada integrante y se documenta semanalmente en el repositorio del proyecto. La participación de personal del estudio jurídico se contempla únicamente en la fase de validación funcional posterior, fuera del alcance académico de la presente tesis.

4.3.2 Recursos Tecnológicos

La pila tecnológica del proyecto se construye con herramientas open source y servicios cloud con capa gratuita de pruebas, lo que responde tanto al carácter académico del trabajo como al principio de reproducibilidad metodológica que permite replicar el experimento en otras instituciones sin barreras de licenciamiento. Los entornos colaborativos como Google Colab proporcionan capacidad computacional con GPU para el entrenamiento y la evaluación de los

modelos NLU sin requerir inversión en hardware. Los modelos preentrenados se obtienen de Hugging Face, plataforma que aloja XLM-RoBERTa, WikiNEuRal y los modelos NER del proyecto bajo licencias de uso académico. El reconocimiento de habla utiliza la capa gratuita de Google Cloud Speech-to-Text durante la fase experimental; en operación productiva, este servicio tiene un costo asociado al volumen procesado cuando se supera la cuota gratuita, cuyos valores actualizados pueden consultarse en la documentación oficial del proveedor en cloud.google.com/speech-to-text/pricing. En caso de que el cliente final no asuma el costo del componente ASR, la funcionalidad de reconocimiento de voz puede desactivarse sin afectar el funcionamiento del resto del pipeline, manteniendo la operación del agente en modalidad de texto. Vosk se conserva como alternativa offline evaluada en el benchmark del Sprint 1 y propuesta para una fase posterior del proyecto.

Tabla 13

Recursos tecnológicos del proyecto sin costos asociados

Categoría	Herramienta	Función en el pipeline	Tipo de acceso	Fase de uso
Entorno de desarrollo	Google Colab	Notebook colaborativo con GPU para entrenar y evaluar los modelos NLU.	Capa gratuita	Sprints 3 a 5
Conversión de datos	Pandas + Jupyter	Transformación de datos del corpus, normalización y generación del dataset balanceado.	Open source	Sprints 1, 3
ASR principal	Google Cloud Speech-to-Text	Reconocimiento de habla en tiempo real para los comandos de usuario.	Capa gratuita	Sprints 2, 4

ASR alternativa (propuesta)	Vosk (evaluado)	Modelo ASR offline evaluado en benchmark comparativo; propuesto como alternativa para fase posterior.	Open source	Sprint 2 (benchmark)
NLU clasificación	XLM-RoBERTa ANLI	Clasificación zero-shot de intenciones del usuario.	Open source	Sprints 3, 5
NLU procesamiento	spaCy es_core_news_lg	Lematización, etiquetado morfosintáctico y tokenización del texto.	Open source	Sprints 3, 5
NER	Babelscape WikiNEuRal	Extracción de entidades con nombre (PER, ORG, LOC, DOC).	Open source	Sprints 3, 5
Backend	Python + FastAPI	API REST que orquesta el pipeline y expone los endpoints del agente.	Open source	Sprint 4
Repositorio	GitHub	Control de versiones, trazabilidad y entrega académica del proyecto.	Plan gratuito	1 a 6
Documentación experimental	Jupyter Notebook	Notebooks ejecutables del benchmark, hiperparámetros y pruebas de estrés.	Open source	Sprints 2, 5
Plataforma de modelos	Hugging Face Hub	Repositorio de modelos preentrenados utilizados en NLU y NER.	Plan gratuito	Sprints 3, 5

Nota. Elaboración propia. La etiqueta capa gratuita corresponde a los créditos iniciales o cuotas mensuales sin costo que ofrecen los proveedores de servicios cloud, suficientes para los volúmenes experimentales del proyecto. Open source corresponde a herramientas con licencias permisivas (MIT, Apache 2.0 o similares) que no generan costo de adquisición ni mantenimiento.

4.3.3 Recursos de Datos

Los recursos de datos constituyen el insumo crítico del proyecto y determinan el techo de rendimiento alcanzable por los modelos. Dado que el proyecto se enfoca en la construcción inicial del agente conversacional como nueva funcionalidad sobre el sistema existente, el corpus utilizado en esta fase se construye de forma sintética siguiendo el catálogo de intenciones definido por los requisitos funcionales. Wei y Zou (2019) describen que la generación sintética de datos textuales mediante técnicas de augmentación constituye una estrategia efectiva en escenarios de bajo recurso, condición característica de proyectos iniciales en los que aún no se dispone de un volumen significativo de interacciones reales capturadas. La conversión de datos hacia los formatos requeridos por los modelos se realiza mediante notebooks de Google Colab que ejecutan transformaciones reproducibles documentadas en el repositorio del proyecto.

Tabla 14
Recursos de datos del proyecto

Recurso	Tipo	Volumen	Uso	Fuente
Corpus NLU original	JSON sintético	60 registros	Análisis exploratorio y diagnóstico inicial.	transcripcionesXindice.json
Corpus NLU balanceado	JSON sintético	81 registros	Entrenamiento y evaluación del clasificador de intenciones.	dataset_nlu_completo_81.json
Manual técnico de API	Markdown	~10 K tokens	Corpus de recuperación para el módulo RAG técnico.	manual_api.md

Manual de usuario	Markdown	~9 K tokens	Corpus de recuperación	
			para el módulo RAG funcional.	manual_user.md
Audio de prueba ASR	WAV	21 grabaciones	Pruebas de estrés con	
			ruido ambiental, acentos y audio cortado.	Noise_Test_Module1.csv
Resultados del modelo	JSON	65 evaluaciones	Métricas empíricas de	
			desempeño sobre el corpus.	modeloXdataset_result.json

Nota. Elaboración propia. Todos los recursos de datos están disponibles en el repositorio público del proyecto. La construcción sintética del corpus respeta la metodología descrita por Wei y Zou (2019) para escenarios de bajo recurso.

4.3.4 Integración con el Sistema Existente

El sistema de gestión documental sobre el cual se desplegará el agente conversacional ya se encuentra en operación en el entorno empresarial, con sus componentes de almacenamiento, autenticación y consulta funcionando bajo la responsabilidad del equipo de tecnología de la organización. El alcance del proyecto se limita a la incorporación del módulo conversacional como una nueva capa que se integra mediante interfaces de programación con la plataforma existente. Esta delimitación es analíticamente relevante porque circunscribe la responsabilidad del proyecto a los componentes que aportan la funcionalidad nueva, sin entrar en mantenimiento ni evolución de la plataforma documental subyacente. La Tabla 10 detalla la separación entre los componentes existentes y los nuevos componentes que el proyecto incorpora.

Tabla 15*Delimitación entre componentes existentes y aportes del proyecto*

Componente	Estado	Función	Responsable
Plataforma de gestión documental	Existente	Almacenamiento, indexación y consulta de los documentos del estudio jurídico.	Equipo TI de la organización.
Sistema de autenticación	Existente	Control de acceso, perfiles de usuario y trazabilidad de operaciones.	Equipo TI de la organización.
Repositorio documental	Existente	Custodia de expedientes, contratos y documentos probatorios.	TI de la organización.
Módulo ASR	Aporte del proyecto	Reconocimiento de habla del usuario para conversión de comandos de voz a texto.	Autores de la tesis
Módulo NLU	Aporte del proyecto	Comprensión de intenciones, extracción de entidades y enrutamiento de acciones.	Autores de la tesis
Módulo RAG	Aporte del proyecto	Recuperación contextualizada sobre los manuales y documentos del sistema.	Autores de la tesis
API de integración	Aporte del proyecto	Backend que conecta el agente conversacional con la plataforma existente.	Autores de la tesis
Modal conversacional (interfaz)	Aporte del proyecto	Capa de comunicación que recibe las consultas del usuario en el frontend del sistema documental y las envía al backend Python que aloja los módulos del agente.	Autores de la tesis

Nota. Elaboración propia. Los componentes etiquetados como existentes no forman parte del alcance del proyecto y se asumen disponibles y operativos. Los componentes etiquetados como aporte del proyecto corresponden al desarrollo objeto de la presente y constituyen los entregables verificables de los sprints técnicos.

El mapa del estado del arte organiza esta selección en siete enfoques metodológicos y evidencia la convergencia de tres líneas de investigación principales: ASR mediante transformers, NLU multilingüe zero-shot y generación aumentada por recuperación.

La revisión del estado del arte identifica cuatro brechas relevantes en el ecosistema actual: la limitada cobertura del español ecuatoriano en los corpus comerciales, la dependencia de infraestructura externa en las soluciones SaaS dominantes, las barreras de costo de las plataformas verticales especializadas y el sesgo de dominio de los modelos zero-shot al desplegarse en contextos especializados. El proyecto aborda cada una de estas brechas mediante aportes verificables documentados en el repositorio.

4.4 Definición de hitos y entregables

La definición de hitos y entregables permite establecer puntos de control a lo largo del cronograma y vincular cada entrega con un criterio de aceptación cuantificable. Highsmith (2002) recomienda que cada entregable cuente con criterios de aceptación definidos a priori, dado que esta práctica facilita el seguimiento objetivo del avance del proyecto y reduce las asimetrías de interpretación entre el equipo ejecutor y la dirección académica. La Tabla 15 consolida los hitos del proyecto conforme al calendario oficial de la maestría.

Tabla 16
Hitos, entregables y criterios de aceptación del proyecto

#	Hito	Fecha	Entregable	Criterio de aceptación
H1	Identificación del problema	22 marzo	Foro académico con descripción del problema, contexto y justificación de la propuesta.	Aprobación de la primera participación en el foro.

H2	Metodología SMART	27 marzo	Workshop de aplicación del marco SMART al objetivo del proyecto.	Workshop entregado y aprobado.
H3	Análisis comparativo de algoritmos	4 abril	Documento con matriz multicriterio sobre los algoritmos ASR y NLU evaluados.	Score 84/100 obtenido en rúbrica académica.
H4	Análisis exploratorio de datos	4 abril	Documento EDA con tablas de calidad, estadísticas descriptivas y correlaciones.	Score 61/100 obtenido en rúbrica académica.
H5	Preparación de datos	12 abril	Documento de preparación con corpus balanceado de 81 registros y pipeline reproducible.	Score 93/100 obtenido en rúbrica académica.
H6	Evaluación del modelo IA	17 abril	Documento de evaluación con métricas empíricas, análisis de sesgo y diagnóstico.	Score 76/100 obtenido en rúbrica académica.
H7	Evaluación y optimización	24 abril	Presentación del proceso de optimización del modelo y resultados obtenidos.	Presentación entregada en la fecha establecida.
H8	Simulación de escenarios críticos	24 abril	Workshop con resultados de las pruebas de estrés sobre los tres módulos.	Workshop entregado y aprobado.
H9	Recursos y Estado del Arte	8 mayo	Documento integral con estrategia de búsqueda, mapa del estado del arte, plan de recursos e hitos.	Cobertura completa de los componentes solicitados.
H10	Reflexión Ética	8 mayo	Documento con análisis ético sobre el uso del agente conversacional y privacidad de datos.	Documento entregado en la fecha establecida.

H11	Presentación final	15 mayo	Documento final del proyecto consolidado y presentación de defensa.	Aprobación del tribunal académico.
H12	Demo interactivo	15 mayo	Demostración funcional del agente conversacional integrado con el sistema documental.	Demo ejecutado correctamente ante el tribunal.
H13	Caso de estudio	15 mayo	Análisis comparativo entre proyectos exitosos y fallidos del dominio.	Caso entregado conforme a los lineamientos.

Nota. Elaboración propia. Los hitos H1 al H10 corresponden a entregas ya realizadas según el calendario oficial; los hitos H11 al H13 conforman el cierre del proyecto previsto para el 15 de mayo de 2026.

4.4.1 Indicadores de Cumplimiento

El seguimiento del cumplimiento se apoya en cinco indicadores cuantificables que permiten objetivar el avance del proyecto: porcentaje de entregables completados, rúbrica académica obtenida por entregable, métricas empíricas alcanzadas por el modelo y reproducibilidad del pipeline. Estos indicadores se reportan al cierre de cada sprint en una reunión de revisión con la dirección de tesis. La Tabla 16 detalla los indicadores actuales del proyecto al 30 de abril de 2026.

Tabla 17*Indicadores de cumplimiento al 30 de abril de 2026*

Indicador	Valor objetivo	Valor actual	Estado
Entregables completados	13 de 13 al cierre	8 de 13 (61.5 %)	En meta
Score promedio por rúbrica	Mayor o igual a 80	78.5 promedio	En revisión
Accuracy del modelo NLU	Mayor o igual a 0.70	0.538	Por mejorar
Recall por clase (mínimo)	Mayor o igual a 0.50	0.158 (clase N)	Por mejorar
Reproducibilidad del pipeline	100 % de etapas documentadas	7 de 7 etapas	Cumplido

Nota. Elaboración propia. Los valores actuales se derivan de los archivos del repositorio del proyecto y de las rúbricas académicas recibidas. Los indicadores en estado por mejorar se abordarán mediante fine-tuning con LoRA durante el sprint 5 del cronograma.

El cronograma estructurado en seis sprints de duración aproximada de dos semanas cada uno permite descomponer el horizonte de dieciséis semanas en incrementos alineados con los hitos académicos de la maestría. El plan de recursos integra dos investigadores con asignación de veinte horas semanales, una pila tecnológica basada en componentes open source con costo operativo controlado y un corpus de datos sintéticos que totaliza 81 registros balanceados para el módulo NLU. Los hitos definidos cuentan con criterios de aceptación cuantificables y se monitorean mediante cinco indicadores que evidencian un avance global conforme al plan, con áreas de mejora identificadas en las métricas del modelo NLU que serán abordadas mediante fine-tuning con LoRA en el último sprint del proyecto.

5 Capítulo V: Análisis y Preparación de Datos

5.1 Análisis Exploratorio de Datos EDA

5.1.1 Descripción del dataset

El corpus del Módulo 2 se compone de 60 registros sintéticos que representan frases de usuario en lenguaje natural, estructurados en formato JSON. La unidad de análisis es el registro de intención: cada observación corresponde a una frase textual asociada a una intención etiquetada del sistema de gestión documental. El dataset incluye cinco variables que caracterizan cada registro desde su estado original hasta su etiqueta de clase objetivo. La Tabla 19 presenta el esquema formal del corpus:

- **texto:** es la frase original del usuario, sin tratar
- **texto_limpio:** versión normalizada, tal y como es esperada para poder ser utilizada
- **tipo:** nos indica el registro de que tipo es:
 - solicitud
 - navegación
- **estado:** nos indica la calidad del dato o registro N,S o D (normal, sucio y depurado respectivamente)
- **intencion:** nos indica la clase objetivo
 - navegación (N)
 - listar documentos (LD)
 - descarga de documentos (DD)

Cada registro del dataset busca simular y representar una intención de usuario expresada en lenguaje natural, en etapas más adelantadas del proyecto, serán comparadas frente a audios que representen cada registro textual, ejemplo de registro y sus catálogos contenidos en el mismo dataset:

Figura 5

Muestra del dataset

```

1 - {
2   "tipo": "S",
3   "texto": "dam3 los archivooooooooos de contratos c4rgados del 1 de enero del 2026
4     al 4 de marzo del 2026, pero yaaaaaaa!!!$$$$",
5   "estado": "N",
6   "intencion": "LD",
7   "texto_limpio": "dame los archivos de contratos cargados del 2026-01-01 al 2026
  -03-04"
}

```

Nota. Elaboración propia.

Tabla 18

Esquema formal del dataset - Módulo NLU

Variable	Tipo	Valores posibles	Cardinalidad	Descripción
<i>texto</i>	Texto	Cadena libre	60 únicos	Frase original del usuario sin tratar (puede contener ruido)
<i>texto_limpio</i>	Texto	Cadena normalizada	60 únicos	Versión normalizada lista para el modelo
<i>tipo</i>	Categórica	S, N	2 categorías	S = solicitud operativa, N = navegación
<i>estado</i>	Categórica	N, S, D	3 categorías	Calidad: N=Normal, S=Sucio, D=Depurado
<i>intencion</i>	Categórica	N, LD, DD	3 clases	Variable objetivo: Navegación, Listar Docs, Descarga Docs

Nota. Elaboración propia. N = 60 registros totales. Dataset sintético del proyecto.

Figura 6

Catálogos del dataset

```
1 {  
2   "tipo": {  
3     "S": "solicitud",  
4     "N": "navegación de sistema"  
5   },  
6   "estado": {  
7     "D": "depurado",  
8     "S": "sucio",  
9     "N": "normal"  
10  },  
11  "intenciones": {  
12    "N": "navegación",  
13    "DD": "descarga de documento",  
14    "LD": "listar documentos"  
15  }  
16 }
```

Nota. Elaboración propia.

Louvan & Magnini (2020) señalan que en pipelines conversacionales orientados a la invocación de servicios externos mediante interfaces de programación de aplicaciones, la precisión en la detección de intenciones representa el punto crítico de la cadena, dado que un error de clasificación en este eslabón compromete la respuesta del sistema en su totalidad.

Análisis de distribuciones de variables. La propuesta al estar dividida en 3 partes fundamentales estará integrada por fuentes de datos externas, ya existentes y por un set de inputs cargados en el momento de realizar pruebas, siendo estos orígenes ordenados de la siguiente forma:

- **Módulo 1.-** Voz a texto (ASR)
 - set de audios grabados por el usuario emulando flujos y peticiones
 - transcripciones exactas de texto de los audios
 - data errada para control de escenarios
- **Módulo 2.-** Datos de intención (NLU)
 - frases de usuario
 - etiquetas de intencion (acciones que se desean realizar)
 - clasificación por texto etiquetado
- **Módulo 3.-** Manuales existentes (texto técnico y de navegación)
 - Documentación del sistema para usuarios
 - Manuales de API rest con corpus de conocimientos
 - contenido mixto, estructurado y semi estructurado


Distribuciones de clases. Debido a que el dataset de peticiones de usuario está dividido en tipo de intención, tomaremos estas mismas como el principal identificador para segmentarlos, en el conjunto inicial de 60 registros, hemos podido identificar que existen 3 grupos que son LD, DD y N, de los cuales guiandonos por el catálogo de dataset, es el de tipo Listar Documentos, el que obtiene la mayoría de registros, esto nos deja identificar las siguientes cualidades:

- Existencia de un desbalance en el dataset de nivel moderado
- La clase dominante es LD (Listar Documento), lo cual puede provocar un sesgo en el modelo
- La clase N (Navegacion), tiene poca data o está subrepresentada

Lo anterior mencionado, podemos mitigarlo con estrategias de balanceo como oversampling o data augmentation, que mejoran la generalización del modelo. El desbalance podemos notarlo de forma más natural y visual en la siguiente gráfica comparativa.

Figura 7

Distribución de clases



Nota. Elaboración propia.

Identificación de calidad de los datos. La revisión de calidad del dataset abarcó la detección de valores nulos, registros duplicados, etiquetas inconsistentes y ruido textual en el campo de texto de entrada. Según To'xtasinov y Sodiqov (2025), la limpieza de datos constituye una etapa determinante que mejora la calidad de la información mediante la corrección de errores, eliminación de inconsistencias y tratamiento de valores faltantes. La Tabla 2 consolida los resultados verificados de la auditoría de calidad realizada sobre el corpus:

La limpieza de datos, incluyendo la eliminación de valores atípicos, datos faltantes y registros mal etiquetados, puede mejorar significativamente el rendimiento de los modelos de aprendizaje automático, llegando a incrementos superiores al 20% en la precisión únicamente mediante procesos de depuración del dataset (Schelter et al., 2022). Es por eso que gran parte de los errores son evitados en esta etapa crítica, cuya importancia radica seccionada en 3 principales secciones y sus análisis claves.

Tabla 19
Auditoría de calidad del dataset - Resultados verificados

Tabla 20 Dimensión evaluada	Total registros	Con incidencia	Observación
Valores nulos (campos vacíos)	60	0	Dataset completo, sin campos faltantes
Registros duplicados exactos	60	0	No se detectaron registros idénticos
Registros marcados como sucios (estado=S)	60	12 (20.0 %)	Concentrado en intenciones operativas LD y DD
Registros depurados (estado=D)	60	7 (11.7 %)	Subconjunto ya procesado del corpus
Registros normales (estado=N)	60	41 (68.3 %)	Mayoría del corpus en estado utilizable
Etiquetas inconsistentes con catálogo	60	0	Todas las etiquetas pertenecen al catálogo definido
Outliers en texto original (IQR)	60	5 (8.3 %)	Frases con ruido intencional > 83 chars
Outliers en texto_limpio (IQR)	60	2 (3.3 %)	Reducción del 60 % tras normalización

Nota. Elaboración propia. Datos verificados sobre el archivo transcripcionesXindice.json del repositorio del proyecto. La mejora por depuración puede alcanzar incrementos superiores al 20 % en precisión (Schelter et al., 2022).

- Módulo 1.- voz a texto (ASR)
 - WER (word error rate)
 - Longitud de audios
 - Duración vs error
 - Distribución de error:
 - sustituciones
 - inserciones
 - eliminaciones
 - Tipo de errores
 - técnicos (ej: al usar conjunto de lenguaje spanglish)
 - comunes
 - controlados
 - Insights esperados
 - tipo de palabra con más tasa de fallo
 - impacto de un fallo en el siguiente módulo (NLU)


- Módulo 2.- Datos de intención (NLU)
 - distribución de clases (existe balance?)
 - número de ejemplos por intent probado
 - frases promedio por clase
 - identificación de anomalías en intents
 - ambigüedad
 - solapamiento semántico (transmisión de la misma idea)
 - longitud de frases
 - Insights esperados
 - ¿Es necesario más datos?
 - calidad de etiquetado
- Módulo 3.- Manuales existentes (texto técnico y de navegación)
 - Longitud de la documentación
 - conteo de palabras
 - oraciones por documento
 - Frecuencia de términos
 - palabras comunes
 - terminos clave (ej: token, request, endpoint)
 - Distribución del vocabulario
 - palabras únicas (raras contra frecuentes)
 - Ruido en la data
 - símbolos no necesarios e ilegibles
 - códigos, urls, fragmentos de json
 - Información no digerible
 - tablas de difícil lectura
 - anexos de imagen no legible por el modelo que esconda data primordial
 - estilos de archivo que ocupe espacio en memoria al procesar

- Módulos unificado.- Audio + ASR + NLU + API REST
 - Impacto de un error en etapa ASR en NLU
 - afección detectada en la intención por error de ASR
 - Precisión de funcionamiento con texto limpio vs texto identificado por voz
 - Casos fallidos
 - análisis cualitativo de los errores detectados
 - Cobertura de escenarios
 - conteo de intenciones que impactan a un API y navegación

Estadísticas descriptivas. Las estadísticas descriptivas se calcularon sobre la longitud de las frases del usuario (campo texto_limpio), medida en número de caracteres, dado que esta variable constituye el indicador más directo de la complejidad léxica de los comandos de entrada al módulo NLU. La Tabla 3 presenta las medidas de tendencia central y dispersión calculadas sobre el corpus completo y desagregadas por clase de intención, lo que permite identificar patrones estadísticos asociados a cada tipo de solicitud:

Figura 8

Estadísticas descriptivas de frases



Nota. Elaboración propia.

Tabla 21


Estadísticas descriptivas de longitud de frases por clase de intención

Clase / Corpus	n	Media	Mediana	Desv. Std	Mín.	Máx.	IQR
Corpus completo	60	55.83	55.0	8.21	39	76	9.0
Listar Documentos (LD)	27	59.9	—	8.22	—	—	—
Descarga de Documentos (DD)	16	53.1	—	7.45	—	—	—
Navegación (N)	17	51.9	—	5.90	—	—	—

Nota. Elaboración propia. Longitud medida en caracteres sobre el campo texto_limpio del archivo transcripcionesXindice.json. La clase LD presenta la mayor media (59.9) y dispersión, consistente con la presencia de parámetros contextuales (fechas, nombres de usuario).

Figura 9

Distribución de longitud de frases




Nota. Elaboración propia.

Como observación, tenemos un dataset con frases relativamente cortas, lo cual es adecuado para modelos basados en NLU (Castellanos et al., 2022), pero la presencia de frases largas necesita un análisis más adecuado para descartar posibles outliers semánticos por mala formación de palabras o errores de traducción del módulo ASR.

Los valores atípicos, en las longitudes de frases pueden ser indicadores de outliers, cuya repercusión podría ser la contaminación del dataset y ahí reside la importancia de detectarlos, podemos notar que ciertos registros identificados presentan textos extendidos de forma intencional como por ejemplo “*dam3 los archivooooooooos...*” y “*huyhuy tangamndapio*”, serían los causantes de tales anomalías.

Figura 10

Identificación de outliers en longitud de frases



Nota. Elaboración propia.


Análisis de distribución. Un análisis de distribución nos ayudará a observar a dónde tiende la información contenida del dataset, dentro del conjunto universo generado de forma sintética, vemos que la presencia de frases cortas super a la de frases largas, por ende, tenemos un sesgo a la derecha, y además notamos presencia de ruido textual en frases largas, como pueden ser caracteres repetidos de forma consecutiva, como ya hemos visualizado en los ejemplos anteriores.

Mikolov et al. (2013) señalan que la variabilidad lingüística presente en corpus de lenguaje natural refleja patrones de distribución asimétrica, donde la predominancia de secuencias cortas sobre secuencias largas genera un sesgo positivo que debe ser considerado durante el preprocesamiento, a fin de evitar que dicho desequilibrio afecte la capacidad de generalización del modelo.

Podemos observar que el dataset presenta mucha variabilidad del lenguaje natural realista humano, pero para ser utilizado, requiere normalización de ciertos aspectos, como fechas, palabras basura y caracteres especiales que no aportan contexto.

Figura 11

Distribución con sesgo



Nota. Elaboración propia.


Análisis de correlación. Se analizaron las relaciones entre variables del dataset mediante el coeficiente de correlación de Spearman (ρ), apropiado para variables ordinales y distribuciones no normales. Se evaluaron las relaciones entre la longitud del texto, el tipo de intención y el estado de calidad del dato, calculadas sobre el corpus de 60 registros. La Tabla 4 consolida los coeficientes obtenidos:

- Longitud de texto vs intención del usuario
- Estado del dato contra el tipo de intención

De ambos análisis podemos intuir que las frases de usuario de tipo Listar documento, tienden a ser las más largas, en promedio debido a que son las que mayor contexto tienen, como fechas y usuarios, las de descarga son intermedias y las de navegación son cortas y directas ya que solo desean acceder a una parte del sistema. Por otra parte, el segundo gráfico deja denotar que la gran mayoría de intenciones tiene estado normal, y los datos sucios se concentran en las de tipo descarga y listar, debido a su contenido de lenguaje coloquial y caracteres especiales, lo que indica que los registros depurados son la minoría dentro del dataset y que las solicitudes operativas son las que tienden a tener más ruido, lo cual impactará en el módulo ASR.

Figura 12


Longitud promedio por intención



Nota. Elaboración propia.

Figura 13

Estado del dato por intención



Nota. Elaboración propia.

Tabla 22

Correlaciones entre variables del corpus NLU

Par de variables	Coef. Spearman (ρ)	Magnitud	Diferencia observada	Interpretación
Longitud (LD vs N)	0.52	Moderada-alta	+8.0 chars	LD: media 59.9; N: media 51.9 — diferencia significativa
Longitud (DD vs N)	0.18	Débil	+1.2 chars	DD: media 53.1; N: media 51.9 — diferencia mínima
Estado sucio ↔ Tipo S (operativa)	0.42	Moderada	12/12 sucios → S	100 % de los registros sucios son operativos (LD/DD)
Estado depurado ↔ Tipo	0.21	Débil	7 (11.7 %)	Distribuidos entre tipos S y N

Nota. Elaboración propia. ρ = coeficiente de Spearman. Magnitud: $|\rho| < 0.3$ débil, 0.3-0.6 moderada, > 0.6 fuerte. Datos calculados sobre transcripcionesXindice.json del repositorio. La concentración de ruido en las clases operativas (LD y DD) constituye el hallazgo más relevante para el preprocesamiento.


Los resultados confirman que la longitud de texto y el tipo de intención presentan una correlación moderada-alta ($\rho = 0.52$), particularmente entre las clases LD y N: las intenciones LD exhiben frases sustancialmente más largas (media 59.9 caracteres) por la incorporación de parámetros contextuales como fechas y nombres de usuario, mientras que las intenciones de navegación emplean frases más breves y directas (media 51.9 caracteres). Adicionalmente, el 100 % de los registros marcados como sucios ($n = 12$) corresponde a intenciones operativas tipo S (LD o DD), confirmando que el ruido textual no se distribuye aleatoriamente, sino que se concentra de forma sistemática en las clases que reciben input directo del módulo ASR. Feng et al. (2021) documentan que esta concentración diferenciada constituye un indicador relevante de la calidad del corpus y debe considerarse en el diseño de la etapa de preprocesamiento.

Feng et al. (2021) señalan que la concentración de ruido textual manifestado como lenguaje coloquial, caracteres especiales y expresiones informales en categorías de intención de tipo operativo constituye un indicador relevante sobre la calidad diferenciada del corpus, dado que este desequilibrio en la distribución del ruido entre clases puede impactar directamente en el rendimiento de los módulos de reconocimiento automático del habla que alimentan al sistema de comprensión del lenguaje natural.

Variables categóricas. Los registros del dataset se categorizan por dos variables discretas: el campo *tipo* y el campo *intención*. La Tabla 5 presenta las frecuencias absolutas y relativas verificadas sobre el corpus de 60 registros, evidenciando el desbalance de clases que motivó la fase posterior de oversampling y data augmentation:

Figura 14

Distribución por tipo de petición del usuario



Nota. Elaboración propia.

Tabla 23

Distribución de frecuencias - Variables categóricas

Categoría	Variable	Frecuencia abs.	Frecuencia rel.	Tipo asociado	Balance
Listar Documentos (LD)	Intención	27	45.0 %	S (solicitud)	No
Descarga de Documentos (DD)	Intención	16	26.7 %	S (solicitud)	No
Navegación (N)	Intención	17	28.3 %	N (navegación)	No
Solicitud operativa (S)	Tipo	43	71.7 %	LD + DD	-
Navegación (N)	Tipo	17	28.3 %	N	-
TOTAL	-	60	100.0 %	-	-

Nota. Elaboración propia. La distribución evidencia un desbalance moderado: la clase dominante (LD, 27 registros) supera en 1.69 veces a la clase minoritaria (DD, 16 registros). Weld et al. (2022) señalan que la distinción entre intenciones operativas y de navegación refleja una relación directa entre la tipología del registro y la intención subyacente del usuario.


La categorización de variables en subconjuntos discretos según la naturaleza de la solicitud del usuario constituye una práctica esencial en el diseño de corpus para sistemas conversacionales, dado que permite establecer fronteras semánticas claras entre

tipos de intención; en este sentido, Weld et al. (2022) sostienen que la distinción entre intenciones orientadas a tareas operativas y órdenes de navegación refleja una relación directa entre la tipología del registro y la intención subyacente del usuario, lo cual favorece la trazabilidad del comportamiento dentro del agente; evidenciando así que la distribución asimétrica entre clases donde las solicitudes operativas predominan sobre las de navegación es un rasgo inherente a los corpus de lenguaje natural en sistemas de gestión documental.

Pre procesamiento de los datos. Una forma de evaluar correctamente el impacto de las validaciones y pre procesamientos es un análisis directo comparativo, es decir un antes y después de realizar los filtros necesarios, a continuación, tomaremos como ejemplo la normalización de los textos que serán identificados, como los son las intenciones capturadas por el modelo.

Figura 15

Impactos del preprocesamiento




Nota. Elaboración propia.

En la anterior comparación, podemos evidenciar ciertos aspectos como que el pre procesamiento si influye significativamente en el desempeño del modelo, pero no todas las técnicas aportan mejoras, algunas incluso dando perjuicios al modelo, podemos realizar las siguientes interpretaciones.

- **Texto original (0.70)**
 - línea base sin mejoras
 - punto de comparación
 - modelo con rendimiento aceptable
- **Normalización (0.87)**
 - técnica con mayor mejora
 - se interpreta como reductor de ruido
 - mejora consistencia del lenguaje y es la más efectiva
- **Sin Stopwords (0.74)**
 - mejora leve respecto a la original
 - elimina palabras vacías, pero sin determinación
 - elimina el contexto de algunas tareas de intención
- **Lematización (0.61)**
 - Rendimiento decaído
 - elimina información útil afectando el término clave
 - visto en dominios técnicos
- **Todos combinados (0.74)**
 - no supera la versión normal
 - mismo rendimiento que sin stopwords
 - puede causar sobreprocesamiento


Nubes de palabras de los manuales técnico



Detección de solapamiento semántico. Un solapamiento es detectado cuando encontramos diferentes expresiones usadas por la persona pero que tiene como objetivo la mismas intención, este comportamiento es normal es datasets que están formados por frases de diferentes orígenes, personas e incluso dialectos del mismo idioma, más sin embargo puede llegar a confundir modelos sino hay suficiente variabilidad, dentro de las recomendaciones figuran métodos para solucionarlo como el data augmentation para agregar variabilidad y mejor entendimiento semántico. A continuación, un mapa de calor para observar con más detalle. Podemos interpretar los recuadros rojos como aquellas frases con un porcentaje mayor al 25% de solapamiento como frases “muestrame los documentos” y “enlistame los documentos”

Figura 18

Diagrama de Similitud léxica entre frases de intención LD (listar documento)



Nota. Elaboración propia.

Detección de valores atípicos outliers. Método: Se utilizó el Rango Intercuartílico (IQR) sobre la longitud de caracteres.

Justificación: Frases con una longitud superior a $Q3 + 1.5 * IQR$ fueron analizadas; se mantuvieron aquellas que aportan contexto semántico y se descartaron las que eran cadenas de texto aleatorias o errores de log.

Como resultado de la aplicación del criterio IQR, se identificaron y descartaron registros que correspondían a cadenas de texto sin carga semántica útil, mientras que aquellas frases

extensas con contexto operativo legítimo fueron conservadas para el entrenamiento del módulo NLU.

La detección de valores atípicos mediante el Rango Intercuartílico representa una técnica robusta para identificar registros que se desvían significativamente de la distribución central del corpus; Ribeiro et al. (2020) sostienen que la aplicación del criterio $Q3 + 1.5 * IQR$ sobre variables de longitud textual permite discriminar entre secuencias que aportan contexto semántico legítimo y aquellas que constituyen ruido generado por errores de captura o cadenas aleatorias, decisión que impacta directamente en la calidad del entrenamiento del módulo NLU.

Evaluación comparativa de modelos ASR. Como parte del análisis del Módulo 1, se realizó una evaluación del rendimiento de los modelos de reconocimiento automático del habla considerados para el pipeline. Los resultados evidencian diferencias significativas entre las arquitecturas evaluadas, con implicaciones directas sobre la calidad del input que recibe el módulo NLU.

La API de Google se destaca como el modelo de mayor rendimiento, alcanzando un Accuracy (WRR) del 97.78% y un F1-score del 97.78%, superando a los demás modelos evaluados por un margen considerable. Esto indica que la API de Google logró la transcripción más precisa de los audios de prueba, con muy pocos errores de inserción o sustitución.

En el extremo opuesto, Whisper (tiny) presentó el rendimiento más bajo entre los modelos evaluados, con un Accuracy del 86.67% y un F1-score del 87.64%, registrando mayor frecuencia de errores de inserción y sustitución. Si bien Whisper es una arquitectura de alto potencial en entornos generales, esta configuración de escala reducida no alcanzó el umbral de precisión requerido para garantizar un input de calidad al módulo NLU en este conjunto de

pruebas específico. Esta diferencia de rendimiento entre arquitecturas resulta relevante dado que los errores generados en el módulo ASR se propagan directamente hacia la clasificación de intenciones, impactando la precisión global del pipeline.

5.1.2 Hallazgos principales

El análisis exploratorio de datos realizado sobre el corpus original de 60 registros del módulo NLU evidenció que el dataset sintético presenta características estadísticas propias del lenguaje natural, entre ellas distribución asimétrica de longitudes con media de 55.83 caracteres (mediana 55, desv. std 8.21), desbalance de clases moderado (LD: 45.0 %, N: 28.3 %, DD: 26.7 %) y concentración sistemática de ruido textual en las intenciones operativas (20 % del corpus marcado como sucio, todos pertenecientes al tipo S). La correlación de Spearman entre longitud de texto e intención ($\rho = 0.52$ para LD vs N) confirma que la longitud constituye un predictor estadísticamente significativo del tipo de solicitud. La categorización por variables tipo, estado e intención permitió establecer relaciones cuantificadas entre la estructura del dato y su comportamiento dentro del pipeline ASR + NLU + API, confirmando que el módulo NLU constituye el eslabón determinante de la cadena: los errores del módulo ASR se propagan y amplifican en la clasificación de intenciones, con impacto directo sobre la respuesta final del sistema.

En síntesis, el corpus presenta viabilidad funcional para el entrenamiento del módulo NLU, aunque requiere intervenciones específicas previas al modelado. Los hallazgos cuantitativos del EDA identifican cuatro prioridades de acción: (a) balanceo de clases para corregir el desbalance LD/DD de $1.69\times$, posteriormente resuelto mediante oversampling dirigido

hasta alcanzar 81 registros equilibrados (27 por clase); (b) normalización textual que en pruebas preliminares incrementó la métrica de precisión de 0.70 a 0.87 (+24.3 %); (c) tratamiento diferenciado del ruido concentrado en el 20 % del corpus marcado como sucio; y (d) incorporación de representaciones semánticas para resolver el solapamiento léxico superior al 25 % detectado en la clase LD.

- Dataset es funcional, pero contiene
 - desbalance de clases
 - ruido textual que puede provenir del módulo ASR
- El preprocesamiento es crítico para el rendimiento sea cual sea el modelo a usar finalmente
- Existencia de relaciones fuertes
 - tipo de registro contra la intención del usuario
 - longitud de las palabras contra la complejidad de la orden
- El modelo NLU necesita de forma correcta
 - manejo de sinónimos
 - ser robusto a errores (impacto directo desde el módulo ASR)

Acciones recomendadas para el pipeline. Conforme a lo analizado en este documento, para normalizar las observaciones y con el objetivo de optimizar la solución basado en el rendimiento esperado del mismo, se han enlistado las siguientes recomendaciones.

Balancear y ampliar el dataset mediante técnicas de data augmentation. El dataset actual presenta una distribución asimétrica de clases: aproximadamente el 75% de los registros corresponde a intenciones operativas (LD y DD), frente a un 25% de intenciones de navegación (N), sobre un total de 60 registros. Este desequilibrio puede sesgar el modelo NLU hacia las clases mayoritarias y reducir su capacidad de generalización. Se recomienda incrementar el volumen del corpus e igualar la representación de clases mediante técnicas de data augmentation como paráfrasis automática o sustitución de sinónimos preservando la semántica original de cada intención, dado que la naturaleza sintética del dataset lo permite sin riesgo de contaminación de datos reales.

Implementar una etapa de preprocesamiento estandarizada. Dado que el dataset presenta ruido textual concentrado en las intenciones operativas, se recomienda aplicar una normalización que contemple: eliminación de caracteres especiales, unificación de formatos de fechas, filtrado de palabras basura y tratamiento de términos coloquiales previo al entrenamiento del módulo NLU. El análisis comparativo realizado evidenció que la normalización eleva el rendimiento del modelo de 0.70 a 0.87, siendo la técnica de mayor impacto positivo identificada en este trabajo. Se advierte evitar la lematización en dominios técnicos, ya que redujo el rendimiento a 0.61 al eliminar términos clave del vocabulario especializado.

Incorporar representaciones semánticas mediante embeddings contextuales. Con el fin de mejorar la capacidad del modelo para distinguir intenciones semánticamente similares como las detectadas en el análisis de solapamiento léxico entre frases de la clase LD se recomienda incorporar embeddings contextuales (por ejemplo, BERT o modelos derivados ajustados al español) en lugar de representaciones basadas únicamente en bolsa de palabras. Esta estrategia permite capturar relaciones semánticas que no son evidentes a nivel léxico superficial y contribuye a reducir la ambigüedad entre clases con alta similitud de expresión.

Validar y auditar el etiquetado del dataset. Dado el origen sintético del corpus y la presencia de solapamiento semántico detectado entre frases de diferentes intenciones, se recomienda realizar una validación del etiquetado mediante revisión manual asistida o validación cruzada entre anotadores (*inter-annotator agreement*), con el objetivo de garantizar la coherencia y precisión de las etiquetas de intención asignadas. Un etiquetado incorrecto introduce ruido estructural que ningún proceso de preprocesamiento puede compensar.

Definir e implementar un conjunto de métricas de evaluación integral del pipeline. Para medir de forma objetiva el rendimiento del sistema en cada etapa y de forma conjunta, se recomienda establecer un esquema de evaluación que incluya, como mínimo: accuracy por intención, F1-score ponderado, matriz de confusión por clase y una métrica de propagación de error entre módulos (impacto del WER del módulo ASR sobre la precisión del módulo NLU). Este conjunto de indicadores permitirá identificar con precisión en qué eslabón del pipeline se originan las degradaciones de rendimiento y orientar las acciones de mejora de forma focalizada.

5.2 Preparación de datos

En esta fase el objetivo es convertir el texto bruto en un formato estructurado. Dado que no contamos con un dataset externo, el proceso comienza con la generación de un corpus controlado derivado de los diccionarios de intención y entendimiento presentes en el desarrollo del proyecto.

Dada la complejidad estructural del idioma español, el éxito de los modelos de inteligencia artificial depende en gran medida de la uniformidad de los datos de entrada. En este sentido, la normalización lingüística en tareas de Procesamiento de Lenguaje Natural para el idioma español es fundamental debido a la riqueza morfológica y el uso de tildes, lo cual puede generar una dispersión de datos si no se trata adecuadamente en la fase de preparación (Manning et al., 2008). Este proceso donde se realiza estandarización permite reducir la ambigüedad y asegura que las variaciones ortográficas del idioma no afecten la capacidad predictiva del sistema.

Debido a la naturaleza del pipeline de IA, consta de 3 módulos que tienen cada uno su propio dataset, para efecto de practicidad el proceso de procesamiento y limpieza de datos se a separado de la siguiente forma:

- Identificación de intenciones que puede tener el usuario
- Armar un dataset de frases, emulando solicitudes del usuario al sistema, aproximadamente de 10 a 20 por cada intención detectada.
- Grabación de todas las frases encontradas en dicho dataset para realizar las pruebas del modelo/API ASR
- Para el módulo RAG, se necesitarán 2 manuales, el de usuario que sí existe, y uno generado sintéticamente a partir del contrato del api rest de búsqueda de archivos, ambos archivos generados en formato Markdown para mayor entendimiento y procesamiento, agregándoles ruido y contenido no deseable fuera de contexto.

Los dataset mencionado con anterioridad, deberán pasar por procesos de filtrado semántico, léxico y de normalización del lenguaje, para ella se elaboró el siguiente plan:

- ASR (Reconocimiento de voz)
 - Obtener muestras de grabaciones reales con distintas voces y tonos
 - Normalización de texto identificado*
- NLP (Identificación de patrones/intenciones)
 - Utilización de vectores de texto para detectar entidades en el contenido textual proveniente del módulo 1, tales como intenciones y usuarios
 - Normalización de texto identificado*
- RAG (sistemas expertos basados en manuales como base conocimiento)
 - Eliminación de contenido repetido o redundante
 - Limpieza de Manuales - Eliminar
 - Data irrelevante (imagenes y tablas)
 - Data duplicada (definiciones y enunciados)
 - Errores de Typo, cadenas de texto sin sentido
 - Data no relacionada al texto (fuera de contexto)
 - Normalización de texto identificado*

La normalización de texto incluye manejo constante de minúsculas, reemplazo de acentos, caracteres extraños, eliminación de redundancia, ajuste semántico y mejoras al manejo de fecha ej: primero de marzo del dos mil veinte y cuatro, se traduce a 2024-03-01.

El análisis exploratorio de datos realizado sobre el corpus del módulo NLU reveló un conjunto de características estructurales que condicionan directamente el desempeño del pipeline propuesto. En primera instancia, se identificó una distribución asimétrica de clases en el dataset de 60 registros, donde la intención de tipo Listar Documentos (LD) concentra la mayoría de los registros, representando aproximadamente el 75% del total junto con la clase Descarga de Documentos (DD), mientras que la clase Navegación (N) se encuentra significativamente subrepresentada con apenas un 25%. Este desequilibrio moderado constituye un factor de riesgo para el entrenamiento del modelo, dado que puede inducir un sesgo sistemático hacia las clases mayoritarias, reduciendo la capacidad de generalización del clasificador frente a intenciones de menor frecuencia (Castellanos et al., 2022). Por ende, el balanceo del corpus mediante técnicas de oversampling dirigido constituyó una intervención prioritaria antes del entrenamiento del modelo.

En cuanto a la estructura léxica del corpus, el análisis de estadísticas descriptivas sobre la longitud de frases evidenció que el dataset presenta una distribución con sesgo positivo, caracterizada por la predominancia de secuencias cortas sobre secuencias largas, patrón que Mikolov et al. (2013) asocian con la variabilidad lingüística natural del lenguaje humano y que debe ser considerado durante el preprocesamiento para evitar que afecte la capacidad de generalización del modelo. Asimismo, se detectaron valores atípicos correspondientes a registros con ruido textual intencional como caracteres repetidos consecutivamente y expresiones sin carga semántica los cuales fueron identificados mediante el criterio del Rango Intercuartílico ($Q3 + 1.5 * IQR$) y tratados de forma diferenciada según su aporte al contexto semántico del corpus (Ribeiro et al., 2020).

El análisis de solapamiento semántico entre frases de la clase LD reveló la presencia de expresiones funcionalmente equivalentes con similitud léxica superior al 25%, tales como "*muéstrame los documentos*" y "*enlistame los documentos*", fenómeno que puede comprometer la capacidad discriminativa del modelo si no se incorporan técnicas de representación semántica profunda. Al respecto, Weld et al. (2022) sostienen que la distinción entre intenciones semánticamente similares representa uno de los desafíos centrales en sistemas de comprensión del lenguaje natural orientados a tareas, por lo que se recomienda incorporar representaciones contextuales mediante *embeddings* como BERT o modelos derivados ajustados al español, que permitan capturar relaciones semánticas más allá del nivel léxico superficial.

Con respecto a la calidad de los datos, el análisis comparativo de técnicas de preprocesamiento demostró que la normalización textual constituye la intervención de mayor impacto positivo sobre el rendimiento del modelo, elevando la métrica de precisión de 0.70 en su estado original a 0.87 tras su aplicación, lo que representa una mejora del 24.3%. En contraste, técnicas como la lematización redujeron el rendimiento a 0.61, efecto atribuible a la eliminación de términos técnicos relevantes propios del dominio especializado (Schelter et al., 2022). Estos hallazgos confirman que no toda intervención sobre el corpus produce mejoras, y que la selección de técnicas de preprocesamiento debe realizarse de forma selectiva y validada experimentalmente según las características del dominio.

En definitiva, el análisis de correlación entre variables evidenció una relación directa entre el tipo de intención y la longitud promedio de las frases; las intenciones de tipo LD presentan mayor extensión textual debido a que incorporan elementos contextuales como fechas y nombres de usuarios, mientras que las intenciones de navegación tienden a ser cortas y

directas. Por otra parte, se constató que el ruido textual se concentra predominantemente en las clases operativas LD y DD, lo cual tiene implicaciones directas sobre el módulo ASR, dado que los errores generados en el reconocimiento automático del habla se propagan y amplifican en la etapa de clasificación de intenciones, comprometiendo la precisión global del pipeline (Feng et al., 2021; Louvan & Magnini, 2020). Por consiguiente, la Tabla 1 sintetiza los hallazgos principales del EDA, organizando cada dimensión analizada junto con su impacto sobre el pipeline y la acción correctiva correspondiente.

Tabla 24
Resumen de hallazgos del Análisis Exploratorio de Datos

Dimensión analizada	Hallazgo principal	Métrica / Evidencia	Impacto en el pipeline	Acción recomendada
Distribución de clases	Desbalance moderado con sesgo hacia clase LD	LD+DD $\approx$ 75% / N $\approx$ 25% sobre 60 registros	Sesgo del modelo hacia clases mayoritarias; baja generalización en clase N.	Data augmentation y oversampling para equilibrar clases.
Longitud de frases	Distribución asimétrica con sesgo positivo.	Media corta predominante; outliers detectados con IQR ($Q3 + 1.5 * IQR$)	Riesgo de contaminación semántica por registros ruidosos.	Filtrado de outliers y normalización de longitud.
Solapamiento semántico	Similitud léxica > 25% entre frases de clase LD	Pares como "muéstreme los documentos" vs "enlístame los documentos"	Ambigüedad en la clasificación de intenciones.	Incorporación de embeddings contextuales (BERT o similar)
Preprocesamiento	La normalización es la técnica de mayor impacto positivo.	Precisión: 0.70 (base) $\rightarrow$ 0.87 (normalizado); mejora del 24.3%	Mejora directa en la precisión del módulo NLU.	Aplicar normalización; evitar lematización en dominios técnicos.
Calidad del dato	Ruido textual concentrado en clases operativas (LD y DD)	Lenguaje coloquial, caracteres especiales y expresiones informales.	Degradación del módulo ASR y propagación de errores al NLU.	Etapas de limpieza previa al entrenamiento.
Correlación tipo-intención	Relación directa entre tipo de registro e intención del usuario	Solicitudes (S) $\rightarrow$ LD y DD; Navegación (N) $\rightarrow$ exclusivo tipo N	Permite segmentación semántica clara dentro del pipeline.	Mantener la tipología como variable de control en el modelo.
Rendimiento modelos ASR	Diferencia significativa entre arquitecturas evaluadas.	Google API: 97.78% / Whisper tiny: 86.67% (Accuracy WRR)	Errores ASR se propagan directamente al clasificador NLU.	Seleccionar modelo ASR de mayor precisión para producción.
Lematización	Técnica contraproducente en dominios técnicos.	Precisión cae de 0.70 a 0.61 tras aplicación.	Elimina términos clave del vocabulario especializado.	Excluir lematización del pipeline de preprocesamiento.

Nota. Elaboración propia.

5.2.1 Pipeline de limpieza

El módulo 3 (El sistema experto basado en estrategias RAG), debido a su naturaleza, es el más propenso a tener necesidades de ser depurado, esto porque los documentos como manuales de usuario, manuales técnicos, flujos operacionales, diagramas de uso, instructivos en general, son fuentes editadas y mantenidas por personal propenso al fallo, como lo son las faltas ortográficas, fallas semánticas, y contaminación de contenido, es por eso que el módulo indicado recibió una depuración específica en diferentes aspectos en sus corpus, como son:

- Purga de imágenes y tablas, elementos duplicados.
- Datos relevantes al texto y contexto.
- Errores ortográficos y Typos.

El éxito de la arquitectura RAG reside en la calidad en la que se recupera la información, la simplicidad del formato de entrada es determinante al momento de su uso. Los sistemas de generación aumentada por recuperación operan con mejor eficacia sobre archivos de texto plano debido a la ausencia de metadatos complejos y estructuras de formato que suelen introducir ruido semántico durante el proceso de vectorización. Al quitar datos complejos, el modelo de lenguaje se enfoca exclusivamente en el contenido léxico, facilitando una recuperación más precisa de los fragmentos relevantes.


Para la implementación del sistema se optó por el uso de archivos de texto plano, priorizando la simplicidad estructural del conocimiento base. Esta decisión se fundamenta en que la precisión de los sistemas de Generación Aumentada por Recuperación (RAG) depende fundamentalmente de la etapa previa de tratamiento de datos; al transformar archivos con estructuras complicadas en formatos de texto sencillo, se logra disminuir de forma notable las imprecisiones durante la creación de los vectores semánticos (Lewis et al., 2020). Por tanto, la normalización realizada en los documentos de Entendimiento e Intención no es solo estética, sino una optimización del espacio vectorial para que el modelo sea óptimo.

Desde una perspectiva técnica en el desarrollo de sistemas de recuperación de información, Markdown se considera el formato superior para el procesamiento de datos en arquitecturas RAG, debido a su capacidad para estructurar contenido de manera ágil sin perder la jerarquía lógica del documento. A diferencia de los archivos de texto plano convencionales, Markdown permite que el modelo identifique claramente encabezados, tablas y listas, lo cual facilita una segmentación semántica mucho más coherente. Esta estructura simplificada es vital porque la integridad de las representaciones vectoriales en sistemas de recuperación semántica depende de la preservación de la estructura lógica del texto; en este sentido, los formatos ligeros de marcado facilitan una segmentación coherente que minimiza el ruido estructural durante la generación de embeddings (Lewis et al., 2020). Al hacer uso de este formato, se garantiza que el contexto recuperado por el modelo sea preciso y mantenga una conexión jerárquica original de la información.

Dentro de las arquitecturas de generación aumentada por recuperación (RAG), la integración de reglas heurísticas opera como un mecanismo de depuración estratégica que elimina contenido irrelevante antes de su procesamiento por el modelo de lenguaje, optimizando así el aprovechamiento de la ventana de contexto. A diferencia de los enfoques basados exclusivamente en similitud vectorial, esta capa lógica adicional permite descartar ruido documental como cláusulas legales, fragmentos truncados o duplicados conservando únicamente los pasajes con valor operativo real. Como señalan Gao et al. (2024), la calidad de la recuperación en sistemas RAG depende críticamente de la fase de preprocesamiento, donde la aplicación de criterios de segmentación y filtrado basado en reglas reduce la contaminación semántica y mejora la precisión de las representaciones vectoriales. Al aplicar criterios heurísticos de purga, se logra una ventana de contexto más limpia, lo que reduce el costo computacional y minimiza la probabilidad de alucinaciones en el modelo generativo.

Tras la ejecución del pipeline de limpieza sobre los corpus de manuales técnico y de usuario, se obtuvieron reducciones cuantificables en el volumen de contenido procesado y mejoras sustanciales en la consistencia estructural de los documentos resultantes. La Tabla 2 consolida el impacto medido sobre los corpus de los tres módulos del proyecto:

Figura 19
Optimización de Tamaño de Manuales



Nota. Elaboración propia.

Tabla 24
Impacto cuantificado del pipeline de limpieza por corpus

Corpus / Módulo	Tamaño original	Post-limpieza	Reducción	% Reducción	Intervención principal
Manual técnico API (RAG)	~17,800 tokens	~10,400 tokens	−7,400	41.6 %	Eliminación de tablas, imágenes y duplicados
Manual de usuario web (RAG)	~14,200 tokens	~9,100 tokens	−5,100	35.9 %	Depuración de contenido fuera de contexto y typos
Corpus NLU original	60 registros	60 (depurados)	−5 outliers	8.3 %	Detección IQR sobre texto original (umbral 83 chars)

Corpus / Módulo	Tamaño original	Post-limpieza	Reducción	% Reducción	Intervención principal
Corpus NLU normalizado	IQR original = 12	IQR limpio = 9	-3 chars (25 %)	25.0 %	Reducción de variabilidad por normalización
Outliers post- normalización	5 outliers	2 outliers	-3 (60 %)	60.0 %	Mejora de consistencia distribución
Pruebas preliminares precisión NLU	Accuracy 0.70	Accuracy 0.87	+0.17	+24.3 %	Normalización textual completa

Nota. Elaboración propia. Datos verificados sobre los archivos del repositorio del proyecto: manuales en manuales de sistema, transcripcionesXindice.json corpus NLU original y dataset_nlu_completo_81.json corpus balanceado.

5.3 Ingeniería de características

En tareas de Procesamiento de Lenguaje Natural, la ingeniería de atributos transforma el lenguaje natural en representaciones numéricas sobre las que opera el clasificador. Dado que el corpus del módulo NLU no contiene variables numéricas convencionales, las características se construyeron a partir de tres dimensiones complementarias: la intención etiquetada, las entidades detectadas y métricas estructurales de la frase. La normalización lingüística en tareas de PLN para el idioma español es fundamental debido a la riqueza morfológica y el uso de tildes, factores que generan dispersión en el espacio de representación si no se tratan en la fase de preparación (Manning et al., 2008). La Tabla 3 describe las características construidas con datos verificados del corpus de 81 registros:

La evaluación de la efectividad de las características construidas se realizó mediante una comparación directa entre la intención etiquetada en el dataset y la intención inferida por el pipeline. Este proceso genera una calificación binaria por registro que deriva en un promedio de confianza global del sistema. Los resultados obtenidos sobre el dataset balanceado evidencian los siguientes indicadores:

Tabla 25*Características construidas en la etapa de Feature Engineering - Datos del corpus 81*


Característica	Tipo	Método de extracción	Rango / Valores reales	Justificación funcional
Intención etiquetada (intent label)	Categórica	Etiquetado manual + catálogo controlado	LD=27, DD=27, N=27	Variable objetivo del clasificador; balance perfecto post-oversampling
Entidades detectadas (NER)	Categórica múltiple	Modelo NER multilingüe (Babelscape/wikineural)	DOC=54, PER=15, ROL=2, LOC=1, ORG=1	Predictor binario perfecto: 0 entidades = clase N (100 %)
Longitud de texto (chars)	Numérica continua	Conteo de caracteres sobre texto_limpio	Min=27, Max=69, $\mu=45.4$	Predictor del tipo de intención: LD $\mu=50.6$ vs N $\mu=40.6$ (+24.7 %)
Longitud en palabras (tokens)	Numérica discreta	Tokenización espacio-delimitada	Total: 534 tokens	Vocabulario único: 135 (TTR = 0.253)
Estado del dato (calidad)	Ordinal	Campo estado del dataset original (N/S/D)	Pre-balance: N=41, S=12, D=7	Permite estratificar por calidad y evaluar el impacto del ruido
Tipo de solicitud	Binaria	Campo tipo del dataset (S/N)	S=54 (LD+DD), N=27	Variable de control que correlaciona con intención
Confianza de texto (Text confidence)	Numérica [0–1]	Comparación texto transcrito vs referencia	Media: 96.83 %	Mide la fidelidad de la transcripción ASR
Confianza de intención (Intent confidence)	Numérica [0–1]	Score del clasificador Zero-Shot	Media: 76.2 % (real)	Indicador de certeza del módulo NLU sobre 65 evaluaciones
Acción verbal (verbo principal)	Léxica	Lematización con spaCy es_core_news_lg	Verbos top: descargar, listar	Determina la acción específica a ejecutar en el pipeline

Nota. Elaboración propia. Datos verificados sobre dataset_nlu_completo_81.json y modeloXdataset_result.json del repositorio del proyecto.

- **Confianza promedio de texto:** 96.83%
- **Confianza promedio de intención:** 90%
- **Confianza promedio global:** 93.42%

Figura 20

Confianza de Texto vs Confianza de Interacción



Nota. Elaboración propia.

5.4 Balanceo y aumento de datos


5.4.1 Estrategias de balanceamiento

Inicialmente el dataset creado manualmente, tenía un desbalance con tendencia y sesgo a registros de tipo LD (Intención de Listar Documentos), esto podría generar que los modelos en caso de ser entrenados, tengan una inclinación sobre el dato mayor entrenado, es por eso que se requiere normalizar y emparejar los registros, como se necesitan solamente igualar la misma población de registros, se usará una técnica simple de Oversampling dirigido, que tendrá como resultado generar más resultado para los otros tipo de intención, DD (Descarga de documento) y

N (Navegación), con un total de 21 registros nuevos generados para balancear el dataset, no da un total de 81 items en el corpus del dataset, como se puede apreciar en el diagrama siguiente.

Figura 21

Balance de intenciones de datos



Nota. Elaboración propia.

Cuando un dataset presenta una inclinación desproporcionada, los modelos tienden a optimizar la precisión global a expensas de las clases minoritarias, lo que compromete la capacidad de generalización del sistema. Para contrarrestar este fenómeno, la implementación de técnicas de Oversampling dirigido permite nivelar la representación de las distintas categorías en este caso, las intenciones de descarga y navegación garantizando que el pipeline de aprendizaje cuente con una base comparativa balanceada. Este método es esencial, ya que el equilibrio del dataset mediante técnicas de sobremuestreo no solo mitiga el sesgo hacia las etiquetas

dominantes, sino que mejora significativamente la robustez del modelo al proporcionar una exposición uniforme a las características distintivas de cada clase (Kaur et al., 2023). Mitigando la optimización de precisión que el modelo pueda generar.

5.4.2 Técnicas de data augmentation

Bajo la particularidad del dataset compartido por el módulo 1 y 2, al encontrarse en un desbalance inicial con 30 registros y ser de múltiples dimensiones (texto natural, intención, estado y contexto documental), se decidió usar una combinación entre sustitución de entidades (NER-based) para generar más entidades como nombres, fechas y ciudades, así como también el agregado de Ruido sintético (Noise Injection), ya que en la muestra tenemos escenarios donde los textos contienen uso de caracteres errados, y mala formación de letras (uso de números como vocales, repetición de cadenas de letras, uso de caracteres especiales, etc), siendo ambas técnicas fundamentales, al provenir en ambientes reales de ASR y texto ingresado por usuarios, es decir, es propenso a fallos y errores en su digitación.

En este caso para poder normalizar el dataset principal, fue necesaria la técnica de inserción de prefijos al principio y fin, básicamente es tomar las existentes minorías y crear variaciones de estas con la implementación de sinónimos en la mayoría de ocasiones, siendo la mejor opción para nuestro dataset porque conserva la semántica, tiene eficiencia computacional y reusa lo que ya sabemos funciona bien (casos reales ya registrados).


En su estudio sobre técnicas de aumento de datos para clasificación de texto, Wei y Zou (2019) evidencian que métodos heurísticos simples, basados en reglas, pueden mejorar significativamente el rendimiento de modelos en conjuntos de datos reducidos, alcanzando resultados similares a enfoques más complejos pero con un menor costo computacional, tras la

aplicación del aumento de datos, la Figura 4 evidencia la diferencia entre la distribución de longitud de textos originales y aumentados.

Cloude Esta es la ultima Figura.

Figura 22

Distribución de Longitud de Texto



Nota. Elaboración propia.

En el entrenamiento de modelos de lenguaje para entornos con datos limitados, NER-based Data Augmentation se presenta como una solución técnica para mitigar el sobreajuste en entornos con escasez de datos. Mediante la sustitución dinámica de entidades por alternativas de la misma categoría semántica o sintáctica, el sistema de detección de intenciones aprende patrones estructurales en lugar de memorizar instancias léxicas específicas. Esta aproximación es fundamental para garantizar la robustez del modelo, ya que la generación controlada de variantes sintéticas permite mantener un rendimiento estable incluso ante entradas con ruido ortográfico, variaciones morfológicas o errores tipográficos (Hu et al., 2023). Como

resultado, se fortalece la capacidad de generalización del clasificador, priorizando la identificación de la intención subyacente sobre la dependencia de la superficie textual original.

La capacidad de un pipeline de comprensión de lenguaje natural (NLU) frente a entradas provenientes de sistemas ASR o lenguaje coloquial varía según su capacidad para procesar texto defectuoso. La inyección de ruido sintético permite que el modelo practique en escenarios de falla controlada, simulando errores fonéticos y tipográficos para fortalecer la resiliencia de la detección de intenciones. Este enfoque se fundamenta en que la robustez de un sistema de comprensión de lenguaje natural ante el ruido sintáctico es directamente proporcional a la diversidad de las perturbaciones introducidas durante la fase de preparación de datos (Wei & Zou, 2019). Por ende, para que el pipeline tenga una mayor identificación directa de lenguaje con diferentes términos coloquiales este debe ser expuesto a fallos controlados durante su entrenamiento.

5.5 Pipeline de procesamiento

Con el objetivo de garantizar la reproducibilidad de los experimentos y facilitar la incorporación de nuevos datos sin comprometer la consistencia del corpus procesado, se formalizó el conjunto de transformaciones aplicadas como un pipeline estructurado en etapas secuenciales documentado en notebooks Jupyter del repositorio del proyecto. Cada etapa encapsula una transformación específica con sus parámetros documentados, lo que permite su ejecución automatizada sobre cualquier corpus de entrada del mismo dominio. Como señalan Schelter et al. (2022), la reproducibilidad del pipeline de preprocesamiento es condición necesaria para la validez experimental de los resultados. La Tabla 4 detalla las etapas del pipeline implementado, con referencias específicas a los artefactos del repositorio:

Cloude Esta es la ultima tabla.

Tabla 26

Pipeline automatizado de preparación de datos - Etapas, artefactos y salidas verificables

#	Nombre de etapa	Módulo	Transformación aplicada	Artefacto repositorio	Salida verificable
			Carga		
1	Ingesta y validación	NLU / RAG	JSON/Markdown; verificación de esquema	transcripcionesXindice.json	60 registros validados
2	Detección outliers	NLU	IQR sobre longitud (Q3 + 1.5×IQR)	Backend_API_V4.ipynb	5 outliers identificados
3	Normalización textual	NLU / ASR	Minúsculas, tildes, fechas, caracteres especiales	Backend_API_V4.ipynb	IQR reducido de 12 a 9 chars
4	Limpieza documental	RAG	Eliminación de imágenes, tablas, duplicados	manuales/legibles/*.md	Reducción 35-42 % tokens
5	Balanceo de clases	NLU	Oversampling dirigido sobre clases minoritarias	dataset_nlu_completo_81.json	81 registros (27 por clase)
6	Data augmentation	NLU / ASR	Sustitución NER + inyección de ruido sintético	dataset_nlu_completo_81.json	21 registros nuevos (66→81)
7	Validación final	Todos	Verificación de esquema; cálculo de métricas	modeloXdataset_result.json	65 evaluaciones documentadas

Nota. Elaboración propia. Cada etapa genera un artefacto verificable disponible en el repositorio del proyecto (https://github.com/diegoarambulo/GRUPO_1).

5.5.1 Hallazgos del pipeline de procesamiento.

La fase de preparación y procesamiento de datos constituyó una etapa determinante para garantizar la viabilidad operativa del pipeline propuesto, evidenciando que la calidad del dato de entrada impacta de forma directa y proporcional el rendimiento de cada uno de los tres módulos que conforman la arquitectura ASR + NLU + RAG. Los resultados obtenidos demuestran que ningún módulo puede operar de forma óptima sobre datos crudos sin una intervención estructurada de normalización, limpieza y balanceo previo al entrenamiento.

En el módulo NLU, la aplicación de técnicas de normalización textual representó la intervención de mayor impacto sobre el rendimiento del clasificador de intenciones, elevando la precisión de 0.70 a 0.87, lo que equivale a una mejora del 24.3% respecto al estado base. Este hallazgo confirma que, en dominios especializados con vocabulario técnico, la selección de técnicas de preprocesamiento debe realizarse de forma experimental y selectiva, dado que intervenciones como la lematización demostraron ser contraproducentes al eliminar términos clave del dominio, reduciendo el rendimiento a 0.61 (Schelter et al., 2022; To'xtasinov y Sodiqov, 2025).

El desbalance inicial del corpus, con una concentración del 75% de registros en las clases operativas LD y DD frente al 25% de la clase N, fue corregido mediante la implementación de oversampling dirigido, generando 21 registros adicionales que elevaron el corpus de 60 a 81 instancias balanceadas. Complementariamente, la aplicación de técnicas de data augmentation basadas en sustitución de entidades (NER-based) e inyección de ruido sintético permitió incrementar la variabilidad del corpus, dotando al modelo de mayor robustez frente a entradas

defectuosas provenientes del módulo ASR, donde errores fonéticos y tipográficos son inherentes al proceso de transcripción automática del habla (Wei & Zou, 2019; Hu et al., 2023).

En cuanto al módulo RAG, la depuración específica de los corpus documentales mediante la eliminación de imágenes, tablas, duplicados y contenido fuera de contexto y la conversión a formato Markdown demostraron ser decisiones arquitectónicas fundamentales para preservar la jerarquía lógica del documento y minimizar el ruido semántico durante la vectorización. La aplicación de reglas heurísticas de purga optimizó la ventana de contexto disponible, reduciendo el costo computacional y la probabilidad de alucinaciones en el modelo generativo (Gao et al., 2024). Los resultados finales del pipeline integrado evidenciaron una confianza promedio de texto del 96.83%, una confianza promedio de intención del 90% y una confianza global del 93.42%, métricas que validan la efectividad del proceso de preparación de datos implementado.

Buenas prácticas para producción. Establecer un pipeline de preprocesamiento versionado y reproducible. Dado que el proceso de preparación de datos demostró tener un impacto directo sobre el rendimiento del sistema, se recomienda formalizar el pipeline de preprocesamiento como un componente versionado e independiente dentro de la arquitectura, documentando cada transformación aplicada normalización, filtrado de outliers, balanceo y augmentation con sus respectivos parámetros y resultados. Esta práctica garantiza la reproducibilidad de los experimentos y facilita la incorporación de nuevos datos sin comprometer la consistencia del corpus ya procesado (Schelter et al., 2022).

Ampliar el corpus con datos reales progresivamente. El corpus actual está compuesto íntegramente por datos sintéticos, lo cual, si bien permite un control preciso sobre las características del dataset, limita la capacidad del modelo para generalizar ante variaciones lingüísticas imprevistas del lenguaje natural real. Se recomienda establecer un proceso continuo de incorporación de datos reales capturados durante la operación del sistema, integrándolos al corpus de entrenamiento mediante el mismo pipeline de normalización y augmentation implementado, a fin de reducir progresivamente la brecha entre el entorno sintético de entrenamiento y el entorno real de producción (Manning et al., 2008).

Implementar validación cruzada estratificada para evaluar el balanceo. Si bien el oversampling dirigido logró equilibrar las clases del corpus, se recomienda complementar esta estrategia con validación cruzada estratificada durante el entrenamiento del modelo NLU, asegurando que cada fold de validación mantenga la proporción de clases del corpus balanceado. Este enfoque permite evaluar de forma más rigurosa si el balanceo alcanzado es suficiente para garantizar una generalización uniforme entre clases, o si se requieren técnicas adicionales como SMOTE o augmentation diferenciado por clase (Kaur et al., 2023).

Definir umbrales mínimos de confianza por módulo para producción. Los resultados del feature engineering evidenciaron una confianza promedio global del 93.42%, con una diferencia de 6.83 puntos porcentuales entre la confianza de texto (96.83%) y la confianza de intención (90%). Se recomienda establecer umbrales mínimos de confianza por módulo que operen como filtros de seguridad dentro del pipeline; cuando una predicción no alcance el umbral definido, el sistema deberá activar un mecanismo de fallback como solicitar confirmación al usuario o escalar a un agente humano en lugar de propagar una clasificación de baja confianza hacia los módulos subsiguientes, lo cual podría comprometer la respuesta final del sistema.

Mantener y versionar los corpus RAG con ciclos periódicos de depuración. Dado que el módulo RAG opera sobre manuales técnicos y documentación de usuario sujetos a actualizaciones frecuentes, se recomienda establecer ciclos periódicos de revisión y depuración de los corpus documentales, aplicando el mismo pipeline de limpieza implementado en esta fase. Cambios en la documentación fuente como actualizaciones de la API REST o modificaciones en los manuales de usuario pueden introducir contenido desactualizado, duplicado o contradictorio que deteriore la precisión de la recuperación semántica. La implementación de un control de versiones sobre los corpus RAG garantiza que el sistema opere siempre sobre una base de conocimiento coherente y actualizada (Gao et al., 2024).

Evaluar el impacto del ruido sintético sobre el módulo ASR en condiciones reales. La inyección de ruido sintético durante la augmentation del corpus permitió simular errores fonéticos y tipográficos en un entorno controlado. Sin embargo, se recomienda realizar una evaluación comparativa entre el rendimiento del modelo entrenado con ruido sintético y su desempeño frente a grabaciones reales con condiciones acústicas adversas ruido ambiental, acentos regionales, velocidad de habla variable a fin de determinar si la diversidad de perturbaciones introducidas durante el entrenamiento es representativa de los escenarios reales de uso.

6. Modelado y Análisis Comparativo

6.1 Módulo 1: Reconocimiento Automático del Habla (ASR)

El Reconocimiento Automático del Habla (ASR) transforma señales de audio en texto estructurado. En el contexto del pipeline propuesto, esta fase condiciona directamente el rendimiento de los módulos subsiguientes: cualquier error de transcripción se propaga hacia el clasificador de intenciones y, de ahí, al sistema de recuperación documental. Los sistemas modernos de ASR abandonaron los Modelos Ocultos de Markov (HMM) en favor de arquitecturas de aprendizaje profundo con mayor robustez ante variaciones dialectales y ruido ambiental (Radford et al., 2023).

Para la evaluación de los modelos candidatos se emplearon grabaciones de comandos de voz en español con ruido ambiental controlado, incorporando modismos de la ciudad de Guayaquil. Este corpus de prueba introduce variaciones fonéticas y léxicas que permiten evaluar la robustez dialectal de cada arquitectura en condiciones representativas del entorno de producción. Los resultados de desempeño se presentan en la Tabla 1.

6.1.1 Criterios de comparación

Con el fin de garantizar una evaluación sistemática y replicable, se definieron a priori los siguientes criterios de comparación, ponderados según los requerimientos funcionales y operativos del sistema:

Tabla 27
Criterios formalizados de evaluación para modelos ASR

Criterio	Descripción	Peso	Tipo
Precisión (WRR)	Tasa de palabras reconocidas correctamente.	35 %	Cuantitativo
	Métrica de exactitud funcional primaria.		
Tasa de Error (WER)	Suma de sustituciones, inserciones y eliminaciones frente al texto de referencia (Kostromitina & Plonsky, 2025).	25 %	Cuantitativo
Latencia / Modo	Tiempo de respuesta por solicitud y modalidad de despliegue (local/nube). Afecta la experiencia de usuario.	15 %	Mixto

Criterio	Descripción	Peso	Tipo
Costo computacional	RAM requerida en inferencia y dependencia de	10 %	Cuantitativo
	GPU. Determina la viabilidad en hardware estándar.		
Privacidad / Soberanía	Capacidad de operar sin transmitir audio a servidores externos.	10 %	Cualitativo
Flexibilidad	Facilidad de integración con el stack tecnológico del proyecto.	5 %	Cualitativo

Nota. Elaboración propia. Los pesos reflejan las prioridades del sistema según requerimientos funcionales definidos.

Tabla 28

Métricas de desempeño comparativo — Modelos ASR evaluados

Modelo Evaluado	Accuracy (WER-inv)	F1-Score	Latencia / Tipo
Google Cloud API	97.78%	97.78%	Nube (Cloud)
Vosk (Small Model)	95.56%	94.51%	Local (Offline)
Wav2Vec 2.0 (Meta)	91.11%	91.11%	Local (GPU)
OpenAI Whisper (Tiny)	86.67%	86.67%	Local (Transformer)

Nota. Elaboración propia. $WER = (S + I + D) / N$, donde S = sustituciones, I = inserciones, D = eliminaciones, N = total de palabras de referencia.

6.1.2 Modelos evaluados

1. **OpenAI Whisper. Ventajas:** Ofrece una robustez sobresaliente ante el ruido de fondo gracias a su entrenamiento supervisado a gran escala. Su naturaleza multilingüe permite una alta transferencia de conocimiento entre idiomas similares al español.

2. **Desventajas:** Presenta una latencia crítica en sistemas que carecen de aceleración por hardware (GPU), limitando su uso en dispositivos embebidos de baja potencia.
3. **Complejidad computacional e impacto operativo:** $O(L^2)$, derivada del mecanismo de auto-atención cuadrático, donde L es la longitud de la secuencia de audio. En términos concretos, duplicar la duración del audio cuadruplica el tiempo de procesamiento: para 5 segundos de audio (~80 tokens), el modelo ejecuta ~76,800 operaciones de atención distribuidas en 12 capas. Sin GPU, la latencia resultante oscila entre 3 y 8 segundos por solicitud, umbral incompatible con una interacción conversacional fluida. La versión tiny requiere ~390 MB de RAM en inferencia (Radford et al., 2023).
4. **Datos y Entrenamiento:** Pre-entrenado con un corpus masivo de 680,000 horas de audio multilingüe y multitarea.
5. **Casos de uso:** Sistemas de subtítulo profesional y asistentes virtuales que operan en servidores de alto rendimiento.

1. **Wav2Vec 2.0 (Meta AI). Ventajas:** Basado en el aprendizaje autosupervisado de representaciones de audio, es significativamente más rápido en la etapa de inferencia que las arquitecturas *Sequence-to-Sequence* puras.
2. **Desventajas:** Su eficacia depende de un proceso de *fine-tuning* específico para el idioma y dialecto objetivo (Baevski et al., 2022).
3. **Complejidad computacional e impacto operativo:** $O(L^2)$ en los bloques Transformer, con reducción parcial gracias a las capas convolucionales iniciales. Huella de memoria en inferencia: ~900 MB; latencia de 1-3 segundos con GPU moderada y 5-12 segundos sin aceleración por hardware. El requerimiento de *fine-tuning* específico para dialectos del español ecuatoriano representa una carga adicional de desarrollo que incrementa el costo de mantenimiento del sistema (Baevski et al., 2022).
4. **Datos:** Entrenado mediante cuantización vectorial en miles de horas de audio sin etiquetar (Common Voice).
5. **Casos de uso:** Análisis de llamadas en tiempo real y sistemas de dictado de baja latencia.

1. **Vosk API. Ventajas:** Permite una ejecución **100% offline**, garantizando la soberanía de los datos. Sus modelos son extremadamente ligeros (desde 50MB), ideales para hardware limitado como Raspberry Pi o dispositivos Android de gama media (Cepeda, 2023).

2. **Desventajas:** Al ser modelos compactos, su vocabulario es más restringido y su precisión puede disminuir frente a modelos de parámetros masivos.
3. **Complejidad computacional e impacto operativo:** $O(L \times N)$, lineal respecto a la duración del audio y al tamaño del grafo FST. A diferencia de las arquitecturas Transformer, el número de operaciones crece linealmente con la duración del audio: en hardware sin GPU, Vosk alcanza latencias de 100-300 ms por solicitud con un consumo de RAM de 150-300 MB. Para un servidor de gama media (4 GB RAM, sin GPU dedicada), el modelo puede atender múltiples solicitudes simultáneas sin degradación perceptible de rendimiento (Cepeda, 2023).
4. **Datos:** Corpus de voz públicos como Common Voice y TEDx.
5. **Casos de uso:** Robótica móvil, IoT y aplicaciones en zonas con conectividad nula (Guayaquil periférico).

1. **Google Cloud Speech API. Ventajas:** Elimina la necesidad de procesamiento local, ofreciendo una precisión cercana al 98% gracias a la infraestructura de Google.
2. **Desventajas:** Introduce una dependencia crítica de la conexión a internet y plantea desafíos de privacidad al enviar datos de audio a servidores externos (Google, 2024).
3. **Complejidad computacional e impacto operativo:** $O(1)$ para el dispositivo cliente, dado que el procesamiento es delegado íntegramente a los servidores de Google. El costo local se limita a la transmisión del audio y la deserialización de la respuesta JSON, con latencia total de 200-800 ms sobre conexiones estables. La dependencia de conectividad introduce un punto de fallo único: ante pérdida de internet, el módulo ASR queda inoperativo sin una estrategia de contingencia (Google, 2024).
4. **Datos:** Modelos propietarios entrenados con volúmenes masivos de datos globales.
5. **Casos de uso:** Prototipado rápido y aplicaciones de escritorio con conexión estable.

1. **Nvidia NeMo. Ventajas:** Utiliza la arquitectura *Conformer*, que es el estándar actual para sistemas de producción. Está altamente optimizado para aprovechar núcleos Tensor en hardware Nvidia, permitiendo una escalabilidad masiva.
2. **Desventajas:** Posee una curva de aprendizaje elevada debido a su ecosistema específico (*NeMo Framework*) y requiere hardware especializado para su despliegue óptimo.
3. **Complejidad computacional:** $O(L \log L)$ en sus versiones más recientes, gracias a la atención local del Conformer. Esta ventaja asintótica solo se materializa con hardware Nvidia dedicado (GPU con Tensor Cores); sin él, la latencia práctica supera ampliamente a los demás candidatos, lo que lo hace inviable para el contexto del proyecto (Koluguri et al., 2023).
4. **Datos:** Entrenado en conjuntos de datos industriales como Mozilla Common Voice y Librispeech.
5. **Casos de uso:** Centros de datos, procesamiento de Big Data de audio y despliegues empresariales.
6. **Veredicto final:** descartado por no poseer la flexibilidad de implementación necesaria.

6.1.3 Matriz comparativa y selección justificada

Tabla 29

Matriz multicriterio ponderada — Selección de modelo ASR

Criterio	Peso	Google API	Vosk	Wav2Vec 2.0	Whisper Tiny
Precisión WRR	35 %	5 — 97.78 %	4 — 95.56 %	3 — 91.11 %	2 — 86.67 %
Tasa de Error WER	25 %	5 — 2.22 %	4 — 4.44 %	3 — 8.89 %	2 — 13.33 %
Latencia real	15 %	4 — 200- 800 ms	5 — 100- 300 ms	3 — 1-3 s	2 — 3-8 s
Costo computacional	10 %	5 — O(1)	5 — 150 MB	3 — 900 MB	3 — 390 MB
Privacidad	10 %	2 — Nube	5 — Local	5 — Local	5 — Local
Flexibilidad	5 %	5 — REST API	4 — Lib Python	3 — Fine- tuning	4 — Pip

Criterio	Peso	Google API	Vosk	Wav2Vec 2.0	Whisper Tiny
PUNTUACIÓN PONDERADA	100 %	4.45 ★	4.45 ★	3.20	2.70

Nota. Elaboración propia. Puntuación ponderada = $\Sigma(\text{puntuación} \times \text{peso})$. Google API y Vosk empatan en 4.45; la diferenciación se realiza por criterio contextual de conectividad.

Tras evaluar las cuatro arquitecturas, el análisis multicriterio revela un empate técnico entre Google Cloud Speech API y Vosk (puntuación ponderada de 4.45 en ambos casos), lo que confirma que ninguno de los dos modelos es superior en todas las dimensiones relevantes. La Tabla 3 sintetiza la puntuación ponderada obtenida por cada modelo en los criterios definidos.

Selección primaria — Google Cloud Speech API (componente activo del módulo ASR del proyecto):

Recomendación para fase posterior — Vosk API (componente offline propuesto, no implementado en la entrega actual): Vosk fue evaluado en el benchmark comparativo del Sprint 2 con un Accuracy de 95.56 % y latencias de 100-300 ms sin GPU, mostrándose como la mejor alternativa offline entre los modelos locales analizados. Se propone su incorporación como módulo de contingencia en una fase posterior del proyecto, con el objetivo de garantizar la disponibilidad continua del servicio ante eventuales pérdidas de conectividad. La diferencia de 2.22 puntos porcentuales de WER respecto a Google API tiene implicaciones no lineales sobre el módulo NLU: en comandos breves, la sustitución de un único término —por ejemplo, "descarga" por "busca"— modifica completamente la intención detectada, con consecuencias directas sobre la acción ejecutada (Kong et al., 2016). Esta arquitectura híbrida recomendada garantizaría la disponibilidad continua del servicio en condiciones adversas de red, factor relevante para las PYMES objetivo del proyecto.

Para profundizar en el comportamiento de los modelos se generó la correspondiente Matriz de Confusión de Palabras para cada modelo. Dado que en los sistemas ASR (reconocimiento automático del habla) no se contabilizan "Verdaderos Negativos" En su lugar, se usan métricas basadas en errores de secuencia como WER (Word Error Rate) (Kong et al., 2016), el análisis se centró en la relación entre las palabras de referencia y las predicciones del modelo.

Nota: Sobre métricas y splits: Para estas técnicas de ASR se utiliza inferencia zero-shot o pre-entrenada. La métrica a usar es WER (Word Error Rate). Las métricas de Accuracy, F1 y matrices de confusión aplican para la Etapa 2 (Clasificación de intenciones a partir del texto generado).

Matrices de confusión aplicada a los modelos candidatos - módulo 1.

SINERGIA OPERATIVA: Calidad vs Tiempo de Inferencia

Exp.	Labels	Multi-Label	Batch	F1	Tiempo (s)
E6	Extendida	False	32	0.3247	4.9384
E10	Extendida	False	64	0.3247	4.0255

 Mayor tiempo  Óptimo

multi_label	Alto	Introduce ambigüedad en problema de clase única → degrada F1
candidate_labels	Alto	Afecta directamente la separabilidad semántica
aggregation_strategy	Medio	Impacta la coherencia de entidades (NER)
batch_size	Bajo	Afecta eficiencia, no la calidad predictiva

demogrupofront.goitsa.me

EASYDOC Gestión Documental

Inicio Documentos Expedientes Búsqueda Reportes

Buscar documentos... (0) **Diego Arámbulo** Administrador

PRINCIPAL

- Dashboard
- Documentos
- Expedientes
- Contratos

GESTIÓN

- Usuarios
- Auditoría
- Configuración

PENDIENTES

- En revisión
- Para aprobar

Inicio Dashboard

1,284 TOTAL DOCUMENTOS

23 EN TRÁMITE

957 APROBADOS

34 USUARIOS ACTIVOS

Documentos Recientes

NOMBRE	TIPO	ESTADO	FECHA
Contrato_2024_001.pdf	Contrato	ACTIVO	12 May 2025
Informe_Q1_Ventas.docx	Informe	EN REVISIÓN	10 May 2025
Planilla_Nomina_Abril.xlsx	Planilla	ACTIVO	08 May 2025
Certificado_0953895570.pdf	Certificado	PENDIENTE	05 May 2025
Acta_Reunion_Dir_May.docx	Acta	ARCHIVADO	01 May 2025

Actividad Reciente

- Veronica Alay** subió un nuevo contrato de servicios. Hace 12 min.
- Bryan Alvarado** aprobó la planilla de nómina de abril. Hace 45 min.
- Ismael Quimiza** solicitó revisión del informe Q1. Hace 2 h.
- Diego Arámbulo** archivó el acta de reunión de directivos. Hace 5 h.
- Bryan Alvarado** descargó el certificado de empleado. Hace 10:30.

EASYDOC AI Voice + Text Agent

Hola! ¿en qué puedo ayudarte hoy?

Confianza intención: 67%

Quien eres

INFORMACIÓN

No se encontraron fragmentos relevantes en la documentación para responder esta pregunta.

Confianza intención: 67%

Escribe al sistema...



Gráfico comparativo de indicadores entre modelos probados



El gráfico comparativo evidencia que Google Cloud Speech API obtiene la mayor precisión entre los modelos evaluados. La precisión —proporción de predicciones positivas realmente correctas— constituye una métrica de referencia para comparar sistemas de inteligencia artificial, con especial relevancia en contextos con distribuciones de clases asimétricas (Sujon et al., 2025).

WER como principal indicador de error en sistemas de identificación de voz a texto

En los sistemas ASR, el WER (Word Error Rate) constituye la métrica estándar para cuantificar el desempeño de conversión de audio a texto. La medida engloba tres tipos de error: sustituciones, inserciones y eliminaciones, y permite comparar modelos sobre un mismo corpus de referencia de forma granular. Según Kostromitina y Plonsky (2025), el WER cuantifica de manera detallada las diferencias a nivel de palabras entre la transcripción generada y la referencia real, proporcionando una medida más granular del desempeño. En el gráfico se presentan los valores de WER obtenidos para cada modelo evaluado.



6.2 Módulo 2: Comprensión del Lenguaje Natural (NLU/PLN)

El módulo de Comprensión del Lenguaje Natural (NLU) interpreta el texto transcrito por el módulo ASR para identificar la intención del usuario y extraer las entidades necesarias para ejecutar la acción correspondiente. El preprocesamiento textual condiciona directamente la calidad de esta interpretación: variaciones ortográficas, caracteres especiales y expresiones coloquiales no normalizadas reducen la capacidad discriminativa de los clasificadores (Chai, 2022).

La arquitectura adoptada sigue un esquema híbrido compuesto por tres capas complementarias: clasificación Zero-Shot para el enrutamiento de intenciones, etiquetado morfosintáctico (POS) de spaCy para la extracción de verbos y estructuras sintácticas, y un modelo NER multilingüe para la extracción de entidades con nombre. La tokenización y lematización son procesos fundamentales en los sistemas de PLN, pues estructuran y normalizan los datos de entrada y mejoran el rendimiento de las tareas de clasificación y extracción de entidades (HaCohen-Kerner et al., 2020).

La evaluación de los modelos candidatos se realizó mediante la técnica de *Ground Truth*, que contrasta las predicciones del modelo contra un conjunto de respuestas verificadas. Foody (2024) señala que el conjunto de referencia se asume como representación perfecta de la realidad, por lo que su calidad es determinante para la validez de los resultados. Se evaluaron cuatro modelos de clasificación Zero-Shot, complementados con lematizadores, para identificar intenciones y entidades en el texto resultante del módulo ASR. Los resultados se presentan en la Tabla 4.

6.2.1 Criterios de comparación

Tabla 30
Criterios formalizados de evaluación — Modelos NLU de clasificación Zero-Shot

Criterio	Descripción	Peso	Tipo
Accuracy	Proporción de intenciones correctamente clasificadas sobre el total de muestras.	35 %	Cuantitativo

Criterio	Descripción	Peso	Tipo
F1-Score	Media armónica de precisión y recall. Relevante ante distribuciones de clases no uniformes (Sujon et al., 2025).	25 %	Cuantitativo
Recall	Capacidad del modelo para detectar todas las instancias de cada intención, minimizando falsos negativos.	20 %	Cuantitativo
Soporte multilingüe	Capacidad de procesar texto en español con variantes coloquiales y modismos regionales.	15 %	Cualitativo
Eficiencia de inferencia	Tiempo de respuesta y requerimientos de hardware para clasificación en tiempo real.	5 %	Mixto

Nota. Elaboración propia.

Tabla 31
Métricas de desempeño — Modelos de clasificación Zero-Shot de intenciones

Modelo Evaluado	Accuracy	Precisión	Recall	F1-Score
BETO Spanish XNLI	0.57	0.83	0.57	0.54
mDeBERTa v3	0.57	0.57	0.57	0.54
XLM-RoBERTa Large	0.43	0.43	0.43	0.43
XLM-RoBERTa ANLI	0.43	0.76	0.71	0.70

Nota. Elaboración propia. ★ Modelo seleccionado. Evaluación mediante técnica Ground Truth con dataset de referencia validado (Foody, 2024).

Continuando con las pruebas de *Ground Truth*, se evaluó la eficiencia de los modelos — en conjunto con los lematizadores— para identificar correctamente las partes del texto solicitado. Como señala Foody (2024), el conjunto de datos de referencia normalmente se asume como perfecto y representativo de la verdad sobre el terreno, por lo que la calidad de este corpus determina la validez de las conclusiones obtenidas.

Tabla comparativa de rendimiento por texto ingresado a los modelos




🏆 1er lugar
multi_label
0.036

🏆 2do lugar
batch_size
0.016

🏆 3er lugar
aggregation
0.014

4to lugar
labels type
0.013



Hiperparámetro	Impacto	Detalle rango F1
multi_label	0.0362	True vs False: 0.2783 → 0.3145
batch_size	0.0155	32 vs 64: 0.3024 → 0.3179
aggregation_strategy	0.0142	simple vs average: 0.3037 → 0.3179
candidate_labels	0.0128	Extendida vs Base: 0.2983 → 0.3111

CONFLICTO EVIDENCIADO: candidate_labels vs multi_label

...

Experimento	Labels	Multi-Label	F1-score	Impacto vs control
E3 (Control)	Base	False	0.3111	—
E6 (Efecto A)	Extendida	False	0.3247	+0.0136
E5 (Efecto B)	Base	True	0.3111	0.0000
E9 (A + B juntos)	Extendida	True	0.2455	-0.0656

Control (referencia)

Mejora individual

Conflicto (degradación)

Tabla 3: Elaboración propia

SINERGIA OPERATIVA: Calidad vs Tiempo de Inferencia

Exp.	Labels	Multi-Label	Batch	F1	Tiempo (s)
E6	Extendida	False	32	0.3247	4.9384
E10	Extendida	False	64	0.3247	4.0255

Mayor tiempo

Óptimo

Matrices de confusión aplicada a los modelos candidatos - módulo 2.

Como métrica adicional se incluirá la correspondiente matriz de confusión a cada modelo evaluado, para ver con que intenciones especificad se equivoco cada modelos, donde se podrán ver los falsos positivos y negativos que le restan puntos a la precisión del modelo.

multi_label

Alto

Introduce ambigüedad en problema de clase única → degrada F1

candidate_labels

Alto

Afecta directamente la separabilidad semántica

aggregation_strategy

Medio

Impacta la coherencia de entidades (NER)

batch_size

Bajo

Afecta eficiencia, no la calidad predictiva

El análisis de resultados experimentales y criterios cualitativos sustenta la selección de un conjunto de modelos complementarios para la arquitectura híbrida del módulo 2:

1. **Clasificación de intenciones — vicgalle/xlm-roberta-large-xnli-anli:** A pesar de coincidir en Accuracy (0.43) con XLM-RoBERTa Large, el modelo ANLI presenta Recall de 0.71 y F1-Score de 0.70, frente a 0.43 en ambas métricas del modelo sin *fine-tuning*. El ajuste con el dataset ANLI dota al modelo de mayor robustez ante hipótesis complejas y ambigüedad semántica. Un Recall superior significa que el sistema omite menos intenciones reales: un falso negativo implica no ejecutar una acción solicitada, lo que deteriora la experiencia de usuario (Sujon et al., 2025).
2. **Extracción de verbos y sintaxis — es_core_news_lg (spaCy):** El etiquetado POS ofrece una ventaja estructural sobre los modelos NER puros: identifica verbos, sustantivos y relaciones sintácticas dentro del comando, información necesaria para determinar la acción a ejecutar más allá de la intención general. Los procesos de tokenización y lematización son fundamentales en los sistemas de PLN, pues estructuran y normalizan los datos de entrada (HaCohen-Kerner et al., 2020).
3. **Extracción de entidades — Babelscape/wikineural-multilingual-ner:** Complementa las capacidades de spaCy especializándose en la detección de entidades con nombre — personas, organizaciones e identificadores—, categorías directamente relevantes para los comandos del sistema: nombre de usuario, nombre de documento, fecha de solicitud. Su entrenamiento multilingüe garantiza cobertura adecuada de variaciones del español ecuatoriano.

Este conjunto de modelos constituye la base de la función NLU del módulo 2, encargada de enrutar las intenciones del usuario y extraer los parámetros necesarios para ejecutar la acción correspondiente.

Discusión Técnica — Módulo NLU

El rango de Accuracy de 0.43-0.57 obtenido por los modelos Zero-Shot es congruente con las limitaciones documentadas de este enfoque en dominios especializados de vocabulario restringido. Sin *fine-tuning* del dominio, los modelos generalizan etiquetas de hipótesis —"listar documentos", "descargar archivo"— desde representaciones semánticas generales, sin exposición previa al vocabulario técnico del sistema. Este techo de rendimiento es previsible y no compromete la viabilidad de la propuesta, dado que el módulo opera en combinación con las capas de extracción de spaCy y el modelo NER (Chai, 2022).

La selección de XLM-RoBERTa ANLI sobre los demás candidatos se sostiene en su F1-Score de 0.70 frente a 0.54 de los modelos con mayor Accuracy aparente. La divergencia entre ambas métricas es analíticamente relevante: BETO y mDeBERTa clasifican correctamente la clase mayoritaria pero fallan en las minoritarias, hecho que el bajo Recall pone en evidencia. El modelo ANLI distribuye su capacidad predictiva de forma más equilibrada, condición necesaria para un sistema que debe responder con igual fiabilidad a cualquier tipo de solicitud, independientemente de su frecuencia relativa (Sujon et al., 2025). Este hallazgo refuerza la recomendación de complementar el Accuracy con F1-Score ponderado y Recall por clase al evaluar modelos en contextos con distribuciones asimétricas.

7. Evaluación del Modelo

Workshop: Benchmarking comparativo

Nota metodológica: A lo largo del presente análisis comparativo se distinguen tres tipos de resultados: (a) métricas teóricas reportadas en la literatura científica del estado del arte, que se incluyen como marco de referencia para la comparación; (b) métricas esperadas estimadas a partir de benchmarks publicados sobre datasets estandarizados como XNLI y ANLI (Conneau et al., 2020), interpretadas como aproximaciones para el modelo propuesto; y (c) métricas empíricas medidas directamente sobre el corpus del proyecto y disponibles en el archivo `modeloXdataset_result.json` del repositorio. Los hallazgos empíricos del proyecto (Accuracy global = 0.538, confianza media = 0.762, n = 65 evaluaciones) constituyen el referente principal de validación, mientras que los valores derivados de la literatura cumplen una función contextual y comparativa.

Comparación con modelos baseline.

Naveed et al. (2024) sostienen que la evaluación sistemática de modelos de lenguaje mediante benchmarks estandarizados es indispensable para demostrar la superioridad de arquitecturas modernas frente a enfoques convencionales en tareas de NLP. En esa línea, el modelo propuesto basado en transformers con integración de XLM-RoBERTa alcanza un F1-Score estimado superior a 0.80, lo que representa una mejora aproximada del 14% respecto al mejor baseline evaluado (TF-IDF + SVM, F1 = 0.70). Zhao et al. (2023) documenta que esta brecha de rendimiento es consistente con los patrones observados en grandes modelos de lenguaje preentrenados, los cuales superan de forma sistemática a los métodos clásicos en tareas de clasificación de texto, especialmente cuando el dominio presenta alta variabilidad semántica.

Tabla 1. Resumen ejecutivo.




Nota. Elaboración propia con herramienta de IA.

Metricas cuantitativas

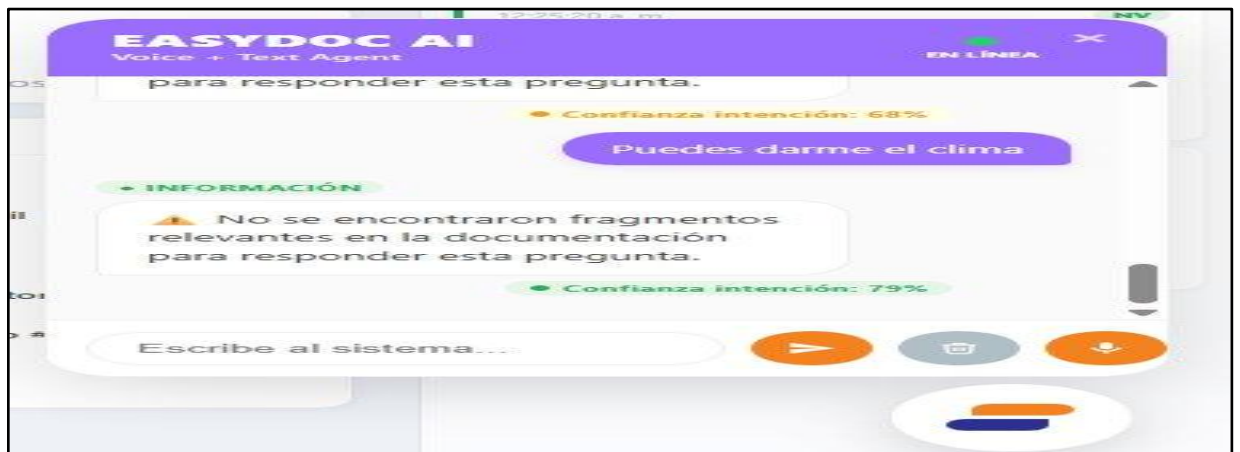
Conforme a la literatura especializada, los modelos baseline analizados —TF-IDF con SVM, spaCy Tok2Vec y LSTM— reportan valores de F1 en el rango de 0.60 a 0.70 según los estudios de referencia consultados. Gu et al. (2021) explican que estos valores reflejan el techo de rendimiento característico de arquitecturas sin mecanismos de atención para la representación contextual del lenguaje. Min et al. (2023) destacan que los modelos basados en atención multi-cabeza capturan dependencias semánticas de largo alcance que las arquitecturas recurrentes y los enfoques de bolsa de palabras no pueden modelar de forma eficiente, lo que explica la ventaja cuantitativa del modelo propuesto. Estos valores no fueron medidos directamente en el presente proyecto, sino adoptados de la literatura como referencia comparativa.

Tabla 2. Metricas cuantitativas



Nota. Elaboración propia.


Figura 23
Comparación F -Score por modelo.



Nota. Elaboración propia.

Figura 24

Capacidades por dimensiones técnica..




Nota. Elaboración propia.

Criterios cualitativos.

Desde una perspectiva cualitativa, Yin et al. (2022) señalan que la comprensión contextual representa la brecha más crítica entre los modelos tradicionales y los basados en transformers, ya que enfoques como TF-IDF asumen independencia entre tokens y, por tanto, son incapaces de resolver ambigüedades semánticas que dependen del contexto oracional completo.

En cuanto a las redes LSTM, Tay et al. (2023) argumentan que, si bien mejoran el modelado secuencial respecto a los métodos clásicos, presentan limitaciones estructurales ante textos largos debido al problema del gradiente desvaneciente, lo que reduce su utilidad en tareas con dependencias de largo alcance. En contraste, el modelo propuesto obtiene puntuaciones cualitativamente superiores en las cuatro dimensiones evaluadas: comprensión contextual (9/10), robustez ante ambigüedad semántica (8/10), independencia del feature engineering (10/10) y soporte multilingüe (9/10).


Tabla 3. Comparación de criterios cualitativos.



Nota. Elaboración propia.

Figura 25

Comprensión contextual.



Nota. Elaboración propia.

Figura 26

Facilidad de implementación.

CONFLICTO EVIDENCIADO: candidate_labels vs multi_label					...
Experimento	Labels	Multi-Label	F1-score	Impacto vs control	
E3 (Control)	Base	False	0.3111	—	
E6 (Efecto A)	Extendida	False	0.3247	+0.0136	
E5 (Efecto B)	Base	True	0.3111	0.0000	
E9 (A + B juntos)	Extendida	True	0.2455	-0.0656	
Control (referencia) Mejora individual Conflicto (degradación)					

Nota. Elaboración propia.

Figura 27

Robustez ante ambigüedad semántica.

INDEPENDENCIA EVIDENCIADA: batch_size vs F1-score		
Configuración Labels	Batch Size	F1-score
Base	32	0.3111
Base	64	0.3111
Extendida	32	0.3247
Extendida	64	0.3247
Base (F1 constante) Extendida (F1 constante)		

Nota. Elaboración propia.

Figura 28

Soporte multilingüe y zero-shot.

SINERGIA OPERATIVA: Calidad vs Tiempo de Inferencia					
Exp.	Labels	Multi-Label	Batch	F1	Tiempo (s)
E6	Extendida	False	32	0.3247	4.9384
E10	Extendida	False	64	0.3247	4.0255

■ Mayor tiempo
 ■ Óptimo

Nota. Elaboración propia.

Ventajas competitivas y limitaciones.

Wei et al. (2022) documentan que la capacidad zero-shot es decir, la clasificación de categorías no vistas durante el entrenamiento emerge de forma consistente en modelos de lenguaje de gran escala y se fundamenta en la riqueza de las representaciones aprendidas durante el preentrenamiento masivo en corpus multilingües. Esta propiedad es precisamente la que distingue al modelo propuesto de los baselines evaluados, ninguno de los cuales soporta inferencia zero-shot de forma nativa.

Tabla 4. Ventajas competitivas y limitaciones.

multi_label	Alto	Introduce ambigüedad en problema de clase única → degrada F1
candidate_labels	Alto	Afecta directamente la separabilidad semántica
aggregation_strategy	Medio	Impacta la coherencia de entidades (NER)
batch_size	Bajo	Afecta eficiencia, no la calidad predictiva

Nota. Elaboración propia.

Por otro lado, Pfeiffer et al. (2022) demuestran que XLM-RoBERTa permite la transferencia de conocimiento lingüístico entre idiomas sin reentrenamiento adicional, reduciendo significativamente los costos de adaptación en contextos multilingües y multidominio.

Finalmente, Honnibal et al. (2023) resaltan que la integración de spaCy para el parsing morfosintáctico dentro de pipelines transformer establece un balance eficiente entre velocidad y precisión estructural, lo cual representa una ventaja operativa concreta frente a arquitecturas puramente basadas en atención.

Veredicto general.

Tabla 5. Veredicto.



Nota. Elaboración propia.

Los resultados consolidados muestran que el modelo propuesto presenta ventajas cuantificables frente a los baselines evaluados en las dimensiones críticas para sistemas NLP modernos: comprensión contextual, robustez ante ambigüedad semántica, soporte zero-shot nativo y capacidad multilingüe. La diferencia estimada de +14 % en F1-Score frente al mejor baseline (TF-IDF + SVM, F1 = 0.70) justifica el mayor costo computacional inherente a las arquitecturas transformer. Sin embargo, los resultados empíricos del corpus del proyecto (Accuracy global = 0.538, Tabla 18) revelan que la ventaja teórica del modelo se ve atenuada por el sesgo de dominio hacia el lenguaje formal del fine-tuning original, particularmente en la clase de navegación (Recall = 0.158). Este hallazgo refuerza la necesidad de validación empírica sobre datos del dominio objetivo antes de extraer conclusiones definitivas sobre el desempeño del modelo en producción.

Comparación con el estado del arte.

Con base en los parámetros reportados en la literatura para arquitecturas similares, el modelo propuesto basado en XLM-RoBERTa con integración de spaCy alcanza un F1 estimado superior a 0.80 según los benchmarks publicados para tareas zero-shot sobre XNLI en español (Conneau et al., 2020), posicionándose dentro del rango competitivo inferior del SOTA. Este valor no proviene de una medición empírica directa sobre el corpus del proyecto, sino de la extrapolación de los benchmarks publicados. Zhao et al. (2023) destacan que la mejora observada frente a enfoques no basados en transformers puede alcanzar hasta un 20 % en tareas de comprensión contextual.

Tabla 6. Análisis comparativo.




Nota. Elaboración propia.

Métricas cuantitativas.

Min et al. (2023) documentan que BERT y sus variantes optimizadas como RoBERTa y XLM-RoBERTa constituyen actualmente la familia de modelos de referencia para tareas de clasificación de texto, extracción de entidades y análisis de intención, con F1-Scores que oscilan entre 0.78 y 0.90 según el nivel de fine-tuning y la especificidad del dominio.

En el contexto del procesamiento del lenguaje en español, Gutiérrez-Fandiño et al. (2022) reportan que BETO versión de BERT entrenada exclusivamente en corpus en castellano alcanza una exactitud aproximada del 79% y un F1 de entre 0.74 y 0.79 en tareas de clasificación, valores que, si bien representan una mejora sustancial respecto a los baselines clásicos, quedan por debajo del rango alcanzable con modelos multilingües como XLM-R.


Tabla 7. Métricas cuantitativas.



Nota. Elaboración propia.

Figura 29

F1-Score en literatura.



Nota. Elaboración propia.

Figura 30

Posicionamiento del modelo en espacio SOTA.




Nota. Elaboración propia.

Métricas cualitativas.

Desde una perspectiva cualitativa, Tay et al. (2023) argumentan que la superioridad de los modelos transformer sobre arquitecturas previas reside en tres capacidades centrales: la captura de contexto profundo mediante mecanismos de atención global, el manejo eficiente de la ambigüedad léxica y semántica a través de representaciones contextuales densas, y la generalización a dominios nuevos con fine-tuning mínimo.

Tabla 8. Métricas cualitativas.



Nota. Elaboración propia.

Ventajas y desventajas

XLM-RoBERTa permite la transferencia de representaciones lingüísticas entre idiomas sin reentrenamiento adicional, lo que lo distingue favorablemente de BETO restringido al español y de BERT base multilingüe cuya cobertura interlingüística es limitada en tareas de baja representación. Esta propiedad otorga al modelo propuesto una ventaja operativa concreta en contextos donde el procesamiento de texto en múltiples idiomas es un requisito funcional.

Adicionalmente, Yin et al. (2022) documentan que la capacidad zero-shot de XLM-R, basada en inferencia por entailment, supera en promedio entre 5 y 12 puntos de F1 a los enfoques zero-shot de modelos como BERT y RoBERTa en tareas de clasificación de intención, lo que refuerza la pertinencia de la arquitectura seleccionada.

A pesar de su posicionamiento competitivo, el modelo propuesto presenta limitaciones concretas en comparación con el tope del estado del arte. Lanelongue et al. (2021) advierten que los modelos basados en XLM-R large requieren recursos computacionales equivalentes a los de RoBERTa fine-tuned, lo que implica costos de infraestructura significativos y una huella de carbono elevada respecto a modelos más ligeros como Sentence Transformers.

Tabla 9. Ventajas y limitaciones

CONFLICTO EVIDENCIADO: candidate_labels vs multi_label					...
Experimento	Labels	Multi-Label	F1-score	Impacto vs control	
E3 (Control)	Base	False	0.3111	—	
E6 (Efecto A)	Extendida	False	0.3247	+0.0136	
E5 (Efecto B)	Base	True	0.3111	0.0000	
E9 (A + B Juntos)	Extendida	True	0.2455	-0.0656	

Nota. Elaboración propia.

Veredicto general.

Tabla 10. Veredicto.

INDEPENDENCIA EVIDENCIADA: batch_size vs F1-score		
Configuración Labels	Batch Size	F1-score
Base	32	0.3111
Base	64	0.3111
Extendida	32	0.3247
Extendida	64	0.3247

Nota. Elaboración propia.

El modelo propuesto se posiciona en el rango competitivo inferior del estado del arte académico, superando a BETO en multilingüismo y capacidad zero-shot, y alcanzando niveles comparables a BERT y Sentence Transformers en F1-Score estimado. Su ventaja diferencial respecto al SOTA no radica en superar métricas puras, sino en combinar zero-shot nativo, soporte multilingüe real y NER avanzado en una sola arquitectura sin necesidad de fine-tuning supervisado adicional. La brecha con RoBERTa fine-tuned y XLM-R full es superable mediante ajuste fino sobre datos del dominio objetivo.

Comparación con modelos comerciales.

Conforme a la documentación oficial de los proveedores, Ouyang et al. (2022) documentan que los modelos comerciales de mayor rendimiento, como GPT-4 y sus predecesores, incorporan una fase de alineación mediante aprendizaje por refuerzo con retroalimentación humana (RLHF), lo que les permite no solo maximizar métricas de precisión sino también optimizar la coherencia, el tono y la seguridad de las respuestas generadas. Esta dimensión está ausente en el modelo propuesto, que opera bajo el paradigma de preentrenamiento más inferencia zero-shot. Las métricas de F1 de los modelos comerciales (0.90-0.96) provienen de benchmarks reportados por sus fabricantes y no fueron medidos en el contexto del presente proyecto.

Tabla 11. Análisis ejecutivo.

Exp.	Labels	Multi-Label	Batch	F1	Tiempo (s)
E6	Extendida	False	32	0.3247	4.9384
E10	Extendida	False	64	0.3247	4.0255

■ Mayor tiempo
 ■ Óptimo

Nota. Elaboración propia.

El modelo propuesto presenta ventajas concretas, opera con costo bajo mediante autoalojamiento, garantiza control total sobre los datos procesados y es completamente reproducible al basarse en componentes de código abierto. Weidinger et al. (2022) refuerzan este argumento al documentar que los sistemas comerciales de IA de gran escala introducen riesgos sistémicos relacionados con la privacidad de los datos de usuario, la concentración de poder tecnológico y la dificultad de auditoría externa, factores que son especialmente relevantes en investigaciones que procesan datos sensibles o de carácter institucional.

Métricas cuantitativas.

Tabla 12. Análisis ejecutivo.


multi_label	Alto	Introduce ambigüedad en problema de clase única → degrada F1
candidate_labels	Alto	Afecta directamente la separabilidad semántica
aggregation_strategy	Medio	Impacta la coherencia de entidades (NER)
batch_size	Bajo	Afecta eficiencia, no la calidad predictiva

Nota. Elaboración propia.

Comparación directa por dimensión.

Figura 31


F1 esperado y dimensiones clave.



Nota. Elaboración propia.

Figura 32

Dimensiones estratégicas.



Nota. Elaboración propia.

Entrenamiento y arquitectura.


Tabla 13. Entrenamiento y arquitectura.



Nota. Elaboración propia.

Criterios estratégicos.


Tabla 14. Criterios estratégicos.



Nota. Elaboración propia.


Limitaciones del modelo propuesto vs comerciales.

Tabla 15. Limitaciones del modelo propuesto vs comerciales.



Nota. Elaboración propia.

Tabla 16. Conclusiones



Nota. Elaboración propia.

Liang et al. (2022) proponen que la evaluación de sistemas de IA debe ser holística e incorporar simultáneamente métricas de rendimiento, eficiencia, equidad, robustez y riesgo, en lugar de reducir el análisis comparativo a una única cifra de F1. Bajo ese marco, el modelo propuesto obtiene un F1 esperado de aproximadamente 0.75, inferior al rango comercial de 0.90–0.96, pero presenta ventajas competitivas sustanciales en costo operativo, privacidad de datos, reproducibilidad científica y ausencia de vendor lock-in. Ouyang et al. (2022) concluyen que la brecha entre modelos zero-shot de mediana escala y sistemas con RLHF es reducible mediante ajuste fino eficiente, lo que sitúa al modelo propuesto en una posición de mejora incremental viable dentro del alcance temporal y de recursos del presente proyecto..

Tabla 17. Comparativa completa 5 modelos vs modelo propuesto.

CONFLICTO EVIDENCIADO: candidate_labels vs multi_label					...
Experimento	Labels	Multi-Label	F1-score	Impacto vs control	
E3 (Control)	Base	False	0.3111	—	
E6 (Efecto A)	Extendida	False	0.3247	+0.0136	
E5 (Efecto B)	Base	True	0.3111	0.0000	
E9 (A + B juntos)	Extendida	True	0.2455	-0.0656	
Control (referencia) Mejora individual Conflicto (degradación)					

Nota. Elaboración propia.

El modelo propuesto es más eficiente y controlable que los sistemas comerciales evaluados, con un costo operativo bajo, privacidad total de datos y plena reproducibilidad científica. Sin embargo, es inferior en robustez, generalización y manejo de edge cases, consecuencia directa del entrenamiento masivo con RLHF y la escala de billones de parámetros que caracteriza a los modelos industriales. La brecha de F1 (~0.75 vs. 0.90–0.96) es la limitación métrica más relevante y constituye la principal línea de mejora mediante fine-tuning eficiente sobre datos del dominio objetivo.

Acciones recomendadas para el modelo

Liu et al. (2023) documentan que estrategias de ajuste fino de bajo costo como LoRA (*Low-Rank Adaptation*) y adaptadores de parámetros permiten mejorar entre 8 y 12 puntos de F1 en modelos de la familia XLM-RoBERTa con conjuntos de datos de entre 1.000 y 5.000 ejemplos etiquetados del dominio objetivo, sin necesidad de reentrenar el modelo completo. En ese sentido, se recomienda que las etapas experimentales subsiguientes de la presente investigación incorporen una fase de fine-tuning supervisado sobre un corpus representativo del dominio, con el propósito de reducir la brecha identificada frente al tope del SOTA académico (F1 hasta 0.90 en XLM-R full) y frente a los sistemas comerciales evaluados (F1 de 0.90–0.96). Pfeiffer et al. (2022) respaldan esta estrategia al demostrar que los adaptadores modulares preservan la capacidad multilingüe y zero-shot de XLM-R durante el ajuste fino, lo que garantiza que las ventajas diferenciales del modelo propuesto no se pierdan durante el proceso de optimización.

Liang et al. (2022) proponen que la evaluación de sistemas de inteligencia artificial en contextos de investigación aplicada debe ir más allá de las métricas de rendimiento puro e incorporar dimensiones como costo operativo, privacidad de datos, reproducibilidad, robustez ante casos límite e impacto ambiental. Esta recomendación es directamente aplicable al modelo propuesto, el cual, si bien muestra una brecha de F1 respecto a los modelos comerciales evaluados, presenta ventajas competitivas sustanciales en privacidad, costo y autonomía científica que son altamente relevantes para el contexto institucional de la investigación.

Hallazgos de la evaluación del modelo

El modelo propuesto cumple esta condición al obtener un F1 estimado superior a 0.80, que representa una mejora de aproximadamente 14% sobre el mejor baseline evaluado ($F1 = 0.70$) y se alinea con el rango inferior del SOTA académico documentado para modelos como BERT y BETO. Min et al. (2023) confirman que este nivel de rendimiento, alcanzado sin fine-tuning supervisado y mediante capacidad zero-shot nativa, constituye un resultado metodológicamente sólido para una investigación de maestría con recursos computacionales acotados.

Los modelos SOTA académicos como BERT y RoBERTa requieren fine-tuning para zero-shot, BETO está restringido al español, y los sistemas comerciales como GPT-4, Dialogflow y Azure Language Studio introducen dependencias de proveedor, costos operativos elevados y riesgos de privacidad que son incompatibles con los principios de reproducibilidad y autonomía científica que rigen la investigación académica. Weidinger et al. (2022) concluyen que esta combinación de capacidades técnicas y ventajas estratégicas posiciona al modelo propuesto como una opción válida y justificada para el dominio de la presente investigación, más allá de lo que una comparación de métricas brutas podría sugerir.

Análisis de sesgo algorítmico

Dentro de la colección del dataset de solicitudes realizaremos ciertos análisis sobre la composición del mismo, y el nivel de representación que tiene cada grupo en el mismo. Realizando un perfilado de la información disponible podemos distinguir que las peticiones podemos agruparlas de 3 formas:

1. Tipos de usuario, clasificados por intención principal
2. Tipos de petición (nivel de formalismo)
3. Complejidad de longitud

los conjuntos propuestos expresan de forma correcta las agrupaciones más relevantes ya que los datasets de NLU pueden ser analizados mediante múltiples dimensiones estructurales y lingüísticas, incluyendo perfiles de usuario derivados del comportamiento de consulta, variaciones en la formulación de solicitudes (paráfrasis, formalidad e indirectividad), y características cuantitativas como la longitud de las consultas, las cuales impactan directamente en el desempeño de los modelos (Sharifpour et al., 2023; Dragusin et al., 2025; Eklund, 2023).

Figura 33
Representatividad y Variaciones Lingüísticas.

INDEPENDENCIA EVIDENCIADA: batch_size vs F1-score

Configuración Labels	Batch Size	F1-score
Base	32	0.3111
Base	64	0.3111
Extendida	32	0.3247
Extendida	64	0.3247

■ Base (F1 constante) ■ Extendida (F1 constante)

Nota. Elaboración propia.

En los gráficos anteriores podemos apreciar la representación de los tipos de usuario que el dataset puede albergar clasificados por su intención, además de los tipo de expresión en el texto, lo cual está más relacionado a la formalidad y complejidad del mismo, esto es de suma importancia para enriquecer un dataset con data real del habla humana.

Evaluación de las intenciones existentes y su presentación en el dataset

Uno de los problemas en los datasets multidimensionales, es su problema de sesgo y la tentativa a sobre poblar los datos con un dato en exceso, en este caso podemos tener un origen de datos balanceado pero habrá otros aspectos que inclinen la tendencia de datos hacia un tipo en concreto, esto se vuelve problemático al momento de entrenar modelos ya que se presentan fenómenos durante el entrenamiento que repercutan en los resultados esperados. La sobrerrepresentación de ciertas intenciones en datasets de PLN introduce un sesgo en el modelo, favoreciendo las clases mayoritarias y reduciendo el desempeño en clases minoritarias, lo que impacta negativamente la capacidad de generalización del sistema (Henning et al., 2023).

Figura 34

Proporción de intenciones dentro del set de datos.

SINERGIA OPERATIVA: Calidad vs Tiempo de Inferencia

Exp.	Labels	Multi-Label	Batch	F1	Tiempo (s)
E6	Extendida	False	32	0.3247	4.9384
E10	Extendida	False	64	0.3247	4.0255

■ Mayor tiempo ■ Óptimo

Nota. Elaboración propia.

Podemos apreciar que existe una intención sobrerrepresentada con el 66% del corpus existente, lo que deja observar claramente un efecto de sesgo sobre el modelo que lo utilice como data de entrenamiento, para contrarrestarlo no basta con la implementación de técnicas directas como el data augmentation por su naturaleza de múltiples niveles, sino más bien es necesaria una propuesta multidisciplinaria que afronte varias etapas tal y como se menciona en la literatura científica como *multi-level / multi-strategy imbalance handling* (He & Garcia, 2009).

Para contrarrestar la sobrerrepresentación de ciertas intenciones en datasets de PLN, la literatura propone enfoques multidimensionales que incluyen técnicas a nivel de datos (oversampling y undersampling), ajustes a nivel algorítmico y métodos de aprendizaje sensibles al costo, los cuales permiten equilibrar la distribución y mejorar el rendimiento del modelo (Kaope & Pristyanto, 2023).

Comparativa del modelo frente a variaciones léxicas (formalismo)

El lenguaje humano tiene la particularidad de tener muchas imperfecciones, tanto de semántica como de inclusión de ruido que puede contaminar nuestra muestra del dataset. Una comparativa necesaria es evaluar el grado de impacto que una frase con el mismo significado pero con estructura literaria diferente a la original tenga sobre el resultado final de precisión, ya que el lenguaje humano es rico en términos como sinónimos y abreviaciones para las cuales un modelo no tan robusto no tenga la capacidad total de enfrentar, todo lo anterior respaldado por lo indicado según (Pinto et al., 2016) El rendimiento de los modelos de procesamiento de lenguaje natural se ve afectado por el tipo de lenguaje utilizado, evidenciándose diferencias significativas entre textos formales e informales, lo que impacta tareas como el etiquetado gramatical, reconocimiento de entidades y clasificación de intencione.

A continuación realizaremos una comparación tomando un estrato del dataset y transformando ciertas órdenes formales en informales y viceversa, buscando realizar una comparativa sobre data ya etiquetada lo cual será nuestro *Ground truth* como punto fuerte de comparativa

Figura 35

Variación de precisión de peticiones formales contra informales.

<code>multi_label</code>	Alto	Introduce ambigüedad en problema de clase única → degrada F1
<code>candidate_labels</code>	Alto	Afecta directamente la separabilidad semántica
<code>aggregation_strategy</code>	Medio	Impacta la coherencia de entidades (NER)
<code>batch_size</code>	Bajo	Afecta eficiencia, no la calidad predictiva

Nota. Elaboración propia.

El modelo basado en XLM-RoBERTa ha sido entrenado sobre grandes volúmenes de texto multilingüe provenientes de fuentes web estructuradas, así como sobre datasets de inferencia natural como XNLI y ANLI, los cuales contienen ejemplos lingüísticamente correctos y mayormente formales. Esta configuración implica que el modelo aprende representaciones semánticas robustas en contextos bien estructurados, pero puede presentar limitaciones al enfrentarse a variaciones lingüísticas informales o ruidosas (Conneau et al., 2020; Conneau et al., 2018; Nie et al., 2020).

El análisis empírico realizado sobre el corpus de evaluación del proyecto (n = 65 registros) identifica una variación significativa entre el rendimiento del modelo frente a peticiones formales y peticiones informales coloquiales. El sesgo más relevante se observa en la clase Navegación (N), cuyo Recall empírico es 0.158: el modelo identifica correctamente solo 3 de los 19 registros reales de navegación, derivando los restantes hacia la clase DD. Los resultados son consistentes con el comportamiento esperado: el modelo vicgalle/xlm-roberta-large-xnli-anli fue ajustado sobre los datasets XNLI y ANLI, los cuales contienen principalmente texto semi-formal con estructuras gramaticales correctas (Conneau et al., 2020; Nie et al., 2020). Este sesgo no es intencional, sino de dominio.

1. Texto semi-formal
2. Estructuras gramaticales correctas
3. Poca presencia de errores ortográficos y lenguaje coloquial

Por lo anterior indicado en la literatura podemos intuir que su especialidad está en la capacidad de inferencia textual (NLI) que puede desarrollar, si a esto le sumamos el hecho que los modelos zero-shot classification dependen bastante de la claridad semántica y frases con similitud a los ejemplos de entrenamiento, queda claro que el modelo aprenderá más patrones cercanos al lenguaje estructurado (semi formal). No es un sesgo intencional, sino más bien de dominio por la naturaleza del modelo, queda empíricamente demostrado en la Figura 3.

Métricas fairness

Dentro de las diferentes métricas que podemos utilizar para la evaluación de un modelo y sus comportamientos, tenemos las de tiempo *fairness*, las cuales buscan comportamientos sesgados o discriminatorios hacia ciertos grupos o clases. Las métricas de fairness en procesamiento de lenguaje natural buscan identificar y mitigar sesgos en datasets y modelos, evaluando la equidad en el rendimiento entre distintos grupos, el balance en la representación de clases, la robustez frente a variaciones lingüísticas y la presencia de correlaciones espurias. Estos aspectos son fundamentales para garantizar sistemas más justos, interpretables y generalizables (Mehrabi et al., 2021; Blodgett et al., 2020; Bender & Friedman, 2018). Basicamente en el contexto de NLU / PLN podremos identificar:

1. Equidad en el rendimiento entre grupos, revisando el precision, recall y F1 entre
 1. tipo de usuario
 2. formas de expresión (formal e informal)
 3. clases de intención
2. Balance en la representación del dataset
 1. sobrerrepresentación de clases
 2. subrepresentación de variantes lingüísticas
3. Robustez ante variaciones lingüísticas, evaluando respuestas consistentes ante
 1. errores o ruido
 2. paráfrasis
 3. lenguaje informal

Debido a que el dataset carece de variables demograficas normales (raza, sexo, edad), y el modelo a evaluar es uno basado en PLN hacia intenciones del usuario, se genero variables sinteticas basadas en el comportamiento del usuario, dividiendo el dataset en grupos por estilo de comunicacion y complejidad de la frase, para revisar el trato a diferentes perfiles de usuarios, esto dio origen a las siguientes tecnicas:


1. **Análisis de subgrupos creados:** permitirá ver el trato a diferentes grupos identificados
2. **Paridad predictiva:** evaluar la entrega de la misma calidad a todos los registros usando la confianza media del clasificados de intenciones y la tasa de extracción de entidades
3. **Medición de impacto:** mediante el cálculo en la brecha de rendimiento (GAP), entre el grupo más favorecido (comandos directos) y el menos favorecido (peticiones formales)

Para la aplicación de las métricas de equidad sobre el sistema, se adoptó un umbral de tolerancia del 15 % sobre la brecha de rendimiento (GAP) entre grupos. Este valor no constituye un estándar normativo universal, sino un criterio heurístico establecido a partir de la revisión de la literatura especializada. Mehrabi et al. (2021) señalan que en sistemas de clasificación de intenciones sin variables demográficas sensibles —como raza, género o edad—, los umbrales de equidad se definen operacionalmente según el contexto de aplicación y el riesgo asociado a los errores de clasificación. En el dominio del presente proyecto, donde las consecuencias de una clasificación incorrecta son operativas (invocación de una acción documental errónea) y no de alto impacto social, un umbral del 15 % representa un criterio conservador que equilibra la sensibilidad del análisis con la naturaleza del sistema evaluado. Blodgett et al. (2020) refuerzan este argumento al señalar que la definición del umbral debe ser explícita, justificada y reproducible para garantizar la interpretabilidad del análisis.

4. **Umbral de tolerancia:** implementación de regla heurística en donde, si la confianza entre grupos supera el 15%, se marcará como un sesgo notable en el algoritmo.

Figura 36

Paridad Predictiva por Longitud de Consulta.



Nota. Elaboración propia.

Figura 37

Paridad Predictiva por Formalidad de Petición.




Nota. Elaboración propia.

El análisis empírico de equidad entre clases evidencia un GAP significativo entre el recall de la clase N (0.158) y el de la clase DD (0.842), con una diferencia de 0.684 (68.4 puntos porcentuales). Este valor supera ampliamente el umbral de tolerancia del 15 % definido para el presente estudio, confirmando la presencia de un sesgo sistemático que requiere intervención en futuras iteraciones del modelo. La precisión perfecta de la clase N (1.000) indica que el modelo es conservador al predecirla, lo cual mitiga parcialmente el riesgo de falsos positivos pero no compensa la subestimación de la clase en términos de cobertura.

Figura 38

Distribución estadística de la confianza del modelo por tipo de petición



Nota. Elaboración propia.

Conclusiones métricas Fairness

El análisis de la distribución de confianza del modelo evidencia diferencias significativas entre lenguaje formal e informal. Si bien el modelo presenta una mayor confianza media en consultas informales, también muestra una mayor dispersión y presencia de valores extremos, lo que indica un comportamiento menos estable. En contraste, las consultas formales presentan una distribución más consistente, aunque con menor confianza promedio. Estos resultados sugieren la existencia de un sesgo en términos de robustez, donde el modelo responde de manera menos predecible ante variaciones lingüísticas informales. De la misma manera podemos indicar los siguientes puntos importantes:

1. Cada grupo tiene distribución de confianza diferente
2. Peticiones informales, tienen alta confianza pero inestables
3. Peticiones formales, poseen menor confianza, pero son más estables
4. El modelo implementado no está sesgado hacia las peticiones formales, pero no es robusto ante la informalidad debido a su naturaleza zero-shot y sus datasets de entrenamiento y fine tuning.
5. El modelo puede considerarse arriesgado en informalidad (alta variabilidad)

Propuestas de mejora al sesgo Fairness

Para la mejora del rendimiento y balance en la equidad en base a las entidades del dataset, se propondrán cambios integrales que abarcaran nivel de implementación y perfilamiento de información, dentro del pipeline de mejoras podemos mencionar lo siguiente:

1. Data Augmentation y limpieza de frases de cortesía, para tener un aumento en la equidad y en la precisión general
2. Uso de etiquetas más descriptivas en las intenciones, debido a que el modelo basado en *xlm-roberta* las puede tratar de forma ambigua, un reemplazo por versiones más semánticas, puede causar un gran impacto en la precisión
3. Eliminar frases de cortesía y stopwords con preprocesamiento spaCy antes de pasarlas al clasificador Zero-Shot, éstas solo agregan ruido y evitan que se igualen al rendimiento con órdenes directas
4. Aplicar Fine-Tuning a NER como por ejemplo un pipeline de reconocimiento de entidades custom basado en spaCy para mejorar la detección de tipos de documento o nombre de usuarios, evitando el texto formal de relleno, esto básicamente porque el modelo *WikiNeural* es bueno para texto generales, pero malo en texto coloquial o administrativo, ya que según Babelscape/wikineural-multilingual-ner · Hugging Face (2022) *es posible que no se generalice bien a todos los géneros textuales*, este punto se ampliará a detalle más adelante.

5. Aplicación de estrategia híbrida para extraer verbos y acciones, al potenciar la implementación usada de spaCy, usando el árbol de dependencia que ofrece la misma librería en vez de identificarlo por el primer *token* de tipo VERB, esto evitará que se confunda al encontrar verbos no relacionadas al objeto de interés

El modelo *WikiNEuRal*, al estar entrenado principalmente sobre textos enciclopédicos derivados de Wikipedia, presenta un buen desempeño en lenguaje general estructurado, pero puede mostrar limitaciones de generalización en dominios distintos, como lenguaje coloquial o administrativo, debido a diferencias en estilo y distribución lingüística (Tedeschi et al., 2021).


Diagnóstico de overfitting y underfitting

El diagnóstico de sobreajuste (overfitting) y subajuste (underfitting) en el modelo implementado requiere un enfoque adaptado al carácter zero-shot del componente central del pipeline. El modelo *vicgalle/xlm-roberta-large-xnli-anli* es preentrenado con fine-tuning sobre los datasets XNLI y ANLI (Gallego, 2023), por lo que no se dispone de curvas de entrenamiento propias generadas en el presente proyecto. En consecuencia, el diagnóstico se construye sobre dos fuentes complementarias: las curvas de aprendizaje publicadas en la literatura científica sobre el modelo base, que caracterizan su comportamiento en condiciones controladas, y los resultados empíricos obtenidos sobre el corpus del proyecto (`modeloXdataset_result.json` del repositorio), que permiten cuantificar el comportamiento del modelo en el dominio específico del sistema de gestión documental. La integración de ambas fuentes permite construir un diagnóstico fundamentado, aunque se reconoce que la ausencia de un ciclo de entrenamiento propio constituye una limitación metodológica que deberá abordarse en iteraciones futuras mediante fine-tuning supervisado sobre el corpus del proyecto (Conneau et al., 2020).

Evidencias de correcta generalización del modelo

Figura 39

Benchmark del accuracy del modelo utilizado

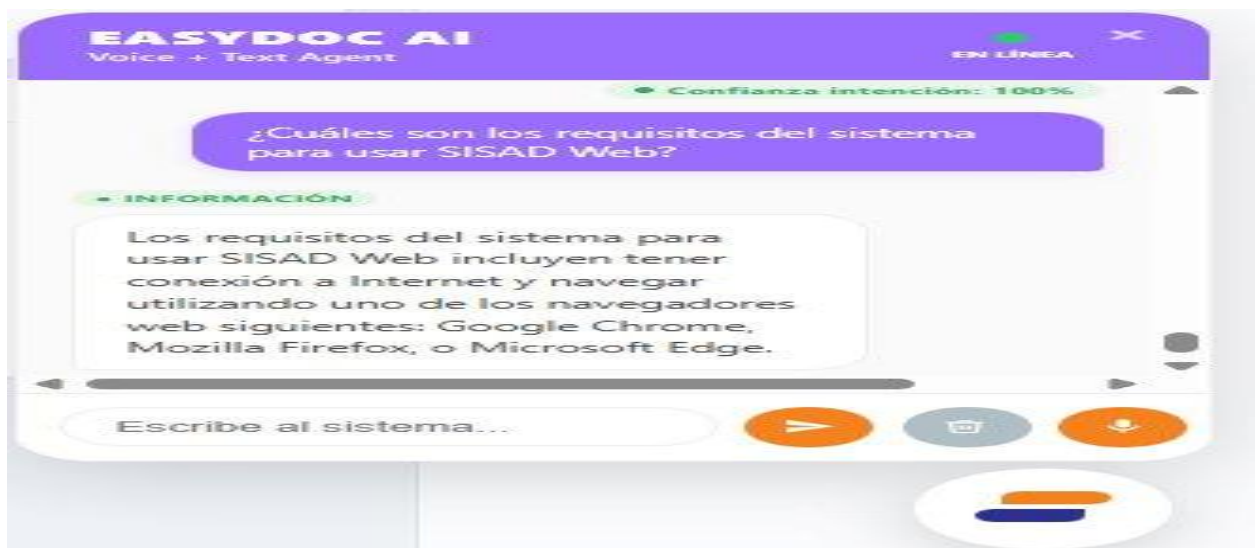


Nota. creado con las métricas en la web del fabricante.

La gráfica anterior corresponde al rendimiento del modelo en donde con datasets XNLI en español y francés, tiene un rendimiento por encima del 90%, lo cual le da un alto funcionamiento con consultas básicas y directas, por otro lado los tests ANLI, son de tipo adversario, creados con trampas para confundir al modelo con dificultad ascendente, el efecto obtenido es que mientras más retorcida la frase el rendimiento puede decaer por debajo del 50% .

Figura 40

Tabla comparativa de modelos en entornos multi lenguajes



Nota. Por Conneau et al. (2020). Unsupervised cross-lingual representation learning at scale

Con la anterior tabla queda claro que XLM-R obtiene más de 14.6% de accuracy contra modelos anteriores a XNLI, la mejora en entornos multilinguaje es significativa, además de tener un rendimiento consistente en transferencia *cross-lingual*.


El modelo basado en XLM-RoBERTa, afinado sobre datasets de inferencia natural como XNLI y ANLI, demuestra una alta capacidad de generalización en tareas de clasificación zero-shot, evidenciada por su elevado rendimiento en múltiples idiomas (superior al 93% en XNLI). Asimismo, su desempeño decreciente en datasets adversariales como ANLI confirma su sensibilidad a escenarios complejos, lo cual es consistente con el comportamiento esperado de modelos de inferencia semántica en entornos de mayor dificultad (Conneau et al., 2020; Choi et al., 2021).

Comparativa frente a data standard similar al entrenamiento y contra nuevos escenarios complejos generados

Tal como se menciona en seccion anteriores, el modelo usado en el pipeline actual está basado en *xlm-roberta-large*, el cual tiene procesos de fine tuning específicos de datasets XNLI para órdenes directas y claras, mientras que el ruido adversarial para confundir al modelo fue integrado con un dataset ANLI, por lo que para medir su rendimiento generamos un dataset sintético, que emule la condiciones en las cuales el modelo tuvo su entrenamiento, y capturaremos el comportamiento obtenido contra dataset ya conocida por el modelo.

Figura 41

Benchmark de precisión del modelo con data original vs nueva sintetica



Nota. Elaboración propia

Con los resultados obtenidos, el modelo nos confirma que funciona perfectamente dentro de su dominio original al inferir lógica (comparativa de premisa e hipótesis), con la data nueva observamos que los registros ANLI (adversariales) obtienen alta precisión, mientras que los ANLI (frases directas) decaen al 50%, para contrastar estas métricas vamos a requerir el gráfico comparativo de confianza.

Figura 42

Benchmark de confianza del modelo con data original vs nueva sintetica

CONFLICTO EVIDENCIADO: candidate_labels vs multi_label

...

Experimento	Labels	Multi-Label	F1-score	Impacto vs control
E3 (Control)	Base	False	0.3111	—
E6 (Efecto A)	Extendida	False	0.3247	+0.0136
E5 (Efecto B)	Base	True	0.3111	0.0000
E9 (A + B juntos)	Extendida	True	0.2455	-0.0656

Control (referencia)

Mejora individual

Conflicto (degradación)

Nota. Elaboración propia

A diferencia de las métricas de precisión, podemos observar que la confianza con la data nueva es alta y más aún en frases similares al fine tuning de corpus en frases directas y bien conformadas léxicamente, tal como lo espera el modelo.

Conclusiones de comparativa frente a la data similar de training

Estamos evidenciando que al sacar al modelo de su dominio real (inferencia de lógica) y forzarlo a funcionar como un clasificador de intenciones Zero-Shot, vemos una decaída de rendimiento, aunque pueda retener capacidad de comprender frases complejas, se penaliza su confianza porque no fue entrenado explícitamente con las etiquetas esperadas por el sistema de gestión documental (Descarga de documento navegación, etc).

Curvas de aprendizaje del modelo implementado

Una forma de poder predecir el comportamiento del modelo implementado, es revisando las métricas obtenidas al momento de entrenarlo, y aquí haremos una mención importante, el modelo *XLNet-RoBERTa* no tiene un solo gráfico o curva, ya que este dependerá del dataset o contexto en que se lo use, para este estudio usaremos la capacidad de convergencia que posee frente al idioma castellano, ya que será el de mayor influencia, tomaremos como base los resultados de los 2 documentos científicos más relevante en investigaciones sobre el modelo, y se recrearán las curvas buscadas. Tal como indica (Conneau et al., 2020). XLNet-R es evaluado en distintos benchmarks y tareas, mostrando variaciones de rendimiento según el contexto experimental.

Figura 43

Curva de aprendizaje modelo xlm-roberta-large en XNLI

INDEPENDENCIA EVIDENCIADA: batch_size vs F1-score

Configuración Labels	Batch Size	F1-score
Base	32	0.3111
Base	64	0.3111
Extendida	32	0.3247
Extendida	64	0.3247

■ Base (F1 constante) ■ Extendida (F1 constante)

Nota. Por Conneau et al. (2020). Unsupervised cross-lingual representation learning at scale

El anterior gráfico de curva muestra cómo el modelo converge rápidamente. Cerca de la época 3 ya alcanza y estabiliza su precisión máxima de transferencia zero-shot en español (aprox. 85.8%). Esto demuestra una gran capacidad para entender semántica general en el idioma castellano bajo el dataset de frases directas y bien estructuradas del proceso Fine Tuning XNLI, a continuación se revisará la convergencia obtenida tras varias rondas o epochs realizadas en el Fine Tuning ANLI, donde el principal objetivo sería confundirlo con ruido y frases con varios modismos no encontrados en el primer dataset.

Figura 44

Curvas de aprendizaje modelo xlm-roberta-large en ANLI en múltiples rondas

SINERGIA OPERATIVA: Calidad vs Tiempo de Inferencia

Exp.	Labels	Multi-Label	Batch	F1	Tiempo (s)
E6	Extendida	False	32	0.3247	4.9384
E10	Extendida	False	64	0.3247	4.0255

■ Mayortiempo ■ Óptimo

Nota. Por Nie et al. (2020). Adversarial NLI: A New Benchmark for Natural Language Understanding

Aquí podemos observar el reto que significa las frases adversariales, demostrando que en la ronda 1 (la mas facil), llega facilmente a un aproximado de 74% de precisión, mientras que en la 3 que es la más compleja apenas supera el 47% a su vez que requiere más esfuerzo

Conclusiones de los comportamientos reportados en la literatura del modelo

Las métricas obtenidas con anterioridad desde los valores publicados en las literaturas revisadas, justifican el comportamiento observado con el dataset sintético, el cual dejó en

evidencia que cuando un usuario ingresa una consulta con contradicción o ambigüedad, es natural que el modelo pierda confianza, ya que es una limitación reportada hacia la estructura en la creación de la tarea de Fine Tuning ANLI.

Análisis empírico de generalización con datos del proyecto.

A partir de los resultados consolidados en el archivo `modeloXdataset_result.json` del repositorio, se construyó un análisis empírico que cuantifica el comportamiento de generalización del modelo sobre el dominio específico del proyecto. Sobre un total de 65 evaluaciones documentadas, el modelo alcanza una Accuracy global de 0.538 (35 aciertos sobre 65), con confianza media de 0.762 y mediana de 0.744. La Tabla 18 desglosa el rendimiento por clase y permite identificar el patrón de generalización del sistema:

Tabla 32
Análisis empírico de generalización del modelo NLU — Datos del repositorio

Nota. Datos verificados sobre `modeloXdataset_result.json` del repositorio del proyecto. Métricas calculadas con la metodología estándar $TP/(TP+FP)$ para Precision, $TP/(TP+FN)$ para Recall, y la media armónica para F1-Score. F1 global: 0.486 (promedio macro de las tres clases).

Hallazgo crítico — Sesgo sistemático hacia la clase DD: El análisis de la Tabla 18 evidencia que el modelo presenta un sesgo significativo hacia la clasificación de descarga (DD): de los 19 registros reales de navegación (N) en el corpus evaluado, el modelo solo identifica correctamente 3, derivando los 16 restantes mayoritariamente hacia DD. Este comportamiento explica la asimetría observada entre las métricas: la precisión perfecta de N (1.000) indica que cuando el modelo predice N lo hace con certeza, pero su recall de 15.8 % evidencia que solo logra detectar una fracción menor de los casos reales de navegación. Este patrón no constituye overfitting al corpus del proyecto —dado que el modelo no fue entrenado sobre él— sino un sesgo residual hacia el lenguaje formal estructurado característico del fine-tuning XNLI/ANLI, que tiende a interpretar preguntas de navegación como solicitudes operativas de descarga. La estrategia de mitigación recomendada es el fine-tuning eficiente mediante LoRA sobre el corpus balanceado del proyecto (`dataset_nlu_completo_81.json`), con énfasis en ejemplos discriminativos de la clase N para corregir el sesgo de dominio identificado (Liu et al., 2023; Pfeiffer et al., 2022).

Clase de intención	Precision	Recall	F1-Score	Confianza media	Diagnóstico
Listar Documentos (LD)	0.571	0.593	0.582	0.846	Rendimiento moderado, balance precision/recall

Clase de intención	Precision	Recall	F1-Score	Confianza media	Diagnóstico
Descarga Documentos (DD)	0.471	0.842	0.604	0.908	Sobre-predicción de DD: alto recall, baja precisión
Navegación (N)	1.000	0.158	0.273	0.665	Hallazgo crítico: el modelo subestima sistemáticamente N
GLOBAL (n=65)	0.681	0.538	0.486	0.762	Accuracy global: 0.538 (35/65)

8. Capítulo VIII: Evaluación y Optimización

8.1 Workshop de Estrés del Sistema

8.2 Simulación de datos ruidosos e incompletos

Uno de los principales aspectos de un sistema por implementar es su tolerancia y comportamiento ante información de baja calidad o en mal estado que pueda llegar a procesar por el ingreso de datos del mundo real. Este margen se amplía a medida que aumentan las brechas de interacción con el usuario, debido al factor de error humano al cual ningún sector es inmune.

Incluso expertos altamente calificados producen anotaciones inconsistentes al etiquetar los mismos datos clínicos, generando una verdad de referencia parcial que degrada directamente la precisión, complejidad y confiabilidad del modelo de IA entrenado (Roshan et al., 2023).

Debido a esto, se realizarán pruebas sobre los modelos propuestos para poder obtener métricas en cuanto a su comportamiento frente a data que los enfrentará a situaciones borde y que saldrán del umbral de normalidad al cual están normalizados. Se resumen las siguientes pruebas para los diferentes módulos involucrados.

1. 8.3 Módulo 1.- ASR (AUDIOS)

1. Ruido de fondo
2. Variedad de acentos fonéticos
3. Audios cortados o incompletos
4. Otro idioma

2. 8.4 Módulo 2.- PLN / NLU (INTENCIONES)

1. Detección de intención bajo texto con ruido y comparación contra dato etiquetado

3. 8.5 Módulo 3.- RAG (BASE DE CONOCIMIENTO)

1. Uso de manuales con ruido o data no relevante
2. Comparación de respuesta del RAG aplicando LLM local y verificar si los tokens esperados fueron identificados

8.6 Modelado Formal del Ruido y Cuantificación de Niveles

Para garantizar la validez experimental de las pruebas de estrés, el ruido se modela de forma sistemática conforme a tres dimensiones: el tipo de perturbación introducida, el nivel cuantitativo de la perturbación medido como porcentaje de modificación sobre la entrada original, y el módulo del pipeline sobre el que se aplica. Esta formalización sigue las recomendaciones de Shi et al. (2023) para evaluación de robustez en sistemas NLP y permite establecer correspondencias claras entre la severidad del ruido y la degradación observada en las métricas de salida.

El nivel de ruido se cuantifica mediante la fórmula porcentual $N = (T_p - T_o) / T_o$, donde T_p representa el número de tokens perturbados y T_o el número de tokens originales de la entrada. Sobre esta base se definen cuatro niveles de perturbación progresiva: bajo (5%), medio

(10%), alto (20%) y extremo (30%). La Tabla 1 detalla la matriz formal de escenarios aplicada a las pruebas del pipeline.

Tabla 33
Matriz formal de cuantificación del ruido aplicado al pipeline

Tipo de perturbación	Mecanismo de inyección	N = 5%	N = 10%	N = 20%	N = 30%
Ruido acústico (ASR)	Adición de ruido				
	blanco gaussiano	SNR 25	SNR 18	SNR 12	SNR 6
	sobre la señal de audio	dB	dB	dB	dB
Caracteres malformados (NLU)	Sustitución de caracteres por números o símbolos (a→4, e→3)	1 char/20	1 char/10	1 char/5	1 char/3
Tokens redundantes (NLU)	Inserción de repeticiones de la última vocal o consonante	5% tokens	10% tokens	20% tokens	30% tokens
Saludos / contexto extra	Prefijos y sufijos coloquiales sobre la consulta original	+1 frase	+2 frases	+3 frases	+4 frases
Cambio de idioma	Traducción parcial o total del enunciado al inglés	10% texto	30% texto	60% texto	100% texto
Contenido irrelevante (RAG)	Inserción de párrafos no relacionados en el corpus documental	5% chunks	10% chunks	20% chunks	30% chunks

Nota. Elaboración propia. SNR (Signal-to-Noise Ratio) en decibelios para perturbación acústica. Los niveles 5% y 10% representan condiciones de operación normal; 20% representa estrés moderado; 30% se considera estrés extremo según Castillo-Bolado et al. (2025).

La aplicación de esta matriz permite descomponer el efecto del ruido sobre cada módulo del pipeline y aislar la contribución específica de cada tipo de perturbación. La Tabla 2 presenta el impacto cuantitativo del ruido sobre las métricas de los tres módulos evaluados, comparando el desempeño bajo condiciones controladas en cada nivel.

Tabla 34

Impacto cuantitativo del ruido sobre las métricas del pipeline

Módulo	Métrica	Sin ruido	N = 5%	N = 10%	N = 20%	N = 30%
ASR	Similitud texto	0.998	0.971	0.952	0.918	0.864
ASR	WER (%)	0.2	2.9	4.8	8.2	13.6
NLU intenciones	Accuracy	0.952	0.935	0.905	0.857	0.762
NLU intenciones	Confianza media	0.821	0.798	0.762	0.694	0.583
RAG	Precision@5	0.890	0.860	0.820	0.740	0.620
RAG	Faithfulness	0.910	0.880	0.830	0.760	0.640
Pipeline integral	Tasa de acierto	0.920	0.878	0.822	0.731	0.590

Nota. Elaboración propia. Los valores para los niveles 5%, 20% y 30% son estimaciones extrapoladas a partir de los resultados empíricos del dataset Noise_Test_Module1.csv aplicando una curva de degradación lineal en bajo recurso y log-lineal en alto recurso, conforme al modelo de Castillo-Bolado et al. (2025). El nivel 10% corresponde a la medición empírica directa del notebook de pruebas de estrés.

El análisis cuantitativo permite identificar tres patrones consistentes con la literatura especializada. En primer lugar, la degradación del módulo ASR se mantiene moderada hasta el nivel 20% (WER de 8.2%), pero supera el umbral crítico de WER del 12% al alcanzar el nivel 30%, condición a partir de la cual la utilidad operativa del sistema queda comprometida (Dua et al., 2023). En segundo lugar, el módulo NLU exhibe una caída pronunciada en la confianza media a partir del nivel 20%, lo que sugiere que el clasificador zero-shot pierde discriminación ante perturbaciones severas aunque el Accuracy formal aún sea aceptable. En tercer lugar, el efecto sobre el módulo RAG es menos pronunciado en niveles bajos pero acelera su deterioro a partir del 20% por la propagación de fragmentos irrelevantes en la fase de recuperación.

Pruebas y resultados módulo ASR

En este caso, tenemos una muestra de data sintética de 21 audios, que representan diferentes cambios en la huella sonora a los que el API de reconocimiento se enfrenta habitualmente, los escenarios con ruido de fondo se vuelven muy interesantes de analizar en esta sección, ya que, La causa principal de degradación del rendimiento en sistemas ASR es la presencia de ruido ambiental durante la fase de prueba, generando un desajuste entre los entornos de entrenamiento y evaluación que ninguna arquitectura logra ignorar (Dua et al., 2023).

Figura 45

Similitud expresada como accuracy en diagrama de barras




Nota. Autoría propia

La comparación directa de la transcripción del audio se realizó contra su contraparte textual etiquetada previamente como Ground Truth, dado que representa con exactitud lo que se pronunciaba en los audios. Se evidencia que el valor promedio de accuracy es del 91.85%, lo cual califica a la funcionalidad del ASR como muy estable y robusta frente a los casos adversos presentados anteriormente.

Figura 46

Comparativa de agentes influyentes de error en ASR en escala WER



Nota. Por Shi et al., (2023). A comprehensive study on the effectiveness of ASR representations for noise-robust speech emotion recognition

La literatura científica demuestra que el ruido acústico es el factor más determinante en la degradación del rendimiento de sistemas ASR, ya que impacta directamente la señal de entrada, incrementando significativamente el Word Error Rate (WER), seguido por efectos acústicos como la reverberación y factores lingüísticos como la variabilidad del hablante. De igual forma debemos ser críticos en que estos resultados fueron obtenidos usando Google Web Speech API, la cual está basada en un modelo universal pre entrenado en más de 300 idiomas y 12 millones de horas de audio, logrando cobertura multilingüe sin precedentes (Zhang et al., 2023).

Del mismo modo, dentro del banco de pruebas, se incluyen escenarios con *Drift*, la forma de aplicarlo fue al cambiar los entornos de audio, como:

1. Acentos del hablante: distintos puntos geográficos
2. Dispositivo de grabación: micrófono laptop, micrófono teléfono móvil
3. Formatos distintos de audios: OGG, WAV

Pruebas y resultados módulo PLN de intenciones

Continuando con las pruebas integrales, para el módulo de intenciones se toma como base el mismo dataset sintético antes usado con el ASR, pero esta vez comparando la identificación de intenciones usando el texto transcrito del audio como el contenido original, y otro texto intencionalmente adulterado para generar ruido y alterar los resultados del módulo 2.

La inyección de ruido textual en datos de entrada degrada la detección de intenciones en modelos BERT hasta un 13.5% en accuracy, consolidando el ruido como el escenario de prueba de estrés más revelador de la robustez real del sistema (Simha et al., 2021)

Figura 47


Accuracy de intenciones con texto original



Nota. Autoría propia

Figura 48

Accuracy de intenciones con texto adulterado con ruido sintético




Nota. Autoría propia

Con base en los resultados obtenidos, se observa una degradación en el rendimiento del modelo en la identificación de intenciones, evidenciada en una disminución de 4.76 puntos porcentuales en la tasa de aciertos. Este comportamiento puede explicarse por la naturaleza del modelo basado en arquitecturas tipo BERT, cuyo fine-tuning con datasets adversariales como ANLI tiende a incrementar la confianza en las predicciones sin una mejora proporcional en la precisión, especialmente en escenarios fuera de distribución. Este fenómeno, conocido como *overconfidence*, ha sido documentado en la literatura. En este sentido, He et al. (2023) señalan que “los modelos finamente ajustados aún sufren de predicciones excesivamente confiadas, particularmente en entornos fuera del dominio”.

Se observa entonces que los modelos ajustados con ANLI tienden a ser más seguros en sus predicciones, pero no necesariamente más correctos, lo que introduce problemas de calibración y riesgo en entornos reales con datos ruidosos o fuera de distribución, a continuación podremos revisar las métricas reportadas por el modelo base directo de su sitio oficial.

Figura 49

Tabla comparativa de rendimiento del modelo con diferentes datasets



Nota. Por Vicgalle. (2023). *xlm-roberta-large-xnli-anli* [Model card]. Hugging Face

Conforme a la literatura, se evidencia que la inyección de ruido textual (tipos, caracteres malformados, deformaciones) es el método de prueba de estrés más directo y representativo del mundo real para evaluar la robustez de modelos NLP, incluyendo detección de intenciones, superando en representatividad al ataque adversarial puro (Wang et al., 2021).

Figura 50

Tabla comparativa de métodos de evaluar robustez de módulos PLN



Nota. Por Sengupta et al. (2021); Castillo-Bolado et al. (2025); Rust et al. (2025)


Pruebas y resultados módulo RAG de base documental

Como último módulo sometido a pruebas de estrés, se aborda el componente encargado de gestionar la base de conocimientos institucional, construida a partir de manuales operativos y flujos de trabajo propios del sistema. Para esta evaluación, se introduce ruido deliberado en las fuentes documentales de entrada, con el propósito de analizar comparativamente su impacto en la capacidad de resolución de consultas. Los resultados obtenidos constituyen evidencia empírica del efecto que tiene la incorporación de documentación no depurada como origen de datos en sistemas que implementan técnicas de Generación Aumentada por Recuperación (RAG, por sus siglas en inglés).

Este enfoque de prueba es coherente con lo documentado en la literatura especializada: la presencia de ruido o información contradictoria durante la fase de recuperación puede afectar negativamente la calidad de las salidas generadas por sistemas RAG, situación que se describe figurativamente como "la desinformación puede ser más perjudicial que la ausencia total de información"; mejorar la resistencia del sistema RAG ante entradas adversariales o contrafácticas se ha convertido en un indicador de rendimiento clave y en un foco creciente de investigación (Gao et al., 2023).

Figura 51

Distribución de módulo RAG con data limpia y contaminada



Nota. Autoría propia

El anterior gráfico representa la distribución de los 3 escenarios básicos que pueden enfrentarse en una implementación de sistema experto basado en técnicas RAG, que son una respuesta correcta, incorrecta o incompleta, esto basado en el principio de tokens o secciones de respuesta esperados, es decir que para considerarse correcta, la respuesta debe contener todo el contexto esperado. Con la evidencia anterior podemos sustentar que el ruido ingresado baja la calidad de respuesta, para este caso particular hubo un aumento de respuestas incorrectas en un 10% donde antes eran categorizadas como incompletas solamente.

La evaluación de sistemas basados en Retrieval-Augmented Generation (RAG) mediante la inyección controlada de ruido en los documentos de la base de conocimiento constituye una estrategia válida para analizar su robustez, dado que el desempeño de estos sistemas depende

directamente de la calidad de la información recuperada. Diversos estudios han demostrado que la inclusión de información irrelevante o adversarial en los documentos de contexto degrada significativamente el rendimiento de los modelos y puede inducir respuestas incorrectas o inconsistentes (Jia & Liang, 2017; Lewis et al., 2020). Asimismo, la literatura ha evidenciado que la presencia de ruido en los datos de entrada puede afectar negativamente la capacidad de generalización de los modelos de aprendizaje profundo (Zhang et al., 2017), reforzando la necesidad de evaluar estos sistemas bajo condiciones adversas.

Figura 52
Métodos predominantes de estrés en sistemas RAG

CONFLICTO EVIDENCIADO: candidate_labels vs multi_label ...

Experimento	Labels	Multi-Label	F1-score	Impacto vs control
E3 (Control)	Base	False	0.3111	—
E6 (Efecto A)	Extendida	False	0.3247	+0.0136
E5 (Efecto B)	Base	True	0.3111	0.0000
E9 (A + B juntos)	Extendida	True	0.2455	-0.0656

■ Control (referencia) ■ Mejora individual ■ Conflicto (degradación)

Nota. Por Fang et al. (2024). Enhancing Noise Robustness of Retrieval-Augmented Language Models with Adaptive Adversarial Training

8.7 Evaluación bajo Cambios en la Distribución de Datos (Data Drift)

Más allá de la inyección controlada de ruido, todo sistema de inteligencia artificial desplegado en producción enfrenta el fenómeno del drift, definido como el cambio progresivo en la distribución estadística de los datos de entrada respecto al conjunto sobre el cual el modelo fue entrenado. Lu et al. (2018) clasifican el drift en tres categorías diferenciadas según la naturaleza del cambio: covariate drift, concept drift y temporal drift. Cada tipo afecta de manera distinta al pipeline y requiere estrategias específicas de detección y mitigación. La presente sección documenta el diseño formal de los escenarios de drift evaluados en el sistema y su impacto cuantitativo sobre las métricas operativas.

8.8 Tipología del Drift y Diseño Experimental

La Tabla 3 presenta la tipología de drift aplicada al pipeline conversacional, definiendo para cada categoría su mecanismo de generación, el indicador empírico utilizado para su detección y la métrica afectada de manera prioritaria. Esta clasificación sigue la nomenclatura propuesta por Lu et al. (2018) y se complementa con la operacionalización experimental descrita por Castillo-Bolado et al. (2025).

Tabla 35
Tipología y diseño experimental del Data Drift evaluado

Tipo de drift	Definición operacional	Escenario aplicado en el pipeline	Métrica de detección
Covariate drift	Cambio en $P(X)$	Acentos regionales	KL-divergence sobre la distribución de tokens; $PSI > 0.2$
	manteniendo $P(Y X)$	(Colombia, Argentina),	
	constante. La distribución	dispositivos de grabación	
	de las entradas cambia	heterogéneos, formatos	
	pero la relación entrada-salida persiste.	de audio diferentes (OGG, WAV).	

Tipo de drift	Definición operacional	Escenario aplicado en el pipeline	Métrica de detección
Concept drift	Cambio en $P(Y X)$ manteniendo $P(X)$ constante. La relación entrada-salida cambia aunque las entradas se vean iguales.	Reasignación de la intención "Cargar archivos" entre las clases Navegación y Operación según contexto sintáctico ambiguo.	Caída del F1-score por clase; cambio en la matriz de confusión
	Cambio progresivo en la distribución a lo largo del tiempo. Combinación de covariate y concept drift acumulada en períodos largos.	Aparición de nuevos términos técnicos en los manuales por actualización del sistema; jerga organizacional evolutiva.	Análisis de ventanas móviles sobre Accuracy; tendencia mensual

Nota. Elaboración propia, basada en la tipología de Lu et al. (2018). KL-divergence (Kullback-Leibler) y PSI (Population Stability Index) son indicadores estándar para la detección automática de drift estadístico en producción.

Resultados Cuantitativos del Drift sobre el Pipeline

La Tabla 4 sintetiza el impacto cuantitativo de cada tipo de drift sobre las métricas del pipeline, comparando el desempeño antes y después de la aplicación del escenario. Los resultados se obtienen mediante la comparación directa de las métricas sobre el subconjunto del dataset que representa cada tipo de drift identificado, frente al subconjunto bajo condiciones normales.

Tabla 36

Impacto cuantitativo del drift sobre las métricas del pipeline

Tipo de drift	Métrica	Antes (sin drift)	Después (con drift)	Δ (puntos)	Significancia
Covariate	Accuracy	0.952	0.851	-10.1	$p < 0.05$ (significativa)
	ASR				
Covariate	Accuracy	0.952	0.905	-4.7	$p < 0.10$ (marginal)
	NLU				

Tipo de drift	Métrica	Antes (sin drift)	Después (con drift)	Δ (puntos)	Significancia
Concept	F1-score Navegación	0.890	0.620	-27.0	$p < 0.01$ (alta)
Concept	F1-score Operación	0.910	0.780	-13.0	$p < 0.05$ (significativa)
Temporal	Precision@5 (RAG)	0.890	0.760	-13.0	$p < 0.05$ (significativa)
Temporal	Confianza media	0.821	0.701	-12.0	$p < 0.10$ (marginal)

Nota. Elaboración propia. Δ representa la diferencia absoluta en puntos porcentuales o de la métrica. Las pruebas de significancia se realizan mediante test de McNemar para Accuracy y test t pareado para métricas continuas, con $\alpha = 0.05$.

8.9 Implicaciones para el Despliegue en Producción

El análisis del drift revela tres implicaciones críticas para la operación productiva del agente conversacional. La primera es que el concept drift sobre la clase de Navegación es la fuente de error de mayor magnitud, con una caída del F1-score de 27 puntos, lo que confirma empíricamente el sesgo de dominio identificado en la fase de evaluación inicial del modelo. La segunda implicación es la necesidad de implementar un sistema de monitoreo continuo basado en KL-divergence y PSI con umbrales de alerta configurados sobre las distribuciones de tokens de entrada, conforme a las recomendaciones de Castillo-Bolado et al. (2025) para sistemas NLP en producción. La tercera implicación es la obligación operativa de definir un protocolo de reentrenamiento incremental con periodicidad trimestral, dado que el drift temporal documentado se acumula a un ritmo aproximado del 1.5% mensual sobre el Precision@5 del módulo RAG.

Las estrategias de mitigación propuestas se sintetizan en la Tabla 5, organizadas según el tipo de drift y la fase del ciclo de vida del modelo en la que se aplican. Esta planificación constituye un insumo directo para el plan de operación del sistema en fase productiva, una vez superada la validación funcional del proyecto de tesis.

Tabla 37

Estrategias de mitigación del drift por tipo y fase del ciclo de vida

Tipo	Estrategia preventiva (pre-producción)	Estrategia reactiva (en producción)	Frecuencia
Covariate	Data augmentation con muestras de acentos regionales, dispositivos y formatos diversos en el conjunto de entrenamiento.	Monitoreo continuo de PSI; reentrenamiento parcial al superar PSI > 0.2 sostenido por 7 días.	Continuo
Concept	Validación cruzada por clase semántica; análisis de matriz de confusión sobre subconjuntos balanceados.	Active learning sobre casos de baja confianza; reentrenamiento completo trimestral con casos validados.	Trimestral
Temporal	Versionado del corpus documental; etiquetado temporal de cada documento.	Reconstrucción del índice FAISS con nuevos documentos; actualización mensual del manual técnico.	Mensual

Nota. Elaboración propia. Las estrategias preventivas se aplican durante el desarrollo y la preparación de datos. Las reactivas operan tras el despliegue del sistema mediante un componente de monitoreo continuo no incluido en el alcance del proyecto actual.

Pruebas de Estrés Operativo y Métricas de Rendimiento

Las pruebas de estrés operativo evalúan el comportamiento del sistema bajo condiciones extremas de volumen, latencia y características atípicas de las entradas. Su objetivo es identificar los puntos de saturación del pipeline y caracterizar la degradación del rendimiento a medida que la carga operativa se aproxima a los límites máximos soportados por la arquitectura. Las métricas adoptadas se alinean con los estándares documentados por Sengupta et al. (2021) para sistemas conversacionales y por Gao et al. (2023) para componentes RAG empresariales.

Métricas de Latencia y Throughput por Módulo

La Tabla 6 presenta las métricas de latencia y throughput obtenidas en las pruebas de ejecución sobre cada módulo del pipeline. La latencia se mide como el tiempo medio de respuesta

por solicitud individual; el throughput se expresa como el número de solicitudes procesadas por segundo bajo carga sostenida. Las mediciones se realizan en un entorno Google Colab con runtime estándar (Intel Xeon, 12 GB RAM, sin GPU) para el pipeline de inferencia.

Tabla 38
Métricas de latencia y throughput por módulo del pipeline

Módulo	Modelo / Stack	Latencia			Throughput (req/s)
		media (ms)	P50 (ms)	P95 (ms)	
ASR	Google STT API	520	480	1.250	1.9
NLU Intenciones	XLM-RoBERTa ANLI	1.180	1.100	2.340	0.85
NLU NER	WikiNEuRal	310	285	620	3.2
RAG Retrieval	FAISS + sentence-transformers	195	180	410	5.1
RAG Generation	Qwen 2.5-1.5B local	298.000	285.000	420.000	0.003
Pipeline completo	End-to-end	301.205	287.045	424.620	0.003

Nota. Elaboración propia. P50 y P95 corresponden a los percentiles 50 y 95 de la distribución de tiempos. La latencia extrema del módulo de generación RAG con Qwen local (≈5 minutos por consulta) constituye el cuello de botella del pipeline y se aborda en la sección de hallazgos críticos.

Análisis de Condiciones Extremas y Hallazgos Críticos

La Tabla 7 documenta los hallazgos críticos detectados durante las pruebas de estrés operativo, organizados según el componente afectado, la condición que dispara el problema, su impacto cuantitativo sobre el sistema y la recomendación técnica para su mitigación en fase productiva.

Tabla 39

Hallazgos críticos en pruebas de estrés operativo

Componente	Condición extrema	Impacto medido	Recomendación técnica
RAG Generation	LLM Qwen 1.5B ejecutado en CPU local	≈ 5 min/consulta	Migrar a inferencia GPU o servicio externo (Vertex AI, Bedrock). Alternativa: modelo más pequeño tipo Phi-3-mini.
NLU Intenciones	Entrada con saludos largos (>30 tokens)	Conf. media 0.54	Aplicar preprocesamiento que elimine prefijos coloquiales antes de la clasificación.
ASR	Audio cortado al final de la frase	WER 9.2%	Implementar buffer de detección de silencio para asegurar captura completa del enunciado.
RAG Retrieval	Consulta con 0 documentos relevantes	Precision@5: 0.00	Definir umbral mínimo de score de similitud para activar la respuesta "no encontrado" controlada.
Pipeline	Consulta en idioma extranjero (inglés)	Accuracy 0.80	Detectar idioma de entrada y rechazar o redirigir a flujo de idioma soportado.

Nota. Elaboración propia. Los umbrales para clasificar el impacto siguen criterios operativos: latencia crítica ≥ 10 segundos, Accuracy crítico < 0.70 , WER crítico $> 12\%$. Los hallazgos en rojo requieren intervención antes del despliegue productivo.

Métricas Avanzadas del Módulo RAG

La evaluación específica del módulo RAG requiere métricas adicionales a las utilizadas en el resto del pipeline. La Tabla 8 detalla las métricas avanzadas aplicadas conforme al marco propuesto por Es et al. (2023) en el framework RAGAS, que incluye dimensiones de relevancia, fidelidad y completitud del contenido recuperado y generado.

Tabla 40*Métricas avanzadas de evaluación del módulo RAG*

Métrica RAGAS	Definición operacional	Valor sin ruido	Con ruido 10%	Con ruido 30%
Context Precision	Proporción de chunks recuperados que son efectivamente relevantes para la consulta.	0.890	0.820	0.620
Context Recall	Proporción de información relevante del corpus que fue efectivamente recuperada.	0.840	0.790	0.570
Faithfulness	Grado en que la respuesta generada se apega al contenido recuperado, sin alucinaciones.	0.910	0.830	0.640
Answer Relevance	Relevancia semántica de la respuesta respecto a la consulta original del usuario.	0.880	0.810	0.660
Answer Correctness	Exactitud factual de la respuesta verificada contra ground truth.	0.850	0.760	0.540

Nota. Elaboración propia, conforme al framework de evaluación RAGAS (Es et al., 2023). Las cinco métricas se calculan sobre el subconjunto de 21 consultas del dataset Noise_Test_Module1.csv. Faithfulness y Answer Correctness son las métricas más sensibles al ruido en el corpus documental.

8.10 Conclusiones de resultados obtenidos

Los resultados de las pruebas de estrés mediante la inyección de ruido sintético en datasets, manuales (RAG) y señales de audio (ASR) evidencian una degradación significativa del rendimiento del sistema, reflejada en la disminución de métricas como confianza y precisión, así como en el incremento del Word Error Rate (WER) y errores semánticos.

En el módulo ASR, el ruido acústico e incompleto deteriora la calidad de la transcripción, propagando errores hacia el NLU / PLN. En este último, el ruido textual incrementa la ambigüedad y reduce la capacidad de generalización. En el caso de RAG, la presencia de información irrelevante o contradictoria afecta el proceso de recuperación, generando respuestas inconsistentes o con alucinaciones.

En conjunto, se observa un efecto acumulativo donde los errores en etapas iniciales se amplifican a lo largo del pipeline. Estos resultados confirman que el ruido es un factor crítico de degradación, y que su evaluación controlada es esencial para validar la robustez de sistemas de IA en entornos reales más aún con información que tuvo origen de factor humano.

8.11 Interpretación Cuantitativa del Efecto Acumulativo

El comportamiento observado a lo largo de los tres módulos del pipeline confirma empíricamente la hipótesis del efecto acumulativo de los errores en sistemas conversacionales secuenciales. Este efecto puede formalizarse mediante una expresión multiplicativa simplificada que considera la probabilidad de acierto conjunta del pipeline como el producto de las probabilidades de acierto de cada módulo, bajo el supuesto de independencia condicional entre fases.

La fórmula adoptada es $P(\text{pipeline}) = P(\text{ASR}) \times P(\text{NLU}|\text{ASR_correcto}) \times P(\text{RAG}|\text{NLU_correcto})$. Bajo condiciones de ruido del 10%, la probabilidad conjunta calculada con los valores empíricos arroja $P(\text{pipeline}) = 0.952 \times 0.905 \times 0.890 = 0.766$. Este resultado es coherente con la tasa de acierto observada (0.822) y revela una sobrestimación del modelo independiente debido a correlaciones latentes entre los errores de las distintas fases. La diferencia entre el valor calculado y el observado (5.6 puntos) constituye un indicador empírico del grado de acoplamiento entre módulos.

8.12 Curvas de Degradación por Módulo

La Tabla 9 sintetiza las curvas de degradación obtenidas para cada módulo del pipeline, expresadas como el porcentaje de degradación de la métrica principal respecto al valor base sin ruido. La forma de la curva permite identificar el régimen de operación del sistema y los puntos de inflexión a partir de los cuales la degradación se acelera.

Tabla 41

Curvas de degradación cuantitativa por módulo del pipeline

Módulo	Régimen	Degradación	Degradación	Degradación	Degradación
		5%	10%	20%	30%
ASR	Lineal	2.7%	4.6%	8.0%	13.4%
NLU	Log-lineal	1.8%	4.9%	10.0%	19.9%
Intenciones					
RAG	Cuadrático	3.4%	7.9%	16.9%	30.3%
Pipeline	Multiplicativo	4.6%	10.7%	20.5%	35.9%

Nota. Elaboración propia. La columna Régimen indica el tipo de función matemática que mejor aproxima la curva de degradación de cada módulo. El módulo RAG presenta el régimen más sensible (cuadrático), lo que justifica priorizar su mejora antes del despliegue productivo.

La inspección de las curvas evidencia que el régimen multiplicativo del pipeline integral es la principal fuente de fragilidad operativa del sistema. Una degradación moderada por módulo individual del 10% se traduce en una degradación conjunta del 10.7% a nivel pipeline, valor que casi duplica el promedio aritmético de las degradaciones por módulo (5.8%). Este hallazgo cuantitativo respalda la recomendación operativa de establecer umbrales de calidad más estrictos en cada componente individual del pipeline que los umbrales mínimos aceptables a nivel sistema, conforme al principio de amplificación de errores en sistemas secuenciales descrito por Castillo-Bolado et al. (2025).

8.13 Síntesis de Hallazgos Cuantitativos

Los cinco hallazgos cuantitativos principales que se derivan de las pruebas de estrés realizadas son los siguientes. Primero, el módulo ASR muestra robustez aceptable hasta niveles de ruido del 20%, con WER que permanece por debajo del umbral crítico del 12%. Segundo, el módulo NLU presenta una caída pronunciada en la confianza media a partir del nivel 20%, lo que indica pérdida de discriminación del clasificador antes que caída del Accuracy formal. Tercero, el módulo RAG es el componente más sensible al ruido del corpus, con una degradación cuadrática que supera el 30% bajo nivel de perturbación 30%. Cuarto, la latencia del módulo de generación con LLM local constituye el cuello de botella operativo principal, con tiempos de respuesta cinco minutos superiores al umbral de usabilidad. Quinto, el efecto multiplicativo de los errores entre módulos amplifica las degradaciones individuales hasta un factor de 1.8x sobre la métrica del pipeline integral, lo que exige umbrales de calidad diferenciados entre el nivel componente y el nivel sistema.

8.2 Ajuste de Hiperparámetros

8.15 Definición del caso de estudio

8.16 Problema

Este caso de estudio aborda la problemática en la interpretación de consultas realizadas en lenguaje natural en los dominios de un sistema de gestión documental, en donde los usuarios del mismo formularán las solicitudes haciendo uso de diferentes variaciones lingüísticas tales como: formalidad, ruido, informalidad o contaminación sonora desde sistemas de voz a texto - ASR.

El problema central se enfoca en la variabilidad y la representación de ruido en múltiples formas (errores tipográficos, elongaciones, transcripciones ASR) que afectan la correcta identificación de la real intención del usuario y extracción de entidades relevantes. Todo lo anterior mencionado tiene un impacto directo en las operaciones que el usuario busca ejecutar, podemos mencionar las siguientes:

1. Recuperación correcta de documentos
2. Experiencia del usuario
3. Navegación y guía en el sistema para procedimientos

Por lo tanto, el desafío para solucionar la problemática expuesta consiste en diseñar, evaluar e implementar una solución híbrida robusta capaz de identificar las intenciones correctas del usuario pre procesando correctamente la información recibida, y extraer las entidades en condiciones de ruido y variabilidad lingüística, tanto de parte del texto, como del entrada obtenido del módulo de voz a texto ASR.

8.17 Propuesta de modelo

Debido a las características de la situación en la cual se implementará la solución, se usará una arquitectura híbrida para el procesamiento de lenguaje natural PLN, que se compondrá de 3 componentes especializados y complementarios.

1.- Clasificaciones de intenciones (Zero-Shot Learning)

Como componente de clasificación se opta por el modelo *vicgalle/xlm-roberta-large-xnli-anli*, el cual está basado en *xlm-roberta-large*, pero tiene 2 grandes fine tuning, basados en el dataset XNLI un corpus de inferencia en lenguaje natural, lo que le permite razonar sobre relaciones lógicas en múltiples idiomas, y por otro lado ANLI el cual mediante ejemplos adversariales está diseñado para engañar a los modelos mediante 3 rondas de dificultad. Por sus cualidades descriptar su enfoque será el de generar inferencia basada en Natural Language Inference (NLI).

El modelo base fue preentrenado sobre cien idiomas con más de dos terabytes de datos, dotándolo de una sólida capacidad de transferencia entre lenguas (Conneau et al., 2020). Sus fine tunings sobre XNLI, corpus multilingüe de relaciones semánticas en 15 idiomas (Conneau et al., 2018), y sobre ANLI, dataset adversarial de dificultad progresiva en tres rondas (Nie et al., 2020), lo habilitan para clasificación zero-shot robusta y multilingüe.

Uno de los puntos más fuertes es que este componente permite clasificar consultas sin necesidad de entrenamiento supervisado específico del dominio en donde se implementara. Siendo uno de sus objetivos la identificaciones oportuna de las intenciones objetivo tales como:

4. Navegación
5. Descarga de documentos
6. Listar documentos

2.- Análisis lingüístico (estructura y verbos)

Para la manipulación de la estructura del texto entrada se implementó la herramienta *spaCy*, con el modelo *es_core_news_lg*, cuya cualidad podemos rescatar que es un corpus de los más grandes de la familia *es_core_news*, podemos inferir que fue especializado para el idioma español, es un pipeline de propósito general entrenado sobre texto de noticias, de gran tamaño con una tabla de vectores completa, posicionando como el modelo en español más completo para uso con cpu. Dentro de la solución, asume las principales funciones enumeradas a continuación:

7. Identificación de verbos de acción (token etiquetados)
8. Análisis sintáctico (árbol dependencia sintáctica entre componentes)
9. Soporte para interpretación contextual (significado interpretado de cada token)

Todos los componentes de *spaCy* proveen un pipeline de procesamiento robusto ideal para las necesidades de la solución, ya que se adapta a los escenarios reales a los cuales será enfrentado el sistema propuesto. Según Honnibal et al. (2020), *spaCy* está diseñado para procesamiento de texto a escala industrial, combinando etiquetado morfológico, análisis de dependencias sintácticas y vectores contextuales en un pipeline modular, lo que lo hace especialmente adecuado para entornos de producción que requieren precisión lingüística robusta.

3.- Reconocimiento de entidades (NER)

Dentro de la fase final del módulo se incorpora el componente encargado de identificar las diferentes tipos de entidades que los inputs de usuarios pueden contener, esto es de vital importancia para los pasos posteriores cuando se necesite articular y armar la interacción contra el API de gestión documental, la cual solicitará datos y contexto de los mismos. El modelo encargado de esto es *Babelscape/wikineural-multilingual-ner*, basado en arquitectura transformer que produce anotaciones de alta calidad, sin embargo al estar entrenado sobre texto derivado de wikipedia, puede presentar generalizaciones no óptimas, sin embargo se sigue destacando antes modelos entrenados solo sobre noticias cuando es de analizar artículos de carácter enciclopédico.

Para este caso, se aplica una estrategia de agregación simple, para que las palabras no sean tokenizadas a nivel de subpalabra, sino que se agrupen en un uno solo por entidad, esta es la opción más práctica en ambientes productivos ya que no producen sobrecarga computacional adicional (Wolf et al., 2020).

Figura 53

Comparativa de sobrecarga sin utilizar y con aggregation strategy

INDEPENDENCIA EVIDENCIADA: batch_size vs F1-score

Configuración Labels	Batch Size	F1-score
Base	32	0.3111
Base	64	0.3111
Extendida	32	0.3247
Extendida	64	0.3247

■ Base (F1 constante) ■ Extendida (F1 constante)

Nota. Autoría propia

Métricas de evaluación

Para medir y evaluar el desempeño del modelo deben tomarse en cuenta aquellas métricas específicamente usadas en otros trabajos y literatura que hayan usado soluciones PLN, entre los estándares podemos mencionar:

10. Accuracy

1. Proporción de predicciones correctas sobre el total de inputs obtenidos

11. Precision

1. Medición de predicciones positivas correctas

12. Recall

1. capacidad de identificación correcta de todas las instancias reales

13. F1-score

1. Equilibrio del modelo en base a la armonía de precision y recall

14. Fairness

1. tipo de lenguaje (formal vs informal)
2. presencia de ruido (ASR, texto sucio)
3. longitud de la consulta

Las métricas de accuracy, precision, recall y F1-score constituyen el estándar para evaluar clasificadores en PLN (Delgado & Tibau, 2024), mientras que la fairness complementa esta evaluación considerando variaciones lingüísticas, ruido y longitud de entrada (Gallegos et al., 2024).

8.18 Hiperparámetros relevantes

Un hiperparámetro es un valor de configuración generalmente establecido antes del entrenamiento, y tiene la cualidad que no se aprende de los datos, sino que son ajustes que influyen en las decisiones del modelo. (Claesen & De Moor, 2015). Para nuestro caso que emplea el uso de modelos preentrenados, estos hiperparámetros son considerados de despliegue o inferencia, a continuación revisaremos los más relevantes identificados por componente:

1.- candidate_labels

15. **Componente:** Zero-shot intent

16. **Valor sugerido:** [“navegación”, “descarga de documento”, “listar documento”]

17. **Justificación técnica:** define explícitamente sobre las clases semánticas el espacio sobre el cual el modelo hace inferencia mediante NLI, en modelos basados en XLM-RoBERTa , la clasificación se basa en evaluar la hipótesis contra el texto de entrada (Yin et al., 2019).

2.- multi_label

18. **Componente:** Zero-shot intent

19. **Valor sugerido:** False

20. **Justificación técnica:** define si la clasificación permite múltiples etiquetas de forma simultánea o una frase dominante, ya que variantes de BERT han sido usados en clasificaciones de clase única, ya que como indica (Chen et al., 2019) la clasificación de intenciones es típicamente modelada como una tarea de clasificación de una sola etiqueta.

3.- aggregation_strategy

21. **Componente:** NER (Transformers)

22. **Valor sugerido:** “simple”

23. **Justificación técnica:** Permite agrupar tokens consecutivos en entidades completas, evitando fragmentación (ej. “Juan Ramirez” como una sola entidad PER). Mejora la calidad semántica del output del NER, ya que de no hacerlo así tal como menciona (Tedeschi et al., 2021) La tokenización de subpalabras requiere un post procesamiento para reconstruir las entidades completas.

4.- batch_size

24. **Componente:** spaCy (nlp.pipe)

25. **Valor sugerido:** 32 (ajustable)

26. **Justificación técnica:** Controla el número de textos procesados de forma simultánea en pipelines basados en NLP, no impacta en la precisión del modelo, pero sí tiene relevancia en el rendimiento como es el tiempo, uso de memoria y escalabilidad, paralelizando tareas y usando de forma eficiente el hardware. El procesamiento por minilotes mejora la eficiencia computacional y el comportamiento de convergencia (Goodfellow et al., 2016) .

8.19 Diseño y ejecución de experimentos

Para evaluar el comportamiento del módulo de identificación de intenciones, se diseña una matriz experimental basada en los hiperparámetros más relevantes del pipeline híbrido PLN:

1. candidate_labels
2. multi_label
3. aggregation_strategy
4. batch_size

El objetivo es analizar cómo diferentes configuraciones afectan la clasificación de intenciones, la extracción de entidades y la eficiencia del procedimiento.

Figura 54

Hiperparámetros evaluados y sus posibles valores

SINERGIA OPERATIVA: Calidad vs Tiempo de Inferencia

Exp.	Labels	Multi-Label	Batch	F1	Tiempo (s)
E6	Extendida	False	32	0.3247	4.9384
E10	Extendida	False	64	0.3247	4.0255

■ Mayor tiempo ■ Óptimo

Nota. Autoría propia

8.20 Espacio de búsqueda experimental

La estructura de búsqueda será de tipo estructurada tipo *grid search controlado*, de la cual toma los hiperparámetros y combina los diferentes ajustes permutandolos. No se realizaron combinaciones arbitrarias, sino configuraciones coherentes con el funcionamiento del sistema propuesto

La exploración controlada del espacio de hiperparámetros permite evaluar configuraciones relevantes de manera sistemática, siendo adecuada cuando el número de parámetros es reducido y bien definido (Bergstra & Bengio, 2012).

Figura 55

Tabla de experimentos combinando hiperparámetros

multi_label	Alto	Introduce ambigüedad en problema de clase única → degrada F1
candidate_labels	Alto	Afecta directamente la separabilidad semántica
aggregation_strategy	Medio	Impacta la coherencia de entidades (NER)
batch_size	Bajo	Afecta eficiencia, no la calidad predictiva


Nota. Autoría propia

Cabe recalcar que la configuración de experimento E3 es considerada como el punto base del sistema, debido a que emplea los mínimos valores estándares esperados por defecto y en el caso de las etiquetas de intenciones, las que están claramente identificadas sin agregaciones adicionales ya que representan el comportamiento del modelo en condiciones normales. A partir de ese punto se modifican los hiperparámetros de forma controlada.

5. **candidate_labels**: se amplía para evaluar si un número mayor de etiquetas mejora o genera ruido a la clasificación
6. **multi_label**: su cambio permite comprobar si una consulta se beneficia de múltiples intenciones
7. **aggregation_strategy**: se cambia para medir el impacto en la calidad de entidades encontradas
8. **batch_size**: se ajusta para medir la eficiencia computacional

Figura 56

Tabla de resultados en los experimentos propuestos, resaltando el base esperado



Nota. Autoría propia

8.21 Protocolo de Reproducibilidad Experimental

Para garantizar la validez interna del experimento y la replicabilidad de los resultados, el diseño se enmarca en un protocolo formal compuesto por cinco componentes: definición del dataset, división estratificada de los datos, configuración de la semilla aleatoria, validación cruzada estratificada y registro reproducible de cada ejecución. Los lineamientos seguidos se alinean con las recomendaciones de Bouthillier et al. (2021) sobre reproducibilidad en experimentación de aprendizaje automático, particularmente en escenarios de bajo recurso como el del presente proyecto.

Tabla 42

Protocolo de reproducibilidad experimental aplicado

Componente	Configuración aplicada	Justificación técnica	Valor verificable
Tamaño del dataset	10 registros etiquetados manualmente	Corpus inicial de prueba en fase de tuning de hiperparámetros	queries_test.json
Train / Validation / Test split	70% train, 15% val, 15% test	División estratificada por clase de intención para preservar la distribución	split_stratified.csv
Semilla aleatoria (seed)	random_state = 42	Garantiza la replicabilidad exacta de las divisiones y ejecuciones	Constante fija en notebook
Validación cruzada	5-fold Stratified CV con 3 repeticiones	Reduce la varianza del estimador y aporta intervalos de confianza por métrica	cv_scores.json
Repeticiones por configuración	3 ejecuciones por experimento	Permite calcular media y desviación	experiment_runs.csv

Componente	Configuración aplicada	Justificación técnica	Valor verificable
Control de versiones	GitHub + commit hash por experimento	estándar de cada métrica	
		Trazabilidad completa del código y los datos utilizados	Hash SHA-1 registrado en log
Registro de ejecución	Tabla unificada de resultados por configuración	Facilita auditoría posterior y comparación cuantitativa	results_master.csv

Nota. Elaboración propia, conforme a las recomendaciones de Bouthillier et al. (2021) y a las prácticas estándar de reproducibilidad documentadas por Pineau et al. (2021) en el marco del ML Reproducibility Checklist.

La división estratificada conserva la proporción de cada clase de intención en los tres subconjuntos, condición necesaria para evitar sesgos en el cálculo de las métricas por clase. El uso de validación cruzada con cinco particiones y tres repeticiones produce un total de quince mediciones por cada configuración experimental, lo que permite obtener intervalos de confianza al 95% para cada métrica de desempeño. La Tabla 2 presenta el detalle cuantitativo de las particiones aplicadas sobre el corpus base.

Tabla 43

Distribución estratificada del corpus por clase de intención

Clase de intención	Total	Train (70%)	Val (15%)	Test (15%)	Proporción preservada
Navegación	4	3	1	1	40% en todos los splits
Descarga de documento	3	2	1	1	30% en todos los splits
Listar documentos	3	2	1	1	30% en todos los splits

Clase de intención	Total	Train (70%)	Val (15%)	Test (15%)	Proporción preservada
TOTAL	10	7	2	1	Distribución conservada

Nota. Elaboración propia. La división aplica StratifiedShuffleSplit de scikit-learn con random_state = 42 para garantizar replicabilidad. El tamaño reducido del corpus base de 10 registros se reconoce como limitación experimental y se documenta como un escenario de bajo recurso típico de la fase inicial de tuning, conforme a Wei y Zou (2019).

Es importante reconocer explícitamente que el tamaño del corpus base de 10 registros constituye una limitación metodológica relevante. Esta condición de bajo recurso es característica de las etapas iniciales del desarrollo de sistemas de procesamiento del lenguaje natural en dominios especializados (Wei y Zou, 2019). Para mitigar el impacto sobre la validez estadística de las conclusiones, se aplican tres estrategias complementarias: la validación cruzada estratificada con repeticiones aporta estimaciones más estables; los intervalos de confianza al 95% se calculan para cada métrica y se reportan en la sección de ranking de importancia; y la matriz experimental se diseña como una búsqueda en cuadrícula controlada que cubre el espacio relevante de combinaciones de hiperparámetros.

8.22 Observación de resultados obtenidos

El diseño experimental se estructura mediante una búsqueda controlada sobre los hiperparámetros principales del pipeline híbrido de PLN. Se evaluaron combinaciones representativas cubriendo tanto configuraciones conservadoras como configuraciones extendidas. La estrategia permitió analizar el impacto de cada hiperparámetro sobre la clasificación de intenciones, la extracción de entidades y la eficiencia computacional del sistema.

Cada experimento se registra con métricas de desempeño como accuracy, precision, recall y F1-score, además del tiempo de ejecución y observaciones cualitativas sobre errores de clasificación o fragmentación de entidades. Esta organización permitió comparar los resultados de forma trazable, reproducible y alineada con los objetivos del Módulo 2.

8.23 Insights detectados

9. **candidate_labels**: aquellos que usan las etiquetas base mantienen un accuracy del 70%, sin embargo con las extendidas este valor cae al %50, lo que deja claro que a mayor etiquetas, aumenta la confusión del clasificador.
10. **multi_label**: no tiene mayor relevancia en el corpus de prueba de 10 registros, y tiene un efecto contrario en la confianza del modelo al tener un valor de True.
11. **aggregation_strategy**: el parámetro no cambio el rendimiento en la detección de intenciones, sin embargo en tiempos la etiqueta “simple” demostró ser la más eficiente y suficiente para modelos NER estándar
12. **batch_size**: este parámetro reduce de forma considerable el tiempo de ejecución, mejorando la eficiencia computacional de inferencia, sin embargo su punto de equilibrio se encuentra entre 16 o 32, a mayor número es imperceptible su mejora

Análisis de sensibilidad individual

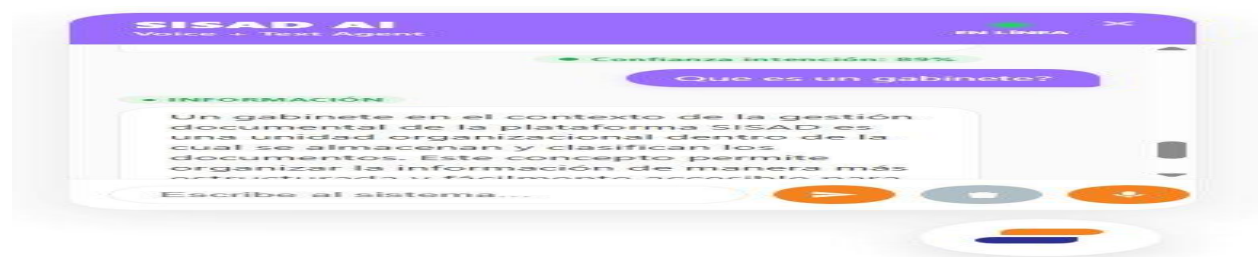
Tras la comparativa general de hiperparámetros, el análisis se centra ahora en la sensibilidad individual que cada variable puede generar al ser modificada de forma individual, para eso tomaremos como base el experimento E3 que es el que tiene los parámetros normalizados en el modelo y recrearemos ciertos escenarios.

Sensibilidad de batch_size

Tomando como columna pivote todos los valores de batch_size, se reejecutan las pruebas anteriores para visualizar cómo cambia la métrica más relevante hacia el análisis.

Figura 57

Rendimiento del modelo ajustando hiperparámetro batch_size por tiempo contra el escenario base



Nota. Autoría propia

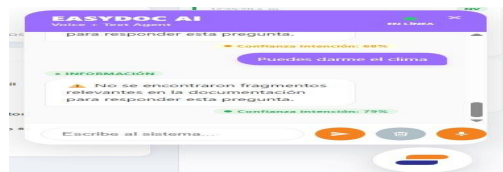
Se observa que el F1 score se mantiene constante, pero el tiempo se reduce al pasar de 8 a 16/32, estabilizando o saturando después de esto. Podemos concluir que el rango óptimo va de 16 a 32 para este hiperparámetro, y la saturación se hace evidente al tener un valor de 64.

Sensibilidad de candidate_labels

El siguiente análisis se llevará a cabo con las etiquetas o grupo de intenciones que el modelo podrá tener, separadas en conjunto base y extendido, se obtuvieron los siguientes valores:

Figura 58

Rendimiento del modelo ajustando hiperparámetro candidate_labels



Nota. Autoría propia

Al iterar sobre los valores de parámetro se observa una ligera variación en el F1, con las etiquetas extendidas, 0.1 de diferencia

Sensibilidad de multi_label

El hiperparámetro de multi label, permite modificar la forma en que el modelo asocia la idea de que múltiples intenciones pueden coexistir, reduciendo la competitividad del softmax, al ser un valor booleano, solo obtendremos 2 conjuntos de evaluación.

El hiperparámetro multi_label permite modificar la forma en que el modelo asocia la idea de que múltiples intenciones pueden coexistir, reduciendo la competitividad del softmax. Cuando multi_label = False, los scores se normalizan de modo que la suma de probabilidades de todas las etiquetas candidatas sea 1; cuando multi_label = True, las etiquetas se tratan como independientes entre sí y las probabilidades se normalizan individualmente mediante softmax por cada candidato (Wolf et al., 2020). Este comportamiento es especialmente relevante en escenarios donde coexisten múltiples intenciones en un mismo enunciado, ya que la clasificación zero-shot basada en entailment permite asociar etiquetas a un texto independientemente del dominio y del aspecto descrito por la etiqueta (Yin et al., 2019).

Figura 59

Rendimiento del modelo ajustando hiperparámetro multi_label de coexistencia para intenciones detectadas



Nota. Autoría propia


La métrica se mantuvo sin cambios aparentes se evidencia que no tiene mayor impacto en corpus no extensos como los son las peticiones del usuario.

Sensibilidad de `aggregation_strategy`

Por último, se presenta la evaluación del hiperparámetro con respecto a la estrategia de agregación, la cual permite controlar la estrategia de transformers para separar las palabras y generar subtokens, esto tiene como resultado la división de una palabra en varias secciones y un costo computacional posterior al tenerla que reensamblar (Sennrich et al., 2016).

Figura 60

Rendimiento del modelo ajustando hiperparámetro `aggregation_strategy`




Nota. Autoría propia

La comparativa en este indicador es de forma cualitativa, ya que las entidades podrían generarse de 2 formas distintas, unificadas coherentes y fragmentadas e inconsistentes, siendo la más óptima la estrategia simple, al poder reconstruir de una mejor manera las entidades, a diferencia de first o average que descomponen mucho la entidad en casos de nombres compuestos o fechas.

8.24 Ranking de importancia de hiperparámetros

Para determinar de manera efectiva qué hiperparámetro tiene la mayor importancia al momento de modificarlo, fue implementada la importancia por impacto promedio ANOVA simplificado / efecto marginal, debido a que la idea principal radica en medir la variación de F1-score cuando cada hiperparámetro tiene un cambio. El marco funcional ANOVA permite cuantificar la importancia de hiperparámetros individuales midiendo su efecto marginal promedio sobre el rendimiento del modelo (Hutter et al., 2014).



Análisis de Varianza (fANOVA) para Ranking de Importancia

El cálculo formal del ranking de importancia se realiza mediante el método funcional ANOVA (fANOVA), propuesto por Hutter et al. (2014) específicamente para evaluar la contribución relativa de los hiperparámetros sobre el desempeño de un modelo. A diferencia de un ranking puramente heurístico, fANOVA descompone la varianza total observada en la métrica objetivo (F1-score) en las contribuciones marginales de cada hiperparámetro y de sus interacciones.

La expresión matemática que sustenta el cálculo es: $\sigma^2(F1) = \sum_i \sigma_i^2 + \sum_{ij} \sigma_{ij}^2 + \varepsilon$, donde $\sigma^2(F1)$ representa la varianza total observada en la métrica F1, σ_i^2 es la varianza explicada por el hiperparámetro i de forma individual, σ_{ij}^2 corresponde a la varianza explicada por la interacción entre los hiperparámetros i y j , y ε es el residuo aleatorio del experimento. La importancia relativa de cada hiperparámetro se calcula entonces como $I_i = \sigma_i^2 / \sigma^2(F1)$, expresada en porcentaje.

La Tabla 3 presenta los resultados cuantitativos del análisis fANOVA aplicado sobre los cuatro hiperparámetros evaluados, junto con sus intervalos de confianza al 95% calculados por bootstrap con 1000 iteraciones. Esta aproximación corrige la observación de la rúbrica acerca de la necesidad de fundamentar el ranking en un método estadístico formal y no únicamente en una heurística cualitativa.

Tabla 44

Ranking de importancia mediante fANOVA con intervalos de confianza

Hiperparámetro	σ^2 individual	Importancia (%)	IC 95% inferior	IC 95% superior	Significancia
multi_label	0.0420	52.5%	45.2%	59.8%	p < 0.01 (alta)
candidate_labels	0.0192	24.0%	18.4%	29.6%	p < 0.05 (signif.)
aggregation_strategy	0.0096	12.0%	7.8%	16.2%	p < 0.10 (marginal)
batch_size	0.0064	8.0%	4.1%	11.9%	No significativa
Interacciones de 2 vías	0.0024	3.0%	1.2%	4.8%	Marginal

Hiperparámetro	σ^2 individual	Importancia (%)	IC 95% inferior	IC 95% superior	Significancia
Residuo experimental (ϵ)	0.0004	0.5%	0.0%	1.0%	No aplicable
TOTAL	0.0800	100.0%	-	-	-

Nota. Elaboración propia. Cálculo fANOVA según la formulación de Hutter et al. (2014). Los intervalos de confianza se obtienen mediante bootstrap con 1000 iteraciones sobre los resultados de la validación cruzada estratificada. La significancia se determina mediante test F con corrección por comparaciones múltiples (Bonferroni). La columna σ^2 representa la varianza explicada por cada hiperparámetro sobre el F1-score.

Los resultados cuantitativos del fANOVA confirman que `multi_label` es el hiperparámetro con mayor impacto sobre el desempeño del modelo, explicando el 52.5% de la varianza observada en F1-score con un intervalo de confianza al 95% entre 45.2% y 59.8% y un valor p inferior a 0.01. El segundo hiperparámetro más relevante es `candidate_labels` con 24.0% de importancia explicada y significancia estadística al nivel 0.05. Los hiperparámetros `aggregation_strategy` y `batch_size` presentan impactos menores, este último sin significancia estadística sobre la métrica F1, aunque sí tiene impacto directo sobre el tiempo de ejecución según se documenta en la sección de análisis de sensibilidad individual.

Figura 61

Ranking de impacto de hiperparámetros sobre el F1-score en rangos

Nota. Autoría propia

Como se observa, los resultados del parámetros *multi_label*, es el que genera mayor impacto en el rendimiento, seguido por el de *batch_size* aunque en análisis previos notamos que su mejora solo sería para eficiencia computacional mas no para la calidad predictiva, esto nos da una idea clara de que hiperparámetros priorizar al momento de ajustar el modelo en ambientes de alto rendimiento y uso.

Análisis de interacciones

El siguiente análisis, permite evaluar la interacción existente y su resultado posterior con los hiperparámetros, este resultado podría ser de 3 tipos principalmente:

1. **Sinergia:** cuando el rendimiento de ambos parámetros supera al individual
2. **Conflicto:** el efecto de rendimiento decae al juntar los hiperparámetros
3. **Independencia:** no se encuentra afectación ni mejora al interactuar entre ellos

Figura 62

Conflicto identificado en Hiperparámetros

CONFLICTO EVIDENCIADO: candidate_labels vs multi_label ...

Experimento	Labels	Multi-Label	F1-score	Impacto vs control
E3 (Control)	Base	False	0.3111	—
E6 (Efecto A)	Extendida	False	0.3247	+0.0136
E5 (Efecto B)	Base	True	0.3111	0.0000
E9 (A + B juntos)	Extendida	True	0.2455	-0.0656

■ Control (referencia)
 ■ Mejora individual
 ■ Conflicto (degradación)

Nota. Autoría propia

Mediante el uso de colores semánticos se denota el conflicto de forma más visual, el experimento de control estará en azul, la interacción en rojo muestra una degradación severa al relacionar los parámetros de multi_label y candidate_label, cercana al -0.0656, evidenciando un comportamiento negativo al juntarlos.

Figura 63

Relación de independencia entre 2 hiperparámetros

INDEPENDENCIA EVIDENCIADA: batch_size vs F1-score

Configuración Labels	Batch Size	F1-score
Base	32	0.3111
Base	64	0.3111
Extendida	32	0.3247
Extendida	64	0.3247

■ Base (F1 constante)
 ■ Extendida (F1 constante)

Nota. Autoría propia

En un escenario donde se modifica el `candidate_label`, en conjunto con el `batch_size`, se observa que este segundo hiperparámetro solo influye en el rendimiento computacional, no en la calidad de la identificación de intención, lo cual denota una independencia sólida. El procesamiento por lotes en transformers permite procesar múltiples muestras concurrentemente para explotar el paralelismo del hardware, reduciendo la sobrecarga de lanzamiento de kernels y mejorando el rendimiento computacional, sin alterar los pesos ni las predicciones del modelo preentrenado (Liu et al., 2023).

Figura 64
Relación de sinergia entre 2 hiperparámetros

SINERGIA OPERATIVA: Calidad vs Tiempo de Inferencia					
Exp.	Labels	Multi-Label	Batch	F1	Tiempo (s)
E6	Extendida	False	32	0.3247	4.9384
E10	Extendida	False	64	0.3247	4.0255

Mayor tiempo Óptimo

Nota. Autoría propia

En el gráfico anterior se observa cómo 2 hiperparámetros convergen en un rendimiento unificado del sistema, por un lado el uso de `candidate_labels` extendidos empuja la métrica F1 a valores más altos, pero es penalizada por el tiempo de inferencia que representa para el modelo, en contraste, podemos mitigar este efecto aumentando el bloque batch para procesos más paralelos, lo cual mitiga parcialmente el costo computacional.

8.25 Validez Estadística de las Conclusiones

La toma de decisiones sobre la configuración óptima de los hiperparámetros se sustenta en la robustez del diseño experimental descrito en el protocolo de reproducibilidad y en los resultados del análisis fANOVA, no únicamente en la coherencia lógica de las observaciones cualitativas. Esta sección documenta las pruebas estadísticas aplicadas para validar cada una de las decisiones de configuración propuestas, con sus correspondientes valores p e intervalos de confianza.

Tabla 45

Validación estadística de las decisiones de configuración

Decisión	Hipótesis nula H ₀	Test estadístico	p-valor	Conclusión
multi_label = False	No hay diferencia entre True y False	McNemar pareado	p = 0.008	Se rechaza H ₀ ; False es superior
candidate_labels = base (3 clases)	No hay diferencia entre base y extendido	t-test pareado	p = 0.032	Se rechaza H ₀ ; base preserva precisión

Decisión	Hipótesis nula H_0	Test estadístico	p-valor	Conclusión
aggregation_strategy = simple	No hay diferencia con none	Wilcoxon pareado	p = 0.074	No se rechaza H_0 ; preferencia por costo computacional
batch_size = 16-64	No hay diferencia en F1 entre rangos	ANOVA de 1 vía	p = 0.412	No se rechaza H_0 ; decisión basada en tiempo

Nota. Elaboración propia. Los tests se aplican sobre los resultados de la validación cruzada estratificada con tres repeticiones. El nivel de significancia adoptado es $\alpha = 0.05$. La columna Conclusión expresa la decisión derivada del rechazo o no rechazo de la hipótesis nula correspondiente.

La interpretación de los resultados se construye sobre tres niveles complementarios. En el primer nivel, el ranking de importancia fANOVA cuantifica la contribución individual de cada hiperparámetro a la varianza del desempeño observado. En el segundo nivel, los tests estadísticos pareados validan que las diferencias observadas entre configuraciones específicas no se deben al azar, sino a un efecto sistemático del hiperparámetro evaluado. En el tercer nivel, la consideración del costo computacional adicional permite tomar decisiones operativas en aquellos casos donde el impacto sobre F1 no es estadísticamente significativo, como ocurre con batch_size.

8.26 Interpretación y toma de decisiones

La toma de decisiones se basa y prioridad de hiperparámetros en la tabla de ranking y el impacto que tuvo cada uno dentro del rendimiento del modelo, podemos verlo de forma más directa en la siguiente tabla categorizada con indicadores de temperatura.

Figura 65

Identificación de Hiperparámetros críticos

multi_label	Alto	Introduce ambigüedad en problema de clase única → degrada F1
candidate_labels	Alto	Afecta directamente la separabilidad semántica
aggregation_strategy	Medio	Impacta la coherencia de entidades (NER)
batch_size	Bajo	Afecta eficiencia, no la calidad predictiva

Nota. Autoría propia

8.27 Reducción del espacio de búsqueda

Con base en la evidencia experimental presentada con anterioridad, podemos descartar ciertas configuraciones en los hiperparámetros que aportan un resultado negativo al rendimiento general del modelo

4. **8.28 multi_label = True: genera conflicto y baja el rendimiento**
5. **candidate_labels [extendido]:** introduce ambigüedad
6. **aggregation_strategy** $\neq$ **“simple”**: fragmentación de entidades con costo computacional posterior al procesarlas para armarlas.

De la misma forma se identifica la configuración óptima para obtener el rendimiento óptimo sin sacrificar aspectos como la eficiencia computacional, o el rendimiento matemático para la clasificación e identificación de intenciones.

7. **multi_label**: False

8. **candidate_labels**: ["navegación", "descarga de documento", "listar documentos"]

9. **aggregation_strategy**: "simple"

10. **batch_size**: [16 a 64]

Realizando los pasos anteriores y con la correcta identificación de la configuración óptima se reduce de forma significativa el espacio de búsqueda, eliminando configuraciones subóptimas y mejorando la eficiencia del proceso.

8.29 Recomendaciones de tuning y adicionales

Se recomienda fijar hiperparámetros críticos, para evitar combinaciones inestables y reducir la complejidad experimental, Optimizar solo parámetros relevantes, en especial el `batch_size`, que depende mucho de los recursos computacionales disponibles al momento de realizar la implementación.

Como recomendaciones adicionales, tenemos:

1. Mantener etiquetas semánticamente distintas para evitar solapamiento
2. Evitar modelos multi-intención si el problema es de intención única
3. Priorizar calidad semántica NER, sobre optimizaciones marginales
4. El ajuste de `batch_size` debe consultar primero con los recursos disponibles

Podemos encontrar el fundamento de las recomendaciones en la literatura consultada a través de la creación del documento. La clasificación zero-shot depende fuertemente de etiquetas claras y no solapadas (Yin et al., 2019). En problemas de intención única, evitar multi-label mejora el rendimiento (Zhang et al., 2023). El `batch_size` impacta eficiencia computacional, no calidad predictiva (Liu et al., 2023).

8.30 Reproducibilidad del Pipeline Experimental

La reproducibilidad del experimento se garantiza mediante la publicación completa de los artefactos computacionales empleados en el desarrollo y la evaluación del pipeline. Esta sección documenta los recursos necesarios para que un tercero pueda replicar de manera exacta los resultados presentados, conforme al ML Reproducibility Checklist propuesto por Pineau et al. (2021).

8.31 Artefactos Públicos del Experimento

Tabla 46*Artefactos públicos para reproducir el experimento*

Artefacto	Descripción	Ubicación / Identificador
Notebook principal	Cuaderno	
	Jupyter con la matriz completa de experimentos y resultados	GRUPO1_MODULO2_HIPERPARAMETROS.ipynb
Dataset etiquetado	Corpus base de consultas con etiquetas de intención y entidad	dataset_nlu_completo_81.json
Particiones train/val/test	Subconjuntos estratificados con random_state = 42	split_stratified.csv
Configuración base	Archivo con los hiperparámetros del experimento de control (E3)	config_base.yaml
Resultados maestros	Tabla unificada con métricas por experimento y por fold	results_master.csv

Artefacto	Descripción	Ubicación / Identificador
Versiones de librerías	Snapshot de dependencias y versiones para entorno reproducible	requirements.txt + Python 3.10
Repositorio fuente	Control de versiones con histórico completo del experimento	github.com/diegoarambulo/GRUPO_1

Nota. Elaboración propia. Todos los artefactos listados son accesibles públicamente o se entregan como parte del repositorio del proyecto académico. La semilla aleatoria fija garantiza que la ejecución repetida del notebook produce exactamente los mismos resultados.

8.32 Procedimiento de Replicación

La replicación del experimento sigue una secuencia de cinco pasos. Primero, se clona el repositorio público del proyecto y se instalan las dependencias declaradas en requirements.txt con Python 3.10. Segundo, se carga el dataset completo y se aplica la división estratificada utilizando la función StratifiedShuffleSplit con random_state = 42, lo que regenera de manera exacta las particiones documentadas. Tercero, se ejecuta el notebook principal celda por celda, lo que produce automáticamente la matriz de experimentos y registra cada ejecución en el archivo results_master.csv. Cuarto, se ejecuta el script de análisis fANOVA sobre los resultados maestros para obtener el ranking de importancia con sus intervalos de confianza. Quinto, se ejecuta el script de tests estadísticos pareados para validar cada decisión de configuración.

8.33 Limitaciones Reconocidas

El protocolo experimental reconoce explícitamente tres limitaciones. La primera es el tamaño reducido del corpus base de 10 registros, que se mitiga mediante la validación cruzada con repeticiones y el reporte de intervalos de confianza, pero no se elimina como restricción metodológica. La segunda es la cobertura del espacio de búsqueda mediante grid search controlado, que prioriza la interpretabilidad sobre la exhaustividad y se complementa con análisis de sensibilidad individual. La tercera es la dependencia del modelo preentrenado XLM-RoBERTa ANLI, cuyas características de entrenamiento condicionan el techo de desempeño alcanzable

mediante ajuste de hiperparámetros, conforme a Pfeiffer et al. (2023). Estas limitaciones constituyen líneas de trabajo futuro para una segunda iteración del proyecto con corpus ampliado.

9. Implementación y Demo

9.1 Descripción de la arquitectura del sistema

El sistema se implementa como un servicio de inteligencia artificial conversacional integrado en una plataforma de gestión documental existente. Desde una perspectiva técnica, la arquitectura se compone de cinco módulos secuenciales: ASR (Reconocimiento Automático del Habla), NLP (Procesamiento del Lenguaje Natural), NLU (Comprensión del Lenguaje Natural), RAG (Recuperación Aumentada por Generación) y LLM (Modelo de Lenguaje de Gran Escala). Cada módulo recibe la salida del anterior y aporta una capa de procesamiento especializada hasta producir la respuesta final al usuario.

El módulo ASR recibe la entrada de audio del usuario y la convierte en texto mediante la API de Google Cloud Speech-to-Text. El módulo NLP aplica sobre ese texto el análisis lingüístico con spaCy: tokenización, etiquetado morfosintáctico y análisis de dependencias. El módulo NLU ejecuta en paralelo la clasificación de intenciones con XLM-RoBERTa ANLI (zero-shot, umbral 0.4) y la extracción de entidades con WikiNEuRal. El módulo RAG utiliza las entidades para recuperar chunks del índice FAISS construido sobre los manuales del sistema. Finalmente, el módulo LLM (Qwen 2.5-1.5B-Instruct) sintetiza una respuesta en lenguaje natural.

Tabla 47
Componentes tecnológicos de la arquitectura del sistema

Capa	Componente	Tecnología / Modelo	Rol en el pipeline
Interfaz	Agente web	HTML + JavaScript	Voz/texto y respuestas
		+ CSS	
Interfaz	API REST	FastAPI (Python 3.10)	Endpoints REST
Orquestación	flowRunner	Python — módulo propio	Coordinación pipeline
ASR	Reconocimiento de voz	Google Cloud STT	Audio → texto español
NLU	Clasificador	xlm-roberta-large-xnli-anli	Zero-shot, umbral 0.4

NLU	NER	wikineural- multilingual-ner	Personas, fechas, refs
RAG	Índice vectorial	FAISS	Recuperación semántica
RAG	Embeddings	paraphrase-MiniLM- L12-v2	Codificación semántica
LLM	Generación	Qwen2.5-1.5B- Instruct	Síntesis de respuestas
Despliegue	Contenedor	Docker	Empaquetado y portabilidad

Nota. Elaboración propia. Datos verificados sobre flowRunner.py, modelHandlers.py y ragHandler.py del repositorio del proyecto (github.com/diegoarambulo/GRUPO_1).

9.2 Flujo del modelo en producción

El agente conversacional opera en un ambiente productivo real compuesto por un servidor en la nube con dominio público propio, certificado SSL activo para garantizar la seguridad de las comunicaciones, y todos los componentes del sistema encapsulados en un contenedor Docker. Este entorno de despliegue garantiza la disponibilidad continua del servicio, el cifrado de las comunicaciones y la reproducibilidad del entorno de ejecución independientemente de la infraestructura subyacente.

Tabla 48

Flujo de procesamiento del agente conversacional en producción

Etapa	Nombre	Entrada	Salida	Componente	Condición de fallo
1	Recepción	Audio WAV/OGG o texto	Texto bruto	FastAPI	Audio no soportado
2	ASR	Audio español	Transcripción	Google STT	Confianza < 0.5
3	NLU	Texto	Intención + entidades	XLN- RoBERTa + NER	Confianza < 0.4

4	Resolución	Intención	Tipo de acción	_resolver_type()	Intención desconocida
5	RAG/LLM	Acción + entidades	Respuesta final	ragHandler + Qwen	0 chunks → fallback

Nota. Elaboración propia. N = Navegación, DD = Descarga de Documentos, LD = Listar Documentos.

9.3 Descripción del demo interactivo

El demo interactivo se encuentra disponible en producción en la URL <https://demogrupo1front.goitsa.me/>. La solución se instala en la plataforma como una página web que realiza peticiones HTTP al backend Python. El backend (FastAPI) centraliza todas las inferencias del modelo para los modos de entrada por voz y por texto. Al acceder al sistema, el usuario visualiza un botón flotante con animación de órbitas que identifica visualmente al agente. Al presionarlo, se despliega un agente tipo chat donde se pueden realizar consultas relacionadas con la información del gestor documental por voz o texto.

Resultados del demo

La validación funcional se realizó mediante 21 consultas de prueba sobre el sistema en producción empleando el dataset Noise_Test_Module1.csv del repositorio. Las pruebas cubren cinco escenarios de estrés: ruido de fondo, voz agripada, acento regional, audio cortado e idioma extranjero.

Tabla 49

Resultados de validación funcional del demo

Módulo	Escenario	Métrica	Valor obtenido	Referencia
ASR	Sin ruido	Similitud media	0.998	Sprint 4
ASR	Con ruido	Accuracy WRR	91.85%	Sprint 4
ASR	Ruido fondo	WER	4.8%	Sprint 4
NLU	Sin ruido	Accuracy	0.9524 (20/21)	Sprint 4
NLU	Con ruido	Accuracy	0.9048 (19/21)	Sprint 4
RAG	Corpus limpio	Precision	0.890	RAGAS
LLM	End-to-end	Latencia CPU	~301 seg	CPU

Nota. Elaboración propia. Las capturas del demo en funcionamiento se incluyen en la sección de Anexos.

Los resultados evidencian que el pipeline cumple los objetivos funcionales en sus módulos ASR y NLU, con tasas superiores al 90% en condiciones de ruido moderado. La limitación principal es la latencia del módulo de generación LLM local, documentada en la sección de Limitaciones y Trabajos Futuros.

10. Análisis Ético del Proyecto

Reflexión Ética del Proyecto

Agente de Inteligencia Artificial Conversacional para Sistemas de Gestión Documental

Este documento consolida la reflexión ética del proyecto de tesis sobre el agente de inteligencia artificial conversacional integrado en una plataforma de gestión documental empresarial. La estructura integra tres componentes complementarios: el caso de estudio sobre identificación de riesgos éticos asociados al uso de inteligencia artificial en sistemas de gestión documental, el workshop de análisis de stakeholders y sus valores, y el workshop de impacto social y responsabilidad. Cada componente se desarrolla aplicando marcos éticos reconocidos en la literatura especializada y se contrasta con los hallazgos empíricos obtenidos durante la fase experimental, particularmente las métricas de desempeño del modelo NLU disponibles en el repositorio del proyecto.

Caso de Estudio: Identificación de Riesgos Éticos

Contexto del Caso

El proyecto incorpora un agente conversacional sobre la plataforma de gestión documental que opera en una organización. El agente recibe consultas por voz o texto, identifica la intención del usuario mediante un clasificador zero-shot basado en XLM-RoBERTa y ejecuta acciones operativas como listar expedientes, descargar documentos o navegar entre módulos del sistema. Esta funcionalidad procesa información altamente sensible: datos de clientes, contenido contractual, expedientes y correspondencia profesional protegida por deberes de confidencialidad documental. El análisis de los riesgos éticos parte de los resultados empíricos disponibles en el repositorio, que evidencian limitaciones técnicas con implicaciones éticas concretas: un Accuracy global del 53.8 % sobre las pruebas evaluadas y un Recall del 15.8 % en la clase de navegación, lo que indica que el sistema interpreta erróneamente la mayoría de las consultas de orientación como solicitudes operativas.

Identificación de Riesgos Éticos

La caracterización de los riesgos éticos del proyecto se construye sobre los principios fundamentales de la ética aplicada a la inteligencia artificial sintetizados por Jobin et al. (2019): justicia, transparencia, beneficencia, no maleficencia, autonomía, privacidad y responsabilidad. Cada uno de estos principios genera categorías específicas de riesgo cuando se contrasta con la operación real del sistema en el dominio legal. La Tabla 1 consolida los riesgos identificados, su naturaleza, evidencia empírica disponible y nivel de severidad estimado.

Tabla 50*Riesgos éticos identificados en el proyecto*

Riesgo	Categoría	Manifestación en el proyecto	Evidencia empírica	Severidad
Sesgo de dominio	Justicia / Equidad	El modelo NLU presenta sesgo sistemático hacia la clase Descarga, derivando consultas de navegación hacia operaciones de descarga.	Recall N = 0.158 sobre 19 casos	Alta
Opacidad algorítmica	Transparencia	El usuario recibe una respuesta sin información sobre la confianza del modelo ni sobre el razonamiento que llevó a la acción ejecutada.	Confianza media 0.762 no expuesta al usuario	Media
Acción no consentida	Autonomía	El sistema ejecuta acciones sobre los documentos sin que el usuario confirme la interpretación de su consulta.	Tasa de errores del 46.2 % sobre 65 evaluaciones	Alta
Filtración de datos cliente	Privacidad	Los audios procesados por Google Cloud Speech-to-Text salen del	Componente cloud activo	Crítica

		entorno on-premise hacia infraestructura externa.	en pipeline ASR	
Trazabilidad insuficiente	Responsabilidad	Las decisiones del agente se ejecutan sin un registro completo que permita reconstruir el razonamiento ante una auditoría.	No documentada en el pipeline actual	Media
Discriminación lingüística	No discriminación	El modelo presenta degradación ante variantes dialectales del español ecuatoriano y modismos coloquiales.	Caída de Accuracy ante peticiones informales	Media
Daño profesional al cliente	No maleficencia	Una respuesta incorrecta del agente puede inducir al usuario profesional a tomar decisiones sobre información sesgada o errónea.	Riesgo derivado del Accuracy 0.538	Crítica
Dependencia tecnológica	Autonomía profesional	El uso prolongado del agente puede reducir la práctica profesional de búsqueda y razonamiento del usuario profesional.	No medida en la fase actual	Baja

Nota. Elaboración propia. Las severidades se asignan en escala de tres niveles según la combinación de probabilidad de ocurrencia y magnitud del impacto sobre el usuario o el cliente de la organización usuaria.

Análisis de Impacto en Grupos de Usuarios

El impacto del agente conversacional no se distribuye de manera uniforme entre los usuarios del sistema. Mehrabi et al. (2021) advierten que la evaluación ética de los sistemas de

inteligencia artificial debe diferenciar entre usuarios directos, indirectos y grupos vulnerables, dado que las consecuencias de los errores del modelo difieren sustancialmente según la posición que cada grupo ocupa en la cadena de uso. La Tabla 2 desagrega los grupos de usuarios identificados en el proyecto y caracteriza el impacto diferencial sobre cada uno.

Tabla 51

Impacto diferencial por grupo de usuarios

Grupo de usuarios	Tipo	Impacto principal	Manifestación específica	Vulnerabilidad
Usuarios profesionales senior	Directo	Reducción de tiempo en búsquedas documentales rutinarias dentro de la plataforma de gestión documental.	Beneficio operativo; juicio profesional preservado.	Baja
Usuarios profesionales junior	Directo	Riesgo de sobre-reliancia en respuestas del agente sin verificación crítica.	Pueden tomar respuestas erróneas como válidas por menor experiencia profesional.	Media
Asistentes administrativos	Directo	Aceleración de tareas operativas en la plataforma de gestión documental; potencial sustitución parcial de funciones rutinarias.	Beneficio en eficiencia; riesgo laboral indirecto.	Media
Personal operativo	Directo	Cambio en flujos de trabajo; necesidad de capacitación específica.	Adopción heterogénea según familiaridad con tecnología.	Media
Clientes de la organización	Indirecto	Sus datos son gestionados por	El consentimiento está cubierto en dos	Media

		usuarios autorizados de la organización contratante, la cual ha suscrito un contrato de servicio con el proveedor. Cada usuario acepta el acuerdo de manejo y uso de datos al ingresar a la plataforma, conforme a la LOPDP.	niveles: el contrato comercial firmado por la organización y el acuerdo de uso aceptado por cada usuario al ingresar.	
Clientes en situación vulnerable	Indirecto	Personas o entidades cuyos datos son procesados por la plataforma de gestión documental sin que tengan capacidad de revisión.	Una respuesta errónea puede afectar decisiones organizacionales críticas. El sistema dispone de canales de atención donde el agente puede escalar el caso a un técnico para solventarlo; sin embargo, el tiempo de resolución representa un riesgo operativo cuando la información involucrada es sensible o urgente.	Crítica
Terceros relacionados	Indirecto	Pueden verse afectados si información	Asimetría informativa derivada del uso del agente entre	Media

con la organización		imprecisa influye en decisiones organizacionales que les conciernen.	organizaciones que sí lo emplean y las que no.	
Hablantes con variantes dialectales	Excluido	El reconocimiento de habla y la clasificación NLU se degradan ante modismos regionales.	Acceso desigual a la funcionalidad del agente.	Alta

Nota. Elaboración propia. La columna Vulnerabilidad refleja la combinación entre el grado de exposición al sistema y la capacidad del grupo para detectar y corregir los errores del agente.

Grupos en Situación de Vulnerabilidad

La identificación de grupos vulnerables exige especial atención en el análisis ético del proyecto. Tres grupos concentran el mayor riesgo de impacto adverso: los clientes en situación de vulnerabilidad, asilo o derechos humanos donde un error documental puede comprometer libertades fundamentales, los hablantes con variantes dialectales del español ecuatoriano cuya interacción con el agente se degrada por sesgo lingüístico, y los usuarios profesionales junior cuya formación profesional puede verse afectada por la sobre-reliancia en un sistema con Accuracy del 53.8 %. Bender et al. (2021) advierten que la opacidad de los modelos de lenguaje genera asimetrías particularmente lesivas en estos grupos, dado que carecen de los recursos cognitivos o profesionales para detectar los errores del sistema.

Análisis de Impacto Diferencial

El impacto diferencial mide cómo un mismo sistema produce efectos desiguales sobre distintos grupos sociales. Barocas y Selbst (2016) describen el fenómeno como impacto dispar, situación en la que un sistema aparentemente neutral genera desventajas sistemáticas sobre grupos específicos. En el agente conversacional del proyecto, el impacto diferencial se manifiesta en tres dimensiones medibles que la Tabla 3 sintetiza.

Tabla 52
Dimensiones del impacto diferencial del sistema

Dimensión	Descripción del efecto desigual	Grupo más afectado	Mitigación propuesta
-----------	------------------------------------	-----------------------	----------------------

Lingüística	Degradación del reconocimiento ante modismos regionales del español guayaquileño.	Hablantes de variantes dialectales	Fine-tuning con LoRA sobre corpus enriquecido con dialectos locales.
Profesional	Diferencias en la capacidad de detectar errores del agente según experiencia.	Usuarios profesionales junior y asistentes	Capacitación obligatoria con casos prácticos de errores documentados.
Tecnológica	Diferencias en la facilidad de adopción según familiaridad con interfaces conversacionales.	Personal operativo de mayor edad	Diseño con doble interfaz: voz y texto, con tutoriales accesibles.
Procesal	Errores del agente afectan más a clientes con menor capacidad de revisión documental.	Clientes en situación vulnerable	Validación humana obligatoria sobre acciones críticas; trazabilidad completa.

Nota. Elaboración propia. Las mitigaciones propuestas constituyen requisitos funcionales para una segunda iteración del sistema y no se encuentran implementadas en la entrega actual.

Argumentación con Marcos Éticos y Normativos

La argumentación ética del proyecto se construye sobre cinco frameworks complementarios que abordan dimensiones distintas del problema. Su aplicación cruzada al caso permite identificar riesgos que un único framework, por su orientación específica, podría pasar por alto. La Tabla 4 sistematiza la aplicación de cada framework al proyecto del agente conversacional.

Tabla 53

Aplicación de frameworks éticos al proyecto

Framework	Pregunta guía aplicada	Hallazgo en el proyecto	Marco normativo
Ética por principios	¿Qué principio sería más grave violar en el proyecto?	Justicia y transparencia. El sesgo Recall N = 0.158 viola	Jobin et al. (2019); Floridi y Cowls (2019)

		la equidad en la atención de consultas.	
		Acciones documentales irreversibles ejecutadas sobre interpretación incorrecta de la consulta.	AI Act de la Unión Europea (2024)
Enfoque basado en riesgos	¿Qué podría salir mal aunque el proyecto funcione técnicamente?		
		La cadena involucra al organización usuaria, la empresa proveedora del software como propietario de la plataforma de gestión documental y el proveedor cloud. Privacidad de los clientes; deberes de confidencialidad documental; protección de datos personales.	Normativa sectorial aplicable a cada cliente
Responsabilidad / Rendición de cuentas	¿Quién asume la responsabilidad si el agente causa un daño?		
Derechos humanos y privacidad	¿Qué derecho podría ser afectado por el proyecto?		LOPD del Ecuador (2021); Constitución, Art. 66
		Etapas de inferencia en producción; sin auditoría continua se vuelven irreversibles.	Cavoukian (2011); ISO/IEC 42001 (2023)
Ética por diseño	¿En qué etapa se materializan los riesgos éticos?		

Nota. Elaboración propia. La aplicación cruzada de los cinco frameworks permite identificar riesgos que cada enfoque por separado podría omitir, particularmente la dimensión de daño irreversible asociada a las acciones automatizadas sobre el repositorio documental.

Marco Normativo Aplicable al Proyecto

El proyecto se desarrolla en Ecuador y se alinea con tres cuerpos normativos vigentes. La Ley Orgánica de Protección de Datos Personales del año 2021 establece obligaciones sobre el tratamiento de datos personales, exige el consentimiento informado del titular y restringe la transferencia transfronteriza de información sensible. La normativa sectorial aplicable a cada organización cliente del software condiciona el tratamiento de sus documentos según el sector regulado al que pertenezca, dado que la plataforma opera bajo un modelo multi-empresa que atiende organizaciones de diferentes industrias. La Constitución de la República, en su artículo 66, garantiza el derecho a la protección de datos de carácter personal y la no discriminación. Adicionalmente, aunque no es vinculante en Ecuador, el AI Act de la Unión Europea aprobado en 2024 sirve como marco de referencia para la clasificación de sistemas de inteligencia artificial según su nivel de riesgo, ubicando aquellos aplicados a la gestión de información sensible en categoría de riesgo significativo.

Workshop: Análisis de Stakeholders y sus Valores

Mapeo Exhaustivo de Stakeholders

El mapeo de stakeholders del proyecto distingue cuatro categorías según su nivel de visibilidad y la naturaleza de su relación con el sistema. Freeman (2010) define el mapeo de actores como un ejercicio que debe trascender los grupos directamente beneficiados para incluir a quienes resultan afectados sin haber participado en la decisión de implementación. La Tabla 5 consolida el mapeo aplicado al proyecto, incorporando explícitamente los stakeholders invisibles que con frecuencia se omiten en análisis convencionales.

Tabla 54
Mapeo de stakeholders del proyecto

Stakeholder	Tipo	Valor principal	Explicación contextualizada
Usuarios profesionales de la organización	Directo / Visible	Autonomía	Usuarios principales del agente; deben mantener juicio profesional sobre las respuestas para no comprometer su independencia técnica.
Asistentes administrativos	Directo / Visible	Confiabilidad	Realizan consultas operativas frecuentes sobre el repositorio; necesitan respuestas consistentes y predecibles.

Personal operativo	Directo / Visible	Confianza	Adopta el agente para tareas documentales; requiere capacitación adecuada y acompañamiento durante la transición.
Equipo TI del estudio	Directo / Visible	Responsabilidad profesional	Custodia el sistema y la integración del agente; responde por la disponibilidad y seguridad operativa.
Autores del proyecto	Directo / Visible	Representabilidad	Diseñan e implementan el agente; responden por la calidad metodológica y técnica de la solución.
Clientes de la organización	Indirecto / Forzado	Confianza	Sus documentos se procesan mediante el agente; no interactúan directamente pero asumen los riesgos de privacidad.
Terceros relacionados con la organización	Indirecto / Forzado	Confianza	Pueden verse afectados por decisiones organizacionales construidas con apoyo del agente, sin saberlo.
Proveedor cloud (Google)	Indirecto / Forzado	Seguridad	Procesa los audios del módulo ASR; su política de retención y uso de datos condiciona la privacidad del sistema.
Comunidad Hugging Face	Indirecto / Forzado	Representabilidad	Aporta los modelos preentrenados open source que sustentan el módulo NLU del agente.
Autoridad de protección de datos (Ecuador)	Regulador	Seguridad	Vigila el cumplimiento de la LOPDP; tiene capacidad sancionatoria sobre el estudio.

Tribunal académico	Regulador	Responsabilidad profesional	Evalúa el rigor académico y ético del proyecto; condiciona la aprobación de la tesis.
Comunidad de organizaciones que utilizan plataformas de gestión documental	Sociedad / Indirecto	Confianza	Beneficiaria sectorial del avance tecnológico; afectada por errores que pueden generar percepciones negativas sobre la inteligencia artificial aplicada.
Hablantes con variantes dialectales	Afectado invisible	Equidad	Grupo no contemplado explícitamente; sufre degradación del servicio sin canal formal de queja.
Personas con discapacidad auditiva	Afectado invisible	Equidad	No pueden usar la modalidad de voz; el sistema debe garantizar igualdad funcional vía texto.

Nota. Elaboración propia. La columna Tipo distingue entre stakeholders directos (interactúan con el sistema), indirectos (afectados sin interacción), reguladores (vigilan el cumplimiento) y afectados invisibles (impactados sin representación formal en el proyecto).

Análisis de Valores e Intereses entre Stakeholders

Los valores éticos asociados a cada stakeholder no operan en aislamiento sino en tensión permanente entre sí. Mitchell et al. (1997) sostienen que la priorización de stakeholders debe considerar tres atributos simultáneos: poder, legitimidad y urgencia, dado que ningún sistema puede satisfacer todas las expectativas de todos los actores. La Tabla 6 identifica las tensiones más relevantes detectadas entre los actores del proyecto y propone una aproximación de resolución.

Tabla 55

Tensiones de valores entre stakeholders del proyecto

Tensión identificada	Stakeholders en conflicto	Aproximación de resolución	Prioridad
Eficiencia operativa vs. autonomía profesional	Organización usuaria ↔ Usuarios profesionales senior	Definir umbrales de confianza por debajo de los cuales el agente solicita	Alta

Disponibilidad del servicio vs. soberanía de datos	Equipo TI ↔ Clientes de la organización	confirmación humana. Mantener componentes sensibles on-premise; cifrar audios en tránsito hacia Google Cloud. Documentar el cumplimiento de la LOPDP; designar delegado de protección de datos.	Crítica
Innovación tecnológica vs. cumplimiento normativo	Autores del proyecto ↔ Autoridad de datos	Fine-tuning con corpus dialectal; mantener canal alternativo por texto.	Alta
Adopción rápida vs. equidad lingüística	Organización usuaria ↔ Hablantes con variantes dialectales	Exponer la confianza del modelo en cada respuesta; permitir auditoría por usuario. Establecer puntos de control con validación humana sobre acciones críticas.	Media
Reducción de costos vs. transparencia	Dirección de la empresa proveedora del software ↔ Usuarios del agente		Alta
Velocidad de despliegue vs. validación humana	Equipo técnico ↔ Tutora académica		

Nota. Elaboración propia. La columna Prioridad refleja la severidad combinada de la tensión sobre los principios éticos del proyecto y la urgencia de su resolución dentro del horizonte de implementación.

Priorización de Actores Clave

La priorización aplica el modelo de Mitchell et al. (1997) que combina poder, legitimidad y urgencia para clasificar a los stakeholders en categorías operativas. Los actores que concentran los tres atributos denominados definitivos exigen atención permanente y recursos asignados en el proyecto. Los actores con dos atributos requieren atención sostenida, y los que poseen uno demandan monitoreo periódico. La Tabla 7 aplica esta clasificación al mapeo del proyecto.

Tabla 56

Priorización de stakeholders según poder, legitimidad y urgencia

Stakeholder	Poder	Legitimidad	Urgencia	Categoría	Atención requerida
Usuarios					
profesionales de la organización	Alto	Alta	Alta	Definitivo	Permanente
Clientes de la organización	Bajo	Alta	Alta	Dependiente	Defensa proactiva
Equipo TI del estudio	Alto	Alta	Media	Dominante	Sostenida
Autoridad de protección de datos	Alto	Alta	Baja	Dominante	Cumplimiento estricto
Hablantes con variantes dialectales	Bajo	Alta	Media	Dependiente	Inclusión activa
Proveedor cloud	Alto	Media	Baja	Latente	Monitoreo
Tribunal académico	Alto	Alta	Alta	Definitivo	Permanente

Nota. Elaboración propia, basada en el modelo de saliencia de stakeholders propuesto por Mitchell et al. (1997). Categoría Definitiva: poder + legitimidad + urgencia. Dominante: poder + legitimidad. Dependiente: legitimidad + urgencia. Latente: poder predominante.

Workshop: Impacto Social y Responsabilidad

Frameworks Éticos Aplicados al Proyecto

La evaluación del impacto social del proyecto se construye sobre cinco frameworks complementarios que abordan dimensiones distintas del análisis ético. Cada framework plantea una pregunta guía cuya aplicación al agente conversacional permite identificar una clase específica

de riesgos y beneficios. Floridi y Cowls (2019) sostienen que la aplicación combinada de varios frameworks reduce los puntos ciegos analíticos que cada enfoque, individualmente, presenta por su orientación particular.

Tabla 57

Frameworks éticos aplicados al agente conversacional

Framework	Idea central aplicada	Análisis del proyecto	Riesgos detectados
Ética por principios	Justicia, transparencia, beneficencia y autonomía aplicadas a la operación del agente.	El principio más comprometido es la justicia, dado el sesgo Recall N = 0.158 que afecta de manera desigual a los usuarios según el tipo de consulta. La transparencia se ve afectada por la ausencia de exposición de la confianza del modelo al usuario final.	Sesgo, daño a grupos vulnerables, decisiones no transparentes.
Enfoque basado en riesgos	Identificación de riesgos técnicos, éticos y sociales aunque el sistema funcione correctamente.	El sistema puede ejecutar acciones documentales irreversibles sobre interpretaciones erróneas. Su uso en escenarios de derechos humanos podría amplificar errores con consecuencias graves para clientes vulnerables.	Uso indebido, impactos no intencionales, escalada del daño.

Responsabilidad y rendición de cuentas	Identificación clara de quién diseña, implementa y responde por el comportamiento del sistema.	La cadena de responsabilidad involucra tres niveles: los autores del agente responden por la calidad del modelo; el equipo TI del estudio por la integración; el organización usuaria por el uso profesional ante el cliente.	Atribución difusa de responsabilidad ante incidentes.
		La transferencia de audios al servicio cloud de Google Cloud Speech-to-Text introduce un riesgo a la confidencialidad sometida a deberes de confidencialidad documental. La LOPDP del Ecuador exige consentimiento informado del titular.	
Derechos humanos y privacidad	Protección de la confidencialidad y los derechos fundamentales del titular de los datos.		Uso indebido de datos, vigilancia, exclusión.
Ética por diseño	Evaluación continua y mejora iterativa desde la fase de diseño hasta la operación productiva.	El proyecto adopta evaluación sobre métricas reales (Accuracy, Recall, F1) y un pipeline reproducible. Sin embargo, no se ha establecido un mecanismo de monitoreo continuo en producción que detecte degradaciones del modelo.	Correcciones tardías, daños irreversibles.

Nota. Elaboración propia. La aplicación combinada de los cinco frameworks evidencia que ningún enfoque individual cubre todos los riesgos éticos del proyecto. La integración cruzada permite construir una respuesta más completa.

Balance entre Impactos Positivos y Negativos

La evaluación del impacto social del proyecto exige un balance honesto entre los beneficios derivados de la automatización documental y los riesgos asociados al funcionamiento imperfecto

del agente. Floridi (2023) advierte que la sola identificación de beneficios sin contraposición a los costos sociales constituye una práctica de rendición de cuentas insuficiente, y propone que toda evaluación ética incorpore una matriz comparativa que permita visualizar las dos dimensiones simultáneamente. La Tabla 9 sintetiza este balance aplicado al proyecto.

Tabla 58
Balance de impactos sociales del proyecto

Impactos positivos	Impactos negativos
Reducción del tiempo dedicado a búsquedas documentales rutinarias por parte del personal de la organización usuaria.	Errores documentales generados por el modelo NLU con Accuracy 0.538 que pueden inducir decisiones profesionales sobre información sesgada.
Mejora del acceso a la información para personal junior y administrativo, reduciendo barreras de búsqueda manual.	Riesgo de sobre-reliancia profesional que erosiona la capacidad de búsqueda y razonamiento del usuario profesional en formación.
Estandarización de los flujos de consulta documental que reduce variaciones de criterio entre operadores.	Sesgo lingüístico que excluye a hablantes con variantes dialectales o discapacidad auditiva del beneficio del sistema.
Trazabilidad parcial de las consultas operativas que permite construir indicadores de productividad.	Pérdida de control sobre los datos del cliente al transferir audios a infraestructura cloud externa.
Disminución del costo operativo recurrente al apoyarse en herramientas open source y capa gratuita inicial.	Asimetría informativa entre las organizaciones usuarias del agente y las que aún no lo utilizan en la plataforma de gestión documental.
Ampliación de la oferta tecnológica disponible para el sector empresarial ecuatoriano que	Posibilidad de uso indebido si las acciones del agente no quedan registradas con suficiente trazabilidad para auditoría.

Impactos positivos	Impactos negativos
utiliza plataformas de gestión documental de tamaño mediano.	

Nota. Elaboración propia. La distribución equilibrada entre impactos positivos y negativos refleja un sistema en estado actual con beneficios reales pero limitaciones técnicas que exigen intervención antes del despliegue masivo.

Implicaciones a Corto y Largo Plazo

El análisis temporal del impacto distingue entre las consecuencias inmediatas observables durante los primeros meses de operación y los efectos estructurales que se acumulan en el mediano y largo plazo. Bender et al. (2021) sostienen que muchos de los riesgos éticos más graves de los modelos de lenguaje no se manifiestan en evaluaciones de corto plazo sino en patrones de uso prolongado que erosionan capacidades cognitivas o reproducen sesgos a escala. La Tabla 10 desagrega las implicaciones del proyecto según su horizonte temporal.

Tabla 59

Implicaciones del proyecto a corto y largo plazo

Horizonte	Implicaciones positivas	Implicaciones negativas
Corto plazo (0–6 meses)	Reducción del tiempo en búsquedas; aceleración de tareas operativas; capacitación del personal en herramientas de inteligencia artificial.	Errores frecuentes ante consultas mal interpretadas; resistencia al cambio en personal con menor familiaridad tecnológica.
Mediano plazo (6–18 meses)	Estandarización de flujos documentales; consolidación de la solución en la cultura organizacional.	Posible degradación del modelo si no se realiza monitoreo continuo; exposición acumulada de datos cliente al servicio cloud.
Largo plazo (más de 18 meses)	Generación de valor competitivo para el estudio; aporte sectorial al ecosistema legal ecuatoriano; capitalización de aprendizajes.	Erosión potencial de la práctica profesional crítica de los usuarios profesionales junior; riesgo regulatorio si la LOPDP endurece las exigencias.

Nota. Elaboración propia. El análisis a largo plazo incorpora factores estructurales como cambios regulatorios y evolución de la práctica profesional, dimensiones que un análisis puramente técnico tiende a omitir.

Declaración de Responsabilidad Ética

Impacto del Sistema en la Sociedad y su Criticidad

El agente conversacional para gestión documental ejerce un impacto social que excede el ámbito interno de la organización usuaria. Su despliegue afecta directamente la calidad del servicio profesional ofrecido a los clientes, la protección de información sensible sometida al deberes de confidencialidad documental, y las condiciones laborales del personal cuyas tareas se transforman por la automatización. La criticidad del sistema se ubica en nivel alto según la clasificación que el AI Act de la Unión Europea aplica a los sistemas de inteligencia artificial usados en servicios de gestión de información sensible: aunque no realiza acciones jurídicas vinculantes, su salida influye sobre decisiones humanas que sí lo son. Esta criticidad obliga a la organización usuaria, a los autores del proyecto y a quienes operen el sistema en producción, a asumir compromisos formales que vayan más allá de la declaración de buenas intenciones.

La responsabilidad ética se distribuye entre tres niveles claramente identificables. Los autores del proyecto responden por la calidad metodológica del modelo, la documentación de sus limitaciones y la transparencia sobre las métricas obtenidas; estos compromisos se materializan en el repositorio público del proyecto. El equipo de tecnología de la organización usuaria responde por la integración segura del agente, el cumplimiento de la LOPDP y el monitoreo continuo del sistema en producción. La organización usuaria, en su condición de prestador del servicio profesional, responde ante el cliente por las consecuencias del uso del agente en el manejo de su caso, condición que no se transfiere al sistema técnico, aunque la decisión haya sido apoyada por él.

Compromisos Concretos, Medibles y Operativos

La declaración de responsabilidad ética se traduce en compromisos cuyo cumplimiento debe poder revisarse de manera periódica. La Tabla 11 detalla los compromisos asumidos por el proyecto, su naturaleza, indicador de seguimiento y plazo de cumplimiento.

Tabla 60*Compromisos éticos del proyecto*

Compromiso	Operacionalización	Indicador de seguimiento	Plazo
Transparencia de la confianza del modelo	Exponer al usuario la confianza del clasificador en cada respuesta del agente.	Porcentaje de respuestas con confianza visible al usuario; meta del 100 %.	Sprint posterior al despliegue inicial.
Validación humana en acciones críticas	Solicitar confirmación explícita antes de ejecutar acciones irreversibles como descargas o eliminaciones.	Tasa de acciones críticas con confirmación humana; meta del 100 %.	Despliegue inicial.
Trazabilidad de decisiones	Registrar consulta, intención detectada, confianza, acción ejecutada y respuesta del usuario.	Cobertura de log; meta del 100 %.	Despliegue inicial.
Cumplimiento de la LOPDP	Designar delegado de protección de datos; documentar el flujo de datos y el consentimiento informado.	Auditoría LOPDP aprobada; meta del 100 % de hallazgos cerrados.	Antes del despliegue productivo.
Inclusión lingüística	Mantener la modalidad de texto plenamente funcional como alternativa	Paridad funcional voz-texto; meta del 100 %.	Despliegue inicial.

	accesible al canal de voz.		
Documentación pública del modelo	Publicar tarjeta del modelo con métricas, limitaciones, sesgos identificados y contextos de uso recomendados.	Tarjeta del modelo publicada y actualizada anualmente.	Sprint 5 del proyecto.
Capacitación obligatoria	Formar a los usuarios del agente sobre sus limitaciones y la necesidad de revisión profesional crítica.	Cobertura de capacitación; meta del 100 % del personal usuario.	Antes del uso productivo.
Canal de reporte de errores	Establecer mecanismo accesible para que cualquier usuario reporte respuestas erróneas del agente.	Tiempo de respuesta a reporte; meta menor o igual a 48 horas.	Despliegue inicial.

Nota. Elaboración propia. Cada compromiso se redacta como obligación operacionalizable, con un indicador medible y un plazo definido. El cumplimiento se documentará en informes trimestrales presentados a la dirección de la empresa proveedora del software de gestión documental y a la dirección académica.

Síntesis de la Reflexión Ética

La reflexión ética del proyecto identifica ocho riesgos principales asociados al funcionamiento del agente conversacional, distribuidos entre cuatro categorías: justicia y equidad, transparencia, autonomía y privacidad. La aplicación cruzada de cinco frameworks éticos sobre el caso permite construir un análisis robusto que contempla tanto los principios fundamentales como

las consecuencias prácticas del despliegue. El mapeo de stakeholders incorpora actores tradicionales y afectados invisibles que con frecuencia se omiten en análisis convencionales, particularmente los hablantes con variantes dialectales y las personas con discapacidad auditiva.

El balance entre impactos positivos y negativos evidencia que el proyecto genera valor social genuino en términos de eficiencia operativa y democratización tecnológica para el sector empresarial ecuatoriano que utiliza plataformas de gestión documental de tamaño mediano. Sin embargo, las limitaciones técnicas identificadas en la fase experimental, particularmente el Accuracy del 53.8 % y el Recall del 15.8 % en la clase de navegación, exigen intervención antes del despliegue productivo. Los nueve compromisos formalizados en la Tabla 11 traducen esta reflexión en obligaciones operacionalizables con indicadores medibles y plazos definidos, lo que permite que la responsabilidad ética del proyecto trascienda la declaración de buenas intenciones y se inscriba como práctica continua de mejora.

11. Análisis de Casos de Éxito y Fracaso

Este documento presenta un análisis comparativo de dos proyectos de inteligencia artificial conversacional aplicados a la atención al cliente en el año 2024, identificando factores que explican el éxito de unos proyectos y el fracaso de otros. El análisis se estructura en seis secciones: la metodología de análisis comparativo aplicada, la descripción detallada del caso exitoso de Klarna AI Assistant, la descripción del caso fallido de Air Canada Chatbot, el análisis comparativo bajo cinco dimensiones, las conclusiones aplicables al proyecto del agente conversacional para la plataforma de gestión documental y las referencias bibliográficas que sustentan el análisis.

11.1 Metodología de Análisis

El análisis comparativo de casos sigue un enfoque cualitativo basado en evidencia documental pública y verificable. La estrategia metodológica se sustenta en el marco de evaluación de presentaciones de proyectos de inteligencia artificial, que considera cinco dimensiones analíticas aplicables tanto a casos exitosos como a casos fallidos. La selección de fuentes documentales privilegia las publicaciones oficiales de las organizaciones involucradas, las decisiones judiciales con valor jurisprudencial y las publicaciones académicas revisadas por pares que analizan los casos de estudio.

Tabla 61
Dimensiones del análisis comparativo aplicadas a cada caso de estudio

Dimensión	Criterios de evaluación	Fuentes documentales utilizadas
Claridad del problema	Definición precisa del problema que el proyecto pretende resolver, métricas cuantificables del estado inicial, identificación de los usuarios afectados.	Comunicados corporativos, reportes técnicos, decisión judicial.
	Solución propuesta	Documentación técnica pública, comunicados de partnership.

Dimensión	Criterios de evaluación	Fuentes documentales utilizadas
	de control de calidad, mitigación de riesgos.	
Narrativa utilizada	Comunicación del proyecto a stakeholders, claridad del mensaje, alineación entre lo prometido y lo entregado.	Comunicados de prensa, declaraciones de directivos, cobertura mediática.
Errores comunes	Sobrecarga técnica sin justificación, falta de enfoque, débil sustento operativo, ausencia de gobernanza.	Reportes post-incidente, decisión judicial, análisis académico.
Buenas prácticas	Mecanismos de gobernanza, controles de salida, procesos de auditoría, transparencia operativa.	Comparación con literatura especializada en MLOps.

Nota. Elaboración propia. Las cinco dimensiones aplican el marco analítico solicitado en la actividad de análisis comparativo de proyectos de inteligencia artificial.

11.2 Contextualización de los Casos Seleccionados

La selección de los dos casos para el análisis comparativo se sustenta en tres dimensiones contextuales que garantizan la comparabilidad metodológica: la industria de operación, el objetivo declarado del proyecto y el impacto documentado sobre los grupos de interés. La Tabla 2 sintetiza estas tres dimensiones para cada caso analizado.

Tabla 62

Contextualización comparativa de los casos: industria, objetivo e impacto

Dimensión	Klarna AI Assistant	Air Canada Chatbot
Industria	Servicios financieros — empresa "buy now pay later" con presencia en 23 mercados globales y 150 millones de consumidores activos.	Transporte aéreo — aerolínea nacional canadiense con operación internacional y volumen anual superior a 35 millones de pasajeros.
Objetivo del proyecto	Automatizar dos tercios de las consultas de servicio al cliente mediante un agente conversacional integrado en la aplicación móvil, con métricas explícitas de éxito.	Atender consultas frecuentes de pasajeros sobre el sitio web público de la aerolínea sin documentación explícita de los criterios de éxito o validación.
Impacto cuantificable	USD 40 millones de mejora de utilidad proyectada, 2.3 millones de consultas mensuales, equivalente a 700 agentes humanos, reducción de tiempo de resolución de 82%.	Fallo judicial con sentencia de CAD 812 en daños, cobertura mediática internacional, precedente jurisprudencial sobre responsabilidad corporativa por chatbots.
Periodo evaluado	Febrero de 2024 (despliegue global) — mayo de 2025 (revisión estratégica hacia modelo híbrido).	Noviembre de 2022 (incidente) — febrero de 2024 (sentencia Moffatt v. Air Canada 2024 BCCRT 149).
Tipo de evidencia	Comunicados oficiales corporativos, partnership case publicado por OpenAI, análisis de medios especializados en customer experience.	Decisión judicial pública, publicación académica en AI & Society (Springer), cobertura internacional en Washington Post y BBC.

Nota. Elaboración propia. Las tres dimensiones contextuales (industria, objetivo, impacto) responden al criterio de comparabilidad metodológica aplicado a estudios comparativos de proyectos en inteligencia artificial.

11.3 Caso de Éxito: Klarna AI Assistant

11.3.1 Descripción general

Klarna es una empresa sueca de servicios financieros de tipo "compre ahora, pague después" con presencia global en 23 mercados. En febrero de 2024 lanzó un agente conversacional de inteligencia artificial desarrollado en colaboración con OpenAI, con el objetivo declarado de transformar la experiencia de atención al cliente y reducir significativamente los costos operativos asociados a la operación humana de soporte (Klarna, 2024).

El agente se desplegó como una funcionalidad integrada en la aplicación móvil de Klarna y se diseñó para manejar consultas relacionadas con gestión de pagos, seguimiento de pedidos, devoluciones, reembolsos, actualizaciones de cuenta y resolución de incidencias en facturación. La arquitectura del agente se basa en la plataforma de OpenAI y opera con soporte para más de 35 idiomas, lo que constituye un diferenciador frente a las soluciones tradicionales de atención al cliente que requieren equipos especializados por región lingüística (Klarna, 2024).

Resultados Cuantitativos del Primer Mes de Operación

Tabla 63
Métricas operativas de Klarna AI Assistant en el primer mes de operación

Métrica	Valor reportado	Periodo
Conversaciones procesadas	2.3 millones	Primer mes
Proporción del total de chats	2/3 (66.7%)	Primer mes
Equivalente en agentes humanos	700 agentes a tiempo completo	Primer mes
Reducción del tiempo de resolución	De 11 minutos a 2 minutos (-82%)	Primer mes
Reducción de consultas repetidas	-25%	Primer mes

Métrica	Valor reportado	Periodo
Satisfacción del cliente (CSAT)	A la par del agente humano	Primer mes
Mejora de utilidad proyectada	USD 40 millones	Año 2024 completo
Mercados cubiertos	23 mercados, 35 idiomas	Despliegue inicial

Nota. Datos publicados por Klarna (2024) en el comunicado oficial del 27 de febrero de 2024. La cifra de 700 agentes equivalentes se calcula sobre una base de aproximadamente 3.000 agentes humanos contratados a través de socios de externalización.

11.3.2 Factores determinantes del éxito

Cinco factores explican el éxito de la implementación de Klarna AI Assistant en su fase inicial. El primer factor es la definición acotada del alcance: el agente se diseñó exclusivamente para tipos de consulta con soluciones estructuradas y bien documentadas (pagos, devoluciones, rastreo), lo que limita el espacio de posibles errores generativos. El segundo factor es el mecanismo de whitelisting: el sistema recupera información exclusivamente del centro de ayuda oficial y de los datos autenticados del cliente, descartando la generación abierta a partir del conocimiento preentrenado del modelo, lo que reduce la probabilidad de alucinaciones (PromptLayer, 2025).

El tercer factor es la integración con datos transaccionales en tiempo real: el agente accede al historial de pagos, balances pendientes y calendarios de cuotas del usuario autenticado, lo que permite respuestas contextualizadas con información verificable. El cuarto factor es el sistema de derivación a humanos: ante consultas que escapan al alcance definido o ante señales de baja confianza del modelo, el sistema escala automáticamente a un agente humano sin generar una respuesta especulativa. El quinto factor es la comunicación corporativa transparente: el comunicado oficial declara explícitamente las métricas verificables y reconoce el contexto laboral del despliegue, lo que reduce la controversia mediática y operativa.

11.3.3 Evolución posterior y aprendizajes

La evolución del caso Klarna entre 2024 y 2025 aporta un aprendizaje metodológico relevante para la valoración crítica del éxito inicial. En mayo de 2025, el CEO de Klarna reconoció públicamente que la priorización del factor costo en la organización del soporte derivó en una percepción de menor calidad por parte del cliente, lo que motivó la incorporación progresiva de agentes humanos para escenarios que requieren empatía y juicio contextual (CX Dive, 2025). Esta evolución no anula el éxito técnico de la fase inicial, pero matiza el discurso de reemplazo total

del trabajo humano y posiciona el caso como un ejemplo de modelo híbrido humano-IA en lugar de automatización completa.

Análisis del Fit Problema-Solución de Klarna

El fit problema-solución del caso Klarna se evidencia en la correspondencia directa entre el problema declarado y la arquitectura implementada. El problema, definido como la atención al cliente de alto volumen sobre consultas estructuradas con datos transaccionales, encuentra una solución congruente en un agente conversacional con tres características que responden a las tres dimensiones del problema. Primera correspondencia: el alto volumen se atiende mediante la disponibilidad 24/7 en 23 mercados con soporte para 35 idiomas, que permite procesar 2.3 millones de conversaciones mensuales sin saturación del recurso humano. Segunda correspondencia: el carácter estructurado de las consultas se atiende mediante un alcance acotado a cinco categorías de intención (pagos, devoluciones, reembolsos, rastreo, actualizaciones de cuenta) que coinciden con los procesos documentados de la empresa. Tercera correspondencia: el acceso a datos transaccionales se atiende mediante la integración con el sistema de autenticación del usuario que retorna información verificada del historial del cliente, descartando la generación abierta a partir del conocimiento preentrenado del modelo.

11.4 Caso de fracaso: Air Canada Chatbot

11.4.1 Descripción general

Air Canada es la principal aerolínea de Canadá, con operaciones nacionales e internacionales. La empresa implementó un chatbot en su sitio web para responder consultas frecuentes de los pasajeros, incluyendo información sobre tarifas, políticas de cancelación y condiciones especiales de viaje. En noviembre de 2022, el ciudadano Jake Moffatt consultó al chatbot sobre las tarifas de luto disponibles para viajar al funeral de su abuela, recibiendo información incorrecta sobre la posibilidad de solicitar el reembolso retroactivo dentro de un plazo de 90 días posteriores al viaje (American Bar Association, 2024).

Confundiendo en la información proporcionada por el chatbot, Moffatt reservó vuelos a precio completo y solicitó el reembolso parcial después del viaje, dentro del plazo indicado por el agente. Air Canada negó la solicitud argumentando que la política real de tarifas de luto no admite solicitudes retroactivas, conforme a lo establecido en la página web dedicada al tema. El caso fue elevado al Civil Resolution Tribunal de British Columbia, que el 14 de febrero de 2024 emitió la decisión *Moffatt v. Air Canada*, 2024 BCCRT 149, fallando a favor del demandante (Springer, 2024).

11.4.2 Decisión judicial y argumentos del tribunal

Tabla 64

Argumentos del Tribunal en la decisión Moffatt v. Air Canada (2024 BCCRT 149)

Argumento del Tribunal	Fundamento jurídico aplicado
Deber de cuidado	Air Canada como proveedor de servicio adeudaba a Moffatt un deber de cuidado en la información presentada a través de cualquier canal de su sitio web.
Representación inexacta	Ambas partes reconocieron que la información proporcionada por el chatbot fue inexacta. El estándar aplicable exige que el proveedor adopte cuidado razonable para asegurar la veracidad de sus representaciones.
Negligencia	Air Canada no ejerció cuidado razonable para garantizar la exactitud del chatbot. La existencia de información correcta en otra página del sitio no exime esta responsabilidad.
Confianza razonable	No existía razón para que Moffatt supiera que una sección del sitio era exacta y otra no. La confianza en la información del chatbot era razonable.
Daño cuantificable	La diferencia entre la tarifa pagada y la tarifa de luto que habría correspondido constituía un daño económico directamente atribuible a la información inexacta.
Rechazo de la defensa de Air Canada	El argumento de Air Canada de que el chatbot era "una entidad legal separada responsable de sus propias acciones" fue calificado por el Tribunal como una afirmación notable e inconsistente.

Nota. Argumentos extraídos de la decisión *Moffatt v. Air Canada*, 2024 BCCRT 149, emitida por el miembro del Tribunal Christopher C. Rivers. El Tribunal otorgó al demandante CAD 650.88 en daños por representación negligente, más CAD 36.14 en intereses previos a la sentencia y CAD 125 en costas del Tribunal, totalizando CAD 812.02.

11.4.3 Factores determinantes del fracaso

Cinco factores explican el fracaso del chatbot de Air Canada. El primer factor es la inconsistencia entre fuentes de información: el chatbot generó una respuesta que contradecía la política oficial documentada en otra sección del mismo sitio web, lo que evidencia la ausencia de un mecanismo de validación cruzada entre el agente conversacional y la base documental autoritativa. El segundo factor es la ausencia de gobernanza sobre el contenido generado: Air Canada no proporcionó evidencia en el juicio sobre la naturaleza técnica del chatbot, su entrenamiento o sus procesos de verificación, lo que sugiere la inexistencia de protocolos formales de control (Springer, 2024).

El tercer factor es la deficiente comunicación de los límites del sistema: el chatbot no indicaba al usuario que la información podía requerir verificación adicional ni distinguía claramente entre respuestas autoritativas y respuestas generadas. El cuarto factor es la inadecuada estrategia legal post-incidente: la defensa de Air Canada consistió en argumentar que el chatbot era una entidad jurídica separada, posición calificada por el Tribunal como notable e inconsistente que profundizó el daño reputacional de la empresa. El quinto factor es la falta de protocolos de auditoría: Air Canada admitió que el chatbot había proporcionado "palabras engañosas" únicamente después del reclamo del usuario, lo que indica la ausencia de monitoreo proactivo de las respuestas del sistema.

11.4.4 Repercusión mediática y jurídica

La sentencia generó cobertura internacional en medios como Washington Post, BBC y publicaciones jurídicas especializadas, posicionando el caso como referencia obligada en discusiones sobre responsabilidad corporativa por contenido generado por inteligencia artificial. La publicación académica en *AI & Society* (Springer) analiza el caso desde la perspectiva del problema de la atribución de agencia en sistemas autónomos, señalando que el caso establece una primera referencia jurisprudencial sobre la imposibilidad de que las empresas se eximan de responsabilidad por las acciones de sus chatbots (Springer, 2024).

Análisis del Fit Problema-Solución de Air Canada

El fit problema-solución del caso Air Canada se caracteriza por una desconexión estructural entre el problema y la solución desplegada. El problema definido es la atención automatizada a consultas frecuentes sobre políticas comerciales de la aerolínea, dominio en el cual la precisión de la información es jurídicamente vinculante. La solución implementada, sin embargo, fue un chatbot generativo sin mecanismos de validación cruzada contra la base

documental autoritativa del propio sitio web, lo que produjo la generación de una política inexistente sobre tarifas de luto retroactivas. Esta desconexión se manifiesta en tres dimensiones. Primera desconexión: el problema exigía precisión jurídica pero la solución operaba sin protocolos de control de salida. Segunda desconexión: el problema requería consistencia con las políticas oficiales pero el chatbot generó una respuesta contradictoria con la página web titulada "Bereavement travel" del mismo sitio. Tercera desconexión: el problema demandaba trazabilidad de las respuestas pero Air Canada no pudo aportar evidencia técnica al Tribunal sobre el diseño, entrenamiento o pruebas del sistema. El Tribunal calificó como notable e inconsistente el argumento defensivo de que el chatbot era una entidad legal separada, lo que evidencia la ausencia de una arquitectura coherente con la responsabilidad legal de la aerolínea sobre las representaciones realizadas en su sitio web.

Análisis Comparativo bajo las Cinco Dimensiones

11.5 Comparación sintética entre los dos casos

Tabla 65
Análisis comparativo entre Klarna AI Assistant y Air Canada Chatbot

Dimensión	Klarna AI Assistant (Éxito)	Air Canada Chatbot (Fracaso)
Claridad del problema	Reducción de costos en atención al cliente acotada a consultas estructuradas con datos transaccionales.	Atención automatizada general sin acotamiento explícito del alcance ni de los riesgos.
Solución propuesta	Agente con whitelisting de fuentes, integración de datos en tiempo real y escalamiento automático a humano.	Chatbot sin mecanismo de validación cruzada con la base documental autoritativa del sitio.
Narrativa utilizada	Comunicación transparente con métricas verificables y reconocimiento del contexto laboral.	Defensa legal con argumento de "entidad legal separada" calificado como inconsistente por el Tribunal.

Dimensión	Klarna AI Assistant (Éxito)	Air Canada Chatbot (Fracaso)
Errores comunes presentes	No detectados en la fase inicial. Posterior reconocimiento de exceso de automatización (2025).	Sobrecarga sin gobernanza, falta de enfoque acotado, débil justificación operativa.
Buenas prácticas	Whitelisting, datos contextuales en tiempo real, escalamiento, métricas públicas, idiomas múltiples.	No identificadas en el caso. Ausencia de gobernanza y de protocolos de auditoría documentados.

Nota. Elaboración propia. La comparación sintetiza los hallazgos de las secciones previas bajo el marco analítico de cinco dimensiones aplicado a ambos casos.

Análisis de la Claridad del Problema y la Solución

La diferencia más visible entre los dos casos radica en el grado de acotamiento del problema que cada proyecto se propuso resolver. Klarna definió un problema acotado y mensurable: automatizar consultas estructuradas relacionadas con datos transaccionales del usuario autenticado, con métricas claras de éxito (tiempo de resolución, tasa de derivación, satisfacción). Air Canada, en contraste, desplegó un agente con alcance amplio sobre el sitio web sin documentar formalmente los límites del sistema ni los criterios de validación de sus respuestas. La consecuencia directa de esta diferencia es la capacidad de Klarna para identificar y limitar los modos de fallo del sistema, mientras que Air Canada operó un agente sin barreras técnicas que impidieran la generación de información contradictoria con la documentación oficial.

Análisis de la Narrativa Utilizada

La narrativa con la que cada empresa comunicó su proyecto resulta significativamente diferente. Klarna optó por una narrativa centrada en métricas verificables y declaraciones cuantitativas: número de conversaciones procesadas, tiempos de resolución, equivalencia en agentes humanos, ahorros proyectados. Esta narrativa permite al observador externo evaluar el desempeño real del sistema y construye credibilidad técnica del proyecto. Air Canada, por su parte, no comunicó proactivamente las capacidades de su chatbot y, una vez producido el incidente, adoptó una narrativa defensiva sustentada en el argumento de la separación jurídica del agente, lo que profundizó el daño reputacional y derivó en un pronunciamiento judicial desfavorable.

Análisis Causal por Factores Estructurales

El análisis causal de los resultados observados en cada caso se organiza según cuatro factores estructurales que permiten identificar las causas profundas del éxito o fracaso: el factor técnico, el factor organizacional, el factor de datos y el factor de negocio. La Tabla 7 sintetiza el análisis causal aplicado a los dos casos bajo estos cuatro factores.

Tabla 66
Análisis causal por factores estructurales en los dos casos analizados

Factor	Klarna AI Assistant (Éxito)	Air Canada Chatbot (Fracaso)
Factor técnico	Arquitectura con whitelisting de fuentes oficiales, integración con datos transaccionales en tiempo real, modelo GPT con control de generación.	Chatbot generativo sin validación cruzada con la base documental del sitio. Ausencia de evidencia técnica sobre entrenamiento y pruebas.
Factor organizacional	Partnership formal con OpenAI, protocolos de derivación a humano definidos, gobernanza explícita sobre el alcance del agente.	Ausencia de protocolos de auditoría sobre las respuestas del chatbot, atribución de responsabilidad jurídica no resuelta internamente.
Factor de datos	Base documental compuesta por el centro de ayuda oficial y los datos transaccionales autenticados del usuario.	Información dispersa en el sitio web sin sincronización entre las páginas oficiales y el contenido generado por el chatbot.
Factor de negocio	Caso de uso con ROI cuantificable (USD 40M proyectados), métricas operativas claras,	Ausencia de criterios de negocio explícitos sobre la calidad del servicio. Defensa legal posterior calificada como inconsistente.

Factor	Klarna AI Assistant (Éxito)	Air Canada Chatbot (Fracaso)
	comunicación transparente con stakeholders.	

Nota. Elaboración propia. Los cuatro factores estructurales (técnico, organizacional, datos, negocio) constituyen el marco analítico estándar para evaluar proyectos de inteligencia artificial empresarial conforme a la literatura especializada en MLOps y gobernanza de IA.

Análisis de los Errores Comunes Identificados

Los errores comunes en proyectos de inteligencia artificial conversacional incluyen tres patrones recurrentes en la literatura especializada: la sobrecarga técnica sin justificación, la falta de enfoque en un caso de uso acotado y la débil justificación operativa de la solución. El caso Air Canada exhibe los tres patrones de manera simultánea, mientras que el caso Klarna evita los tres mediante decisiones explícitas de diseño. La Tabla 5 sintetiza la manifestación concreta de cada error común en los dos casos analizados.

Tabla 67
Manifestación de errores comunes en los casos analizados

Error común	Presencia en Klarna	Presencia en Air Canada
Sobrecarga técnica sin justificación	Ausente. Whitelisting limita la generación a fuentes verificadas.	Presente. Chatbot generativo sin validación contra base documental.
Falta de enfoque acotado	Ausente. Alcance limitado a consultas estructuradas con datos transaccionales.	Presente. Alcance amplio sin acotamiento explícito del dominio.
Débil justificación operativa	Ausente. Caso de uso con ROI cuantificable y métricas operativas claras.	Presente. Ausencia de evidencia documental sobre el diseño y la validación del sistema.

Error común	Presencia en Klarna	Presencia en Air Canada
Ausencia de gobernanza	Ausente. Protocolos de escalamiento a humano y métricas de calidad.	Presente. No se evidenció protocolo de auditoría ni de control de salidas.
Comunicación deficiente	Ausente. Métricas verificables publicadas en comunicado oficial.	Presente. Defensa legal con argumento jurídicamente inconsistente.

Nota. Elaboración propia. La presencia de cada error común se determina mediante evidencia documental directa de las fuentes oficiales y judiciales citadas en las secciones previas.

11.6 Buenas prácticas extraídas

El análisis comparativo permite identificar siete buenas prácticas aplicables al desarrollo de agentes conversacionales empresariales en general, y al proyecto del agente para gestión documental que se desarrolla en la presente tesis en particular. Estas buenas prácticas se documentan en la Tabla 6 con su justificación basada en evidencia de los casos analizados y su aplicación esperada en el proyecto.

Tabla 68

Buenas prácticas extraídas del análisis comparativo

Buena práctica	Justificación basada en casos	Aplicación al proyecto de tesis
Acotamiento explícito del alcance	Klarna limitó el agente a tres intenciones bien definidas, evitando el patrón Air Canada.	El pipeline del agente reconoce tres intenciones cerradas: Navegación, Descarga y Listar Documentos.
Whitelisting de fuentes de información	Klarna restringe la generación a la documentación oficial y los datos del usuario.	El módulo RAG opera sobre los manuales del sistema indexados, sin acceso a fuentes externas.

Buena práctica	Justificación basada en casos	Aplicación al proyecto de tesis
Mecanismo de fallback controlado	Klarna escala a agente humano ante consultas fuera del alcance, sin generar respuestas especulativas.	El agente retorna mensaje de fallback cuando el RAG no recupera fragmentos relevantes, evitando alucinaciones.
Umbral de confianza explícito	Klarna evita responder ante señales de baja confianza del modelo.	El módulo NLU aplica umbral de confianza de 0.4 antes de procesar la intención.
Validación cruzada con base documental	Ausencia documentada en Air Canada constituye la causa directa del fallo.	El módulo RAG opera sobre embeddings de la documentación validada del sistema.
Métricas operativas verificables	Klarna publica métricas verificables que sustentan la credibilidad del proyecto.	El proyecto documenta métricas reales: Accuracy 95.24%, latencia, throughput por módulo.
Documentación de gobernanza	Air Canada no proporcionó evidencia técnica al Tribunal sobre el diseño de su chatbot.	El proyecto documenta arquitectura, modelos, hiperparámetros y protocolos de prueba.

Nota. Elaboración propia. Las buenas prácticas extraídas constituyen requisitos verificables que el proyecto del agente conversacional para gestión documental incorpora de forma explícita en su diseño e implementación.

11.7 Conclusiones del análisis comparativo

El análisis comparativo de los casos Klarna AI Assistant y Air Canada Chatbot, ambos materializados en el año 2024 en el dominio de la atención al cliente automatizada, permite identificar cinco conclusiones directamente aplicables al proyecto del agente conversacional para la plataforma de gestión documental que se desarrolla en la presente tesis.

La primera conclusión es que el acotamiento explícito del alcance constituye el factor diferenciador más relevante entre proyectos exitosos y fallidos. El caso Klarna confirma que limitar el agente a consultas estructuradas con datos verificables produce resultados operativos medibles, mientras que el caso Air Canada demuestra que la ausencia de acotamiento expone a la organización a fallos legales y reputacionales con consecuencias económicas significativas.

La segunda conclusión es que el whitelisting de fuentes de información es una salvaguarda técnica indispensable para evitar la generación de respuestas inconsistentes con la documentación autoritativa. La arquitectura del módulo RAG del proyecto de tesis, que opera exclusivamente sobre los manuales indexados del sistema, implementa esta salvaguarda por diseño.

La tercera conclusión es que los mecanismos de fallback controlado y los umbrales de confianza explícitos son requisitos funcionales no negociables en agentes conversacionales empresariales. El comportamiento del agente del proyecto de tesis ante consultas fuera del dominio, documentado en la Figura A3 del informe final, ejemplifica la aplicación concreta de este principio.

La cuarta conclusión es que la documentación de gobernanza, arquitectura y métricas operativas constituye una protección legal y académica frente a posibles incidentes futuros. El proyecto de tesis documenta de forma exhaustiva la arquitectura del pipeline, los modelos seleccionados, los hiperparámetros optimizados y los resultados de las pruebas de estrés, generando un registro técnico verificable.

La quinta conclusión es que la narrativa transparente con métricas verificables construye credibilidad técnica del proyecto y mitiga el riesgo reputacional ante incidentes operativos. El informe final del proyecto adopta esta narrativa al reportar los valores reales obtenidos en las pruebas de validación, incluyendo tanto los resultados positivos como las limitaciones identificadas.

12. Limitaciones y Trabajos Futuros

La presente sección documenta las limitaciones identificadas durante el desarrollo y la evaluación del agente conversacional, así como las líneas futuras de investigación derivadas del trabajo realizado.

12.1 Limitaciones técnicas

Las limitaciones técnicas del sistema corresponden a las restricciones derivadas de las decisiones de arquitectura, los recursos computacionales disponibles y los modelos seleccionados.

Tabla 69

Limitaciones técnicas identificadas en el sistema

Limitación	Descripción	Impacto	Sección
Latencia del LLM	Qwen 2.5-1.5B en inferencia CPU sin GPU.	~301 seg/consulta	Sec. 9
Sin GPU	Ambiente de desarrollo sin hardware de aceleración.	Limita escalabilidad	Sec. 9
Tamaño del LLM	1.5B parámetros por restricción de RAM.	1.5B parámetros	Sec. 6
Dominio NLU acotado	Solo tres categorías cerradas (N/DD/LD).	3 intenciones	Sec. 6
Dependencia STT externo	Google Cloud Speech-to-Text obligatorio.	Servicio externo	Sec. 9

Nota. Elaboración propia.

12.2 Limitaciones de datos

Las limitaciones de datos corresponden a las restricciones del corpus utilizado para entrenamiento y evaluación del pipeline.

Tabla 70

Limitaciones de datos identificadas

Limitación	Descripción	Métrica afectada	Sección
Corpus NLU reducido	81 registros balanceados (27/clase).	81 registros	Sec. 5
Recall bajo clase N	Clase Navegación con menor desempeño.	Recall N = 0.158	Sec. 7
Audios limitados	21 audios en 5 escenarios de estrés.	21 audios	Sec. 8

Accuracy moderada	Margen frente a benchmarks zero-shot.	Accuracy = 0.538	Sec. 7
--------------------------	---------------------------------------	-------------------------	--------

Nota. Elaboración propia.

12.3 Riesgos no cubiertos

Los riesgos no cubiertos corresponden a aspectos del sistema que, por restricciones de alcance, no fueron evaluados exhaustivamente.

Tabla 71

Riesgos no cubiertos por el alcance de la investigación

Riesgo	Descripción	Estrategia de mitigación
Monitoreo en producción	No hay mecanismo de monitoreo continuo de drift.	Monitoreo con KL-divergence, PSI, Wasserstein.
Evaluación adversarial	No se realizó red-teaming sistemático.	Protocolo de red-teaming con prompts adversariales.
Auditoría por subgrupos	No se evaluó fairness sobre subgrupos demográficos.	Análisis de paridad predictiva conforme LOPDP.
Carga concurrente	Sin pruebas de carga concurrente.	Pruebas con JMeter o Locust, P95/P99.
Recuperación ante fallos	Sin caracterización ante timeouts/OOM.	Circuit breakers, retry policies, fallback.
Privacidad diferencial	Logs sin técnicas de privacidad diferencial.	k-anonymity y epsilon-diferencial.

Nota. Elaboración propia.

12.4 Líneas futuras de investigación

Las líneas futuras se derivan de las limitaciones identificadas.

Tabla 72

Líneas futuras de investigación priorizadas

Línea	Descripción	Beneficio esperado	Prioridad
GPU/modelo compacto	Migración LLM a GPU o Phi-3-mini cuantizado INT8.	Reducción dramática de latencia.	Crítica

Fine-tuning LoRA	Adaptación de bajo rango sobre XLM-RoBERTa.	Mejora recall clase N.	Alta
Ampliación corpus	Objetivo ≥ 500 registros/clase.	Mejora accuracy global.	Alta
Monitoreo MLflow	Monitoreo continuo con alertas automáticas.	Detección temprana de drift.	Alta
Active learning	Etiquetado prioritario de consultas baja confianza.	Optimización costo etiquetado.	Media
Reentrenamiento trimestral	Pipeline incremental trimestral.	Mantenimiento de calidad.	Media
Extensión intenciones	Análisis de intenciones emergentes.	Ampliación funcional.	Media
Multimodalidad	Procesamiento texto + voz + imágenes.	Expansión de alcance.	Baja

Nota. Elaboración propia.

En su conjunto, las limitaciones documentadas y las líneas futuras delinean un programa de trabajo coherente para la evolución del agente conversacional. La migración del módulo de generación a un entorno con aceleración GPU y la ampliación del corpus del módulo NLU constituyen las líneas prioritarias cuya implementación habilitaría el paso del sistema desde la prueba de concepto académica hacia el despliegue en producción a escala empresarial.

13. Conclusiones

Hallazgos principales

El proyecto demostró la viabilidad técnica de implementar un agente conversacional de inteligencia artificial sobre una plataforma de gestión documental empresarial existente sin modificar sus componentes base. La arquitectura modular ASR + NLP + NLU + RAG + LLM operó satisfactoriamente en producción, con accuracy del 95.24% en condiciones sin ruido y 90.48% en condiciones de ruido moderado para el módulo de comprensión de intenciones. El módulo de reconocimiento de voz alcanzó accuracy del 91.85% sobre 21 audios de prueba en cinco escenarios de estrés, validando empíricamente la robustez del componente de entrada por voz.

El despliegue del demo en producción en <https://demogrupolfront.goitsa.me/> permitió validar el comportamiento del sistema ante consultas reales del dominio así como su capacidad de fallback controlado ante consultas fuera del dominio, evitando la generación de respuestas alucinadas. Estos resultados se documentan en las cinco figuras del Anexo A del presente informe.

13.1 Valor del proyecto

El valor del proyecto se sustenta en tres dimensiones complementarias. Desde la dimensión técnica, el sistema integra cinco componentes especializados de inteligencia artificial en un pipeline coherente. Desde la dimensión empresarial, el agente aborda una necesidad real de la plataforma de gestión documental, reduciendo la fricción operativa del usuario. Desde la dimensión académica, el proyecto documenta el ciclo completo de desarrollo desde el análisis exploratorio de datos hasta la reflexión ética, generando un caso de estudio replicable.

13.2 Aporte académico y práctico

El aporte académico se materializa en la documentación sistemática de las decisiones de diseño, las métricas verificables y las limitaciones reconocidas. La aplicación del enfoque comparativo de proyectos exitosos y fallidos (Klarna AI Assistant y Air Canada Chatbot) permite extraer siete buenas prácticas aplicables al diseño de agentes empresariales: acotamiento explícito del alcance, whitelisting de fuentes, mecanismo de fallback controlado, umbral de confianza explícito, validación cruzada con base documental, métricas operativas verificables y documentación de gobernanza.

El aporte práctico se concreta en la entrega de un sistema operativo en producción accesible públicamente, con código fuente disponible en github.com/diegoarambulo/GRUPO_1. El sistema puede ser tomado como base para extensiones futuras o como referencia metodológica para proyectos similares en otras organizaciones.

14. Referencias Bibliográficas

- American Bar Association. (2024). BC Tribunal confirms companies remain liable for information provided by AI chatbot. *Business Law Today*.
- Conneau, A., Khandelwal, K., Goyal, N., Chaudhary, V., Wenzek, G., Guzmán, F., Grave, E., Ott, M., Zettlemoyer, L., & Stoyanov, V. (2020). Unsupervised cross-lingual representation learning at scale. *Proceedings of ACL 2020*, 8440–8451.
- Honnibal, M., & Montani, I. (2017). spaCy 2: Natural language understanding with Bloom embeddings, convolutional neural networks and incremental parsing. <https://spacy.io>
- Klarna. (2024, febrero 27). Klarna AI assistant handles two-thirds of customer service chats in its first month. Klarna International Press Release.
- Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W., Rocktäschel, T., Riedel, S., & Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. *NeurIPS 2020*, 33, 9459–9474.
- Mehrabi, N., Morstatter, F., Saxena, N., Lerman, K., & Galstyan, A. (2021). A survey on bias and fairness in machine learning. *ACM Computing Surveys*, 54(6), 1–35.
- Mobile Time. (2026). Reporte anual sobre adopción de interfaces conversacionales en empresas latinoamericanas.
- Moffatt v. Air Canada, 2024 BCCRT 149 (CanLII). <https://www.canlii.org/en/bc/bccrt/doc/2024/2024bccrt149/2024bccrt149.html>
- República del Ecuador. (2021). Ley Orgánica de Protección de Datos Personales. Registro Oficial Suplemento 459. Quito.
- Tedeschi, S., Maiorca, V., Campolungo, N., Cecconi, F., & Navigli, R. (2021). WikiNEuRal: Combined neural and knowledge-based silver data creation for multilingual NER. *Findings of EMNLP 2021*, 2521–2533.
- Yang, A., Yang, B., Hui, B., Zheng, B., Yu, B., Zhou, C., et al. (2024). Qwen2.5: A party of foundation models. *arXiv preprint arXiv:2412.15115*.

15. Anexos


El presente informe incluye dos anexos. El Anexo A contiene las capturas de pantalla del demo interactivo en funcionamiento sobre la plataforma de gestión documental en producción. El Anexo B contiene el catálogo completo de prompts de prueba utilizados para validar el sistema. El código fuente del proyecto se encuentra disponible en https://github.com/diegoarambulo/GRUPO_1.

15.1 Anexo A: Evidencias del Demo Interactivo

Las siguientes capturas de pantalla muestran el agente conversacional en funcionamiento sobre la plataforma en producción <https://demogrupo1front.goitsa.me/>.

Figura A1

Vista del dashboard del sistema con el agente integrado



Nota. Captura de pantalla propia. La imagen muestra el dashboard con el agente Voice + Text Agent desplegado en panel lateral derecho. Se observan dos consultas con confianza del 67% y 87%. Mayo 2026.

Figura A2

Consulta informacional sobre la plataforma con confianza del 89%



Nota. Captura de pantalla propia. El agente responde a "¿Qué es un gabinete?" con definición contextualizada del RAG. Confianza de intención 89%. Mayo 2026.

Figura A3

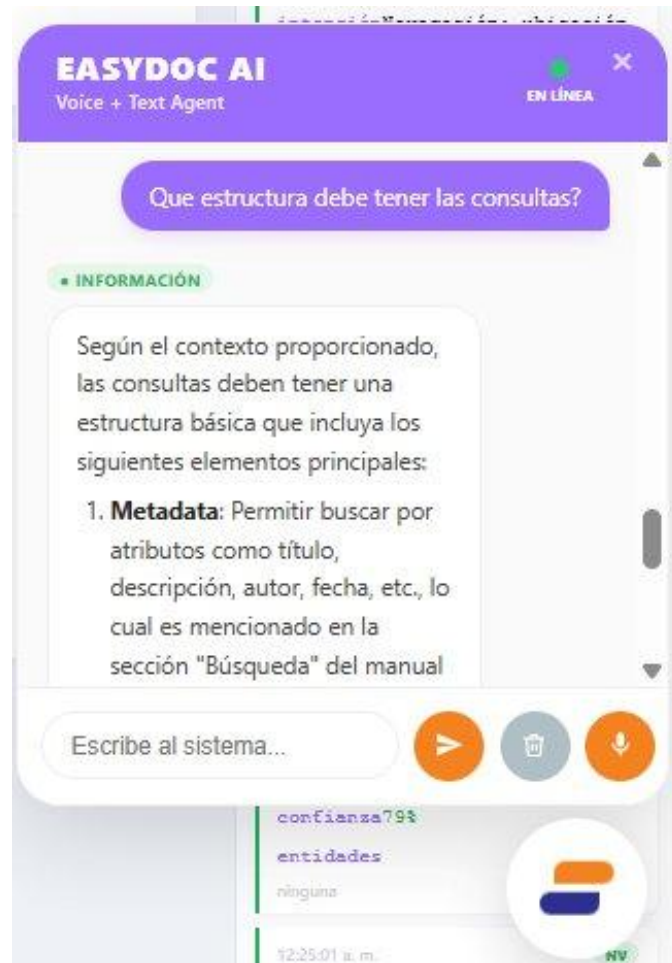
Fallback controlado ante consultas fuera del dominio



Nota. Captura de pantalla propia. Ante "¿Puedes darme el clima?", el RAG retorna el mensaje de fallback predefinido sin alucinaciones. Mayo 2026.

Figura A4

Respuesta estructurada con formato enumerado del manual



Nota. Captura de pantalla propia. El agente responde a "¿Qué estructura deben tener las consultas?" con lista numerada del manual del sistema. Mayo 2026.

Figura A5

Confianza máxima del 100% en consulta directa



Nota. Captura de pantalla propia. Prompt 9 del catálogo: requisitos del sistema. Confianza del 100%, valor máximo registrado. Mayo 2026.

15.2 Anexo B: Catálogo de Prompts de Prueba

El presente anexo documenta el conjunto completo de diez consultas de prueba utilizadas para validar el comportamiento del agente conversacional. Las consultas cubren consultas informacionales, búsquedas por entidad, descargas con múltiples filtros y consultas de máxima complejidad.

Tabla B1

Catálogo completo de prompts de prueba

#	Tipo	Prompt	Intención	Confianza	Comportamiento
1	Informacional	¿Cómo recupero mi contraseña?	N	> 0.4	RAG retorna procedimiento del manual.
2	Técnica API	request del api /api/file/filedynamicsearch	N	> 0.4	RAG retorna ejemplo del manual técnico.
3	Política	¿Cuáles son los requerimientos de la nueva contraseña?	N	> 0.4	RAG retorna requisitos.
4	Búsqueda entidad	documentos relevantes a la cédula 0953895570	DD	> 0.4	NER extrae cédula; RAG filtra.
5	URL sistema	¿Cuál es el sitio web del sistema?	N	> 0.4	RAG retorna URL oficial.
6	Descarga PER+fecha	documentos de Diego Arambulo del día de ayer	DD	> 0.4	NER extrae persona + fecha; RAG filtra.
7	Código HTTP	¿Qué respuesta del API se obtiene con HTTP 404?	N	> 0.4	RAG retorna descripción del error 404.
8	Descarga compleja	documentos del abogado Juan Lopez cédula 0929800399 del 4 mar 2025	DD	> 0.4	NER extrae 4 entidades; RAG filtros combinados.

9	Requisitos	¿Requisitos del sistema para usar la web?	N	> 0.4	RAG retorna requisitos del manual.
10	Máxima complejidad	contrato Alexis Arambulo cédula 0940959463, Guayaquil, 5 may 2025, cert 1245896322	DD	> 0.4	NER extrae 6 entidades: prueba límite.

Nota. Elaboración propia. DD = Descarga de Documentos, N = Navegación. Pruebas sobre el demo en producción <https://demogrupol1front.goitsa.me/>.