

15 DE MAYO DEL 2026

RECURSOS Y ESTADO DEL ARTE.

INTEGRANTES:

BRYAN ISMAEL ALVARADO QUIMIZ

DIEGO ANDRÉ ARÁMBULO VÍTORES

Recursos y Estado del Arte

Agente de Inteligencia Artificial Conversacional para Sistemas de Gestión Documental

Este documento expone los recursos del proyecto y el estado del arte que sustenta la propuesta del proyecto. La estructura del trabajo se organiza en cuatro componentes: el mapa del estado del arte con análisis de tendencias, soluciones existentes y brechas identificadas, el cronograma metodológico ágil, el plan integral de recursos y la definición de hitos y entregables. La revisión bibliográfica privilegia fuentes primarias publicadas entre los años 2020 y 2025, con énfasis en investigaciones de alto impacto académico que documentan avances en reconocimiento automático del habla, comprensión del lenguaje natural y generación aumentada por recuperación, las tres dimensiones técnicas que estructuran la arquitectura propuesta.

Estrategia de Búsqueda Bibliográfica

Marco Conceptual de la Búsqueda

La estrategia de búsqueda se diseñó conforme a los lineamientos de la metodología PRISMA adaptada a revisiones de tipo narrativo-analítico, dado que el alcance del trabajo no exige un protocolo sistemático completo, pero sí demanda trazabilidad en la selección de fuentes. Page et al. (2021) describen que la transparencia en la documentación de la estrategia de búsqueda constituye una práctica recomendada en cualquier revisión académica, independientemente de su naturaleza sistemática o narrativa, porque permite reproducir el proceso de identificación de literatura y verificar la cobertura temática lograda.

Bases de Datos Consultadas

La búsqueda se ejecutó sobre cinco repositorios académicos reconocidos por su rigor en el dominio de la inteligencia artificial y el procesamiento del lenguaje natural. Las bases consultadas fueron Scopus, IEEE Xplore, ACM Digital Library, ACL Anthology y arXiv. La inclusión de arXiv responde a la velocidad de publicación característica del campo, donde los avances metodológicos relevantes circulan inicialmente como preprints antes de su aparición en actas de congresos arbitrados. Como complemento, se utilizó Google Académico para la consulta de citaciones y revisión de trabajos derivados.

Ecuaciones de Búsqueda y Palabras Clave

Tabla 1

Ecuaciones de búsqueda aplicadas en la revisión bibliográfica

Eje temático	Ecuación de búsqueda	Scopus	IEEE	ACM	ACL	arXiv	Total	Selec.
1. Reconocimiento automático del habla	("automatic speech recognition" OR "ASR") AND ("transformer" OR "self-supervised") AND ("multilingual" OR "Spanish") NOT ("medical")	68	82	35	19	10	214	3
2. Clasificación de intenciones NLU	("intent classification" OR "natural language understanding") AND ("zero-shot" OR "transfer learning") AND ("XLM" OR "multilingual")	54	38	42	38	14	186	5
3. Generación aumentada por recuperación	("retrieval-augmented generation" OR "RAG") AND ("document" OR "enterprise") AND ("evaluation" OR "benchmark")	78	52	55	45	68	298	6
4. Sesgo y equidad en modelos de lenguaje	("bias" OR "fairness") AND ("language model" OR "NLP") AND ("evaluation" OR "metric")	125	87	118	52	30	412	3
5. Metodología ágil en proyectos de IA	("agile" OR "scrum") AND ("research project" OR "machine learning") AND ("management" OR "framework")	52	38	25	0	12	127	3
TOTALES	5 ecuaciones aplicadas sobre 5 repositorios académicos	377	297	275	154	134	1.237	20

Nota. Elaboración propia. Las ecuaciones se aplicaron sobre los campos de título, resumen y palabras clave de los repositorios consultados, de los años 2020-2025.

Criterios de Inclusión y Exclusión

La aplicación de criterios explícitos de inclusión y exclusión permitió reducir el universo inicial de 1.237 documentos a una selección final de 20 referencias relevantes para los ejes temáticos del proyecto. La Tabla 2 detalla los criterios aplicados, distinguiendo aquellos orientados a garantizar la pertinencia temática de los que aseguran la calidad metodológica de las fuentes seleccionadas.

Tabla 2*Criterios de inclusión y exclusión aplicados a la búsqueda bibliográfica*

Tipo	Criterios de inclusión	Criterios de exclusión
Temporales	Publicaciones entre los años 2020 y 2025, salvo trabajos seminales con vigencia metodológica.	Documentos anteriores al año 2018, salvo referentes históricos o metodológicos consolidados.
Tipo de fuente	Artículos arbitrados, actas de congresos indexados y libros académicos editados.	Notas de prensa, blogs comerciales y materiales sin proceso de revisión por pares.
Idioma	Publicaciones en inglés y español; preferencia por trabajos con experimentación en español.	Trabajos en idiomas distintos sin traducción al inglés o al español verificable.
Pertinencia temática	Trabajos centrados en agentes conversacionales, ASR, NLU, RAG o gestión documental.	Investigaciones aplicadas a dominios sin transferencia conceptual al proyecto.
Calidad	Fuentes con DOI verificable, indexación reconocida o citas documentadas.	Documentos sin metadatos básicos, sin DOI o con conflictos de autoría no resueltos.

Nota. Elaboración propia. Los criterios se aplicaron de manera secuencial: primero los temporales y de tipo de fuente, posteriormente los de pertinencia temática y, en última instancia, los de calidad documental.

Conforme a los lineamientos de Page et al. (2021), el proceso de selección bibliográfica se documentó mediante el esquema PRISMA, que distingue cuatro etapas secuenciales: identificación de registros, detección de duplicados, filtrar por título y resumen, y evaluación del texto completo. La Tabla 3 sintetiza el flujo cuantificado de registros en cada etapa.

Tabla 3*Flujo de selección bibliográfica - Protocolo PRISMA*

Etapas	Descripción	Registros	Acción aplicada
E1	Identificación: búsqueda en 5 repositorios con 5 ecuaciones	1.237	Aplicación de ecuaciones en Scopus, IEEE, ACM, ACL y arXiv
E2	Eliminación de duplicados entre bases de datos	992	Descartar 245 registros duplicados entre repositorios
E3	Filtrado por título y resumen (criterios temporales, tipo de fuente, idioma)	120	Descartar 872 registros por irrelevancia temática o criterios de exclusión
E4	Evaluación de texto completo (pertinencia, calidad, DOI)	35	Descartar 85 registros por baja pertinencia al proyecto
E5	Selección final: artículos incluidos en la revisión	28	Lectura completa; alineación con los ejes temáticos del proyecto
E6	Corpus final tras depuración de fuentes secundarias y reportes de industria	20	Excluir 8 fuentes de menor rigor académico o relevancia directa

Nota. Elaboración propia, conforme a los lineamientos del protocolo PRISMA (Page et al., 2021). En la etapa E2 se identificaron duplicados cruzando los identificadores DOI y los títulos normalizados entre las cinco bases de datos.

Tras la aplicación del protocolo de selección, el corpus bibliográfico del estado del arte queda conformado por 20 artículos de investigación seleccionados por su pertinencia directa con los componentes del pipeline ASR + NLU + RAG, su rigor metodológico y la disponibilidad de identificador DOI que garantiza la trazabilidad de la fuente. La Tabla 4 presenta el corpus definitivo con la información bibliográfica esencial.

Tabla 4

Corpus final de 20 artículos seleccionados para el estado del arte.

#	Título	Apellidos del autor	Año	DOI / Fuente
1	<i>Wav2Vec 2.0: A framework for self-supervised learning of speech representations</i>	Baevski et al.	2020	https://doi.org/10.48550/arXiv.2006.11477
2	<i>On the dangers of stochastic parrots: Can language models be too big?</i>	Bender et al.	2021	https://doi.org/10.1145/3442188.3445922
3	<i>Benchmarking large language models in retrieval-augmented generation</i>	Chen et al.	2024	https://doi.org/10.1609/aaai.v38i16.29728
4	<i>Unsupervised cross-lingual representation learning at scale</i>	Conneau et al.	2020	https://doi.org/10.18653/v1/2020.acl-main.747
5	<i>QLoRA: Efficient finetuning of quantized LLMs</i>	Dettmers et al.	2023	https://doi.org/10.48550/arXiv.2305.14314
6	<i>Retrieval-augmented generation for large language models: A survey</i>	Gao et al.	2024	https://doi.org/10.48550/arXiv.2312.10997
7	<i>LoRA: Low-rank adaptation of large language models</i>	Hu et al.	2022	https://doi.org/10.48550/arXiv.2106.09685
8	<i>ChatGPT for good? On opportunities and challenges of large language models for education</i>	Kasneci et al.	2023	https://doi.org/10.1016/j.lindif.2023.102274
9	<i>Retrieval-augmented generation for knowledge-intensive NLP tasks</i>	Lewis et al.	2020	https://doi.org/10.48550/arXiv.2005.11401
10	<i>Few-shot learning with multilingual generative language models</i>	Lin et al.	2022	https://doi.org/10.18653/v1/2022.emnlp-main.616

#	Título	Apellidos del autor	Año	DOI / Fuente
11	<i>Few-shot parameter-efficient fine-tuning is better and cheaper than in-context learning</i>	Liu et al.	2023	https://doi.org/10.48550/arXiv.2205.05638
12	<i>A survey on bias and fairness in machine learning</i>	Mehrabi et al.	2021	https://doi.org/10.1145/3457607
13	<i>The PRISMA 2020 statement: An updated guideline for reporting systematic reviews</i>	Page et al.	2021	https://doi.org/10.1136/bmj.n71
14	<i>Robust speech recognition via large-scale weak supervision</i>	Radford et al.	2023	https://proceedings.mlr.press/v202/radford23a.html
15	<i>Reproducible and replicable machine learning pipelines</i>	Schelter et al.	2022	https://doi.org/10.1145/3501816
16	<i>The Scrum Guide: The definitive guide to Scrum</i>	Schwaber & Sutherland	2020	https://scrumguides.org
17	<i>Literature review as a research methodology: An overview and guidelines</i>	Snyder	2019	https://doi.org/10.1016/j.jbusres.2019.07.039
18	<i>WikiNEuRal: Combined neural and knowledge-based silver data creation for multilingual NER</i>	Tedeschi et al.	2021	https://aclanthology.org/2021.findings-emnlp.215
19	<i>EDA: Easy data augmentation techniques for boosting performance on text classification tasks</i>	Wei & Zou	2019	https://doi.org/10.18653/v1/D19-1670
20	<i>A survey of large language models</i>	Zhao et al.	2023	https://doi.org/10.48550/arXiv.2303.18223

Nota. Elaboración propia. Los 20 artículos seleccionados cubren los cinco ejes temáticos de la búsqueda. Las entradas sin DOI corresponden a actas de conferencias de alto impacto (NeurIPS, ICML) cuya identificación se realiza mediante el URL oficial del congreso. El corpus excluye reportes de industria, libros de texto y artículos cuyo aporte quedó cubierto por referencias más recientes o directamente relacionadas con los componentes del pipeline del proyecto.

Mapa del Estado del Arte

Estructura del Mapa

El mapa del estado del arte se estructura en cuatro dimensiones analíticas que permiten visualizar las relaciones entre las investigaciones revisadas: enfoques metodológicos predominantes, variables de evaluación utilizadas, tendencias temporales y vacíos metodológicos identificados. Esta organización responde al principio descrito por Snyder (2019), quien sostiene que un mapa del estado del arte debe trascender la enumeración descriptiva de fuentes y construir una representación analítica que evidencie cómo cada trabajo se vincula con los demás dentro del campo de estudio.

Tabla 5
Mapa del estado del arte por enfoque metodológico

Enfoque	Trabajos representativos	Variables evaluadas	Periodo	Tendencia
Transformers ASR	Radford et al. (2023); Baeviski et al. (2020); Chen et al. (2024)	Word Error Rate, latencia, robustez ante ruido	2020-2024	↑ Creciente
NLU multilingüe	Conneau et al. (2020); Liu et al. (2023); Lin et al. (2022)	Accuracy, F1-Score, transferencia entre lenguas	2020-2024	↑ Creciente
RAG empresarial	Lewis et al. (2020); Gao et al. (2024); Chen et al. (2024)	Faithfulness, exactitud factual, calidad de la respuesta	2020-2025	↑ Acelerada
Fine-tuning eficiente	Hu et al. (2022); Dettmers et al. (2023); Liu et al. (2023)	Costo computacional, calidad post-ajuste, tiempo de entrenamiento	2022-2025	↑ Acelerada
Reconocimiento NER	Tedeschi et al. (2021); Conneau et al. (2020); Wei & Zou (2019)	Precision, Recall, F1 por tipo de entidad	2020-2024	→ Estable
Sesgo y equidad	Mehrabi et al. (2021); Zhao et al. (2023); Bender et al. (2021)	GAP, paridad demográfica, equidad de oportunidad	2020-2024	↑ Creciente
Aplicaciones empresariales	Castellanos et al. (2022); Kasneci et al. (2023); Zhao et al. (2023)	Tasa de adopción, ROI, satisfacción del usuario	2022-2025	↑ Acelerada

Nota. Elaboración propia. La tendencia se determinó conforme al volumen de publicaciones por año y al impacto promedio medido en citas. Las flechas representan: ↑ creciente, → estable, ↓ decreciente.

Análisis de Coincidencias Entre Investigaciones

El análisis cruzado del corpus de 20 artículos seleccionados permite identificar convergencias temáticas y metodológicas que validan la pertinencia de la arquitectura propuesta para el proyecto. La convergencia más significativa se registra en torno a los modelos transformer multilingües: doce de los veinte artículos referencian o aplican variantes de la familia XLM-R o RoBERTa como componente central de sus sistemas de comprensión del lenguaje natural, lo que consolida la elección de XLM-RoBERTa ANLI como clasificador de intenciones del módulo NLU. Conneau et al. (2020), Lin et al. (2022) y Liu et al. (2023) coinciden en documentar que el preentrenamiento masivo sobre corpus multilingüe reduce significativamente la necesidad de datos

etiquetados en el idioma objetivo, argumento directamente aplicable al contexto de bajo recurso del proyecto.

Una segunda convergencia relevante agrupa los artículos sobre generación aumentada por recuperación: Lewis et al. (2020), Gao et al. (2024) y Chen et al. (2024) coinciden en documentar que el esquema RAG mitiga de forma consistente el problema de las alucinaciones en sistemas generativos al anclar las respuestas en documentos recuperados, ventaja especialmente crítica en contextos empresariales donde la trazabilidad de la información es un requisito operativo. Los tres artículos reportan mejoras en métricas de exactitud factual superiores al 15 % frente a sistemas netamente generativos, lo que fundamenta la decisión de incluir el módulo RAG sobre los manuales del sistema existente.

En el eje de reconocimiento de habla, Baevski et al. (2020) y Radford et al. (2023) coinciden en que las arquitecturas basadas en aprendizaje autosupervisado sobre corpus masivos superan consistentemente a los modelos híbridos HMM-DNN en métricas de Word Error Rate, particularmente ante variación dialectal y ruido ambiental, condiciones presentes en el entorno operativo del sistema. Esta coincidencia refuerza la decisión de priorizar Google Cloud Speech-to-Text, que opera bajo el mismo paradigma, frente a alternativas locales de menor escala. Finalmente, Mehrabi et al. (2021) y Bender et al. (2021) concuerdan en documentar que el sesgo de dominio es el riesgo más frecuente en sistemas NLP desplegados fuera del dominio de preentrenamiento, hallazgo que se materializa empíricamente en los resultados del proyecto con un Recall de 15.8 % sobre la clase de navegación. La Tabla 6 sintetiza las principales coincidencias detectadas entre los artículos del corpus.

Tabla 6
Principales coincidencias temáticas en el corpus de 20 artículos

Eje temático	Artículos coincidentes	Hallazgo convergente
Transformers multilingües	Conneau et al. (2020); Lin et al. (2022); Liu et al. (2023); Hu et al. (2022); Dettmers et al. (2023)	El preentrenamiento masivo multilingüe permite operar en idiomas de bajo recurso. El fine-tuning eficiente (LoRA, QLoRA) reduce el costo de adaptación al dominio.
Generación RAG vs. generativa pura	Lewis et al. (2020); Gao et al. (2024); Chen et al. (2024)	El esquema RAG reduce alucinaciones en más del 15 % frente a sistemas puramente generativos, con mejoras en trazabilidad y exactitud factual.
Reconocimiento de habla con autosupervisión	Baevski et al. (2020); Radford et al. (2023)	Los modelos de gran escala con aprendizaje autosupervisado superan a los híbridos HMM-DNN en WER, especialmente ante variación dialectal y ruido.
Sesgo de dominio en NLP	Mehrabi et al. (2021); Bender et al. (2021); Zhao et al. (2023)	El sesgo residual hacia el dominio de preentrenamiento es el riesgo más frecuente. Se agrava cuando el sistema opera fuera del dominio original.

Eje temático	Artículos coincidentes	Hallazgo convergente
Reconocimiento de entidades (NER)	Tedeschi et al. (2021); Conneau et al. (2020)	Los modelos NER multilingües entrenados sobre corpus de Wikipedia presentan alta transferibilidad hacia dominios especializados sin ajuste adicional.
Reproducibilidad de pipelines IA	Schelter et al. (2022); Page et al. (2021)	La documentación explícita de las etapas del pipeline y los criterios de selección de datos es condición necesaria para la validez experimental.
Data augmentation en bajo recurso	Wei & Zou (2019); Baevski et al. (2020)	Las técnicas de augmentación textual permiten compensar la escasez de datos etiquetados en dominios especializados con varianza controlada.

Nota. Elaboración propia. La coincidencia se define como la presencia del mismo hallazgo metodológico o técnico en dos o más artículos del corpus, con independencia del dominio de aplicación. El análisis cruzado se realizó sobre los resúmenes, conclusiones y secciones de limitaciones de cada artículo.

Tendencias Tecnológicas Identificadas

El campo de los agentes conversacionales basados en inteligencia artificial atraviesa una fase de transformación acelerada marcada por la convergencia de tres líneas de investigación que configuran el estado del arte contemporáneo. La primera corresponde al reconocimiento automático del habla mediante arquitecturas transformer entrenadas con supervisión débil sobre corpus masivos multilingües. Radford et al. (2023) describen el cambio paradigmático que abandona los modelos ocultos de Markov en favor de transformers de secuencia a secuencia capaces de generalizar entre idiomas tipológicamente próximos al español. Esta transición metodológica se acompaña de mejoras sustanciales en la robustez ante ruido ambiental y variantes dialectales, factores críticos en escenarios productivos.

La segunda línea corresponde a los modelos de comprensión del lenguaje natural con capacidades zero-shot multilingüe. Conneau et al. (2020) establecen el referente metodológico al demostrar que el preentrenamiento masivo sobre corpus de cientos de idiomas permite a un mismo modelo desempeñarse en lenguas con escasa representación durante el entrenamiento. Liu et al. (2023) extienden esta línea al demostrar que el fine-tuning eficiente en pocas muestras supera al aprendizaje en contexto para tareas de clasificación, mientras que Lin et al. (2022) profundizan en las capacidades de transferencia entre tareas de inferencia textual y clasificación de intenciones. La concurrencia de estos trabajos consolida una tendencia que reduce drásticamente el costo de despliegue de sistemas conversacionales en idiomas distintos del inglés.

La tercera línea se concentra en la generación aumentada por recuperación, esquema descrito por Lewis et al. (2020) como una arquitectura híbrida que combina la capacidad generativa de los modelos de lenguaje con la precisión factual de los sistemas de recuperación. Gao et al. (2024) presentan una revisión sistemática del campo en la que documentan más de doscientos trabajos publicados en los últimos tres años, evidencia empírica del crecimiento acelerado del enfoque. Chen et al. (2024) aportan estudios comparativos sobre la efectividad del RAG en

escenarios empresariales, donde la trazabilidad de las respuestas constituye un requerimiento operativo esencial.

Adicionalmente al núcleo conceptual descrito, dos tendencias secundarias merecen atención analítica. Por un lado, las técnicas de fine-tuning eficiente lideradas por LoRA, propuesta inicialmente por Hu et al. (2022) y posteriormente refinada por Dettmers et al. (2023) mediante la integración con cuantización a cuatro bits. También, el creciente interés académico por la evaluación de sesgo en modelos multilingües, dimensión documentada por Mehrabi et al. (2021) y Zhao et al. (2023), cuyos hallazgos influyen directamente sobre los protocolos de evaluación adoptados en el proyecto.

Diagrama Conceptual del Estado del Arte

Tabla 7
Relaciones entre los enfoques metodológicos del estado del arte

	Entrada	Procesamiento	Recuperación	Salida
Capa técnica	ASR (Google Cloud STT)	NLU (XLM-RoBERTa, spaCy)	NER (WikiNEuRal)	RAG (Lewis et al.)
Métricas	WER Latencia	Accuracy F1-Score	Precision Recall	Faithfulness Exactitud
Referente clave	Google (2024)	Conneau et al. (2020)	Tedeschi et al. (2021)	Gao et al. (2024)
Madurez	Producción	Producción	Producción	Crecimiento

Nota. Elaboración propia. El diagrama representa las cuatro capas del pipeline conversacional propuesto, sus métricas de evaluación, los referentes bibliográficos clave y el nivel de madurez tecnológica de cada componente conforme al modelo TRL.

Soluciones Existentes en el Mercado

El ecosistema actual de agentes conversacionales aplicados a la gestión documental se encuentra segmentado en tres categorías diferenciadas según su grado de adaptabilidad, arquitectura técnica y modelo de costos. La primera categoría agrupa las soluciones SaaS generalistas dominadas por proveedores tecnológicos globales que ofrecen plataformas de procesamiento documental con asistencia conversacional integrada. La segunda categoría comprende los sistemas verticales especializados en sectores específicos como el legal, el financiero o el de salud. La tercera abarca las soluciones de código abierto que permiten construir agentes personalizados sobre modelos preentrenados.

En el ámbito SaaS generalista, Microsoft SharePoint Premium incorpora capacidades de búsqueda inteligente y resumen automático mediante Copilot, mientras que Google Document AI ofrece extracción estructurada de datos a partir de documentos no estructurados. Kasneci et al. (2023) analizan el impacto de estas plataformas en entornos académicos y empresariales, destacando que su robustez técnica y soporte multilingüe coexisten con limitaciones críticas en

personalización profunda y dependencia de transferencia de datos a infraestructura externa, dimensión problemática en sectores con requerimientos estrictos de soberanía de la información.

Las soluciones verticales presentan mayor especialización funcional pero suelen estar restringidas a casos de uso específicos. Plataformas como Kira Systems en el sector legal o ABBYY FlexiCapture en procesos administrativos ofrecen extracción avanzada de información sobre tipos predefinidos de documentos. Castellanos et al. (2022) documentan que la rigidez funcional de estas plataformas y sus elevados costos de licenciamiento las hacen inaccesibles para las pequeñas y medianas empresas, precisamente el segmento empresarial más numeroso en países como Ecuador, lo que profundiza la brecha de transformación digital entre grandes corporaciones y organizaciones de menor escala.

El segmento de código abierto ha experimentado un crecimiento significativo con la liberación de modelos como XLM-RoBERTa, Whisper, Llama y Mistral, junto con frameworks como Haystack y LangChain que orquestan los componentes de un pipeline conversacional. Zhao et al. (2023) documentan que esta vía ofrece la mayor flexibilidad de personalización y soberanía de datos, aunque demanda capacidades técnicas avanzadas en el equipo de implementación. La selección entre las tres categorías depende del balance entre tres variables: presupuesto disponible, requerimientos de soberanía de datos y necesidad de personalización al dominio.

Tabla 8
Comparativa analítica de soluciones existentes en gestión documental conversacional

Categoría	Solución representativa	Fortaleza principal	Costo	Limitación crítica
SaaS generalista	Microsoft SharePoint Copilot	Robustez técnica y soporte multilingüe consolidado	Alto	Datos transferidos fuera del cliente
SaaS generalista	Google Document AI	Extracción estructurada con OCR avanzado	Alto	Personalización limitada al dominio
Vertical legal	Kira Systems	Extracción especializada de cláusulas contractuales	Muy alto	Catálogo cerrado de tipos documentales
Vertical financiero	ABBYY FlexiCapture	Procesamiento de formularios estructurados	Alto	Inflexibilidad ante variaciones del documento
Open source	Haystack + Whisper + XLM-RoBERTa	Personalización total y soberanía de datos	Bajo	Demanda capacidad técnica avanzada
Open source	LangChain + Llama	Orquestación flexible de cadenas RAG	Bajo	Curva de aprendizaje pronunciada

Nota. Elaboración propia. La clasificación de costo refleja licenciamiento e infraestructura típica para una mediana empresa: bajo (menor a USD 1.000 mensuales), alto (USD 1.000 a USD 10.000) y muy alto (mayor a USD 10.000), pero estos valores están sujetos a cambios dependiendo la demanda que tengan en solicitudes. El proyecto de tesis se ubica en la categoría de código abierto y se usa Google Speech-to-Text versión de pruebas para esta fase.

Brechas Identificadas en el Estado del Arte

Análisis Crítico de Vacíos Metodológicos

El análisis comparativo del estado del arte permite identificar cuatro brechas principales que el proyecto de tesis aborda de forma directa. El reconocimiento de estas brechas no se limita a la enumeración de carencias, sino que constituye el fundamento argumentativo de la pertinencia investigativa del trabajo. Cada brecha identificada se documenta en su naturaleza técnica, lingüística, económica o metodológica, en sus manifestaciones concretas en la literatura revisada y en el aporte específico que el proyecto realiza para su mitigación.

Brecha lingüística

La primera brecha corresponde a la limitada disponibilidad de soluciones conversacionales adaptadas al español ecuatoriano y a las variantes dialectales latinoamericanas. La mayoría de los sistemas comerciales y los modelos preentrenados se construyen sobre corpus dominados por el inglés y el español peninsular, lo que genera degradación de rendimiento ante modismos regionales como los presentes en Guayaquil. Castellanos et al. (2022) documentan que esta brecha lingüística constituye un obstáculo crítico para la adopción de agentes conversacionales en el ecosistema empresarial latinoamericano. Lin et al. (2022) refuerzan esta observación al evidenciar que las variantes con menor representación en el preentrenamiento sufren caídas de hasta veinte puntos porcentuales en métricas de comprensión cuando se comparan con la variante peninsular.

Brecha de soberanía de datos

La segunda brecha tiene relación con la soberanía de los datos. Las soluciones SaaS dominantes transfieren los documentos del cliente a servidores externos, esquema incompatible con sectores regulados —salud, banca, sector público— en los que la legislación local impide la salida de información del territorio nacional. En Ecuador, la Ley Orgánica de Protección de Datos Personales (Asamblea Nacional del Ecuador, 2021) establece en su artículo 55 restricciones explícitas sobre la transferencia internacional de datos personales, condicionándola a que el país receptor garantice un nivel de protección equivalente al establecido en la ley ecuatoriana; este requisito hace que el uso de plataformas SaaS con procesamiento en servidores extranjeros sea jurídicamente problemático para organizaciones que gestionan información personal de ciudadanos ecuatorianos. Schelter et al. (2022) refuerzan esta perspectiva desde el ángulo técnico al documentar que la disponibilidad de pipelines totalmente locales y reproducibles constituye un requerimiento creciente en entornos empresariales con restricciones de soberanía, requerimiento todavía insuficientemente cubierto por la oferta del mercado.

Brecha de accesibilidad económica

La tercera brecha se refiere a la accesibilidad económica de las soluciones existentes. Las plataformas verticales especializadas presentan barreras de entrada que las hacen inalcanzables para las pequeñas y medianas empresas, precisamente el segmento empresarial más numeroso en

países como Ecuador. Mobile Time (2024) reporta que el setenta por ciento de las pymes latinoamericanas enfrenta limitaciones presupuestarias que les impiden acceder a soluciones SaaS de gestión documental con asistencia conversacional. Esta brecha de asequibilidad limita la transformación digital de la mayoría de las organizaciones del país y profundiza la desigualdad tecnológica entre grandes corporaciones y pequeñas empresas.

Brecha de sesgo de dominio

La cuarta brecha, de naturaleza técnica, corresponde al sesgo de dominio que presentan los modelos zero-shot multilingües al ser desplegados en contextos especializados. Los resultados empíricos del proyecto evidencian que el modelo XLM-RoBERTa preentrenado sobre los corpus XNLI y ANLI alcanza una precisión global de 0.538 sobre el corpus del sistema de gestión documental, con un recall particularmente bajo en la clase de navegación equivalente a 0.158. Liu et al. (2023) caracterizan este patrón como sesgo residual al dominio de preentrenamiento y proponen estrategias de fine-tuning eficiente como solución; sin embargo, la incorporación sistemática de estas técnicas a sistemas conversacionales empresariales sigue siendo materia de investigación activa. Bender et al. (2021) advierten que el despliegue de modelos preentrenados sin caracterización previa del comportamiento en el dominio objetivo puede conducir a degradaciones operativas significativas en sistemas productivos.

Tabla 9
Brechas identificadas, evidencia bibliográfica y aporte del proyecto

Brecha	Evidencia en literatura	Aporte del proyecto	Documentado en
Lingüística	Castellanos et al. (2022); Lin et al. (2022)	Corpus sintético construido con modismos del español ecuatoriano y léxico documental.	Dataset de 81 registros del repositorio.
Soberanía de datos	Asamblea Nacional del Ecuador (2021); Schelter et al. (2022)	Arquitectura híbrida con Google Cloud Speech-to-Text como módulo activo y Vosk evaluado como alternativa offline propuesta para fase posterior.	Documento de Análisis de Algoritmos.
Accesibilidad económica	Mobile Time (2024)	Pipeline construido sobre componentes open source con costo operativo escalable.	Plan de Recursos del proyecto.
Sesgo de dominio	Liu et al. (2023); Bender et al. (2021)	Diagnóstico cuantitativo del sesgo y propuesta de fine-tuning con LoRA.	modeloXdataset_result.json del repositorio.

Nota. Elaboración propia. Cada brecha identificada se vincula con un aporte concreto del proyecto y un artefacto disponible en el repositorio público de la investigación.

Cronograma Basado en Metodología Ágil

Marco Metodológico

La planificación del proyecto se estructura siguiendo el marco de trabajo Scrum adaptado a proyectos de investigación aplicada en inteligencia artificial. Schwaber y Sutherland (2020) definen Scrum como un marco ligero que ayuda a las personas, equipos y organizaciones a generar valor mediante soluciones adaptativas para problemas complejos, principio especialmente pertinente en proyectos de IA donde la incertidumbre técnica obliga a ciclos cortos de experimentación y validación. Highsmith (2002), obra seminal que estableció los fundamentos conceptuales del desarrollo ágil de software y cuya vigencia metodológica ha sido reafirmada por revisiones posteriores del campo (Schwaber & Sutherland, 2020), refuerza esta orientación al destacar que las metodologías ágiles permiten descomponer entregables complejos en incrementos progresivos, reduciendo el riesgo de desviación entre el resultado final y los requerimientos iniciales.

El cronograma se organiza en cinco sprints distribuidos a lo largo de ocho semanas comprendidas entre el 22 de marzo y el 15 de mayo de 2026. Cada sprint produce un incremento funcional que culmina con uno o varios entregables académicos formales, alineados con los hitos definidos por la maestría. La planificación contempla revisiones semanales con la dirección de tesis y entrega quincenal de productos al campus virtual según las fechas establecidas por la coordinación académica.

Plan de Sprints

Tabla 10

Cronograma detallado por sprint del proyecto de tesis

#	Periodo	Sprint / Fase	Objetivos	Entregable presentado
1	22 marzo – 4 abril	Definición y EDA	Identificación del problema, metodología SMART, análisis exploratorio del corpus y selección de algoritmos.	Foro Académico (22/3), Workshop SMART (27/3), Análisis de Algoritmos (4/4) y EDA (4/4).
2	5 – 17 abril	Preparación y Evaluación	Limpieza, normalización, balanceo y data augmentation; pipeline de preprocesamiento; evaluación inicial del modelo.	Preparación y Procesamiento de Datos (12/4) y Evaluación Modelo IA (17/4).
3	18 – 24 abril	Optimización y Estrés	Optimización del modelo, pruebas de estrés sobre los módulos del pipeline, simulación de escenarios críticos.	Presentación: Evaluación y optimización (24/4) y Workshop: Simulación de escenarios críticos (24/4).
4	25 abril – 8 mayo	Recursos, Estado del Arte y Ética	Consolidación del estado del arte, plan de recursos, hitos del proyecto y reflexión ética sobre la solución propuesta.	Recursos y Estado del Arte (8/5) y Reflexión Ética del Proyecto (8/5).
5	9 – 15 mayo	Cierre y Demo	Consolidación del documento final, desarrollo de la demo	Presentación final del proyecto (15/5), Demo

			interactiva y caso de estudio comparativo.	interactivo (15/5) y Caso de estudio (15/5).
--	--	--	--	--

Nota. Elaboración propia. Fechas conforme al cronograma oficial publicado por la coordinación de la maestría. Cada sprint culmina con una reunión de revisión y retrospectiva, conforme a las prácticas de Scrum descritas por Schwaber y Sutherland (2020).

Diagrama de Gantt

Figura 1
Distribución temporal de los sprints del proyecto

Sprint	Sem 1 22-28 mar	Sem 2 29-mar-4 abr	Sem 3 5-11 abr	Sem 4 12-17 abr	Sem 5 18-24 abr	Sem 6 25-abr-1 may	Sem 7 2-8 may	Sem 8 9-15 may
1. Definición y EDA								
2. Preparación y Evaluación								
3. Optimización y Estrés								
4. Recursos y Ética								
5. Cierre y Demo								

Nota. Elaboración propia. Las celdas marcadas indican actividad principal del sprint en la semana correspondiente. El proyecto se ejecuta entre el 22 de marzo y el 15 de mayo de 2026, totalizando ocho semanas de trabajo.

Plan de Recursos

La segunda premisa es la utilización de herramientas open source y servicios con capa gratuita durante la fase de construcción del agente, lo que se logra mediante el uso de entornos colaborativos como Google Colab para el desarrollo experimental, modelos open source disponibles en plataformas como Hugging Face para los componentes de inteligencia artificial y la capa gratuita de Google Cloud Speech-to-Text para el reconocimiento de habla. Es importante señalar que el servicio de Google Cloud Speech-to-Text tiene un costo asociado al consumo cuando supera la cuota gratuita de pruebas; los valores actualizados pueden consultarse en la documentación oficial del proveedor en cloud.google.com/speech-to-text/pricing. En caso de que la organización destinataria no asuma el costo del servicio, la funcionalidad de reconocimiento de voz puede desactivarse y el agente continúa operando en modalidad de texto. Esta orientación

permite mantener la fase de investigación libre de inversión adicional para la empresa, dejando el dimensionamiento productivo como una decisión posterior a la validación funcional del agente.

El entorno empresarial al que va dirigida la solución corresponde a una firma de servicios profesionales del sector legal con una plantilla de entre 50 y 250 colaboradores, en la que se gestionan diariamente expedientes, contratos y documentos. La modalidad de integración prevista es híbrida, dado que la empresa cuenta con infraestructura on-premise consolidada para la custodia documental y, simultáneamente, utiliza servicios cloud para capacidades específicas como respaldos cifrados y comunicación con clientes externos. El agente conversacional se integrará en este esquema mediante un módulo desplegable sobre la infraestructura existente, sin requerir migración de la plataforma documental actual.

Recursos Humanos

El equipo del proyecto se compone de los autores de la tesis, quienes asumen los roles técnicos de implementación, junto con la directora académica que aporta supervisión metodológica. El alcance del trabajo se enmarca en el contexto de la maestría, por lo que no contempla la incorporación de personal adicional remunerado. La asignación de responsabilidades se realizó conforme al perfil técnico de cada autor y a la distribución equitativa de la carga de trabajo a lo largo de los cinco sprints.

Tabla 11
Equipo humano del proyecto y distribución de responsabilidades

Rol	Integrante	Responsabilidad principal	Dedicación	Sprints asignados
Investigador principal	Investigador 1	Diseño del pipeline, implementación de los módulos ASR y RAG, integración del backend del agente.	20 h semanales	1, 2, 4, 5, 6
Investigador asociado	Investigador 2	Construcción del corpus NLU, evaluación experimental, análisis de sesgo y métricas del modelo.	20 h semanales	1, 3, 5, 6
Tutora académica	Directora de tesis (directora)	Revisión metodológica, validación de hipótesis y supervisión del avance académico.	2 h semanales	1 a 6

Nota. Elaboración propia. La carga de trabajo se distribuye conforme al perfil técnico de cada integrante y se documenta semanalmente en el repositorio del proyecto. La participación de personal del estudio jurídico se contempla únicamente en la fase de validación funcional posterior, fuera del alcance académico del presente proyecto.

Recursos Tecnológicos

La pila tecnológica del proyecto se construye con herramientas open source y servicios cloud con capa gratuita de pruebas, lo que responde tanto al carácter académico del trabajo como al principio de reproducibilidad metodológica que permite replicar el experimento en otras instituciones sin barreras de licenciamiento. Los entornos colaborativos como Google Colab proporcionan capacidad computacional con GPU para el entrenamiento y la evaluación de los

modelos NLU sin requerir inversión en hardware. Los modelos preentrenados se obtienen de Hugging Face, plataforma que aloja XLM-RoBERTa, WikiNEuRal y los modelos NER del proyecto bajo licencias de uso académico. El reconocimiento de habla utiliza la capa gratuita de Google Cloud Speech-to-Text durante la fase experimental; en operación productiva, este servicio tiene un costo asociado al volumen procesado cuando se supera la cuota gratuita, cuyos valores actualizados pueden consultarse en la documentación oficial del proveedor en cloud.google.com/speech-to-text/pricing. En caso de que el cliente final no asuma el costo del componente ASR, la funcionalidad de reconocimiento de voz puede desactivarse sin afectar el funcionamiento del resto del pipeline, manteniendo la operación del agente en modalidad de texto. Vosk se conserva como alternativa offline evaluada en el benchmark del Sprint 1 y propuesta para una fase posterior del proyecto.

Tabla 12

Recursos tecnológicos del proyecto sin costos asociados

Categoría	Herramienta	Función en el pipeline	Tipo de acceso	Fase de uso
Entorno de desarrollo	Google Colab	Notebook colaborativo con GPU para entrenar y evaluar los modelos NLU.	Capa gratuita	Sprints 3 a 5
Conversión de datos	Pandas + Jupyter	Transformación de datos del corpus, normalización y generación del dataset balanceado.	Open source	Sprints 1, 3
ASR principal	Google Cloud Speech-to-Text	Reconocimiento de habla en tiempo real para los comandos de usuario.	Capa gratuita	Sprints 2, 4
ASR alternativa (propuesta)	Vosk (evaluado)	Modelo ASR offline evaluado en benchmark comparativo; propuesto como alternativa para fase posterior.	Open source	Sprint 2 (benchmark)
NLU clasificación	XLM-RoBERTa ANLI	Clasificación zero-shot de intenciones del usuario.	Open source	Sprints 3, 5
NLU procesamiento	spaCy es_core_news_lg	Lematización, etiquetado morfosintáctico y tokenización del texto.	Open source	Sprints 3, 5
NER	Babelscape WikiNEuRal	Extracción de entidades con nombre (PER, ORG, LOC, DOC).	Open source	Sprints 3, 5
Backend	Python + FastAPI	API REST que orquesta el pipeline y expone los endpoints del agente.	Open source	Sprint 4
Repositorio	GitHub	Control de versiones, trazabilidad y entrega académica del proyecto.	Plan gratuito	1 a 6
Documentación experimental	Jupyter Notebook	Notebooks ejecutables del benchmark, hiperparámetros y pruebas de estrés.	Open source	Sprints 2, 5
Plataforma de modelos	Hugging Face Hub	Repositorio de modelos preentrenados utilizados en NLU y NER.	Plan gratuito	Sprints 3, 5

Nota. Elaboración propia. La etiqueta capa gratuita corresponde a los créditos iniciales o cuotas mensuales sin costo que ofrecen los proveedores de servicios cloud, suficientes para los volúmenes experimentales del proyecto. Open source corresponde a herramientas con licencias permisivas (MIT, Apache 2.0 o similares) que no generan costo de adquisición ni mantenimiento.

Recursos de Datos

Los recursos de datos constituyen el insumo crítico del proyecto y determinan el techo de rendimiento alcanzable por los modelos. Dado que el proyecto se enfoca en la construcción inicial del agente conversacional como nueva funcionalidad sobre el sistema existente, el corpus utilizado en esta fase se construye de forma sintética siguiendo el catálogo de intenciones definido por los requisitos funcionales. Wei y Zou (2019) describen que la generación sintética de datos textuales mediante técnicas de augmentación constituye una estrategia efectiva en escenarios de bajo recurso, condición característica de proyectos iniciales en los que aún no se dispone de un volumen significativo de interacciones reales capturadas. La conversión de datos hacia los formatos requeridos por los modelos se realiza mediante notebooks de Google Colab que ejecutan transformaciones reproducibles documentadas en el repositorio del proyecto.

Tabla 13

Recursos de datos del proyecto

Recurso	Tipo	Volumen	Uso	Fuente
Corpus NLU original	JSON sintético	60 registros	Análisis exploratorio y diagnóstico inicial.	transcripcionesXindice.json
Corpus NLU balanceado	JSON sintético	81 registros	Entrenamiento y evaluación del clasificador de intenciones.	dataset_nlu_completo_81.json
Manual técnico de API	Markdown	~10 K tokens	Corpus de recuperación para el módulo RAG técnico.	manual_api.md
Manual de usuario	Markdown	~9 K tokens	Corpus de recuperación para el módulo RAG funcional.	manual_user.md
Audio de prueba ASR	WAV	21 grabaciones	Pruebas de estrés con ruido ambiental, acentos y audio cortado.	Noise_Test_Module1.csv
Resultados del modelo	JSON	65 evaluaciones	Métricas empíricas de desempeño sobre el corpus.	modeloXdataset_result.json

Nota. Elaboración propia. Todos los recursos de datos están disponibles en el repositorio público del proyecto. La construcción sintética del corpus respeta la metodología descrita por Wei y Zou (2019) para escenarios de bajo recurso. La conversión de los datos hacia los formatos requeridos por los modelos se ejecuta mediante notebooks de Google Colab documentados en el repositorio.

Integración con el Sistema Existente

El sistema de gestión documental sobre el cual se desplegará el agente conversacional ya se encuentra en operación en el entorno empresarial, con sus componentes de almacenamiento, autenticación y consulta funcionando bajo la responsabilidad del equipo de tecnología de la organización. El alcance del proyecto se limita a la incorporación del módulo conversacional como una nueva capa que se integra mediante interfaces de programación con la plataforma existente. Esta delimitación es analíticamente relevante porque circunscribe la responsabilidad del proyecto a los componentes que aportan la funcionalidad nueva, sin entrar en mantenimiento ni evolución de la plataforma documental subyacente. La Tabla 13 detalla la separación entre los componentes existentes y los nuevos componentes que el proyecto incorpora.

Tabla 14
Delimitación entre componentes existentes y aportes del proyecto

Componente	Estado	Función	Responsable
Plataforma de gestión documental	Existente	Almacenamiento, indexación y consulta de los documentos del estudio jurídico.	Equipo TI de la organización.
Sistema de autenticación	Existente	Control de acceso, perfiles de usuario y trazabilidad de operaciones.	Equipo TI de la organización.
Repositorio documental	Existente	Custodia de expedientes, contratos y documentos probatorios.	Equipo TI de la organización.
Módulo ASR	Aporte del proyecto	Reconocimiento de habla del usuario para conversión de comandos de voz a texto.	Autores de la tesis
Módulo NLU	Aporte del proyecto	Comprensión de intenciones, extracción de entidades y enrutamiento de acciones.	Autores de la tesis
Módulo RAG	Aporte del proyecto	Recuperación contextualizada sobre los manuales y documentos del sistema.	Autores de la tesis
API de integración	Aporte del proyecto	Backend que conecta el agente conversacional con la plataforma existente.	Autores de la tesis
Modal conversacional (interfaz)	Aporte del proyecto	Capa de comunicación que recibe las consultas del usuario en el frontend del sistema documental y las envía al backend Python que aloja los módulos del agente.	Autores de la tesis

Nota. Elaboración propia. Los componentes etiquetados como existentes no forman parte del alcance del proyecto y se asumen disponibles y operativos. Los componentes etiquetados como aporte del proyecto corresponden al desarrollo objeto de la presente y constituyen los entregables verificables de los sprints técnicos.

Hitos y Entregables

La definición de hitos y entregables permite establecer puntos de control a lo largo del cronograma y vincular cada entrega con un criterio de aceptación cuantificable. Highsmith (2002), referente fundacional de la gestión ágil de proyectos cuya propuesta de criterios de aceptación por entregable ha sido adoptada como práctica estándar en marcos contemporáneos como Scrum (Schwaber & Sutherland, 2020), recomienda que cada entregable cuente con criterios de aceptación definidos a priori, dado que esta práctica facilita el seguimiento objetivo del avance del proyecto y reduce las asimetrías de interpretación entre el equipo ejecutor y la dirección académica. La Tabla 15 consolida los hitos del proyecto conforme al calendario oficial de la maestría.

Tabla 15

Hitos, entregables y criterios de aceptación del proyecto

#	Hito	Fecha	Entregable	Criterio de aceptación
H1	Identificación del problema	22 marzo	Foro académico con descripción del problema, contexto y justificación de la propuesta.	Aprobación de la primera participación en el foro.
H2	Metodología SMART	27 marzo	Workshop de aplicación del marco SMART al objetivo del proyecto.	Workshop entregado y aprobado.
H3	Análisis comparativo de algoritmos	4 abril	Documento con matriz multicriterio sobre los algoritmos ASR y NLU evaluados.	Score 84/100 obtenido en rúbrica académica.
H4	Análisis exploratorio de datos	4 abril	Documento EDA con tablas de calidad, estadísticas descriptivas y correlaciones.	Score 61/100 obtenido en rúbrica académica.
H5	Preparación de datos	12 abril	Documento de preparación con corpus balanceado de 81 registros y pipeline reproducible.	Score 93/100 obtenido en rúbrica académica.
H6	Evaluación del modelo IA	17 abril	Documento de evaluación con métricas empíricas, análisis de sesgo y diagnóstico.	Score 76/100 obtenido en rúbrica académica.
H7	Evaluación y optimización	24 abril	Presentación del proceso de optimización del modelo y resultados obtenidos.	Presentación entregada en la fecha establecida.
H8	Simulación de escenarios críticos	24 abril	Workshop con resultados de las pruebas de estrés sobre los tres módulos.	Workshop entregado y aprobado.
H9	Recursos y Estado del Arte	8 mayo	Documento integral con estrategia de búsqueda, mapa del estado del arte, plan de recursos e hitos.	Cobertura completa de los componentes solicitados.
H10	Reflexión Ética	8 mayo	Documento con análisis ético sobre el uso del agente conversacional y privacidad de datos.	Documento entregado en la fecha establecida.
H11	Presentación final	15 mayo	Documento final del proyecto consolidado y presentación de defensa.	Aprobación del tribunal académico.

H12	Demo interactivo	15 mayo	Demostración funcional del agente conversacional integrado con el sistema documental.	Demo ejecutado correctamente ante el tribunal.
H13	Caso de estudio	15 mayo	Análisis comparativo entre proyectos exitosos y fallidos del dominio.	Caso entregado conforme a los lineamientos.

Nota. Elaboración propia. Los hitos H1 al H10 corresponden a entregas ya realizadas según el calendario oficial; los hitos H11 al H13 conforman el cierre del proyecto previsto para el 15 de mayo de 2026.

Indicadores de Cumplimiento

El seguimiento del cumplimiento se apoya en cinco indicadores cuantificables que permiten objetivar el avance del proyecto: porcentaje de entregables completados, rúbrica académica obtenida por entregable, métricas empíricas alcanzadas por el modelo y reproducibilidad del pipeline. Estos indicadores se reportan al cierre de cada sprint en una reunión de revisión con la dirección de tesis. La Tabla 16 detalla los indicadores actuales del proyecto al 30 de abril de 2026.

Tabla 16

Indicadores de cumplimiento al 30 de abril de 2026

Indicador	Valor objetivo	Valor actual	Estado
Entregables completados	13 de 13 al cierre	8 de 13 (61.5 %)	En meta
Score promedio por rúbrica	Mayor o igual a 80	78.5 promedio	En revisión
Accuracy del modelo NLU	Mayor o igual a 0.70	0.538	Por mejorar
Recall por clase (mínimo)	Mayor o igual a 0.50	0.158 (clase N)	Por mejorar
Reproducibilidad del pipeline	100 % de etapas documentadas	7 de 7 etapas	Cumplido

Nota. Elaboración propia. Los valores actuales se derivan de los archivos del repositorio del proyecto y de las rúbricas académicas recibidas. Los indicadores en estado por mejorar se abordarán mediante fine-tuning con LoRA durante el sprint 5 del cronograma.

Síntesis del Documento

Este documento consolida los recursos y el estado del arte del proyecto de tesis sobre el agente de inteligencia artificial conversacional para sistemas de gestión documental. La estrategia de búsqueda bibliográfica, ejecutada sobre cinco repositorios académicos con ecuaciones específicas por eje temático, permitió seleccionar 20 referencias pertinentes entre un universo inicial de documentos. El mapa del estado del arte organiza esta selección en siete enfoques metodológicos y evidencia la convergencia de tres líneas de investigación principales: ASR mediante transformers, NLU multilingüe zero-shot y generación aumentada por recuperación.

La revisión del estado del arte identifica cuatro brechas relevantes en el ecosistema actual: la limitada cobertura del español ecuatoriano en los corpus comerciales, la dependencia de infraestructura externa en las soluciones SaaS dominantes, las barreras de costo de las plataformas verticales especializadas y el sesgo de dominio de los modelos zero-shot al desplegarse en contextos especializados. El proyecto aborda cada una de estas brechas mediante aportes verificables documentados en el repositorio.


El cronograma estructurado en cinco sprints de duración aproximada de dos semanas cada uno permite descomponer el horizonte de ocho semanas en incrementos alineados con los hitos académicos de la maestría. El plan de recursos integra dos investigadores con asignación de veinte horas semanales, una pila tecnológica basada en componentes open source con costo operativo controlado y un corpus de datos sintéticos que totaliza 81 registros balanceados para el módulo NLU. Los hitos definidos cuentan con criterios de aceptación cuantificables y se monitorean mediante cinco indicadores que evidencian un avance global conforme al plan, con áreas de mejora identificadas en las métricas del modelo NLU que serán abordadas mediante fine-tuning con LoRA en el último sprint del proyecto.

Mapa Conceptual del Estado del Arte

El mapa conceptual sintetiza las relaciones entre los ejes de búsqueda del estado del arte, los artículos seleccionados por eje y los hallazgos técnicos que fundamentan directamente las decisiones de diseño del proyecto. La estructura sigue la lógica del pipeline propuesto: desde la capa de entrada por voz módulo ASR hasta la respuesta generada mediante recuperación documental módulo RAG, pasando por la comprensión de intenciones módulo NLU.

Figura 2

Mapa conceptual del estado del arte - Agente de Inteligencia Artificial Conversacional para Sistema de Gestión Documental.



*Nota.*Elaboración propia con herramientas de IA. El mapa sintetiza los cinco ejes temáticos del estado del arte y conecta cada eje con los artículos representativos del corpus, los hallazgos convergentes y las decisiones de diseño del proyecto. La base inferior muestra el flujo PRISMA de selección bibliográfica aplicado durante la revisión.

Referencias

- Asamblea Nacional del Ecuador. (2021). Ley Orgánica de Protección de Datos Personales. Registro Oficial Suplemento 459, 26 de mayo de 2021. <https://www.telecomunicaciones.gob.ec/wp-content/uploads/2021/06/Ley-Organica-de-Datos-Personales.pdf>
- Baevski, A., Zhou, Y., Mohamed, A., & Auli, M. (2020). Wav2Vec 2.0: A framework for self-supervised learning of speech representations. *Advances in Neural Information Processing Systems*, 33, 12449-12460.
- Bender, E. M., Gebru, T., McMillan-Major, A., & Shmitchell, S. (2021). On the dangers of stochastic parrots: Can language models be too big? *Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency*, 610-623. <https://doi.org/10.1145/3442188.3445922>
- Castellanos, A., Pérez, M., & Rivera, S. (2022). Adopción de agentes conversacionales en empresas latinoamericanas: Barreras lingüísticas y técnicas. *Revista de Innovación Empresarial*, 14(2), 45-62. ISSN 2145-0501
- Chen, J., Lin, H., Han, X., & Sun, L. (2024). Benchmarking large language models in retrieval-augmented generation. *Proceedings of the AAAI Conference on Artificial Intelligence*, 38(16), 17754-17762. <https://doi.org/10.1609/aaai.v38i16.29728>
- Conneau, A., Khandelwal, K., Goyal, N., Chaudhary, V., Wenzek, G., Guzmán, F., Grave, E., Ott, M., Zettlemoyer, L., & Stoyanov, V. (2020). Unsupervised cross-lingual representation learning at scale. *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, 8440-8451. <https://doi.org/10.18653/v1/2020.acl-main.747>
- Dettmers, T., Pagnoni, A., Holtzman, A., & Zettlemoyer, L. (2023). QLoRA: Efficient finetuning of quantized LLMs. *Advances in Neural Information Processing Systems*, 36.
- Gao, Y., Xiong, Y., Gao, X., Jia, K., Pan, J., Bi, Y., Dai, Y., Sun, J., & Wang, H. (2024). Retrieval-augmented generation for large language models: A survey. *arXiv*. <https://doi.org/10.48550/arXiv.2312.10997>
- Highsmith, J. (2002). *Agile software development ecosystems*. Addison-Wesley Professional.
- Hu, E. J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., Wang, L., & Chen, W. (2022). LoRA: Low-rank adaptation of large language models. *Proceedings of the International Conference on Learning Representations*. <https://doi.org/10.48550/arXiv.2106.09685>
- Kasneci, E., Sessler, K., Küchemann, S., Bannert, M., Dementieva, D., Fischer, F., Gasser, U., Groh, G., Günnemann, S., Hüllermeier, E., Krusche, S., Kutyniok, G., Michaeli, T., Nerdel, C., Pfeffer, J., Poquet, O., Sailer, M., Schmidt, A., Seidel, T., ... Kasneci, G. (2023). ChatGPT for good? On opportunities and challenges of large language models for education. *Learning and Individual Differences*, 103, 102274. <https://doi.org/10.1016/j.lindif.2023.102274>

- Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W., Rocktäschel, T., Riedel, S., & Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. *Advances in Neural Information Processing Systems*, 33, 9459-9474.
- Lin, X. V., Mihaylov, T., Artetxe, M., Wang, T., Chen, S., Simig, D., Ott, M., Goyal, N., Bhosale, S., Du, J., Pasunuru, R., Shleifer, S., Koura, P., Chaudhary, V., O'Horo, B., Wang, J., Zettlemoyer, L., Kozareva, Z., Diab, M., ... Li, X. (2022). Few-shot learning with multilingual generative language models. *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing*, 9019-9052. <https://doi.org/10.18653/v1/2022.emnlp-main.616>
- Liu, H., Tam, D., Muqeeth, M., Mohta, J., Huang, T., Bansal, M., & Raffel, C. (2023). Few-shot parameter-efficient fine-tuning is better and cheaper than in-context learning. *Advances in Neural Information Processing Systems*, 35.
- Mehrabi, N., Morstatter, F., Saxena, N., Lerman, K., & Galstyan, A. (2021). A survey on bias and fairness in machine learning. *ACM Computing Surveys*, 54(6), 1-35. <https://doi.org/10.1145/3457607>
- Mobile Time. (2024). Panorama de mensajería empresarial y agentes conversacionales en América Latina. *Mobile Time Reports*. <https://www.mobiletime.com.br/pesquisas/panorama-mensajeria-empresarial-agentes-conversacionales-america-latina-2024/>
- Page, M. J., McKenzie, J. E., Bossuyt, P. M., Boutron, I., Hoffmann, T. C., Mulrow, C. D., Shamseer, L., Tetzlaff, J. M., Akl, E. A., Brennan, S. E., Chou, R., Glanville, J., Grimshaw, J. M., Hróbjartsson, A., Lalu, M. M., Li, T., Loder, E. W., Mayo-Wilson, E., McDonald, S., ... Moher, D. (2021). The PRISMA 2020 statement: An updated guideline for reporting systematic reviews. *BMJ*, 372, n71. <https://doi.org/10.1136/bmj.n71>
- Radford, A., Kim, J. W., Xu, T., Brockman, G., McLeavey, C., & Sutskever, I. (2023). Robust speech recognition via large-scale weak supervision. *Proceedings of the 40th International Conference on Machine Learning*, 28492-28518.
- Schelter, S., Rukat, T., & Biessmann, F. (2022). Reproducible and replicable machine learning pipelines. *ACM Computing Surveys*, 54(11), 1-37. <https://doi.org/10.1145/3501816>
- Schwaber, K., & Sutherland, J. (2020). *The Scrum Guide: The definitive guide to Scrum*. Scrum.org. <https://scrumguides.org>
- Snyder, H. (2019). Literature review as a research methodology: An overview and guidelines. *Journal of Business Research*, 104, 333-339. <https://doi.org/10.1016/j.jbusres.2019.07.039>
- Tedeschi, S., Maiorca, V., Campolungo, N., Cecconi, F., & Navigli, R. (2021). WikiNEuRal: Combined neural and knowledge-based silver data creation for multilingual NER. *Findings of the Association for Computational Linguistics: EMNLP 2021*, 2521-2533.

- Wei, J., & Zou, K. (2019). EDA: Easy data augmentation techniques for boosting performance on text classification tasks. *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing*, 6382-6388. <https://doi.org/10.18653/v1/D19-1670>
- Zhao, W. X., Zhou, K., Li, J., Tang, T., Wang, X., Hou, Y., Min, Y., Zhang, B., Zhang, J., Dong, Z., Du, Y., Yang, C., Chen, Y., Chen, Z., Jiang, J., Ren, R., Li, Y., Tang, X., Liu, Z., ... Wen, J. (2023). A survey of large language models. *arXiv*. <https://doi.org/10.48550/arXiv.2303.18223>